



UNIVERSIDAD
COMPLUTENSE
MADRID

NOMBRE ASIGNATURA ¹

CIENCIAS MATEMÁTICAS E INGENIERÍA INFORMÁTICA

Autores:

Pau Frangi Mahiques, Diego Rodríguez Cubero y Jaime Nieto
Petinal

Primer Cuatrimestre 2025-2026

¹Basado en los apuntes de NOMBRE PROFESOR

Introducción

Estos apuntes han sido elaborados por Pau Frangi Mahiques, Diego Rodríguez Cubero y Jaime Nieto Petinal, estudiantes de 3.º del Doble Grado en Matemáticas e Ingeniería Informática, con el objetivo de ofrecer un material claro, cohesionado y útil para el estudio de la asignatura de ASIGNATURA.

El contenido está basado en las clases del profesor/a NOMBRE PROFESOR, a quien agradecemos su dedicación y claridad expositiva.

El documento está organizado para acompañar el progreso del curso: DESCRIBIR CONTENIDOS. Se incluyen asimismo ejercicios seleccionados y exámenes resueltos, así como material gráfico y esquemas realizados con TikZ para apoyar la intuición geométrica.

Nuestro propósito es doble: por un lado, facilitar la preparación continuada de la asignatura mediante una exposición sistemática, con resultados claramente enunciados y, cuando procede, demostraciones o esbozos de demostración; por otro, servir como referencia rápida para técnicas de cálculo habituales. Aunque hemos procurado la máxima precisión, este material puede contener erratas u omisiones.

Invitamos encarecidamente a los estudiantes que cursen la asignatura en el futuro a ampliar, mejorar o complementar estos apuntes. Cualquier corrección, propuesta o contribución será bienvenida. Para ello, pueden:

- Ponerse en contacto con nosotros mediante nuestros perfiles de GitHub, enlazados en la portada y en el pie de página.
- Podeis mandarnos un correo electrónico a:
 - Diego Rodríguez Cubero: diegorocux3x@gmail.com.
 - Pau Frangi Mahiques: pau.frangi@gmail.com.
 - Jaime Nieto Petinal: jaimenietopetinal1@gmail.com.
- Abrir una incidencia (*issue*) o enviar una contribución (*pull request*) en el repositorio del proyecto.

Estos apuntes reflejan la materia cursada y quedan finalizados conforme al curso ya completado. A partir de aquí, invitamos a futuros alumnos a proponer mejoras, correcciones o ampliaciones; las contribuciones serán valoradas y, en su caso, incorporadas en ediciones posteriores. Agradecemos de antemano toda colaboración que ayude a hacerlos más claros, completos y útiles para la comunidad, ya sea puliendo detalles, corrigiendo erratas o añadiendo contenido relevante, ya sea teórico, ejemplos, ejercicios, exámenes resueltos o material gráfico.

Índice General

Índice General	2
I Teoría	3
1 Matrices y sus propiedades	4
1.1 Tipos de matrices	4
1.2 Autovalores y autovectores	13
1.3 Teoremas importantes	15
1.4 Matrices hermiticas definidas positivas	19
1.5 Normas matriciales	20
1.6 Normas subordinadas	21
1.7 Potencias de matrices	24
1.8 Condicionamiento de matrices	25
2 Resolución de sistemas lineales	27
2.1 Introducción a los sistemas lineales	27
II Ejercicios	33
Hoja 1: Hoja 1	34
Hoja 2: Método de Gauss Jordan	37
III Exámenes	41
Examen 1: Primer examen	42
IV Apéndice	43
Apéndice A: Normas comunes	44
Apéndice B: Agradecimientos	46
B.1 Varios compañeros	46

Part I

Teoría

Índice de Teoría

1	Matrices y sus propiedades	4
1.1	Tipos de matrices	4
1.2	Autovalores y autovectores	13
1.3	Teoremas importantes	15
1.4	Matrices hermiticas definidas positivas	19
1.5	Normas matriciales	20
1.6	Normas subordinadas	21
1.7	Potencias de matrices	24
1.8	Condicionamiento de matrices	25
2	Resolución de sistemas lineales	27
2.1	Introducción a los sistemas lineales	27

1 Matrices y sus propiedades

1.1 Tipos de matrices

Veamos algunos tipos de matrices que nos encontraremos a lo largo del curso:

Definición 1.1.1 [Matrices introductorias]

- **Matriz fila:** Una matriz que tiene una sola fila. Por ejemplo, la matriz $A = [a_1, a_2, a_3]$ es una matriz fila de tamaño 1×3 .
- **Matriz columna:** Una matriz que tiene una sola columna. Por ejemplo, la matriz $B = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix}$ es una matriz columna de tamaño 3×1 .
- **Matriz cuadrada:** Una matriz que tiene el mismo número de filas y columnas. Por ejemplo, la matriz $C = \begin{bmatrix} c_{11} & c_{12} \\ c_{21} & c_{22} \end{bmatrix}$ es una matriz cuadrada de tamaño 2×2 .
- **Matriz diagonal:** Una matriz cuadrada en la que todos los elementos fuera de la diagonal principal son cero. Por ejemplo, la matriz $D = \begin{bmatrix} d_{11} & 0 \\ 0 & d_{22} \end{bmatrix}$ es una matriz diagonal.
- **Matriz identidad:** Una matriz diagonal en la que todos los elementos de la diagonal principal son uno. Por ejemplo, la matriz $I = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$ es una matriz identidad de tamaño 2×2 .
- **Matriz nula:** Una matriz en la que todos los elementos son cero. Por ejemplo, la matriz $O = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}$ es una matriz nula de tamaño 2×2 .
- **Matriz transpuesta:** La matriz obtenida al intercambiar las filas por las columnas de una matriz dada. Si A es una matriz de tamaño $m \times n$, su transpuesta A^T será de tamaño $n \times m$. Por ejemplo, si $A = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}$, entonces su transpuesta es $A^T = \begin{bmatrix} a_{11} & a_{21} \\ a_{12} & a_{22} \end{bmatrix}$.
- **Matriz simétrica:** Una matriz cuadrada que es igual a su transpuesta. Es decir, $A = A^T$. Por ejemplo, la matriz $S = \begin{bmatrix} s_{11} & s_{12} \\ s_{12} & s_{22} \end{bmatrix}$ es simétrica.
- **Matriz antisimétrica:** Una matriz cuadrada que es igual a la negativa de su transpuesta. Es decir, $A = -A^T$. Por ejemplo, la matriz $T = \begin{bmatrix} 0 & t_{12} \\ -t_{12} & 0 \end{bmatrix}$ es antisimétrica.
- **Matriz triangular:** Una matriz cuadrada que tiene todos los elementos por encima (o por debajo) de la diagonal principal iguales a cero. Si los elementos por debajo de la diagonal son cero, se llama matriz triangular superior; si los elementos por encima son cero, se llama matriz triangular inferior. Por ejemplo, la matriz $U = \begin{bmatrix} u_{11} & u_{12} \\ 0 & u_{22} \end{bmatrix}$ es triangular superior.
- **Matriz ortogonal:** Una matriz cuadrada Q es ortogonal si su transpuesta es igual a su inversa, es decir, $Q^T = Q^{-1}$. Esto implica que $QQ^T = Q^TQ = I$, donde I es la matriz identidad. Tam-

bien se caracteriza porque sus columnas (y filas) forman un conjunto ortonormal en el espacio euclídeo. Por ejemplo, la matriz $Q = \begin{bmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$ es ortogonal.

- **Traspuesto conjugado:** Denotado como A^* , es la matriz obtenida al tomar la traspuesta de una matriz y luego tomar el conjugado complejo de cada uno de sus elementos. Por ejemplo, si $A = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}$, entonces su traspuesto conjugado es $A^* = \begin{bmatrix} \overline{a_{11}} & \overline{a_{21}} \\ \overline{a_{12}} & \overline{a_{22}} \end{bmatrix}$, donde $\overline{a_{ij}}$ denota el conjugado complejo de a_{ij} .
- **Matriz definida positiva/negativa:** Una matriz cuadrada A es definida positiva si para cualquier vector no nulo x , se cumple que $x^T A x > 0$. De manera similar, A es definida negativa si para cualquier vector no nulo x , se cumple que $x^T A x < 0$.
- **Matriz semidefinida positiva/negativa:** Una matriz cuadrada A es semidefinida positiva si para cualquier vector x , se cumple que $x^T A x \geq 0$. De manera similar, A es semidefinida negativa si para cualquier vector x , se cumple que $x^T A x \leq 0$.
- **Matriz indefinida:** Una matriz cuadrada A es indefinida si existen vectores x y y tales que $x^T A x > 0$ y $y^T A y < 0$.

Ahora definamos algunos tipos de matrices más avanzados:

Definición 1.1.2 [Matriz hermitiana]

Una matriz cuadrada A es hermitiana si es igual a su traspuesto conjugado, es decir, $A = A^*$. En el caso de matrices con entradas reales, una matriz hermitiana es simplemente una matriz simétrica, es decir:

$$A \in \mathbb{R}^{n \times n} \text{ es hermitiana} \iff A = A^T$$

Veamos un par de ejemplos de matrices hermitianas:

Ejemplo

- La matriz $A = \begin{bmatrix} 2 & 3+i \\ 3-i & 4 \end{bmatrix}$ es hermitiana, ya que su traspuesto conjugado es $A^* = \begin{bmatrix} 2 & 3-i \\ 3+i & 4 \end{bmatrix}$, que es igual a A .
- La matriz $B = \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}$ es hermitiana, ya que su traspuesto conjugado es $B^* = \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}$, que es igual a B .

Definición 1.1.3 [Matriz unitaria]

Una matriz cuadrada U es unitaria si su traspuesto conjugado es igual a su inversa, es decir, $U^* = U^{-1}$. Esto implica que $UU^* = U^*U = I$, donde I es la matriz identidad.

Veamos un par de ejemplos de matrices unitarias:

Ejemplo

- La matriz $U = \begin{bmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$ es unitaria, ya que su traspuesto conjugado es $U^* = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$, y se cumple que $UU^* = I$.
- La matriz $V = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$ es unitaria, ya que su traspuesto conjugado es $V^* = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$, y se cumple que $VV^* = I$.

Observación 1.1.1

Se puede apreciar que si U es una matriz unitaria compleja:

$$U^* = U^{-1} \implies U^*U = I \implies U^*U = \begin{pmatrix} u_1^* \\ \vdots \\ u_n^* \end{pmatrix} (u_1 \quad \dots \quad u_n) = \begin{pmatrix} u_1^*u_1 & \dots & u_1^*u_n \\ \vdots & \ddots & \vdots \\ u_n^*u_1 & \dots & u_n^*u_n \end{pmatrix} = \begin{pmatrix} 1 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & 1 \end{pmatrix}$$

De lo cual se deduce que los vectores columna de U forman un conjunto ortonormal en el espacio complejo, es decir, $u_i^*u_j = \delta_{ij}$, ya que el producto $u_i^*u_j$ representa el producto interno entre los vectores u_i y u_j en el espacio complejo, y hemos visto que $u_i^*u_j = 0$ si $i \neq j$ y $u_i^*u_i = \|u_i\|^2 = 1$.

Definición 1.1.4 [Matriz normal]

Una matriz cuadrada A es normal si conmuta con su traspuesto conjugado, es decir, si se cumple que $AA^* = A^*A$.

Veamos un par de ejemplos de matrices normales:

Ejemplo

- La matriz $A = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}$ es normal, ya que su traspuesto conjugado es $A^* = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}$, y se cumple que $AA^* = A^*A = \begin{bmatrix} 4 & 0 \\ 0 & 9 \end{bmatrix}$.
- La matriz $B = \begin{bmatrix} 1 & i \\ -i & 1 \end{bmatrix}$ es normal, ya que su traspuesto conjugado es $B^* = \begin{bmatrix} 1 & i \\ -i & 1 \end{bmatrix}$, y se cumple que $BB^* = B^*B = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$.

Observación 1.1.2

Notese que si A es hermitiana, entonces $A = A^*$, por lo que:

$$AA^* = AA = A^2 = A^*A$$

Por lo tanto, toda matriz hermitiana es normal.

Algo similar ocurre con las matrices unitarias, ya que si U es unitaria, entonces $U^* = U^{-1}$, por lo

que:

$$UU^* = UU^{-1} = I = U^{-1}U = U^*U$$

Por lo tanto, toda matriz unitaria es normal.

Proposición 1.1.1 [Producto de matrices triangulares]

Sean $A, B \in \mathbb{C}^{n \times n}$ dos matrices triangulares inferiores (superiores). Entonces, el producto $C = AB$ es también una matriz triangular inferior (superior).

Demostración. Podemos aplicar una inducción sencilla sobre el tamaño de las matrices.

Caso base: Para $n = 1$, las matrices son simplemente escalares, y el producto de dos escalares es un escalar, que puede considerarse como una matriz triangular inferior (superior) trivialmente.

Paso inductivo: Supongamos que la proposición es cierta para matrices de tamaño $(n-1) \times (n-1)$. Consideremos dos matrices triangulares inferiores $A, B \in \mathbb{C}^{n \times n}$:

$$A = \frac{a_{11}}{\alpha} \left| \begin{array}{c|c} 0 & \\ \hline A_{(n-1)} \end{array} \right., \quad B = \frac{b_{11}}{\beta} \left| \begin{array}{c|c} 0 & \\ \hline B_{(n-1)} \end{array} \right.$$

Y su producto:

$$C = AB = \frac{a_{11}b_{11}}{\alpha b_{11} + A_{(n-1)}\beta} \left| \begin{array}{c|c} 0 & \\ \hline A_{(n-1)}B_{(n-1)} \end{array} \right.$$

Por la hipótesis inductiva, $A_{(n-1)}B_{(n-1)}$ es una matriz triangular inferior de tamaño $(n-1) \times (n-1)$. Además, el elemento en la posición $(n, 1)$ de C es $\alpha b_{11} + A_{(n-1)}\beta$, que es un vector columna. Por lo tanto, todos los elementos por encima de la diagonal principal de C son cero, lo que demuestra que C es una matriz triangular inferior.

Por lo tanto, por el principio de inducción matemática, la proposición es cierta para todas las matrices triangulares inferiores (superiores) de tamaño $n \times n$. $\square$

Definición 1.1.5 [Matriz banda]

Se define una matriz banda como una matriz cuadrada en la que los elementos no nulos se encuentran dentro de una franja diagonal alrededor de la diagonal principal. Esta franja está determinada por dos enteros no negativos k_1 y k_2 , que representan el número de subdiagonales y superdiagonales, respectivamente. Formalmente, una matriz $A \in \mathbb{R}^{n \times n}$ es una matriz banda si:

$$a_{ij} = 0 \quad \text{si } |i - j| > k$$

donde $k = \max(k_1, k_2)$.

Veamos un par de ejemplos de matrices banda:

Ejemplo

- Una matriz tridiagonal es una matriz banda con $k_1 = k_2 = 1$. Por ejemplo, la matriz $A =$

$$\begin{bmatrix} a_{11} & a_{12} & 0 & 0 \\ a_{21} & a_{22} & a_{23} & 0 \\ 0 & a_{32} & a_{33} & a_{34} \\ 0 & 0 & a_{43} & a_{44} \end{bmatrix} \text{ es tridiagonal.}$$

- Una matriz pentadiagonal es una matriz banda con $k_1 = k_2 = 2$. Por ejemplo, la matriz

$$B = \begin{bmatrix} b_{11} & b_{12} & b_{13} & 0 & 0 \\ b_{21} & b_{22} & b_{23} & b_{24} & 0 \\ b_{31} & b_{32} & b_{33} & b_{34} & b_{35} \\ 0 & b_{42} & b_{43} & b_{44} & b_{45} \\ 0 & 0 & b_{53} & b_{54} & b_{55} \end{bmatrix} \text{ es pentadiagonal.}$$

Definición 1.1.6 [Matriz de diagonal estrictamente dominante]

Una matriz cuadrada $A = [a_{ij}] \in \mathbb{R}^{n \times n}$ se dice que es de diagonal estrictamente dominante si para cada fila i se cumple que:

$$|a_{ii}| > \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}|$$

Es decir, el valor absoluto del elemento en la diagonal principal de cada fila es mayor que la suma de los valores absolutos de los demás elementos en esa fila.

Veamos un par de ejemplos de matrices de diagonal estrictamente dominante:

Ejemplo

- La matriz $A = \begin{bmatrix} 4 & 1 & 2 \\ 3 & 5 & 1 \\ 1 & 1 & 6 \end{bmatrix}$ es de diagonal estrictamente dominante, ya que:

$$|4| > |1| + |2|, \quad |5| > |3| + |1|, \quad |6| > |1| + |1|$$

- La matriz $B = \begin{bmatrix} 10 & 2 & 1 \\ 1 & 8 & 2 \\ 2 & 1 & 9 \end{bmatrix}$ es de diagonal estrictamente dominante, ya que:

$$|10| > |2| + |1|, \quad |8| > |1| + |2|, \quad |9| > |2| + |1|$$

Definición 1.1.7 [Traza de una matriz]

La traza de una matriz cuadrada $A = [a_{ij}] \in \mathbb{R}^{n \times n}$ se define como la suma de los elementos en la diagonal principal de la matriz. Matemáticamente, se expresa como:

$$\text{tr}(A) = \sum_{i=1}^n a_{ii}$$

donde a_{ii} son los elementos en la diagonal principal de la matriz A .

Veamos un par de ejemplos de cálculo de la traza de una matriz:

Ejemplo

- Para la matriz $A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}$, la traza es:

$$\text{tr}(A) = 1 + 5 + 9 = 15$$

- Para la matriz $B = \begin{bmatrix} 2 & 0 & 1 \\ 0 & 3 & 4 \\ 5 & 6 & 7 \end{bmatrix}$, la traza es:

$$\text{tr}(B) = 2 + 3 + 7 = 12$$

Proposición 1.1.2 [Propiedades de la traza]

Veamos algunas propiedades importantes de la traza de una matriz:

- **Linealidad:** La traza es una función lineal, es decir, para dos matrices cuadradas A y B del mismo tamaño y un escalar c , se cumple que:

$$\text{tr}(A + B) = \text{tr}(A) + \text{tr}(B)$$

$$\text{tr}(cA) = c \cdot \text{tr}(A)$$

- **Invarianza bajo trasposición:** La traza de una matriz es igual a la traza de su transpuesta:

$$\text{tr}(A) = \text{tr}(A^T)$$

- **Invarianza bajo conjugación:** La traza de una matriz es igual a la traza de su traspuesto conjugado:

$$\text{tr}(\overline{A}) = \text{tr}(A^*)$$

- **Cyclicidad:** La traza del producto de dos matrices es invariante bajo el cambio de orden:

$$\text{tr}(AB) = \text{tr}(BA)$$

Las propiedades anteriores se prueban directamente a partir de la definición de traza y las propiedades básicas de las operaciones matriciales, veamos solo la última:

$$C = AB \implies c_{ii} = \sum_{k=1}^n a_{ik} b_{ki} \implies \text{tr}(C) = \sum_{i=1}^n c_{ii} = \sum_{i=1}^n \sum_{k=1}^n a_{ik} b_{ki}$$

$$D = BA \implies d_{ii} = \sum_{k=1}^n b_{ik} a_{ki} \implies \text{tr}(D) = \sum_{i=1}^n d_{ii} = \sum_{i=1}^n \sum_{k=1}^n b_{ik} a_{ki}$$

Cambiando el orden de las sumas en ambos casos, se llega a la igualdad:

$$\text{tr}(C) = \text{tr}(D)$$

Definición 1.1.8 [Rango de una matriz]

El rango de una matriz $A \in \mathbb{R}^{m \times n}$ es el número máximo de columnas linealmente independientes que tiene la matriz. Se denota como $\text{rg}(A)$. El rango también puede ser interpretado como la dimensión del espacio generado por las columnas de la matriz, o como el número de filas no nulas en la forma escalonada reducida por filas de la matriz.

Observación 1.1.3

Notese que el rango de una matriz A es igual al rango de su transpuesta A^T , es decir, $\text{rg}(A) = \text{rg}(A^T)$. Esto se debe a que el número de columnas linealmente independientes en A es igual al número de filas linealmente independientes en A^T , ya que las filas de A^T corresponden a las columnas de A .

Definición 1.1.9 [Determinante]

El determinante de una matriz cuadrada $A \in \mathbb{R}^{n \times n}$ es un valor escalar que se asocia a la matriz y que proporciona información sobre ciertas propiedades de la misma, como su invertibilidad y el volumen de transformación lineal que representa. El determinante se denota como $\det(A)$ o $|A|$, y se calcula como:

$$\det(A) = \sum_{\sigma \in S_n} \text{sgn}(\sigma) \prod_{i=1}^n a_{i,\sigma(i)}$$

donde S_n es el conjunto de todas las permutaciones de los números $1, 2, \dots, n$, y $\text{sgn}(\sigma)$ es el signo de la permutación σ .

Proposición 1.1.3 [Propiedades del determinante]

Veamos algunas propiedades importantes del determinante de una matriz:

- **Multiplicatividad:** El determinante del producto de dos matrices es igual al producto de sus determinantes:

$$\det(AB) = \det(A) \cdot \det(B)$$

- **Determinante de matrices diagonales:** El determinante de una matriz diagonal es igual al producto de los elementos en la diagonal principal:

$$\det(D) = \prod_{i=1}^n d_{ii}$$

- **Transposición:** El determinante de una matriz es igual al determinante de su transpuesta:

$$\det(A) = \det(A^T)$$

- **Escalar:** Si c es un escalar y A es una matriz cuadrada de tamaño $n \times n$, entonces:

$$\det(cA) = c^n \cdot \det(A)$$

- **Inversión:** Si A es una matriz invertible, entonces:

$$\det(A^{-1}) = \frac{1}{\det(A)}$$

Todas estas propiedades se pueden demostrar utilizando la definición del determinante y las propiedades básicas de las operaciones matriciales.

Proposición 1.1.4 [Determinante de una matriz unitaria]

Sea $U \in \mathbb{C}^{n \times n}$ una matriz unitaria. Entonces, el valor absoluto de su determinante es igual a 1, es decir:

$$|\det(U)| = 1$$

Demostración. Sea U una matriz unitaria, por definición, se cumple que $U^* = U^{-1}$. Aplicando la propiedad de multiplicatividad del determinante, tenemos:

$$UU^* = I \implies \det(UU^*) = \det(I) = 1 \implies \det(U) \cdot \det(U^*) = \det(U) \cdot \overline{\det(U)} = |\det(U)|^2 = 1$$

De donde se deduce que:

$$|\det(U)| = 1$$

□

Teorema 1.1.1 [Caracterización de las matrices invertibles]

Sea $A \in \mathbb{R}^{n \times n}$ una matriz cuadrada. Entonces, las siguientes afirmaciones son equivalentes:

1. A es invertible, es decir $\exists A^{-1}$ tal que $AA^{-1} = A^{-1}A = I$.
2. El determinante de A es diferente de cero, es decir, $\det(A) \neq 0$.
3. El espectro de A no contiene el valor cero, es decir, $0 \notin \sigma(A)$.

Demostración. Veamos las implicaciones:

2) $\iff$ 3) Sabemos que el espectro de una matriz A está dado por los valores propios de la matriz, que son las soluciones de la ecuación característica $\det(A - \lambda I) = 0$. Si $0 \in \sigma(A)$, entonces existe un valor propio $\lambda = 0$ tal que $\det(A - 0 \cdot I) = \det(A) = 0$. Por lo tanto, si $\det(A) \neq 0$, entonces $0 \notin \sigma(A)$, y viceversa.

1) $\implies$ 2) Si A es invertible, entonces existe una matriz A^{-1} tal que $AA^{-1} = I$. Aplicando la propiedad de multiplicatividad del determinante, tenemos:

$$\det(AA^{-1}) = \det(I) = 1 \implies \det(A) \cdot \det(A^{-1}) = 1 \implies \det(A) = (\det(A^{-1}))^{-1} \neq 0$$

De donde se deduce que $\det(A) \neq 0$.

2) $\implies$ 1) Si $\det(A) \neq 0$, entonces la ecuación característica $\det(A - \lambda I) = 0$ no tiene $\lambda = 0$ como solución, lo que implica que A no tiene un núcleo no trivial. Por lo tanto, la transformación lineal asociada a A es inyectiva y, dado que A es cuadrada, también es sobreyectiva. Por el teorema de la inversa, esto implica que A es invertible.

Otra forma de demostrarlo es utilizando la descomposición LU o la eliminación de Gauss. Si $\det(A) \neq$

0, entonces A puede ser reducida a la matriz identidad mediante operaciones elementales, es decir, $\exists E_1, E_2, \dots, E_k$ matrices elementales tales que:

$$AE = AE_1 E_2 \dots E_k = I$$

Donde $E = E_1 E_2 \dots E_k$ es una matriz invertible, ya que es el producto de matrices elementales. Por lo tanto, podemos escribir:

$$A = E^{-1} I = E^{-1}$$

Y se deduce que A es invertible, con $A^{-1} = E$.

□

Veamos ahora varias propiedades interesantes del calculo de determinantes.

Corolario 1.1.1 [Determinante de una matriz triangular]

El determinante de una matriz triangular (superior o inferior) es igual al producto de los elementos en la diagonal principal. Es decir, si A es una matriz triangular, entonces:

$$\det(A) = \prod_{i=1}^n a_{ii}$$

Esto se da ya que si en una permutacion tenemos un elemento fuera de la diagonal principal, entonces el producto de los elementos correspondientes a esa permutacion sera cero, ya que si el elemento esta por debajo de la diagonal principal (en una triangular superior) o por encima de la diagonal principal (en una triangular inferior), entonces ese elemento es cero, lo que hace que el producto de los elementos correspondientes a esa permutacion sea cero, esta en el otro lado de la diagonal, debe haber un elemento fuera de la diagonal principal, lo que hace que el producto de los elementos correspondientes a esa permutacion sea cero, y asi sucesivamente para todas las permutaciones que tengan un elemento fuera de la diagonal principal, lo que hace que el unico producto no nulo sea el producto de los elementos en la diagonal principal, que corresponde a la permutacion identidad.

Corolario 1.1.2

Sea $M = \left(\begin{array}{c|c} A & 0 \\ \hline 0 & B \end{array} \right)$ una matriz con "solo 2 esquinas", entonces ocurre lo siguiente:

$$\det(M) = \left| \begin{array}{c|c} A & 0 \\ \hline 0 & B \end{array} \right| = \left| \begin{array}{c|c} A & 0 \\ \hline 0 & I \end{array} \right| \cdot \left| \begin{array}{c|c} I & 0 \\ \hline 0 & B \end{array} \right| = \det(A) \cdot \det(B)$$

Corolario 1.1.3

Sea $M = \left(\begin{array}{c|c} A & C \\ \hline 0 & B \end{array} \right)$ una matriz con "solo 3 esquinas", entonces ocurre lo siguiente:

$$\left| \begin{array}{c|c} I & \Gamma \\ \hline 0 & I \end{array} \right| \cdot \left| \begin{array}{c|c} A & C \\ \hline 0 & B \end{array} \right| = \left| \begin{array}{c|c} A & C + \Gamma B \\ \hline 0 & B \end{array} \right|$$

Ahora si tomamos $\Gamma = -CB^{-1}$, entonces:

$$\left| \begin{array}{c|c} I & -CB^{-1} \\ \hline 0 & I \end{array} \right| \cdot \left| \begin{array}{c|c} A & C \\ \hline 0 & B \end{array} \right| = \left| \begin{array}{c|c} A & 0 \\ \hline 0 & B \end{array} \right|$$

Esto lo podemos hacer ya que si B no es invertible, entonces habria una combinación lineal de las filas de B que daría como resultado la fila nula, la cual al replicarse en la esquina inferior derecha de M haría que M no sea invertible, lo que implicaría que $\det(M) = 0$, y por lo tanto, $\det(A) \cdot \det(B) = 0$, lo que implica que $\det(B) = 0$.

Por lo tanto, si B es invertible, entonces podemos realizar la operación anterior para obtener una matriz con "solo 2 esquinas", y aplicar el resultado del corolario anterior para concluir que:

$$\det(M) = \det(A) \cdot \det(B)$$

Ya que el primer determinante $\left| \begin{array}{c|c} I & \Gamma \\ \hline 0 & I \end{array} \right|$ es igual a 1, por ser una matriz triangular superior con 1's en la diagonal principal.

1.2 Autovalores y autovectores

Para definir los autovalores y autovectores de una matriz, primero necesitamos definir el concepto de espectro de una matriz, y el polinomio característico de una matriz.

Definición 1.2.1 [Espectro de una matriz]

El espectro de una matriz cuadrada $A \in \mathbb{R}^{n \times n}$ es el conjunto de todos los valores propios de la matriz, es decir, el conjunto de todos los escalares λ para los cuales existe un vector no nulo v tal que:

$$Av = \lambda v$$

El espectro se denota como $\sigma(A) = sp(A)$.

Definición 1.2.2 [Polinomio característico de una matriz]

El polinomio característico de una matriz cuadrada $A \in \mathbb{R}^{n \times n}$ es un polinomio en la variable λ definido como:

$$p_A(\lambda) = \det(A - \lambda I)$$

donde I es la matriz identidad de tamaño $n \times n$.

Los valores propios de la matriz A son las raíces del polinomio característico, es decir, los valores de λ para los cuales $p_A(\lambda) = 0$.

Ahora sí, podemos definir formalmente los autovalores y autovectores de una matriz:

Definición 1.2.3 [Autovalores y autovectores de una matriz]

Dada una matriz cuadrada $A \in \mathbb{R}^{n \times n}$, un escalar λ se llama autovalor de A si existe un vector no nulo $v \in \mathbb{R}^n$ tal que:

$$Av = \lambda v$$

En este caso, el vector v se llama autovector asociado al autovalor λ .

El conjunto de todos los autovectores asociados a un autovalor λ forma un subespacio vectorial llamado espacio propio o eigenspace correspondiente a λ . Este espacio se denota como $E_\lambda = \{v \in \mathbb{R}^n : Av = \lambda v\}$.

Notese que a los autovalores también se les conoce como valores propios, y a los autovectores como vectores propios.

Una forma de calcular los autovalores de una matriz es utilizando el polinomio característico, ya que los autovalores son las raíces de dicho polinomio. Para calcular los autovectores asociados a un autovalor λ , se puede resolver el sistema de ecuaciones lineales dado por:

$$(A - \lambda I)v = 0$$

que corresponde a encontrar el núcleo de la matriz $A - \lambda I$. El espacio propio E_λ es precisamente el núcleo de esta matriz, y sus elementos son los autovectores asociados al autovalor λ .

Notese también que el espectro es el conjunto de autovalores, y que cada autovalor puede tener uno o más autovectores asociados, dependiendo de su multiplicidad algebraica y geométrica.

Definición 1.2.4 [Multiplicidad algebraica y geométrica de un autovalor]

Dado un autovalor λ de una matriz $A \in \mathbb{R}^{n \times n}$, se define la multiplicidad algebraica de λ como el número de veces que λ aparece como raíz del polinomio característico $p_A(\lambda)$.

Por otro lado, la multiplicidad geométrica de λ se define como la dimensión del espacio propio E_λ , es decir, el número máximo de autovectores linealmente independientes asociados al autovalor λ .

Es importante destacar que la multiplicidad geométrica de un autovalor siempre es menor o igual a su multiplicidad algebraica.

Definición 1.2.5 [Radio espectral de una matriz]

El radio espectral de una matriz cuadrada $A \in \mathbb{R}^{n \times n}$ se define como el máximo valor absoluto de los autovalores de la matriz. Matemáticamente, se expresa como:

$$\rho(A) = \max_{\lambda \in \sigma(A)} |\lambda|$$

El radio espectral proporciona información sobre el comportamiento asintótico de las potencias de la matriz A , ya que si $\rho(A) < 1$, entonces las potencias de A tienden a cero, mientras que si $\rho(A) > 1$, entonces las potencias de A crecen sin límite.

Veamos ahora como el espectro se mantiene ante la conmutación del producto de matrices.

Proposición 1.2.1

Si $A, B \in \mathbb{R}^{n \times n}$ son dos matrices cuadradas, entonces el espectro de AB es igual al espectro de BA , es decir:

$$\sigma(AB) = \sigma(BA)$$

Demostración. Para ver esto, veamos como $\forall \lambda \in \sigma(AB)$, entonces existe un vector no nulo v tal que:

$$BAv = \lambda v$$

Es decir, que λ es un autovalor de BA (la implicación contraria es análoga). Para ello distingamos dos casos:

$\lambda = 0$ En este caso:

$$0 \in \sigma(AB) \iff \det(AB) = 0 \det(BA) \iff 0 \in \sigma(BA)$$

$\lambda \neq 0$ En este caso, como $v \neq 0$ es un autovector asociado al autovalor λ de AB , entonces $ABv = \lambda v$. Multiplicando ambos lados por B , obtenemos:

$$BA(Bv) = B(ABv) = \lambda(Bv)$$

Por lo que Bv es un autovector asociado al autovalor λ de BA . Además, como v es un vector no nulo y $\lambda \neq 0$, entonces Bv también es un vector no nulo, lo que garantiza que $\lambda \in \sigma(BA)$, ya que además $\det(B) \neq 0$ (si B no es invertible, entonces $0 \in \sigma(B)$, lo que implica que $0 \in \sigma(BA)$, lo que contradice la suposición de que $\lambda \neq 0$).

□

Veamos ahora como el espectro de una matriz se traslada al de sus potencias.

Proposición 1.2.2

Si $A \in \mathbb{R}^{n \times n}$ es una matriz cuadrada, entonces el espectro de A^k es igual al conjunto de los autovalores de A elevados a la potencia k , es decir:

$$\sigma(A^k) = \{\lambda^k : \lambda \in \sigma(A)\}$$

Demostración. Para ver esto, veamos como $\forall \lambda \in \sigma(A)$, entonces existe un vector no nulo v tal que:

$$Av = \lambda v$$

Ahora apliquemos inducción sobre k para demostrar que $A^k v = \lambda^k v$:

- **Caso base:** Para $k = 1$, se cumple que $A^1 v = Av = \lambda v$, lo que es cierto por la definición de autovalor y autovector.
- **Paso inductivo:** Supongamos que para algún $k \geq 1$, se cumple que $A^k v = \lambda^k v$. Entonces, para $k + 1$, tenemos:

$$A^{k+1} v = A(A^k v) = A(\lambda^k v) = \lambda^k (Av) = \lambda^k (\lambda v) = \lambda^{k+1} v$$

Por lo tanto, por el principio de inducción matemática, se cumple que $A^k v = \lambda^k v$ para todo $k \geq 1$.

De donde se deduce que λ^k es un autovalor de A^k con el mismo autovector v . Además, como v es un vector no nulo, entonces λ^k también es un valor propio de A^k . Por lo tanto, se concluye que:

$$\sigma(A^k) = \{\lambda^k : \lambda \in \sigma(A)\}$$

□

1.3 Teoremas importantes

Teorema 1.3.1 [Descomposición QR]

Sea $A \in \mathbb{K}^{m \times n}$ una matriz de rango máximo.

Entonces existen una matriz unitaria (ortogonal) $Q \in \mathbb{K}^{m \times m}$ y una matriz triangular superior $R \in \mathbb{K}^{m \times n}$ tal que:

$$A = QR \iff Q^*A = R$$

$Q^{-1} = Q^*$

Antes de la demostración, conviene definir el operador de proyección ortogonal de un vector sobre otro.

Definición 1.3.1 [Proyección ortogonal de un vector sobre otro]

Dados dos vectores $u, a \in \mathbb{K}^n$, la proyección ortogonal de a sobre u se define como el vector:

$$p : \mathbb{K}^n \times \mathbb{K}^n \rightarrow \mathbb{K}^n$$

$$(u, a) \mapsto p(u, a) = \frac{\langle u, a \rangle}{\|u\|^2} u = \left\langle \frac{u}{\|u\|}, a \right\rangle \frac{u}{\|u\|}$$

Teniendo en cuenta que:

$$\langle u, a \rangle = u^* a = a^* u$$

$$\|u\|^2 = \langle u, u \rangle = u^* u$$

Demostración. Vamos a realizar una demostración constructiva utilizando el proceso de Gram-Schmidt para ortogonalizar las columnas de la matriz A , es decir, queremos contruir una base ortogonal tal que $Q = (q_1, q_2, \dots, q_n)$, y para ello haremos lo siguiente:

Iremos tomando vectores u_i que sean ortogonales entre sí, y luego los normalizaremos para obtener los vectores q_i que formarán la matriz unitaria Q .

Para el primer vector, tomamos $u_1 = a_1$, donde a_1 es la primera columna de A . Luego, normalizamos u_1 para obtener $q_1 = \frac{u_1}{\|u_1\|}$.

Ahora para obtener el segundo vector, tomamos $u_2 = a_2 - p(u_1, a_2)$, donde $p(u_1, a_2)$ es la proyección ortogonal de a_2 sobre u_1 . Luego, normalizamos u_2 para obtener $q_2 = \frac{u_2}{\|u_2\|}$.

Para el tercer vector, tomamos $u_3 = a_3 - p(u_1, a_3) - p(u_2, a_3)$, donde $p(u_1, a_3)$ y $p(u_2, a_3)$ son las proyecciones ortogonales de a_3 sobre u_1 y u_2 , respectivamente. Luego, normalizamos u_3 para obtener $q_3 = \frac{u_3}{\|u_3\|}$.


Continuando de esta manera, para el k -ésimo vector, tomamos:

$$u_k = a_k - \sum_{j=1}^{k-1} p(u_j, a_k)$$

Luego, normalizamos u_k para obtener $q_k = \frac{u_k}{\|u_k\|}$.

De esta forma, obtenemos una base ortonormal $Q = (q_1, q_2, \dots, q_n)$ que forma una matriz unitaria.

Todo esto se puede entender geoméricamente como ir proyectando cada columna de A sobre el espacio generado por las columnas anteriores, quitándole la parte que está en ese espacio, y luego normalizando el resultado para obtener un vector unitario, vease el siguiente dibujo:



Así, hemos construido la matriz unitaria Q a partir de las columnas de A , ya que los vectores q_i son ortonormales y forman una base del espacio generado por las columnas de A , es decir, de $\mathbb{K}^n$.

Gracias a esta construcción, podemos definir la matriz triangular superior R como:

$$R = Q^* A = \begin{pmatrix} q_1^* \\ q_2^* \\ \vdots \\ q_n^* \end{pmatrix} \cdot (a_1 \ a_2 \ \cdots \ a_n) = \begin{pmatrix} q_1^* a_1 & q_1^* a_2 & \cdots & q_1^* a_n \\ 0 & q_2^* a_2 & \cdots & q_2^* a_n \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & q_n^* a_n \end{pmatrix}$$

Estos 0 aparecen ya que:

$$q_m^* a_k = \langle q_m, a_k \rangle = \langle q_m, u_k + \sum_{j=1}^{k-1} p(u_j, a_k) \rangle = \langle q_m, u_k \rangle + \sum_{j=1}^{k-1} \langle q_m, p(u_j, a_k) \rangle$$

Y ahora:

$$\langle q_m, u_k \rangle = \begin{cases} 0 & \text{si } m < k \\ \|u_k\| & \text{si } m = k \end{cases}$$

Por lo que si $m > k$, entonces $q_m^* a_k = 0$, y si $m = k$, entonces $q_m^* a_k = \|u_k\|$.

De esta forma, obtenemos una matriz triangular superior R con los elementos de la diagonal principal dados por $\|u_k\|$, y los elementos por encima de la diagonal dados por $q_m^* a_k$ para $m < k$.

Finalmente, como Q es una matriz unitaria, se cumple que $Q^{-1} = Q^*$, por lo que podemos escribir:

$$A = QR \iff Q^* A = R$$

Y con esto, hemos demostrado la existencia de la descomposición QR para cualquier matriz de rango máximo. $\square$

Veamos ahora otra descomposición importante, la descomposición de Schur.

Teorema 1.3.2 [Descomposición de Schur]

Sea $A \in \mathbb{C}^{n \times n}$ una matriz cuadrada. Entonces, existe una matriz unitaria $U \in \mathbb{C}^{n \times n}$ y una matriz triangular superior $T \in \mathbb{C}^{n \times n}$ tal que:

$$A = UTU^* \iff_{U^{-1}=U^*} U^*AU = T$$

Si además A es hermítica, entonces T es diagonal, es decir:

$$A = UDU^* \iff_{U^{-1}=U^*} U^*AU = D$$

Demostración. Sea $\lambda \in sp(A)$ un autovalor de A , y sea v un autovector asociado a λ , al cual imponemos ser unitario, es decir, $\|v\| = 1$.

Ahora completamos a una base ortonormal $(v, w_2, w_3, \dots, w_n)$ de $\mathbb{C}^n$, y formamos la matriz unitaria $U_1 = (v, w_2, w_3, \dots, w_n)$.

La idea a partir de aquí es ir aplicando el proceso de Gram-Schmidt a las columnas de A para obtener una matriz triangular superior, pero en lugar de empezar con la primera columna, empezamos con la columna correspondiente al autovector v , que es la primera columna de U_1 , y finalmente obtendremos una matriz triangular superior T tal que $U_1^* A U_1 = T$.

La demostración no se va a realizar. $\square$

Veamos ahora varias proposiciones interesantes.

Corolario 1.3.1 [Determinante de una matriz triangular]

El determinante de una matriz triangular (superior o inferior) es igual al producto de los elementos en la diagonal principal. Es decir, si A es una matriz triangular, entonces:

$$\det(A) = \prod_{i=1}^n a_{ii}$$

Esto ya se probó anteriormente, solo lo recordamos, pero ahora lo podemos entender como una consecuencia directa de la descomposición de Schur, ya que si $A = UTU^*$, entonces:

$$\det(A) = \det(UTU^*) = \det(U) \cdot \det(T) \cdot \det(U^*) = |\det(U)|^2 \cdot \prod_{i=1}^n t_{ii} = \prod_{i=1}^n t_{ii}$$

Donde t_{ii} son los elementos de la diagonal principal de T , y se ha utilizado el hecho de que U es una matriz unitaria, por lo que $|\det(U)| = 1$.

Corolario 1.3.2 [Espectro de una matriz triangular]

El espectro de una matriz triangular (superior o inferior) es igual al conjunto de los elementos en la diagonal principal. Es decir, si A es una matriz triangular, entonces:

$$\sigma(A) = \{a_{11}, a_{22}, \dots, a_{nn}\}$$

Corolario 1.3.3 [Espectro de una matriz bajo la descomposición de Schur]

Si $A \in \mathbb{C}^{n \times n}$ es una matriz cuadrada, y $A = UTU^*$ es su descomposición de Schur, entonces el espectro de A es igual al conjunto de los elementos en la diagonal principal de T . Es decir:

$$\sigma(A) = \{t_{11}, t_{22}, \dots, t_{nn}\}$$

Esto se ve fácilmente tomando $\lambda \in \sigma(A)$ y v un autovector asociado a λ , entonces:

$$Av = UTU^*v \implies \lambda v = UTU^*v \implies \lambda U^*v = TU^*v \xRightarrow[u=U^*v \neq 0]{} \lambda u = Tu$$

Corolario 1.3.4 [La traza de una matriz es igual a la suma de sus autovalores]

Si $A \in \mathbb{C}^{n \times n}$ es una matriz cuadrada, y $A = UTU^*$ es su descomposición de Schur, entonces la traza de A es igual a la suma de los elementos en la diagonal principal de T , que a su vez es igual a la suma de los autovalores de A . Es decir:

$$tr(A) = tr(AUU^*) \underset{tr(AB)=tr(BA)}{=} tr(U^*AU) = tr(T) = \sum_{i=1}^n t_{ii} = \sum_{\lambda \in \sigma(A)} \lambda$$

Corolario 1.3.5 [Espectro de la inversa de una matriz]

Si $A \in \mathbb{C}^{n \times n}$ es una matriz cuadrada invertible, entonces el espectro de A^{-1} es igual al conjunto de los inversos de los elementos en la diagonal principal de T . Es decir:

$$\sigma(A) = \{\lambda_i\} \implies \sigma(A^{-1}) = \{\lambda_i^{-1}\} = \left\{\frac{1}{\lambda_i}\right\}$$

Esto se ve facilmente tomando $\lambda \in \sigma(A)$ y v un autovector asociado a λ , entonces:

$$Av = \lambda v \implies A^{-1}Av = A^{-1}\lambda v \implies v = \lambda A^{-1}v \implies A^{-1}v = \frac{1}{\lambda}v$$

Corolario 1.3.6 [Espectro de una matriz hermítica]

Si $A \in \mathbb{C}^{n \times n}$ es una matriz hermítica, entonces el espectro de A es un conjunto de números reales. Es decir:

$$A = A^* \implies \sigma(A) \subseteq \mathbb{R}$$

Esto se ve facilmente tomando $\lambda \in \sigma(A)$ y v un autovector asociado a λ , entonces:

$$Av = \lambda v \implies (Av)^* = (\lambda v)^* \implies v^* A^* = v^* \lambda^* \implies v^* A = \lambda^* v^* \implies v^* Av = \lambda^* \|v\|^2 \implies$$

$$v^* \lambda v = \lambda v^* v \implies \lambda \|v\|^2 = \lambda^* \|v\|^2 \implies \lambda = \lambda^*$$

De donde se deduce que como $\lambda^* = \lambda$, implica que λ es un número real.

1.4 Matrices hermiticas definidas positivas

Definición 1.4.1 [Matriz hermítica definida positiva]

Una matriz $A \in \mathbb{C}^{n \times n}$ se dice que es hermítica definida positiva, o h.d.p., si cumple las siguientes condiciones:

- A es hermítica, es decir, $A = A^*$.
- Para todo vector no nulo $x \in \mathbb{C}^n$, se cumple que $x^* Ax > 0$.

Proposición 1.4.1 [Espectro de una matriz h.d.p.]

Las siguientes afirmaciones son equivalentes para una matriz $A \in \mathbb{C}^{n \times n}$:

- A es hermítica definida positiva.
- A es hermítica y su espectro $\sigma(A)$ está contenido en el conjunto de los números reales positivos, es decir, $\sigma(A) \subseteq \mathbb{R}_{>0}$.

Demostración. Para demostrar la equivalencia, veamos cada implicación por separado:

(1) $\Rightarrow$ (2): Supongamos que A es hermítica definida positiva. Entonces, por definición, para todo vector no nulo $x \in \mathbb{C}^n$, se cumple que $x^* Ax > 0$. En particular, si tomamos un autovector v asociado a un

autovalor λ , entonces:

$$v^*Av = v^*(\lambda v) = \lambda v^*v = \lambda \|v\|^2 \implies \lambda = \frac{v^*Av}{\|v\|^2} > 0$$

Dado que v es un vector no nulo, entonces $\|v\|^2 > 0$, lo que implica que $\lambda > 0$. Por lo tanto, todos los autovalores de A son positivos, y como A es hermítica, su espectro está contenido en el conjunto de los números reales positivos.

(2) $\Rightarrow$ (1): Supongamos que A es hermítica y su espectro está contenido en el conjunto de los números reales positivos. Entonces, por la descomposición de Schur, existe una matriz unitaria U y una matriz triangular superior T tal que:

$$A = UTU^*$$

Donde los elementos de la diagonal principal de T , que son los autovalores de A , son todos positivos. Ahora, para cualquier vector no nulo $x \in \mathbb{C}^n$, tenemos:

$$x^*Ax = x^*UTU^*x = (U^*x)^*T(U^*x) = w^*Dw = \sum_{i=1}^n t_{ii}|w_i|^2 = \sum_{i=1}^n \lambda_i|w_i|^2$$

Notese que hemos podido tomar una matriz diagonal D en lugar de la matriz triangular T , ya que el producto w^*Tw solo depende de los elementos de la diagonal principal de T , que son los autovalores de A . Dado que $\lambda_i > 0$ para todo i , y que $w = U^*x$ es un vector no nulo (ya que U es una matriz unitaria), entonces al menos uno de los términos $|w_i|^2$ es positivo, lo que implica que la suma es estrictamente mayor que cero. Por lo tanto:

$$x^*Ax > 0$$

Por lo tanto, se concluye que A es hermítica definida positiva. $\square$

1.5 Normas matriciales

Empecemos recordando que es una norma vectorial.

Definición 1.5.1 [Norma vectorial general]

Una norma vectorial es una función que asigna a cada vector $v \in \mathbb{K}^n$ un número real no negativo, y que satisface las siguientes propiedades:

$$\begin{aligned} \|\cdot\| : \mathbb{K}^n &\rightarrow \mathbb{R}_{\geq 0} \\ v &\mapsto \|v\| \end{aligned}$$

- **Positividad:** $\|v\| \geq 0$ para todo $v \in \mathbb{K}^n$, y $\|v\| = 0$ si y solo si $v = 0$.
- **Definitud:** $\|v\| = 0$ si y solo si $v = 0$.
- **Homogeneidad:** $\|\alpha v\| = |\alpha| \cdot \|v\|$ para todo $v \in \mathbb{K}^n$ y todo escalar $\alpha \in \mathbb{K}$.
- **Desigualdad triangular:** $\|u + v\| \leq \|u\| + \|v\|$ para todo $u, v \in \mathbb{K}^n$.

Recordemos como se define la equivalencia entre normas vectoriales.

Definición 1.5.2 [Equivalencia entre normas vectoriales]

Dos normas vectoriales $\|\cdot\|_a$ y $\|\cdot\|_b$ en $\mathbb{K}^n$ se dicen equivalentes si existen constantes positivas $C_1, C_2 > 0$ tales que:

$$C_1\|v\|_a \leq \|v\|_b \leq C_2\|v\|_a$$

para todo $v \in \mathbb{K}^n$.

Esto significa que ambas normas definen la misma topología en $\mathbb{K}^n$, es decir, los conjuntos abiertos y cerrados son los mismos para ambas normas, y por lo tanto, las propiedades de convergencia, continuidad y demás conceptos topológicos son equivalentes bajo ambas normas.

Ahora veamos la definición de norma matricial.

Definición 1.5.3 [Norma matricial]

Una norma matricial es una función que asigna a cada matriz $A \in \mathbb{K}^{m \times n}$ un número real no negativo, y que satisface las siguientes propiedades:

$$\begin{aligned} \|\cdot\| : \mathbb{K}^{m \times n} &\rightarrow \mathbb{R}_{\geq 0} \\ A &\mapsto \|A\| \end{aligned}$$

- **Positividad:** $\|A\| \geq 0$ para todo $A \in \mathbb{K}^{m \times n}$, y $\|A\| = 0$ si y solo si $A = 0$.
- **Definitud:** $\|A\| = 0$ si y solo si $A = 0$.
- **Homogeneidad:** $\|\alpha A\| = |\alpha| \cdot \|A\|$ para todo $A \in \mathbb{K}^{m \times n}$ y todo escalar $\alpha \in \mathbb{K}$.
- **Desigualdad triangular:** $\|A + B\| \leq \|A\| + \|B\|$ para todo $A, B \in \mathbb{K}^{m \times n}$.
- **Submultiplicatividad:** $\|AB\| \leq \|A\| \cdot \|B\|$ para todo $A \in \mathbb{K}^{m \times p}$ y todo $B \in \mathbb{K}^{p \times n}$.

Algunas normas particulares son las siguientes (para vectores):

- **Normas p-ésimas:** Para $1 \leq p < \infty$, la norma p-ésima de un vector $v \in \mathbb{K}^n$ se define como:

$$\|v\|_p = \left(\sum_{i=1}^n |v_i|^p \right)^{\frac{1}{p}}$$

- **Norma p-1-ésima:** Para $p = 1$, la norma p-1-ésima de un vector $v \in \mathbb{K}^n$ se define como:

$$\|v\|_1 = \sum_{i=1}^n |v_i|$$

- **Norma p-2-ésima o euclídea:** Para $p = 2$, la norma p-2-ésima de un vector $v \in \mathbb{K}^n$ se define como:

$$\|v\|_2 = \sqrt{\sum_{i=1}^n |v_i|^2}$$

- **Norma p-infinito-ésima:** Para $p = \infty$, la norma p-infinito-ésima de un vector $v \in \mathbb{K}^n$ se define como:

$$\|v\|_\infty = \lim_{p \rightarrow \infty} \|v\|_p = \max_{1 \leq i \leq n} |v_i|$$

1.6 Normas subordinadas

Definamos ahora la norma subordinada de una matriz, que es una norma matricial que se define a partir de una norma vectorial.

Definición 1.6.1 [Norma subordinada de una matriz]

Sea $A \in \mathbb{K}^{m \times n}$ una matriz, y sea $p \in [1, \infty]$. La norma subordinada de A con respecto a la norma p -ésima se define como:

$$\|A\|_p = \sup_{v \neq 0} \frac{\|Av\|_p}{\|v\|_p} = \sup_{v \neq 0} \left\| A \frac{v}{\|v\|_p} \right\|_p = \sup_{\|v\|_p=1} \|Av\|_p$$

Veamos que se cumplen las propiedades de una norma matricial para la norma subordinada de una matriz.

- **Norma de una matriz nula:** Para la matriz nula $0 \in \mathbb{K}^{m \times n}$, se cumple que $\|0\|_p = 0$ para cualquier $p \in [1, \infty]$, ya que $Av = 0$ para cualquier vector v , lo que implica que $\|Av\|_p = 0$ y por lo tanto, el supremum es cero.
- **Norma bajo escala:** Para cualquier matriz $A \in \mathbb{K}^{m \times n}$ y cualquier escalar $\alpha \in \mathbb{K}$, se cumple que $\|\alpha A\|_p = |\alpha| \cdot \|A\|_p$, lo que se deduce directamente de la homogeneidad de la norma vectorial.
- **Norma bajo la suma:** Para cualquier matriz $A, B \in \mathbb{K}^{m \times n}$, se cumple que $\|A+B\|_p \leq \|A\|_p + \|B\|_p$, lo que se deduce directamente de la desigualdad triangular de la norma vectorial.
- **Norma bajo el producto:** Para cualquier matriz $A \in \mathbb{K}^{m \times p}$ y cualquier matriz $B \in \mathbb{K}^{p \times n}$, se cumple que $\|AB\|_p \leq \|A\|_p \cdot \|B\|_p$, lo que se deduce directamente de la submultiplicatividad de la norma matricial.

Otra forma de probar esto es usando que:

$$\begin{aligned} \|AB\|_p &= \sup_{\|v\|_p=1} \|ABv\|_p = \sup_{\|v\|_p=1} \left(\frac{\|ABv\|_p \|Bv\|_p}{\|Bv\|_p} \right) = \sup_{\|v\|_p=1} \left(\left\| A \frac{Bv}{\|Bv\|_p} \right\|_p \cdot \|Bv\|_p \right) \leq \\ &\quad \sup_{\|v\|_p=1} \|Av\|_p \cdot \sup_{\|v\|_p=1} \|Bv\|_p = \|A\|_p \cdot \|B\|_p \end{aligned}$$

Y como se ha demostrado que se cumplen las propiedades de una norma matricial, entonces la norma subordinada de una matriz es una norma matricial válida.

Veamos ahora algunas propiedades de las matrices de covarianzas, tras haber definido las normas necesarias.

Proposición 1.6.1 [Matriz de covarianza es h.d.p.]

Si X es una matriz de datos en m variables y n medidas con $n \gg m$:

$$X = (x_1, \dots, x_n) \text{ (} m \text{ variables) } n \text{ medidas}$$

Siendo μ las medidas o promedios y $\tilde{x}_i = x_i - \mu_i$, entonces la matriz de covarianza de X se define como:

$$C = \tilde{X}^t \tilde{X} \in \mathbb{R}^{m \times m}$$

Demostración. Tomando $\tilde{X} = (\tilde{x}_1, \dots, \tilde{x}_n)$, entonces C es una matriz hermítica definida positiva, ya que en primer lugar es simétrica:

$$C^t = (\tilde{X}^t \tilde{X})^t = \tilde{X}^t \tilde{X} = C$$

Y como pertenece a $\mathbb{R}^{m \times m}$, entonces C es hermítica (ya que en $\mathbb{R}$, la conjugación no afecta a los elementos de la matriz).

Ahora para ver que es h.d.p., tenemos que comprobar que $sp(C) \subseteq \mathbb{R}_{>0}$ (ya sabemos que es real). Para ello, tomemos $\lambda \in \sigma(C)$ un autovalor de C , y sea v un autovector asociado a λ :

$$Cv = \lambda v \implies \tilde{X}^t \tilde{X}v = \lambda v \implies v^t \tilde{X}^t \tilde{X}v = \lambda v^t v = \lambda \|v\|^2 = \lambda \implies$$

$$(\tilde{X}v)^t (\tilde{X}v) = \|\tilde{X}v\|_2^2 = \lambda \|v\|_2^2 \implies$$

Usando ahora que $v^t v = \langle v, v \rangle = \|v\|_2^2$, entonces en particular, $\|v\|_2^2 = 1$, por lo que $\|v\|_2^2 = v^* v = 1$, y por lo tanto:

$$\lambda = \|\tilde{X}v\|_2^2 \geq 0$$

□

Algunas normas matriciales particulares son las siguientes (normas subordinadas):

- **Norma p-ésima subordinada:** La norma p-ésima subordinada de una matriz $A \in \mathbb{K}^{m \times n}$ se define como (que es la norma p-ésima subordinada):

$$\|A\|_p = \sup_{\|v\|_p=1} \|Av\|_p$$

- **Norma 1:** La norma 1 de una matriz $A \in \mathbb{K}^{m \times n}$ se define como (que es la norma 1 subordinada):

$$\|A\|_1 = \sup_{\|v\|_1=1} \|Av\|_1$$

- **Norma 2 o espectral:** La norma 2 de una matriz $A \in \mathbb{K}^{m \times n}$ se define como (que es la norma 2 subordinada):

$$\|A\|_2 = \sup_{\|v\|_2=1} \|Av\|_2$$

- **Norma infinito:** La norma infinito de una matriz $A \in \mathbb{K}^{m \times n}$ se define como (que es la norma infinito subordinada):

$$\|A\|_\infty = \sup_{\|v\|_\infty=1} \|Av\|_\infty$$

Teorema 1.6.1 [Calculo simplificado de normas subordinadas]

Sea $A \in \mathbb{K}^{m \times n}$ una matriz, entonces sus normas subordinadas se pueden calcular de la siguiente forma:

- La norma 1 subordinada de A es igual al máximo valor absoluto de la suma de los elementos de cada columna de A . Es decir:

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|$$

- La norma infinito subordinada de A es igual al máximo valor absoluto de la suma de los elementos de cada fila de A . Es decir:

$$\|A\|_\infty = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|$$

- La norma 2 subordinada de A es igual a la raíz cuadrada del máximo autovalor de $A^* A$. Es decir:

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^* A)} = \sqrt{\rho(A^* A)}$$

Demostración. Las dos primeras formulas son triviales de demostrar, ya que se pueden obtener directamente de la definición de la norma subordinada y de la forma en que se calcula el producto Av .

Para la tercera formula, hagamos los siguientes cálculos:

$$\begin{aligned} \|A\|_2^2 &= \left(\sup_{\|v\|_2=1} \|Av\|_2 \right)^2 = \sup_{\|v\|_2=1} \|Av\|_2^2 = \sup_{\|v\|_2=1} (Av)^*(Av) = \sup_{\|v\|_2=1} v^* A^* A v \\ &\stackrel{H=A^*A \text{ es hermítica}}{=} \sup_{\|v\|_2=1} v^* H v \stackrel{\text{Schur}}{=} \sup_{\|v\|_2=1} v^* U D U^* v \stackrel{z=U^*v}{=} \sup_{\|z\|_2=1} z^* D z =^* \end{aligned}$$

Ahora hemos usado que como U es una matriz unitaria, entonces $\|z\|_2 = \|v\|_2 = 1$, por lo que el supremum se puede tomar sobre z en lugar de sobre v , con fórmula $\|z\|_2^2 = z^* z = v^* U U^* v = v^* v = \|v\|_2^2$.

Continuando con el cálculo, y denotando:

$$\begin{aligned} D &= \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{pmatrix} \Rightarrow \\ z^* D z &= (\bar{z}_1 \quad \bar{z}_2 \quad \cdots \quad \bar{z}_n) \cdot \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{pmatrix} \cdot \begin{pmatrix} z_1 \\ z_2 \\ \vdots \\ z_n \end{pmatrix} = \sum_{i=1}^n \lambda_i |z_i|^2 \end{aligned}$$

Y ahora podemos usar que como $\|z\|_2^2 = 1$, entonces $\sum_{i=1}^n |z_i|^2 = 1$, por lo que $z^* D z$ es una combinación convexa de los autovalores de H (y de D por tanto), lo que implica que el supremum de $z^* D z$ es igual al máximo autovalor de D , que es el máximo autovalor de H . Por lo tanto:

$$=^* \lambda_{\max}(D) = \lambda_{\max}(H) = \lambda_{\max}(A^* A) \Rightarrow \|A\|_2 = \sqrt{\lambda_{\max}(A^* A)}$$

Y si denotamos el operador $\rho(M)$ como el máximo valor absoluto de los autovalores de M , podemos tener el resultado como $\|A\|_2 = \sqrt{\rho(A^* A)}$. $\square$

Definición 1.6.2 [Norma de Frobenius]

La norma de Frobenius de una matriz $A \in \mathbb{K}^{m \times n}$ se define como:

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2}$$

1.7 Potencias de matrices

Veamos algunas propiedades de las potencias de matrices, que son muy útiles para el cálculo de autovalores y autovectores.

Teorema 1.7.1 [Convergencia a 0 de las potencias de una matriz con espectro menor que 1]

Si $A \in \mathbb{C}^{n \times n}$, entonces son equivalentes las siguientes afirmaciones:

1. A tiende a 0, es decir:

$$\lim_{k \rightarrow \infty} A^k = 0$$

2. La imagen de todo vector bajo A^k tiende a 0, es decir:

$$\lim_{k \rightarrow \infty} A^k v = 0 \quad \forall v \in \mathbb{C}^n$$

3. El espectro de A está acotado por 1, es decir:

$$\rho(A) < 1$$

4. Existe una norma matricial $\|\cdot\|$ tal que $\|A\| < 1$.

Demostración. Veamos las implicaciones por separado: **(1) $\Rightarrow$ (2):** Si $A^k \rightarrow 0$, entonces para cualquier vector $v \in \mathbb{C}^n$, se cumple que:

$$\|A^k v\| \leq \|A^k\| \cdot \|v\| \rightarrow 0$$

(2) $\Rightarrow$ (3): Si hubiera un autovalor λ de A tal que $|\lambda| \geq 1$, entonces tomando un autovector asociado a λ , se tendría que:

$$A^k v = \lambda^k v \implies \|A^k v\| = |\lambda|^k \|v\| \not\rightarrow 0$$

Lo que contradice la hipótesis, por lo que todos los autovalores de A deben tener módulo menor que 1, es decir, $\rho(A) < 1$.

También se puede usar que $\|A^k v\| = \|\lambda|^k v\|$ para cualquier autovalor λ y su autovector asociado v , por lo que como debe converger a 0 para todo v , entonces $|\lambda|^k \|v\| \rightarrow 0$ para todo autovalor λ , lo que implica que $|\lambda| < 1$ para todo autovalor λ .

□

1.8 Condicionamiento de matrices

Veamos un teorema importante sobre sistemas de ecuaciones lineales

Teorema 1.8.1 [Existencia de solución única para sistemas de ecuaciones lineales]

Si $A \in \mathbb{C}^{n \times n}$ es una matriz cuadrada, entonces el sistema de ecuaciones lineales $Ax = b$ tiene una solución única para cada $b \in \mathbb{C}^n$ si y solo si A es invertible. Es decir:

$$\text{El sistema } Ax = b \text{ tiene solución única para cada } b \in \mathbb{C}^n \iff A \text{ es invertible} \iff \det(A) \neq 0$$

Ahora nos podemos preguntar como de estable es la solución de un sistema de ecuaciones lineales ante pequeñas perturbaciones en los datos.

Si modificamos $\bar{b} = b + \delta$ podemos ver que el error de b es:

$$E_b = \frac{\|\bar{b} - b\|}{\|b\|} = \frac{\|\delta\|}{\|b\|}$$

Ahora podemos definir $\bar{x} = A^{-1}\bar{b} = x + \epsilon$, y por tanto podemos hacer el siguiente despeje:

$$A\bar{x} = \bar{b} \iff A(x + \epsilon) = b + \delta \iff A\epsilon = \delta \implies \epsilon = A^{-1}\delta$$

Y por tanto el error de x es:

$$\begin{aligned} E_x &= \frac{\|\bar{x} - x\|}{\|x\|} = \frac{\|\epsilon\|}{\|x\|} = \frac{\|A^{-1}\delta\|}{\|x\|} \leq \frac{\|A^{-1}\| \cdot \|\delta\|}{\|x\|} = \frac{\|A^{-1}\| \cdot \|b\|}{\|x\|} \cdot \frac{\|\delta\|}{\|b\|} = \\ &= \frac{\|A^{-1}\| \cdot \|b\|}{\|x\|} \cdot E_b = \frac{\|A^{-1}\| \cdot \|Ax\|}{\|x\|} \cdot E_b \leq \|A^{-1}\| \cdot \|A\| \cdot E_b = \text{cond}(A) \cdot E_b \end{aligned}$$

Donde $\text{cond}(A) = \|A^{-1}\| \cdot \|A\|$ es el número de condición de la matriz A , el cual si es muy grande, significara que el sistema de ecuaciones lineales es muy sensible a pequeñas perturbaciones en los datos, lo que se conoce como un sistema mal condicionado. Por otro lado, si $\text{cond}(A)$ es pequeño, entonces el sistema de ecuaciones lineales es estable ante pequeñas perturbaciones en los datos, lo que se conoce como un sistema bien condicionado.

2 Resolución de sistemas lineales

2.1 Introducción a los sistemas lineales

Sea $A \in \mathbb{K}^{n \times n}$ y $b \in \mathbb{K}^n$. Un sistema lineal es la búsqueda de $x \in \mathbb{K}^n$ tal que $S \equiv Ax = b$. En este apartado se estudiarán diferentes métodos para resolver sistemas lineales, así como sus propiedades y análisis de convergencia.

Es fácil ver que si A es invertible, entonces el sistema tiene una única solución dada por $x = A^{-1}b$. Sin embargo, calcular la inversa de una matriz puede ser computacionalmente costoso y numéricamente inestable. Por ello, se han desarrollado diversos métodos para resolver sistemas lineales sin necesidad de calcular la inversa de la matriz.

Teorema 2.1.1 [Metodo de Cramer]

Sea el sistema $S \equiv Ax = b$ con $A \in \mathbb{K}^{n \times n}$ invertible. Entonces, si denotamos:

$$A_i = \begin{bmatrix} a_{11} & \cdots & a_{1,i-1} & b_1 & a_{1,i+1} & \cdots & a_{1n} \\ a_{21} & \cdots & a_{2,i-1} & b_2 & a_{2,i+1} & \cdots & a_{2n} \\ \vdots & & \vdots & \vdots & \vdots & & \vdots \\ a_{n1} & \cdots & a_{n,i-1} & b_n & a_{n,i+1} & \cdots & a_{nn} \end{bmatrix} = (a_1, \dots, a_{i-1}, b, a_{i+1}, \dots, a_n)$$

Dónde a_j es la j -ésima columna de A , entonces la solución del sistema es:

$$x_i = \frac{\det(A_i)}{\det(A)} \quad \forall i = 1, \dots, n$$

Sin embargo, el método de Cramer es computacionalmente ineficiente para matrices grandes, ya que el cálculo de determinantes tiene una complejidad factorial. Por ello, se utilizan otros métodos como el método de Gauss, que es mucho más eficiente y estable para resolver sistemas lineales, se pueden apreciar los tiempos necesarios en la siguiente tabla:

n	10	100	10^3
Cramer	10^8	10^{162}	10^{2573}
Gauss	800	10^6	10^9

Siendo n el tamaño de la matriz A , el metodo de Cramer tiene una complejidad de $O(n^2 \cdot n!)$ mientras que el método de Gauss tiene una complejidad de $O(n^3)$.

En los siguientes apartados se estudiarán diferentes métodos para resolver sistemas lineales, así como sus propiedades y análisis de convergencia.

Un caso particular de sistemas lineales es el caso de sistemas diagonales, que tienen esta forma:

$$\begin{pmatrix} a_{11} & 0 & \cdots & 0 \\ 0 & a_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & a_{nn} \end{pmatrix} \cdot x = b$$

De lo que se deduce trivialmente que la solución es $x_i = \frac{b_i}{a_{ii}}$ para $i = 1, \dots, n$.

Estos sistemas diagonales tiene una complejidad de $O(n)$, ya que se necesitan n operaciones para calcular la solución.

Otro sistema particular es el sistema triangular superior, que tiene esta forma:

$$\begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ 0 & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & a_{nn} \end{pmatrix} \cdot x = b$$

En este caso, se puede resolver el sistema mediante sustitución hacia atrás, comenzando por la última ecuación y avanzando hacia la primera, es decir:

$$x_i = \frac{1}{a_{ii}} \left(b_i - \sum_{j=i+1}^n a_{ij}x_j \right) \quad \forall i \in \{n, n-1, \dots, 1\}$$

Analogamente, un sistema triangular inferior tiene esta forma:

$$\begin{pmatrix} a_{11} & 0 & \cdots & 0 \\ a_{21} & a_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix} \cdot x = b$$

Y se puede resolver mediante sustitución hacia adelante, comenzando por la primera ecuación y avanzando hacia la última, es decir:

$$x_i = \frac{1}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij}x_j \right) \quad \forall i \in \{1, 2, \dots, n\}$$

Estos sistemas triangulares tienen una complejidad de $O(n^2)$, ya que se necesitan n operaciones para calcular cada x_i , y hay n variables.

Ahora veamos algunos metodos de resolución de sistemas lineales más generales.

Proposición 2.1.1 [Método de eliminación Gaussiana]

El método de eliminación Gaussiana es un algoritmo para resolver sistemas lineales que consiste en transformar la matriz A en una matriz triangular superior mediante operaciones elementales de fila, es decir:

$$Ax = b \longrightarrow Tx = b'$$

Para pasar a una matriz triangular superior T , usaremos una matriz E cuyo determinante no sea nula, de tal forma que tengamos el siguiente sistema equivalente:

$$\underbrace{E \cdot A}_T x = \underbrace{E \cdot b}_{b'}$$

Para ver quien es esta matriz E , se pueden usar matrices de permutación para intercambiar filas, matrices de escala para multiplicar una fila por un escalar distinto de cero, y matrices de eliminación para sumar un múltiplo de una fila a otra fila. Denotemos:

$$E = E_k \cdot E_{k-1} \cdots E_1$$

Siendo E_i una matriz elemental que representa una de las operaciones mencionadas anteriormente, y siendo:

$$E_i \cdot A_{i-1} = A_i \quad b_i = E_i \cdot b_{i-1} \longrightarrow A_i x = b_i$$

Y por tanto el algoritmo se basara en llegar a un k que cumpla:

$$A_k = E_k \cdot E_{k-1} \cdots E_1 \cdot A = E \cdot A = T$$

Ahora veamos como encontrar una matriz E_i que nos permita hacer cada una de las operaciones elementales descritas anteriormente:

- **Multiplicar una fila por un escalar distinto de cero:** Para multiplicar la fila i por un escalar $\lambda \neq 0$, se puede usar la matriz de escala E_i que tiene la forma:

$$E_i = \begin{pmatrix} 1 & \cdots & 0 \\ 0 & \ddots & \cdots & 0 \\ \vdots & 0 & \lambda & 0 \\ 0 & 0 & \cdots & 1 \end{pmatrix}$$

Donde el elemento en la posición (i, i) es λ y el resto de los elementos son 1 en la diagonal y 0 en el resto de la matriz, y transforma A_{i-1} en A_i multiplicando la fila i por λ :

$$E_i \cdot A_{i-1} = \begin{pmatrix} 1 & 0 & \cdots & 0 \\ 0 & \ddots & \cdots & 0 \\ \vdots & 0 & \lambda & 0 \\ 0 & 0 & \cdots & 1 \end{pmatrix} \cdot \begin{pmatrix} a_i^T \\ \vdots \\ a_i^T \\ \vdots \\ a_n^T \end{pmatrix} = \begin{pmatrix} a_i^T \\ \vdots \\ \lambda a_i^T \\ \vdots \\ a_n^T \end{pmatrix}$$

- **Intercambiar dos filas:** Para intercambiar las filas i y j , se puede usar la matriz de permutación E_i que tiene la forma:

$$E_i = \begin{pmatrix} 1 & \cdots & 0 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & \cdots & 1 \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 1 & \cdots & 0 \end{pmatrix}$$

Donde el elemento en la posición (i, j) es 1, el elemento en la posición (j, i) es 1, y el resto de los elementos son 1 en la diagonal y 0 en el resto de la matriz, y transforma A_{i-1} en A_i

intercambiando las filas i y j :

$$E_i \cdot A_{i-1} = \begin{pmatrix} 1 & 0 & \cdots & 0 & \cdots & 0 \\ 0 & \ddots & \vdots & \ddots & \vdots & \vdots \\ \vdots & 0 & 0 & \cdots & 1 & 0 \\ 0 & \cdots & 1 & \cdots & 0 & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \vdots \\ 0 & \cdots & 0 & \cdots & 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} a_1^T \\ \vdots \\ a_i^T \\ \vdots \\ a_j^T \\ \vdots \\ a_n^T \end{pmatrix} = \begin{pmatrix} a_1^T \\ \vdots \\ a_j^T \\ \vdots \\ a_i^T \\ \vdots \\ a_n^T \end{pmatrix}$$

- **Suma de dos filas:** Para sumar una fila i a otra fila j , se puede usar la matriz de eliminación E_i que tiene la forma:

$$E_i = \begin{pmatrix} 1 & \cdots & 0 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 1 & \cdots & 1 \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & \cdots & 1 \end{pmatrix}$$

Donde el elemento en la posición (j, i) es 1, el elemento en la posición (j, j) es 1, y el resto de los elementos son 1 en la diagonal y 0 en el resto de la matriz, y transforma A_{i-1} en A_i sumando la fila i a la fila j :

$$E_i \cdot A_{i-1} = \begin{pmatrix} 1 & 0 & \cdots & 0 & \cdots & 0 \\ 0 & \ddots & \vdots & \ddots & \vdots & \vdots \\ 0 & \cdots & 1 & \cdots & 1 & 0 \\ 0 & \cdots & 0 & \cdots & 1 & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \vdots \\ 0 & \cdots & 0 & \cdots & 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} a_1^T \\ \vdots \\ a_i^T \\ \vdots \\ a_j^T \\ \vdots \\ a_n^T \end{pmatrix} = \begin{pmatrix} a_1^T \\ \vdots \\ a_i^T + a_j^T \\ \vdots \\ a_j^T \\ \vdots \\ a_n^T \end{pmatrix}$$

Tras comprobar esto, veamos como aplicarlo a un sistema lineal, suponiendo que $\det(A) \neq 0$, entonces el sistema tiene una única solución, y podemos aplicar el método de eliminación Gaussiana para resolverlo.

1. Como $\det(A) \neq 0$, entonces $\exists i \in \{1, \dots, n\}$ tal que $a_{i1} \neq 0$, entonces podemos usar la matriz de permutación E_1 para intercambiar la fila i con la fila 1, y obtener una nueva matriz A_1 con un elemento a no nulo en la posición $(1, 1)$:

$$E_1 \cdot A = A_1 = \left(\begin{array}{c|c} a & \beta^T \\ \hline \alpha & A_{n-1} \end{array} \right)$$

2. Despues, multiplicamos la fila 1 por $\frac{1}{a}$ usando la matriz de escala E_2 , y obtenemos una nueva matriz A_2 con un elemento 1 en la posición $(1, 1)$:

$$E_2 \cdot A_1 = A_2 = \left(\begin{array}{c|c} 1 & \frac{\beta^T}{a} \\ \hline \alpha & A_{n-1} \end{array} \right)$$

3. Finalmente, sumamos un múltiplo de la fila 1 a cada una de las filas $2, \dots, n$ según los elementos de α usando las matrices de eliminación $E_{l1}, \dots, E_{ln}$, las cuales componen E_3 , y obtenemos una nueva matriz A_3 con ceros en la primera columna excepto en la posición $(1, 1)$:

$$E_n \cdots E_3 \cdot A_2 = A_n = \left(\begin{array}{c|c} 1 & \frac{\beta^T}{a} \\ \hline 0 & A_{n-1} - \frac{\alpha \cdot \beta^T}{a} \end{array} \right)$$

4. Si ahora denotamos $B_{n-1} = A_{n-1} - \frac{\alpha \cdot \beta^T}{a}$, entonces podemos repetir este proceso con la matriz B_{n-1} , y así sucesivamente hasta obtener una matriz triangular superior T :

$$E_k \cdots E_3 \cdot A_2 = T$$

Tras aplicar estos pasos, obtenemos una matriz triangular superior T y un vector b' tal que el sistema $Tx = b'$ es equivalente al sistema original $Ax = b$. Luego, podemos resolver el sistema triangular superior $Tx = b'$ mediante sustitución hacia atrás para obtener la solución del sistema original.

Teorema 2.1.2 [Descomposición Gaussiana]

Sea $A \in \mathbb{K}^{n \times n}$ arbitraria, entonces $\exists E \in \mathbb{K}^{n \times n}$ con $\det(E) \neq 0$ tal que:

$$E \cdot A = T$$

Donde T es una matriz triangular superior.

Demostración. La demostración es seguir el proceso descrito en el método de eliminación Gaussiana, aplicando operaciones elementales de fila para transformar la matriz A en una matriz triangular superior T , visto en la proposición anterior. □

Observación 2.1.1

Si además $\det(A) = 0$, entonces podemos encontrar T cuya diagonal esté compuesta por 0 y 1.

Demostración. Para ver esto, como $\det(T) = \det(E) \cdot \det(A)$, entonces $\det(T) = 0$, lo que implica que al menos un elemento de la diagonal de T es 0 (recordemos que el determinante de una matriz triangular es el producto de los elementos de su diagonal).

El proceso de eliminación gaussiana seguirá igual hasta llegar a una columna j tal que este compuesta de ceros, en esa situación, pasamos a la siguiente submatriz A_{n-j} , y repetimos el proceso hasta llegar a una matriz triangular superior T cuya diagonal este compuesta por 0 y 1 (los 0 vienen de las columnas compuestas por ceros, y los 1 vienen de las columnas con elementos no nulos en la diagonal, que se convierten en 1 al multiplicar la fila por el inverso del elemento no nulo). □

Teorema 2.1.3 [Factorización LU]

Sea $A \in \mathbb{K}^{n \times n}$, entonces $\exists L \in \mathbb{K}^{n \times n}$ una matriz triangular inferior con 1 en la diagonal, y $\exists U \in \mathbb{K}^{n \times n}$

una matriz triangular superior tal que:

$$A = LU$$

Notese que con esta descomposición:

$$\det(A) = \det(L) \cdot \det(U) = 1 \cdot \prod_{i=1}^n u_{ii} = \prod_{i=1}^n u_{ii}$$

Lo que implica que:

$$\det(A) \neq 0 \iff u_{ii} \neq 0 \forall i = 1, \dots, n$$

$$\iff$$

$$\det(A) = 0 \iff \exists i \in \{1, \dots, n\} : u_{ii} = 0$$

Esta descomposición es muy útil para resolver sistemas lineales, ya que si $A = LU$, entonces el sistema $Ax = b$ se puede transformar en $LUx = b$.

Proposición 2.1.2 [Resolución de sistemas lineales con la factorización LU]

Si $A = LU$, entonces el sistema $Ax = b$ se puede resolver en dos pasos:

1. Descomponemos A en L y U , por lo que:

$$Ax = b \longrightarrow LUx = b$$

2. Denotamos $Ux = w \in \mathbb{K}^n$.

3. Resolvemos aplicando el método de remonte:

$$Lw = b \longrightarrow \exists! w \in \mathbb{K}^n : w = L^{-1}b$$

4. Resolvemos también aplicando el método de remonte:

$$Ux = w \longrightarrow \exists! x \in \mathbb{K}^n : x = U^{-1}w$$

Además, podemos resumir el cálculo de x como:

$$x = U^{-1}L^{-1}b$$

Para ver como hacer la factorización veamos que:

$$A_n = \left(\begin{array}{c|c} a_{11} & \beta^T \\ \hline \alpha & A_{n-1} \end{array} \right) = L_n \cdot U_n = \left(\begin{array}{c|c} 1 & 0 \\ \hline v & L_{n-1} \end{array} \right) \cdot \left(\begin{array}{c|c} u_{11} & w^T \\ \hline 0 & U_{n-1} \end{array} \right) = \left(\begin{array}{c|c} u_{11} & w^T \\ \hline vu_{11} & vw^T + L_{n-1}U_{n-1} \end{array} \right)$$

De lo que deducimos que:

$$u_{11} = a_{11} \quad w^T = \beta^T \quad vu_{11} = \alpha \quad vw^T + L_{n-1}U_{n-1} = A_{n-1}$$

Part II

Ejercicios

Índice de Ejercicios

Hoja 1: Hoja 1	34
Hoja 2: Método de Gauss Jordan	37

Hoja de Ejercicios 1: Hoja 1

Ejercicio 1

Enunciado:

Desarrollo:

Ejercicio 2

Enunciado:

Desarrollo:

Ejercicio 3

Enunciado:

Desarrollo:

Ejercicio 4

Enunciado:

Desarrollo:

Ejercicio 5

Enunciado:

Desarrollo:

Ejercicio 6

Enunciado:

Desarrollo:

Ejercicio 7

Enunciado:

Desarrollo:

Ejercicio 8

Enunciado:

Desarrollo:

Ejercicio 9

Enunciado:

Desarrollo:

Ejercicio 10

Enunciado:

Desarrollo:

Ejercicio 11

Enunciado:

Desarrollo:

Ejercicio 12

Enunciado:

Desarrollo:

Ejercicio 13

Enunciado:

Desarrollo:

Ejercicio 14

Enunciado:

Desarrollo:

Ejercicio 15

Enunciado:

Desarrollo:

Ejercicio 16

Enunciado:

Desarrollo:

Ejercicio 17

Enunciado: Sea $A \in M_n$ una matriz hermítica (resp. simétrica) definida positiva.

- a) Probar que existe $B \in M_n$ hermítica (resp. simétrica) definida positiva tal que $A = B^2$.
- b) Demostrar que si $\text{cond}_2(A) > 1$ entonces $\text{cond}_2(B) < \text{cond}_2(A)$.

Desarrollo: a) Primero podemos aplicar el teorema de Schur para descomponer $A = UTU^*$, donde U es una matriz unitaria (resp. ortogonal) y T es triangular superior. Luego, como A es h.d.p., T debe ser diagonal con entradas positivas. Por lo tanto, podemos definir $\sqrt{D}$ como la matriz diagonal con las raíces cuadradas de las entradas de $D = T$:

$$A = U\sqrt{D}\sqrt{D}U^* = (U\sqrt{D}U^*)^2 = B^2$$

Por tanto, $B = U\sqrt{D}U^*$ es la matriz que buscamos, y es hermítica (resp. simétrica) y definida positiva, ya que $\sqrt{D}$ es diagonal con entradas positivas y U es unitaria (resp. ortogonal).

b) Ahora, como U es unitaria (resp. ortogonal) y $\sqrt{D}$ es diagonal con entradas positivas, B también es hermítica (resp. simétrica) y definida positiva, y además:

$$\text{cond}_2(B) = \|B\|_2 \|B^{-1}\|_2 = \|U\sqrt{D}U^*\|_2 \|(U\sqrt{D}U^*)^{-1}\|_2 = \|\sqrt{D}\|_2 \|\sqrt{D}^{-1}\|_2 = \sqrt{\text{cond}_2(A)}$$

Otra forma es darse cuenta de que:

$$\|A\|_2^2 = \rho(A^*A) = \rho(A^2) = \rho^2(A) = \lambda_{\max}^2(A)$$

Y la de su inversa:

$$\|A^{-1}\|_2^2 = \rho((A^{-1})^*A^{-1}) = \rho((A^{-1})^2) = \rho^2(A^{-1}) = \lambda_{\max}^2(A^{-1}) = \lambda_{\min}^{-2}(A)$$

Y por tanto su condición es:

$$\text{cond}_2(A) = \|A\|_2 \|A^{-1}\|_2 = \frac{\lambda_{\max}(A)}{\lambda_{\min}(A)}$$

Análogamente para B , su condición es:

$$\text{cond}_2(B) = \|B\|_2 \|B^{-1}\|_2 = \frac{\lambda_{\max}(B)}{\lambda_{\min}(B)} = \frac{\sqrt{\lambda_{\max}(A)}}{\sqrt{\lambda_{\min}(A)}} = \sqrt{\text{cond}_2(A)}$$

Por tanto, si $\text{cond}_2(A) > 1$ entonces $\text{cond}_2(B) < \text{cond}_2(A)$, ya que:

$$\sqrt{\text{cond}_2(A)} < \text{cond}_2(A) \iff \text{cond}_2(A) > 1$$

Hoja de Ejercicios 2: Método de Gauss Jordan

Ejercicio 1

Enunciado: Sea $A \in M_n$ una matriz invertible.

- Adaptar el método de Gauss Jordan para calcular $\widetilde{M}$ que cumpla que $\widetilde{M}A = I$.
- Usando el apartado anterior, explicar como calcular A^{-1} con el método de Gauss Jordan.

Desarrollo: Veamos ambas partes por separado:

- Primero, según el método de Gauss Jordan, podemos realizar operaciones elementales sobre las filas de A para llevarla a la forma escalonada reducida, es decir, encontrar matrices E y T (triangular superior) tal que $EA = T$. Luego, podemos aplicar operaciones elementales sobre las filas de T para llevarla a la forma identidad, es decir, encontrar matrices R y I tal que $RT = I$. Combinando ambas partes, tenemos que $R(EA) = I$, lo que implica que $\widetilde{M} = RE$ cumple la condición $\widetilde{M}A = I$.

Para el cálculo de R , podremos ir descomponiéndola como el producto de n matrices elementales, cada una de las cuales corresponde a una operación elemental sobre las filas de T , y de manera análoga al método de Gauss, vamos a ir aplicando estas operaciones sobre la última columna de T , dejando una submatriz con la que repetir el proceso:

$$R_1 \underbrace{T_0}_{=T} = \left(\begin{array}{c|c} I & -\beta \\ \hline 0 & 1 \end{array} \right) \left(\begin{array}{c|c} T_1 & \beta \\ \hline 0 & 1 \end{array} \right) = \left(\begin{array}{c|c} T_1 & 0 \\ \hline 0 & 1 \end{array} \right)$$

Y podemos repetir el proceso con T_1 y así sucesivamente hasta llegar a la forma identidad, obteniendo R como el producto de las matrices elementales correspondientes a cada operación elemental sobre las filas de T .

- Para calcular A^{-1} con el método de Gauss Jordan, podemos aplicar el método de Gauss Jordan a la matriz, primero escogiendo un número distinto de cero en cada columna, de la forma α_{ij} donde $i \geq j$, que debe existir al ser A invertible, y luego eliminando los elementos de esa columna, y así sucesivamente hasta llegar a la forma identidad. Veamos una iteración del proceso:

$$\left(\begin{array}{c|c|c} I & \alpha_1 & \beta_1 \\ \hline 0 & 1 & \beta_2 \\ \hline 0 & \alpha_2 & \beta_3 \end{array} \right) \xrightarrow{R_i} \left(\begin{array}{c|c|c} I & 0 & \beta'_1 \\ \hline 0 & 1 & \beta'_2 \\ \hline 0 & 0 & \beta'_3 \end{array} \right)$$

Notese que si realizamos este proceso sobre la matriz aumentada $[A|I]$, al llegar a la forma identidad en la parte izquierda, la parte derecha de la matriz aumentada se habrá transformado en A^{-1} , es decir, $[I|A^{-1}]$.

Esto es debido a que las operaciones elementales sobre las filas de A se corresponden con multiplicar A por matrices elementales, y estas mismas operaciones aplicadas a la parte derecha de la matriz aumentada se corresponden con multiplicar I por las mismas matrices elementales, lo que da como resultado A^{-1} al llegar a la forma identidad en la parte izquierda, ya que al haber multiplicado A por las matrices elementales correspondientes a cada operación elemental sobre las filas de A , se habrá obtenido la forma identidad, lo que implica que I se habrá multiplicado por las mismas matrices elementales, dando como resultado $A^{-1} = R_n \cdots R_1 EA = R_n \cdots R_1 E = \widetilde{M}$.

En resumen, para calcular A^{-1} con el método de Gauss Jordan, podemos aplicar el método de Gauss Jordan a la matriz aumentada $[A|I]$, realizando operaciones elementales sobre las filas de A para llevarla a la forma identidad, y aplicando las mismas operaciones elementales sobre las filas de I para obtener A^{-1} en la parte derecha de la matriz aumentada.

Ejercicio 2

Enunciado:

Desarrollo:

Ejercicio 3

Enunciado:

Desarrollo:

Ejercicio 4

Enunciado:

Desarrollo:

Ejercicio 5

Enunciado:

Desarrollo:

Ejercicio 6

Enunciado:

Desarrollo:

Ejercicio 7

Enunciado:

Desarrollo:

Ejercicio 8

Enunciado:

Desarrollo:

Ejercicio 9

Enunciado:

Desarrollo:

Ejercicio 10

Enunciado:

Desarrollo:

Ejercicio 11

Enunciado:

Desarrollo:

Ejercicio 12

Enunciado:

Desarrollo:

Ejercicio 13

Enunciado:

Desarrollo:

Ejercicio 14

Enunciado:

Desarrollo:

Ejercicio 15

Enunciado:

Desarrollo:

Ejercicio 16

Enunciado:

Desarrollo:

Ejercicio 17

Enunciado:

Desarrollo:

Part III

Exámenes

Índice de Exámenes

Examen 1: Primer examen	42
-----------------------------------	----

Examen 1: Primer examen

Part IV

Apéndice

Índice de Apéndice

Apéndice A: Normas comunes	44
Apéndice B: Agradecimientos	46
B.1 Varios compañeros	46

Apéndice A: Normas comunes

Definición A.0.1 [Norma euclídea de un vector]

Dado un vector $x \in \mathbb{R}^n$, su norma euclídea se define como

$$\|x\|_2 = \sqrt{x_1^2 + x_2^2 + \cdots + x_n^2}.$$

Definición A.0.2 [Norma 1 de un vector]

Dado un vector $x \in \mathbb{R}^n$, su norma 1 se define como

$$\|x\|_1 = \sum_{i=1}^n |x_i|.$$

Definición A.0.3 [Norma infinito de un vector]

Dado un vector $x \in \mathbb{R}^n$, su norma infinito se define como

$$\|x\|_\infty = \max_{1 \leq i \leq n} |x_i|.$$

Definición A.0.4 [Norma p de un vector]

Dado un vector $x \in \mathbb{R}^n$ y $p \geq 1$, su norma p se define como

$$\|x\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}.$$

Definición A.0.5 [Norma 1 de una matriz]

Dada una matriz $A \in \mathbb{R}^{m \times n}$, su norma 1 se define como

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|.$$

Es decir, el máximo de las sumas absolutas de las columnas.

Definición A.0.6 [Norma infinito de una matriz]

Dada una matriz $A \in \mathbb{R}^{m \times n}$, su norma infinito se define como

$$\|A\|_{\infty} = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|.$$

Es decir, el máximo de las sumas absolutas de las filas.

Definición A.0.7 [Norma de Frobenius]

Dada una matriz $A \in \mathbb{R}^{m \times n}$, su norma de Frobenius se define como

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2}.$$

Definición A.0.8 [Norma 2 o espectral de una matriz]

Dada una matriz $A \in \mathbb{R}^{m \times n}$, su norma 2 (o espectral) se define como

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)},$$

donde $\lambda_{\max}(A^T A)$ es el mayor valor propio de $A^T A$. Equivalentemente, es el mayor valor singular de A .

Definición A.0.9 [Norma p subordinada de una matriz]

Dada una matriz $A \in \mathbb{R}^{m \times n}$ y una norma vectorial $\|\cdot\|_p$, la norma p subordinada de A se define como

$$\|A\|_p = \sup_{\|x\|_p=1} \|Ax\|_p.$$

Apéndice B: Agradecimientos

Queremos expresar nuestro más sincero agradecimiento a todas las personas que han hecho posible la realización de este trabajo.

B.1 Varios compañeros

Por su inestimable ayuda en la revisión del contenido teórico y por sus valiosas sugerencias que han enriquecido significativamente este trabajo, queremos agradecer a los siguientes compañeros:

- Daniel Pozo Ranchal
- Alba Cervantes Menéndez
- Teresa Marín Marín
- Marta Simó Álvarez
- Jesus Sancho Hagen
- Jorge San Pedro Solanas

This work is licensed under a Creative Commons “Attribution-NonCommercial-NoDerivs 3.0 Unported” license.

