



UNIVERSIDAD
COMPLUTENSE
MADRID

Métodos Numéricos ¹

CIENCIAS MATEMÁTICAS E INGENIERÍA INFORMÁTICA

Autores:

Pau Frangi Mahiques, Diego Rodríguez Cubero y Jaime Nieto
Petinal

Primer Cuatrimestre 2025-2026

¹Basado en las clases del profesor Valeri Makarov

Introducción

Estos apuntes han sido elaborados por Pau Frangi Mahiques, Diego Rodríguez Cubero y Jaime Nieto Petinal, estudiantes de 3.º del Doble Grado en Matemáticas e Ingeniería Informática, con el objetivo de ofrecer un material claro, cohesionado y útil para el estudio de la asignatura de Métodos Numéricos.

El contenido está basado en las clases del profesor Valeri Makarov, a quien agradecemos su dedicación y claridad expositiva.

El documento está organizado para acompañar el progreso del curso. En la parte teórica se estudian las matrices y sus propiedades, la resolución de sistemas lineales, los métodos iterativos, la interpolación polinómica, la diferenciación numérica, la integración numérica y la resolución de ecuaciones no lineales. Se incluyen asimismo ejercicios seleccionados y exámenes resueltos, junto con material gráfico y esquemas realizados con TikZ para apoyar la intuición geométrica y numérica.

Nuestro propósito es doble: por un lado, facilitar la preparación continuada de la asignatura mediante una exposición sistemática, con resultados claramente enunciados y, cuando procede, demostraciones o esbozos de demostración; por otro, servir como referencia rápida para técnicas de cálculo habituales. Aunque hemos procurado la máxima precisión, este material puede contener erratas u omisiones.

Invitamos encarecidamente a los estudiantes que cursen la asignatura en el futuro a ampliar, mejorar o complementar estos apuntes. Cualquier corrección, propuesta o contribución será bienvenida. Para ello, pueden:

- Ponerse en contacto con nosotros mediante nuestros perfiles de GitHub, enlazados en la portada y en el pie de página.
- Mandarnos un correo electrónico a:
 - Diego Rodríguez Cubero: diegorocux3x@gmail.com.
 - Pau Frangi Mahiques: pau.frangi@gmail.com.
 - Jaime Nieto Petinal: jaimenietopetinal1@gmail.com.
- Abrir una incidencia (*issue*) o enviar una contribución (*pull request*) en el repositorio del proyecto.

Estos apuntes reflejan la materia cursada y quedan finalizados conforme al curso ya completado. A partir de aquí, invitamos a futuros alumnos a proponer mejoras, correcciones o ampliaciones; las contribuciones serán valoradas y, en su caso, incorporadas en ediciones posteriores. Agradecemos de antemano toda colaboración que ayude a hacerlos más claros, completos y útiles para la comunidad, ya sea puliendo detalles, corrigiendo erratas o añadiendo contenido relevante, como teoría, ejemplos, ejercicios, exámenes resueltos o material gráfico.

Índice General

Índice General	2
I Teoría	4
1 Matrices y sus propiedades	6
1.1 Tipos de matrices	6
1.2 Autovalores y autovectores	15
1.3 Teoremas importantes	17
1.4 Matrices hermiticas definidas positivas	21
1.5 Normas matriciales	22
1.6 Normas subordinadas	23
1.7 Potencias de matrices	26
1.8 Condicionamiento de matrices	27
2 Resolución de sistemas lineales	29
2.1 Introducción a los sistemas lineales	29
2.2 Factorización LU	33
2.3 Factorización de Cholesky	37
3 Métodos iterativos para resolver sistemas lineales	39
3.1 Motivación	39
3.2 Convergencia de métodos iterativos	39
3.3 Método de Jacobi y método de Gauss-Seidel	40
3.4 Métodos de relajación	44
4 Interpolación polinómica	48
4.1 Motivación e Introducción	48
4.2 Planteamiento formal del problema	48
4.3 Existencia y unicidad: El determinante de Vandermonde	50
4.4 Polinomios de Lagrange	50
4.5 Error de interpolación	51
4.6 Método de Newton	53
4.6.1 Diferencias divididas	54
4.6.2 Construcción del Polinomio de Newton	55
4.7 Splines	57
4.7.1 Construcción del Spline Cúbico Natural	59
5 Diferenciación Numérica	62
5.1 Motivación e Introducción	62
5.2 Aproximación por interpolación polinómica	62
5.3 Aproximación mediante Desarrollos de Taylor	63
5.4 Diferencias Centradas y Derivadas de Orden Superior	64
6 Integración Numérica	66
6.1 Motivación e Introducción	66
6.2 Aproximación mediante Interpolación (Fórmulas de Newton-Cotes)	66
6.3 Regla del Punto Medio (Rectángulo Centrado)	67
6.3.1 Construcción de la fórmula aproximada	67
6.3.2 Deducción del término del error	68
6.3.3 Integración y Error Final	69

6.4	Regla del Trapecio	70
6.4.1	Deducción analítica de la fórmula	70
6.4.2	Análisis del error de truncamiento	71
6.4.3	Comparación conceptual	71
6.5	Regla de Simpson	72
6.5.1	Deducción analítica de los pesos de cuadratura	72
6.5.2	El milagro de la simetría: Análisis del error	73
6.6	Tabla Resumen de Fórmulas Simples	73
6.7	Fórmulas Compuestas de Integración	73
6.7.1	Regla del Trapecio Compuesta	74
6.7.2	Regla de Simpson Compuesta	75
6.7.3	Fórmula de los trapecios compuesta (cerrada)	75
6.7.4	Fórmula de Simpson compuesta (cerrada)	76
6.7.5	Comparación de ratios de error	76
6.8	Tabla resumen	77
7	Resolución de ecuaciones no lineales	78
7.1	Motivación	78
7.2	Raíces aisladas	78
7.3	Separación de raíces	78
7.4	Raíces de polinomios	80
7.5	Métodos numéricos	82
7.6	Métodos del punto fijo	83
7.6.1	Teorema de Banach	84
7.6.2	Criterios de parada	85
7.6.3	Salvar el método	85
7.7	Método de Newton	87
II	Ejercicios	90
	Hoja 1: Resolución de ecuaciones no lineales	91
III	Exámenes	98
	Examen 1: Final (20 de diciembre de 2022)	99
IV	Apéndice	104
	Apéndice A: Normas comunes	105
	Apéndice B: Agradecimientos	107
	B.1 Varios compañeros	107

Part I

Teoría

Índice de Teoría

1	Matrices y sus propiedades	6
1.1	Tipos de matrices	6
1.2	Autovalores y autovectores	15
1.3	Teoremas importantes	17
1.4	Matrices hermiticas definidas positivas	21
1.5	Normas matriciales	22
1.6	Normas subordinadas	23
1.7	Potencias de matrices	26
1.8	Condicionamiento de matrices	27
2	Resolución de sistemas lineales	29
2.1	Introducción a los sistemas lineales	29
2.2	Factorización LU	33
2.3	Factorización de Cholesky	37
3	Métodos iterativos para resolver sistemas lineales	39
3.1	Motivación	39
3.2	Convergencia de métodos iterativos	39
3.3	Método de Jacobi y método de Gauss-Seidel	40
3.4	Métodos de relajación	44
4	Interpolación polinómica	48
4.1	Motivación e Introducción	48
4.2	Planteamiento formal del problema	48
4.3	Existencia y unicidad: El determinante de Vandermonde	50
4.4	Polinomios de Lagrange	50
4.5	Error de interpolación	51
4.6	Método de Newton	53
4.7	Splines	57
5	Diferenciación Numérica	62
5.1	Motivación e Introducción	62
5.2	Aproximación por interpolación polinómica	62
5.3	Aproximación mediante Desarrollos de Taylor	63

5.4	Diferencias Centradas y Derivadas de Orden Superior	64
6	Integración Numérica	66
6.1	Motivación e Introducción	66
6.2	Aproximación mediante Interpolación (Fórmulas de Newton-Cotes)	66
6.3	Regla del Punto Medio (Rectángulo Centrado)	67
6.4	Regla del Trapecio	70
6.5	Regla de Simpson	72
6.6	Tabla Resumen de Fórmulas Simples	73
6.7	Fórmulas Compuestas de Integración	73
6.8	Tabla resumen	77
7	Resolución de ecuaciones no lineales	78
7.1	Motivación	78
7.2	Raíces aisladas	78
7.3	Separación de raíces	78
7.4	Raíces de polinomios	80
7.5	Métodos numéricos	82
7.6	Métodos del punto fijo	83
7.7	Método de Newton	87

1 Matrices y sus propiedades

1.1 Tipos de matrices

Veamos algunos tipos de matrices que nos encontraremos a lo largo del curso:

Definición 1.1.1 [Matrices introductorias]

- **Matriz fila:** Una matriz que tiene una sola fila. Por ejemplo, la matriz $A = [a_1, a_2, a_3]$ es una matriz fila de tamaño 1×3 .
- **Matriz columna:** Una matriz que tiene una sola columna. Por ejemplo, la matriz $B = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix}$ es una matriz columna de tamaño 3×1 .
- **Matriz cuadrada:** Una matriz que tiene el mismo número de filas y columnas. Por ejemplo, la matriz $C = \begin{bmatrix} c_{11} & c_{12} \\ c_{21} & c_{22} \end{bmatrix}$ es una matriz cuadrada de tamaño 2×2 .
- **Matriz diagonal:** Una matriz cuadrada en la que todos los elementos fuera de la diagonal principal son cero. Por ejemplo, la matriz $D = \begin{bmatrix} d_{11} & 0 \\ 0 & d_{22} \end{bmatrix}$ es una matriz diagonal.
- **Matriz identidad:** Una matriz diagonal en la que todos los elementos de la diagonal principal son uno. Por ejemplo, la matriz $I = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$ es una matriz identidad de tamaño 2×2 .
- **Matriz nula:** Una matriz en la que todos los elementos son cero. Por ejemplo, la matriz $O = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}$ es una matriz nula de tamaño 2×2 .
- **Matriz transpuesta:** La matriz obtenida al intercambiar las filas por las columnas de una matriz dada. Si A es una matriz de tamaño $m \times n$, su transpuesta A^T será de tamaño $n \times m$. Por ejemplo, si $A = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}$, entonces su transpuesta es $A^T = \begin{bmatrix} a_{11} & a_{21} \\ a_{12} & a_{22} \end{bmatrix}$.
- **Matriz simétrica:** Una matriz cuadrada que es igual a su transpuesta. Es decir, $A = A^T$. Por ejemplo, la matriz $S = \begin{bmatrix} s_{11} & s_{12} \\ s_{12} & s_{22} \end{bmatrix}$ es simétrica.
- **Matriz antisimétrica:** Una matriz cuadrada que es igual a la negativa de su transpuesta. Es decir, $A = -A^T$. Por ejemplo, la matriz $T = \begin{bmatrix} 0 & t_{12} \\ -t_{12} & 0 \end{bmatrix}$ es antisimétrica.
- **Matriz triangular:** Una matriz cuadrada que tiene todos los elementos por encima (o por debajo) de la diagonal principal iguales a cero. Si los elementos por debajo de la diagonal son cero, se llama matriz triangular superior; si los elementos por encima son cero, se llama matriz triangular inferior. Por ejemplo, la matriz $U = \begin{bmatrix} u_{11} & u_{12} \\ 0 & u_{22} \end{bmatrix}$ es triangular superior.
- **Matriz ortogonal:** Una matriz cuadrada Q es ortogonal si su transpuesta es igual a su inversa, es decir, $Q^T = Q^{-1}$. Esto implica que $QQ^T = Q^TQ = I$, donde I es la matriz identidad. Tam-

bien se caracteriza porque sus columnas (y filas) forman un conjunto ortonormal en el espacio euclídeo. Por ejemplo, la matriz $Q = \begin{bmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$ es ortogonal.

- **Traspuesto conjugado:** Denotado como A^* , es la matriz obtenida al tomar la traspuesta de una matriz y luego tomar el conjugado complejo de cada uno de sus elementos. Por ejemplo, si $A = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}$, entonces su traspuesto conjugado es $A^* = \begin{bmatrix} \overline{a_{11}} & \overline{a_{21}} \\ \overline{a_{12}} & \overline{a_{22}} \end{bmatrix}$, donde $\overline{a_{ij}}$ denota el conjugado complejo de a_{ij} .
- **Matriz definida positiva/negativa:** Una matriz cuadrada A es definida positiva si para cualquier vector no nulo x , se cumple que $x^T A x > 0$. De manera similar, A es definida negativa si para cualquier vector no nulo x , se cumple que $x^T A x < 0$.
- **Matriz semidefinida positiva/negativa:** Una matriz cuadrada A es semidefinida positiva si para cualquier vector x , se cumple que $x^T A x \geq 0$. De manera similar, A es semidefinida negativa si para cualquier vector x , se cumple que $x^T A x \leq 0$.
- **Matriz indefinida:** Una matriz cuadrada A es indefinida si existen vectores x y y tales que $x^T A x > 0$ y $y^T A y < 0$.

Ahora definamos algunos tipos de matrices más avanzados:

Definición 1.1.2 [Matriz hermitiana]

Una matriz cuadrada A es hermitiana si es igual a su traspuesto conjugado, es decir, $A = A^*$. En el caso de matrices con entradas reales, una matriz hermitiana es simplemente una matriz simétrica, es decir:

$$A \in \mathbb{R}^{n \times n} \text{ es hermitiana} \iff A = A^T$$

Veamos un par de ejemplos de matrices hermitianas:

Ejemplo

- La matriz $A = \begin{bmatrix} 2 & 3+i \\ 3-i & 4 \end{bmatrix}$ es hermitiana, ya que su traspuesto conjugado es $A^* = \begin{bmatrix} 2 & 3-i \\ 3+i & 4 \end{bmatrix}$, que es igual a A .
- La matriz $B = \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}$ es hermitiana, ya que su traspuesto conjugado es $B^* = \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}$, que es igual a B .

Definición 1.1.3 [Matriz unitaria]

Una matriz cuadrada U es unitaria si su traspuesto conjugado es igual a su inversa, es decir, $U^* = U^{-1}$. Esto implica que $UU^* = U^*U = I$, donde I es la matriz identidad.

Veamos un par de ejemplos de matrices unitarias:

Ejemplo

- La matriz $U = \begin{bmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$ es unitaria, ya que su traspuesto conjugado es $U^* = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$, y se cumple que $UU^* = I$.
- La matriz $V = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$ es unitaria, ya que su traspuesto conjugado es $V^* = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$, y se cumple que $VV^* = I$.

Observación 1.1.1

Se puede apreciar que si U es una matriz unitaria compleja:

$$U^* = U^{-1} \implies U^*U = I \implies U^*U = \begin{pmatrix} u_1^* \\ \vdots \\ u_n^* \end{pmatrix} (u_1 \quad \dots \quad u_n) = \begin{pmatrix} u_1^*u_1 & \dots & u_1^*u_n \\ \vdots & \ddots & \vdots \\ u_n^*u_1 & \dots & u_n^*u_n \end{pmatrix} = \begin{pmatrix} 1 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & 1 \end{pmatrix}$$

De lo cual se deduce que los vectores columna de U forman un conjunto ortonormal en el espacio complejo, es decir, $u_i^*u_j = \delta_{ij}$, ya que el producto $u_i^*u_j$ representa el producto interno entre los vectores u_i y u_j en el espacio complejo, y hemos visto que $u_i^*u_j = 0$ si $i \neq j$ y $u_i^*u_i = \|u_i\|^2 = 1$.

Definición 1.1.4 [Matriz normal]

Una matriz cuadrada A es normal si conmuta con su traspuesto conjugado, es decir, si se cumple que $AA^* = A^*A$.

Veamos un par de ejemplos de matrices normales:

Ejemplo

- La matriz $A = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}$ es normal, ya que su traspuesto conjugado es $A^* = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}$, y se cumple que $AA^* = A^*A = \begin{bmatrix} 4 & 0 \\ 0 & 9 \end{bmatrix}$.
- La matriz $B = \begin{bmatrix} 1 & i \\ -i & 1 \end{bmatrix}$ es normal, ya que su traspuesto conjugado es $B^* = \begin{bmatrix} 1 & i \\ -i & 1 \end{bmatrix}$, y se cumple que $BB^* = B^*B = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$.

Observación 1.1.2

Notese que si A es hermitiana, entonces $A = A^*$, por lo que:

$$AA^* = AA = A^2 = A^*A$$

Por lo tanto, toda matriz hermitiana es normal.

Algo similar ocurre con las matrices unitarias, ya que si U es unitaria, entonces $U^* = U^{-1}$, por lo

que:

$$UU^* = UU^{-1} = I = U^{-1}U = U^*U$$

Por lo tanto, toda matriz unitaria es normal.

Proposición 1.1.1 [Producto de matrices triangulares]

Sean $A, B \in \mathbb{C}^{n \times n}$ dos matrices triangulares inferiores (superiores). Entonces, el producto $C = AB$ es también una matriz triangular inferior (superior).

Demostración. Podemos aplicar una inducción sencilla sobre el tamaño de las matrices.

Caso base: Para $n = 1$, las matrices son simplemente escalares, y el producto de dos escalares es un escalar, que puede considerarse como una matriz triangular inferior (superior) trivialmente.

Paso inductivo: Supongamos que la proposición es cierta para matrices de tamaño $(n-1) \times (n-1)$. Consideremos dos matrices triangulares inferiores $A, B \in \mathbb{C}^{n \times n}$:

$$A = \begin{array}{c|c} a_{11} & 0 \\ \hline \alpha & A_{(n-1)} \end{array}, \quad B = \begin{array}{c|c} b_{11} & 0 \\ \hline \beta & B_{(n-1)} \end{array}$$

Y su producto:

$$C = AB = \begin{array}{c|c} a_{11}b_{11} & 0 \\ \hline \alpha b_{11} + A_{(n-1)}\beta & A_{(n-1)}B_{(n-1)} \end{array}$$

Por la hipótesis inductiva, $A_{(n-1)}B_{(n-1)}$ es una matriz triangular inferior de tamaño $(n-1) \times (n-1)$. Además, el elemento en la posición $(n, 1)$ de C es $\alpha b_{11} + A_{(n-1)}\beta$, que es un vector columna. Por lo tanto, todos los elementos por encima de la diagonal principal de C son cero, lo que demuestra que C es una matriz triangular inferior.

Por lo tanto, por el principio de inducción matemática, la proposición es cierta para todas las matrices triangulares inferiores (superiores) de tamaño $n \times n$. $\square$

Definición 1.1.5 [Matriz banda]

Se define una matriz banda como una matriz cuadrada en la que los elementos no nulos se encuentran dentro de una franja diagonal alrededor de la diagonal principal. Esta franja está determinada por dos enteros no negativos k_1 y k_2 , que representan el número de subdiagonales y superdiagonales, respectivamente. Formalmente, una matriz $A \in \mathbb{R}^{n \times n}$ es una matriz banda si:

$$a_{ij} = 0 \quad \text{si } |i - j| > k$$

donde $k = \max(k_1, k_2)$.

Veamos un par de ejemplos de matrices banda:

Ejemplo

- Una matriz tridiagonal es una matriz banda con $k_1 = k_2 = 1$. Por ejemplo, la matriz $A =$

$$\begin{bmatrix} a_{11} & a_{12} & 0 & 0 \\ a_{21} & a_{22} & a_{23} & 0 \\ 0 & a_{32} & a_{33} & a_{34} \\ 0 & 0 & a_{43} & a_{44} \end{bmatrix} \text{ es tridiagonal.}$$

- Una matriz pentadiagonal es una matriz banda con $k_1 = k_2 = 2$. Por ejemplo, la matriz

$$B = \begin{bmatrix} b_{11} & b_{12} & b_{13} & 0 & 0 \\ b_{21} & b_{22} & b_{23} & b_{24} & 0 \\ b_{31} & b_{32} & b_{33} & b_{34} & b_{35} \\ 0 & b_{42} & b_{43} & b_{44} & b_{45} \\ 0 & 0 & b_{53} & b_{54} & b_{55} \end{bmatrix} \text{ es pentadiagonal.}$$

Definición 1.1.6 [Matriz de diagonal estrictamente dominante]

Una matriz cuadrada $A = [a_{ij}] \in \mathbb{R}^{n \times n}$ se dice que es de diagonal estrictamente dominante si para cada fila i se cumple que:

$$|a_{ii}| > \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}|$$

Es decir, el valor absoluto del elemento en la diagonal principal de cada fila es mayor que la suma de los valores absolutos de los demás elementos en esa fila.

Veamos un par de ejemplos de matrices de diagonal estrictamente dominante:

Ejemplo

- La matriz $A = \begin{bmatrix} 4 & 1 & 2 \\ 3 & 5 & 1 \\ 1 & 1 & 6 \end{bmatrix}$ es de diagonal estrictamente dominante, ya que:

$$|4| > |1| + |2|, \quad |5| > |3| + |1|, \quad |6| > |1| + |1|$$

- La matriz $B = \begin{bmatrix} 10 & 2 & 1 \\ 1 & 8 & 2 \\ 2 & 1 & 9 \end{bmatrix}$ es de diagonal estrictamente dominante, ya que:

$$|10| > |2| + |1|, \quad |8| > |1| + |2|, \quad |9| > |2| + |1|$$

Definición 1.1.7 [Traza de una matriz]

La traza de una matriz cuadrada $A = [a_{ij}] \in \mathbb{R}^{n \times n}$ se define como la suma de los elementos en la diagonal principal de la matriz. Matemáticamente, se expresa como:

$$\text{tr}(A) = \sum_{i=1}^n a_{ii}$$

donde a_{ii} son los elementos en la diagonal principal de la matriz A .

Veamos un par de ejemplos de cálculo de la traza de una matriz:

Ejemplo

- Para la matriz $A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}$, la traza es:

$$\text{tr}(A) = 1 + 5 + 9 = 15$$

- Para la matriz $B = \begin{bmatrix} 2 & 0 & 1 \\ 0 & 3 & 4 \\ 5 & 6 & 7 \end{bmatrix}$, la traza es:

$$\text{tr}(B) = 2 + 3 + 7 = 12$$

Proposición 1.1.2 [Propiedades de la traza]

Veamos algunas propiedades importantes de la traza de una matriz:

- **Linealidad:** La traza es una función lineal, es decir, para dos matrices cuadradas A y B del mismo tamaño y un escalar c , se cumple que:

$$\text{tr}(A + B) = \text{tr}(A) + \text{tr}(B)$$

$$\text{tr}(cA) = c \cdot \text{tr}(A)$$

- **Invarianza bajo trasposición:** La traza de una matriz es igual a la traza de su transpuesta:

$$\text{tr}(A) = \text{tr}(A^T)$$

- **Invarianza bajo conjugación:** La traza de una matriz es igual a la traza de su traspuesto conjugado:

$$\text{tr}(A) = \text{tr}(A^*)$$

- **Cyclicidad:** La traza del producto de dos matrices es invariante bajo el cambio de orden:

$$\text{tr}(AB) = \text{tr}(BA)$$

Las propiedades anteriores se prueban directamente a partir de la definición de traza y las propiedades básicas de las operaciones matriciales, veamos solo la ultima:

$$C = AB \implies c_{ii} = \sum_{k=1}^n a_{ik} b_{ki} \implies \text{tr}(C) = \sum_{i=1}^n c_{ii} = \sum_{i=1}^n \sum_{k=1}^n a_{ik} b_{ki}$$

$$D = BA \implies d_{ii} = \sum_{k=1}^n b_{ik} a_{ki} \implies \text{tr}(D) = \sum_{i=1}^n d_{ii} = \sum_{i=1}^n \sum_{k=1}^n b_{ik} a_{ki}$$

Cambiando el orden de las sumas en ambos casos, se llega a la igualdad:

$$\text{tr}(C) = \text{tr}(D)$$

Definición 1.1.8 [Rango de una matriz]

El rango de una matriz $A \in \mathbb{R}^{m \times n}$ es el número máximo de columnas linealmente independientes que tiene la matriz. Se denota como $\text{rg}(A)$. El rango también puede ser interpretado como la dimensión del espacio generado por las columnas de la matriz, o como el número de filas no nulas en la forma escalonada reducida por filas de la matriz.

Observación 1.1.3

Notese que el rango de una matriz A es igual al rango de su transpuesta A^T , es decir, $\text{rg}(A) = \text{rg}(A^T)$. Esto se debe a que el número de columnas linealmente independientes en A es igual al número de filas linealmente independientes en A^T , ya que las filas de A^T corresponden a las columnas de A .

Definición 1.1.9 [Determinante]

El determinante de una matriz cuadrada $A \in \mathbb{R}^{n \times n}$ es un valor escalar que se asocia a la matriz y que proporciona información sobre ciertas propiedades de la misma, como su invertibilidad y el volumen de transformación lineal que representa. El determinante se denota como $\det(A)$ o $|A|$, y se calcula como:

$$\det(A) = \sum_{\sigma \in S_n} \text{sgn}(\sigma) \prod_{i=1}^n a_{i,\sigma(i)}$$

donde S_n es el conjunto de todas las permutaciones de los números $1, 2, \dots, n$, y $\text{sgn}(\sigma)$ es el signo de la permutación σ .

Proposición 1.1.3 [Propiedades del determinante]

Veamos algunas propiedades importantes del determinante de una matriz:

- **Multiplicatividad:** El determinante del producto de dos matrices es igual al producto de sus determinantes:

$$\det(AB) = \det(A) \cdot \det(B)$$

- **Determinante de matrices diagonales:** El determinante de una matriz diagonal es igual al producto de los elementos en la diagonal principal:

$$\det(D) = \prod_{i=1}^n d_{ii}$$

- **Transposición:** El determinante de una matriz es igual al determinante de su transpuesta:

$$\det(A) = \det(A^T)$$

- **Escalar:** Si c es un escalar y A es una matriz cuadrada de tamaño $n \times n$, entonces:

$$\det(cA) = c^n \cdot \det(A)$$

- **Inversión:** Si A es una matriz invertible, entonces:

$$\det(A^{-1}) = \frac{1}{\det(A)}$$

Todas estas propiedades se pueden demostrar utilizando la definición del determinante y las propiedades básicas de las operaciones matriciales.

Proposición 1.1.4 [Determinante de una matriz unitaria]

Sea $U \in \mathbb{C}^{n \times n}$ una matriz unitaria. Entonces, el valor absoluto de su determinante es igual a 1, es decir:

$$|\det(U)| = 1$$

Demostración. Sea U una matriz unitaria, por definición, se cumple que $U^* = U^{-1}$. Aplicando la propiedad de multiplicatividad del determinante, tenemos:

$$UU^* = I \implies \det(UU^*) = \det(I) = 1 \implies \det(U) \cdot \det(U^*) = \det(U) \cdot \overline{\det(U)} = |\det(U)|^2 = 1$$

De donde se deduce que:

$$|\det(U)| = 1$$

□

Teorema 1.1.1 [Caracterización de las matrices invertibles]

Sea $A \in \mathbb{R}^{n \times n}$ una matriz cuadrada. Entonces, las siguientes afirmaciones son equivalentes:

1. A es invertible, es decir $\exists A^{-1}$ tal que $AA^{-1} = A^{-1}A = I$.
2. El determinante de A es diferente de cero, es decir, $\det(A) \neq 0$.
3. El espectro de A no contiene el valor cero, es decir, $0 \notin \sigma(A)$.

Demostración. Veamos las implicaciones:

2) $\iff$ 3) Sabemos que el espectro de una matriz A está dado por los valores propios de la matriz, que son las soluciones de la ecuación característica $\det(A - \lambda I) = 0$. Si $0 \in \sigma(A)$, entonces existe un valor propio $\lambda = 0$ tal que $\det(A - 0 \cdot I) = \det(A) = 0$. Por lo tanto, si $\det(A) \neq 0$, entonces $0 \notin \sigma(A)$, y viceversa.

1) $\implies$ 2) Si A es invertible, entonces existe una matriz A^{-1} tal que $AA^{-1} = I$. Aplicando la propiedad de multiplicatividad del determinante, tenemos:

$$\det(AA^{-1}) = \det(I) = 1 \implies \det(A) \cdot \det(A^{-1}) = 1 \implies \det(A) = (\det(A^{-1}))^{-1} \neq 0$$

De donde se deduce que $\det(A) \neq 0$.

2) $\implies$ 1) Si $\det(A) \neq 0$, entonces la ecuación característica $\det(A - \lambda I) = 0$ no tiene $\lambda = 0$ como solución, lo que implica que A no tiene un núcleo no trivial. Por lo tanto, la transformación lineal asociada a A es inyectiva y, dado que A es cuadrada, también es sobreyectiva. Por el teorema de la inversa, esto implica que A es invertible.

Otra forma de demostrarlo es utilizando la descomposición LU o la eliminación de Gauss. Si $\det(A) \neq$

0, entonces A puede ser reducida a la matriz identidad mediante operaciones elementales, es decir, $\exists E_1, E_2, \dots, E_k$ matrices elementales tales que:

$$AE = AE_1 E_2 \dots E_k = I$$

Donde $E = E_1 E_2 \dots E_k$ es una matriz invertible, ya que es el producto de matrices elementales. Por lo tanto, podemos escribir:

$$A = E^{-1} I = E^{-1}$$

Y se deduce que A es invertible, con $A^{-1} = E$.

□

Veamos ahora varias propiedades interesantes del calculo de determinantes.

Corolario 1.1.1 [Determinante de una matriz triangular]

El determinante de una matriz triangular (superior o inferior) es igual al producto de los elementos en la diagonal principal. Es decir, si A es una matriz triangular, entonces:

$$\det(A) = \prod_{i=1}^n a_{ii}$$

Esto se da ya que si en una permutacion tenemos un elemento fuera de la diagonal principal, entonces el producto de los elementos correspondientes a esa permutacion sera cero, ya que si el elemento esta por debajo de la diagonal principal (en una triangular superior) o por encima de la diagonal principal (en una triangular inferior), entonces ese elemento es cero, lo que hace que el producto de los elementos correspondientes a esa permutacion sea cero, esta en el otro lado de la diagonal, debe haber un elemento fuera de la diagonal principal, lo que hace que el producto de los elementos correspondientes a esa permutacion sea cero, y asi sucesivamente para todas las permutaciones que tengan un elemento fuera de la diagonal principal, lo que hace que el unico producto no nulo sea el producto de los elementos en la diagonal principal, que corresponde a la permutacion identidad.

Corolario 1.1.2

Sea $M = \left(\begin{array}{c|c} A & 0 \\ \hline 0 & B \end{array} \right)$ una matriz con "solo 2 esquinas", entonces ocurre lo siguiente:

$$\det(M) = \left| \begin{array}{c|c} A & 0 \\ \hline 0 & B \end{array} \right| = \left| \begin{array}{c|c} A & 0 \\ \hline 0 & I \end{array} \right| \cdot \left| \begin{array}{c|c} I & 0 \\ \hline 0 & B \end{array} \right| = \det(A) \cdot \det(B)$$

Corolario 1.1.3

Sea $M = \left(\begin{array}{c|c} A & C \\ \hline 0 & B \end{array} \right)$ una matriz con "solo 3 esquinas", entonces ocurre lo siguiente:

$$\left| \begin{array}{c|c} I & \Gamma \\ \hline 0 & I \end{array} \right| \cdot \left| \begin{array}{c|c} A & C \\ \hline 0 & B \end{array} \right| = \left| \begin{array}{c|c} A & C + \Gamma B \\ \hline 0 & B \end{array} \right|$$

Ahora si tomamos $\Gamma = -CB^{-1}$, entonces:

$$\left| \begin{array}{c|c} I & -CB^{-1} \\ \hline 0 & I \end{array} \right| \cdot \left| \begin{array}{c|c} A & C \\ \hline 0 & B \end{array} \right| = \left| \begin{array}{c|c} A & 0 \\ \hline 0 & B \end{array} \right|$$

Esto lo podemos hacer ya que si B no es invertible, entonces habria una combinación lineal de las filas de B que daría como resultado la fila nula, la cual al replicarse en la esquina inferior derecha de M haría que M no sea invertible, lo que implicaría que $\det(M) = 0$, y por lo tanto, $\det(A) \cdot \det(B) = 0$, lo que implica que $\det(B) = 0$.

Por lo tanto, si B es invertible, entonces podemos realizar la operación anterior para obtener una matriz con "solo 2 esquinas", y aplicar el resultado del corolario anterior para concluir que:

$$\det(M) = \det(A) \cdot \det(B)$$

Ya que el primer determinante $\left| \begin{array}{c|c} I & \Gamma \\ \hline 0 & I \end{array} \right|$ es igual a 1, por ser una matriz triangular superior con 1's en la diagonal principal.

1.2 Autovalores y autovectores

Para definir los autovalores y autovectores de una matriz, primero necesitamos definir el concepto de espectro de una matriz, y el polinomio característico de una matriz.

Definición 1.2.1 [Espectro de una matriz]

El espectro de una matriz cuadrada $A \in \mathbb{R}^{n \times n}$ es el conjunto de todos los valores propios de la matriz, es decir, el conjunto de todos los escalares λ para los cuales existe un vector no nulo v tal que:

$$Av = \lambda v$$

El espectro se denota como $\sigma(A) = sp(A)$.

Definición 1.2.2 [Polinomio característico de una matriz]

El polinomio característico de una matriz cuadrada $A \in \mathbb{R}^{n \times n}$ es un polinomio en la variable λ definido como:

$$p_A(\lambda) = \det(A - \lambda I)$$

donde I es la matriz identidad de tamaño $n \times n$.

Los valores propios de la matriz A son las raíces del polinomio característico, es decir, los valores de λ para los cuales $p_A(\lambda) = 0$.

Ahora sí, podemos definir formalmente los autovalores y autovectores de una matriz:

Definición 1.2.3 [Autovalores y autovectores de una matriz]

Dada una matriz cuadrada $A \in \mathbb{R}^{n \times n}$, un escalar λ se llama autovalor de A si existe un vector no nulo $v \in \mathbb{R}^n$ tal que:

$$Av = \lambda v$$

En este caso, el vector v se llama autovector asociado al autovalor λ .

El conjunto de todos los autovectores asociados a un autovalor λ forma un subespacio vectorial llamado espacio propio o eigenspace correspondiente a λ . Este espacio se denota como $E_\lambda = \{v \in \mathbb{R}^n : Av = \lambda v\}$.

Notese que a los autovalores también se les conoce como valores propios, y a los autovectores como vectores propios.

Una forma de calcular los autovalores de una matriz es utilizando el polinomio característico, ya que los autovalores son las raíces de dicho polinomio. Para calcular los autovectores asociados a un autovalor λ , se puede resolver el sistema de ecuaciones lineales dado por:

$$(A - \lambda I)v = 0$$

que corresponde a encontrar el núcleo de la matriz $A - \lambda I$. El espacio propio E_λ es precisamente el núcleo de esta matriz, y sus elementos son los autovectores asociados al autovalor λ .

Notese también que el espectro es el conjunto de autovalores, y que cada autovalor puede tener uno o más autovectores asociados, dependiendo de su multiplicidad algebraica y geométrica.

Definición 1.2.4 [Multiplicidad algebraica y geométrica de un autovalor]

Dado un autovalor λ de una matriz $A \in \mathbb{R}^{n \times n}$, se define la multiplicidad algebraica de λ como el número de veces que λ aparece como raíz del polinomio característico $p_A(\lambda)$.

Por otro lado, la multiplicidad geométrica de λ se define como la dimensión del espacio propio E_λ , es decir, el número máximo de autovectores linealmente independientes asociados al autovalor λ .

Es importante destacar que la multiplicidad geométrica de un autovalor siempre es menor o igual a su multiplicidad algebraica.

Definición 1.2.5 [Radio espectral de una matriz]

El radio espectral de una matriz cuadrada $A \in \mathbb{R}^{n \times n}$ se define como el máximo valor absoluto de los autovalores de la matriz. Matemáticamente, se expresa como:

$$\rho(A) = \max_{\lambda \in \sigma(A)} |\lambda|$$

El radio espectral proporciona información sobre el comportamiento asintótico de las potencias de la matriz A , ya que si $\rho(A) < 1$, entonces las potencias de A tienden a cero, mientras que si $\rho(A) > 1$, entonces las potencias de A crecen sin límite.

Veamos ahora como el espectro se mantiene ante la conmutación del producto de matrices.

Proposición 1.2.1

Si $A, B \in \mathbb{R}^{n \times n}$ son dos matrices cuadradas, entonces el espectro de AB es igual al espectro de BA , es decir:

$$\sigma(AB) = \sigma(BA)$$

Demostración. Para ver esto, veamos como $\forall \lambda \in \sigma(AB)$, entonces existe un vector no nulo v tal que:

$$BAv = \lambda v$$

Es decir, que λ es un autovalor de BA (la implicación contraria es análoga). Para ello distingamos dos casos:

$\lambda = 0$ En este caso:

$$0 \in \sigma(AB) \iff \det(AB) = 0 \det(BA) \iff 0 \in \sigma(BA)$$

$\lambda \neq 0$ En este caso, como $v \neq 0$ es un autovector asociado al autovalor λ de AB , entonces $ABv = \lambda v$. Multiplicando ambos lados por B , obtenemos:

$$BA(Bv) = B(ABv) = \lambda(Bv)$$

Por lo que Bv es un autovector asociado al autovalor λ de BA . Además, como v es un vector no nulo y $\lambda \neq 0$, entonces Bv también es un vector no nulo, lo que garantiza que $\lambda \in \sigma(BA)$, ya que además $\det(B) \neq 0$ (si B no es invertible, entonces $0 \in \sigma(B)$, lo que implica que $0 \in \sigma(BA)$, lo que contradice la suposición de que $\lambda \neq 0$).

□

Veamos ahora como el espectro de una matriz se traslada al de sus potencias.

Proposición 1.2.2

Si $A \in \mathbb{R}^{n \times n}$ es una matriz cuadrada, entonces el espectro de A^k es igual al conjunto de los autovalores de A elevados a la potencia k , es decir:

$$\sigma(A^k) = \{\lambda^k : \lambda \in \sigma(A)\}$$

Demostración. Para ver esto, veamos como $\forall \lambda \in \sigma(A)$, entonces existe un vector no nulo v tal que:

$$Av = \lambda v$$

Ahora apliquemos inducción sobre k para demostrar que $A^k v = \lambda^k v$:

- **Caso base:** Para $k = 1$, se cumple que $A^1 v = Av = \lambda v$, lo que es cierto por la definición de autovalor y autovector.
- **Paso inductivo:** Supongamos que para algún $k \geq 1$, se cumple que $A^k v = \lambda^k v$. Entonces, para $k + 1$, tenemos:

$$A^{k+1} v = A(A^k v) = A(\lambda^k v) = \lambda^k (Av) = \lambda^k (\lambda v) = \lambda^{k+1} v$$

Por lo tanto, por el principio de inducción matemática, se cumple que $A^k v = \lambda^k v$ para todo $k \geq 1$.

De donde se deduce que λ^k es un autovalor de A^k con el mismo autovector v . Además, como v es un vector no nulo, entonces λ^k también es un valor propio de A^k . Por lo tanto, se concluye que:

$$\sigma(A^k) = \{\lambda^k : \lambda \in \sigma(A)\}$$

□

1.3 Teoremas importantes

Teorema 1.3.1 [Descomposición QR]

Sea $A \in \mathbb{K}^{m \times n}$ una matriz de rango máximo.

Entonces existen una matriz unitaria (ortogonal) $Q \in \mathbb{K}^{m \times m}$ y una matriz triangular superior $R \in \mathbb{K}^{m \times n}$ tal que:

$$A = QR \iff Q^*A = R$$

$Q^{-1}=Q^*$

Antes de la demostración, conviene definir el operador de proyección ortogonal de un vector sobre otro.

Definición 1.3.1 [Proyección ortogonal de un vector sobre otro]

Dados dos vectores $u, a \in \mathbb{K}^n$, la proyección ortogonal de a sobre u se define como el vector:

$$p : \mathbb{K}^n \times \mathbb{K}^n \rightarrow \mathbb{K}^n$$

$$(u, a) \mapsto p(u, a) = \frac{\langle u, a \rangle}{\|u\|^2} u = \left\langle \frac{u}{\|u\|}, a \right\rangle \frac{u}{\|u\|}$$

Teniendo en cuenta que:

$$\langle u, a \rangle = u^* a = a^* u$$

$$\|u\|^2 = \langle u, u \rangle = u^* u$$

Demostración. Vamos a realizar una demostración constructiva utilizando el proceso de Gram-Schmidt para ortogonalizar las columnas de la matriz A , es decir, queremos contruir una base ortogonal tal que $Q = (q_1, q_2, \dots, q_n)$, y para ello haremos lo siguiente:

Iremos tomando vectores u_i que sean ortogonales entre sí, y luego los normalizaremos para obtener los vectores q_i que formarán la matriz unitaria Q .

Para el primer vector, tomamos $u_1 = a_1$, donde a_1 es la primera columna de A . Luego, normalizamos u_1 para obtener $q_1 = \frac{u_1}{\|u_1\|}$.

Ahora para obtener el segundo vector, tomamos $u_2 = a_2 - p(u_1, a_2)$, donde $p(u_1, a_2)$ es la proyección ortogonal de a_2 sobre u_1 . Luego, normalizamos u_2 para obtener $q_2 = \frac{u_2}{\|u_2\|}$.

Para el tercer vector, tomamos $u_3 = a_3 - p(u_1, a_3) - p(u_2, a_3)$, donde $p(u_1, a_3)$ y $p(u_2, a_3)$ son las proyecciones ortogonales de a_3 sobre u_1 y u_2 , respectivamente. Luego, normalizamos u_3 para obtener $q_3 = \frac{u_3}{\|u_3\|}$.


Continuando de esta manera, para el k -ésimo vector, tomamos:

$$u_k = a_k - \sum_{j=1}^{k-1} p(u_j, a_k)$$

Luego, normalizamos u_k para obtener $q_k = \frac{u_k}{\|u_k\|}$.

De esta forma, obtenemos una base ortonormal $Q = (q_1, q_2, \dots, q_n)$ que forma una matriz unitaria.

Todo esto se puede entender geoméricamente como ir proyectando cada columna de A sobre el espacio generado por las columnas anteriores, quitándole la parte que está en ese espacio, y luego normalizando el resultado para obtener un vector unitario, vease el siguiente dibujo:



Así, hemos construido la matriz unitaria Q a partir de las columnas de A , ya que los vectores q_i son ortonormales y forman una base del espacio generado por las columnas de A , es decir, de $\mathbb{K}^n$.

Gracias a esta construcción, podemos definir la matriz triangular superior R como:

$$R = Q^* A = \begin{pmatrix} q_1^* \\ q_2^* \\ \vdots \\ q_n^* \end{pmatrix} \cdot (a_1 \ a_2 \ \cdots \ a_n) = \begin{pmatrix} q_1^* a_1 & q_1^* a_2 & \cdots & q_1^* a_n \\ 0 & q_2^* a_2 & \cdots & q_2^* a_n \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & q_n^* a_n \end{pmatrix}$$

Estos 0 aparecen ya que:

$$q_m^* a_k = \langle q_m, a_k \rangle = \langle q_m, u_k + \sum_{j=1}^{k-1} p(u_j, a_k) \rangle = \langle q_m, u_k \rangle + \sum_{j=1}^{k-1} \langle q_m, p(u_j, a_k) \rangle$$

Y ahora:

$$\langle q_m, u_k \rangle = \begin{cases} 0 & \text{si } m < k \\ \|u_k\| & \text{si } m = k \end{cases}$$

Por lo que si $m > k$, entonces $q_m^* a_k = 0$, y si $m = k$, entonces $q_m^* a_k = \|u_k\|$.

De esta forma, obtenemos una matriz triangular superior R con los elementos de la diagonal principal dados por $\|u_k\|$, y los elementos por encima de la diagonal dados por $q_m^* a_k$ para $m < k$.

Finalmente, como Q es una matriz unitaria, se cumple que $Q^{-1} = Q^*$, por lo que podemos escribir:

$$A = QR \iff Q^* A = R$$

Y con esto, hemos demostrado la existencia de la descomposición QR para cualquier matriz de rango máximo. $\square$

Veamos ahora otra descomposición importante, la descomposición de Schur.

Teorema 1.3.2 [Descomposición de Schur]

Sea $A \in \mathbb{C}^{n \times n}$ una matriz cuadrada. Entonces, existe una matriz unitaria $U \in \mathbb{C}^{n \times n}$ y una matriz triangular superior $T \in \mathbb{C}^{n \times n}$ tal que:

$$A = UTU^* \iff_{U^{-1}=U^*} U^* AU = T$$

Si además A es hermítica, entonces T es diagonal, es decir:

$$A = UDU^* \iff_{U^{-1}=U^*} U^* AU = D$$

Demostración. Sea $\lambda \in sp(A)$ un autovalor de A , y sea v un autovector asociado a λ , al cual imponemos ser unitario, es decir, $\|v\| = 1$.

Ahora completamos a una base ortonormal $(v, w_2, w_3, \dots, w_n)$ de $\mathbb{C}^n$, y formamos la matriz unitaria $U_1 = (v, w_2, w_3, \dots, w_n)$.

La idea a partir de aquí es ir aplicando el proceso de Gram-Schmidt a las columnas de A para obtener una matriz triangular superior, pero en lugar de empezar con la primera columna, empezamos con la columna correspondiente al autovector v , que es la primera columna de U_1 , y finalmente obtendremos una matriz triangular superior T tal que $U_1^* A U_1 = T$.

La demostración no se va a realizar. $\square$

Veamos ahora varias proposiciones interesantes.

Corolario 1.3.1 [Determinante de una matriz triangular]

El determinante de una matriz triangular (superior o inferior) es igual al producto de los elementos en la diagonal principal. Es decir, si A es una matriz triangular, entonces:

$$\det(A) = \prod_{i=1}^n a_{ii}$$

Esto ya se probó anteriormente, solo lo recordamos, pero ahora lo podemos entender como una consecuencia directa de la descomposición de Schur, ya que si $A = UTU^*$, entonces:

$$\det(A) = \det(UTU^*) = \det(U) \cdot \det(T) \cdot \det(U^*) = |\det(U)|^2 \cdot \prod_{i=1}^n t_{ii} = \prod_{i=1}^n t_{ii}$$

Donde t_{ii} son los elementos de la diagonal principal de T , y se ha utilizado el hecho de que U es una matriz unitaria, por lo que $|\det(U)| = 1$.

Corolario 1.3.2 [Espectro de una matriz triangular]

El espectro de una matriz triangular (superior o inferior) es igual al conjunto de los elementos en la diagonal principal. Es decir, si A es una matriz triangular, entonces:

$$\sigma(A) = \{a_{11}, a_{22}, \dots, a_{nn}\}$$

Corolario 1.3.3 [Espectro de una matriz bajo la descomposición de Schur]

Si $A \in \mathbb{C}^{n \times n}$ es una matriz cuadrada, y $A = UTU^*$ es su descomposición de Schur, entonces el espectro de A es igual al conjunto de los elementos en la diagonal principal de T . Es decir:

$$\sigma(A) = \{t_{11}, t_{22}, \dots, t_{nn}\}$$

Esto se ve fácilmente tomando $\lambda \in \sigma(A)$ y v un autovector asociado a λ , entonces:

$$Av = UTU^*v \implies \lambda v = UTU^*v \implies \lambda U^*v = TU^*v \xRightarrow[u=U^*v \neq 0]{} \lambda u = Tu$$

Corolario 1.3.4 [La traza de una matriz es igual a la suma de sus autovalores]

Si $A \in \mathbb{C}^{n \times n}$ es una matriz cuadrada, y $A = UTU^*$ es su descomposición de Schur, entonces la traza de A es igual a la suma de los elementos en la diagonal principal de T , que a su vez es igual a la suma de los autovalores de A . Es decir:

$$\text{tr}(A) = \text{tr}(AUU^*) \underset{\text{tr}(AB)=\text{tr}(BA)}{=} \text{tr}(U^*AU) = \text{tr}(T) = \sum_{i=1}^n t_{ii} = \sum_{\lambda \in \sigma(A)} \lambda$$

Corolario 1.3.5 [Espectro de la inversa de una matriz]

Si $A \in \mathbb{C}^{n \times n}$ es una matriz cuadrada invertible, entonces el espectro de A^{-1} es igual al conjunto de los inversos de los elementos en la diagonal principal de T . Es decir:

$$\sigma(A) = \{\lambda_i\} \implies \sigma(A^{-1}) = \{\lambda_i^{-1}\} = \left\{\frac{1}{\lambda_i}\right\}$$

Esto se ve facilmente tomando $\lambda \in \sigma(A)$ y v un autovector asociado a λ , entonces:

$$Av = \lambda v \implies A^{-1}Av = A^{-1}\lambda v \implies v = \lambda A^{-1}v \implies A^{-1}v = \frac{1}{\lambda}v$$

Corolario 1.3.6 [Espectro de una matriz hermítica]

Si $A \in \mathbb{C}^{n \times n}$ es una matriz hermítica, entonces el espectro de A es un conjunto de números reales. Es decir:

$$A = A^* \implies \sigma(A) \subseteq \mathbb{R}$$

Esto se ve facilmente tomando $\lambda \in \sigma(A)$ y v un autovector asociado a λ , entonces:

$$Av = \lambda v \implies (Av)^* = (\lambda v)^* \implies v^* A^* = v^* \lambda^* \implies v^* A = \lambda^* v^* \implies v^* Av = \lambda^* \|v\|^2 \implies$$

$$v^* \lambda v = \lambda v^* v \implies \lambda \|v\|^2 = \lambda^* \|v\|^2 \implies \lambda = \lambda^*$$

De donde se deduce que como $\lambda^* = \lambda$, implica que λ es un número real.

1.4 Matrices hermiticas definidas positivas

Definición 1.4.1 [Matriz hermítica definida positiva]

Una matriz $A \in \mathbb{C}^{n \times n}$ se dice que es hermítica definida positiva, o h.d.p., si cumple las siguientes condiciones:

- A es hermítica, es decir, $A = A^*$.
- Para todo vector no nulo $x \in \mathbb{C}^n$, se cumple que $x^* Ax > 0$.

Proposición 1.4.1 [Espectro de una matriz h.d.p.]

Las siguientes afirmaciones son equivalentes para una matriz $A \in \mathbb{C}^{n \times n}$:

- A es hermítica definida positiva.
- A es hermítica y su espectro $\sigma(A)$ está contenido en el conjunto de los números reales positivos, es decir, $\sigma(A) \subseteq \mathbb{R}_{>0}$.

Demostración. Para demostrar la equivalencia, veamos cada implicación por separado:

(1) $\Rightarrow$ (2): Supongamos que A es hermítica definida positiva. Entonces, por definición, para todo vector no nulo $x \in \mathbb{C}^n$, se cumple que $x^* Ax > 0$. En particular, si tomamos un autovector v asociado a un

autovalor λ , entonces:

$$v^*Av = v^*(\lambda v) = \lambda v^*v = \lambda \|v\|^2 \implies \lambda = \frac{v^*Av}{\|v\|^2} > 0$$

Dado que v es un vector no nulo, entonces $\|v\|^2 > 0$, lo que implica que $\lambda > 0$. Por lo tanto, todos los autovalores de A son positivos, y como A es hermítica, su espectro está contenido en el conjunto de los números reales positivos.

(2) $\Rightarrow$ (1): Supongamos que A es hermítica y su espectro está contenido en el conjunto de los números reales positivos. Entonces, por la descomposición de Schur, existe una matriz unitaria U y una matriz triangular superior T tal que:

$$A = UTU^*$$

Donde los elementos de la diagonal principal de T , que son los autovalores de A , son todos positivos. Ahora, para cualquier vector no nulo $x \in \mathbb{C}^n$, tenemos:

$$x^*Ax = x^*UTU^*x = (U^*x)^*T(U^*x) = w^*Dw = \sum_{i=1}^n t_{ii}|w_i|^2 = \sum_{i=1}^n \lambda_i|w_i|^2$$

Notese que hemos podido tomar una matriz diagonal D en lugar de la matriz triangular T , ya que el producto w^*Tw solo depende de los elementos de la diagonal principal de T , que son los autovalores de A . Dado que $\lambda_i > 0$ para todo i , y que $w = U^*x$ es un vector no nulo (ya que U es una matriz unitaria), entonces al menos uno de los términos $|w_i|^2$ es positivo, lo que implica que la suma es estrictamente mayor que cero. Por lo tanto:

$$x^*Ax > 0$$

Por lo tanto, se concluye que A es hermítica definida positiva. $\square$

1.5 Normas matriciales

Empecemos recordando que es una norma vectorial.

Definición 1.5.1 [Norma vectorial general]

Una norma vectorial es una función que asigna a cada vector $v \in \mathbb{K}^n$ un número real no negativo, y que satisface las siguientes propiedades:

$$\begin{aligned} \|\cdot\| : \mathbb{K}^n &\rightarrow \mathbb{R}_{\geq 0} \\ v &\mapsto \|v\| \end{aligned}$$

- **Positividad:** $\|v\| \geq 0$ para todo $v \in \mathbb{K}^n$, y $\|v\| = 0$ si y solo si $v = 0$.
- **Definitud:** $\|v\| = 0$ si y solo si $v = 0$.
- **Homogeneidad:** $\|\alpha v\| = |\alpha| \cdot \|v\|$ para todo $v \in \mathbb{K}^n$ y todo escalar $\alpha \in \mathbb{K}$.
- **Desigualdad triangular:** $\|u + v\| \leq \|u\| + \|v\|$ para todo $u, v \in \mathbb{K}^n$.

Recordemos como se define la equivalencia entre normas vectoriales.

Definición 1.5.2 [Equivalencia entre normas vectoriales]

Dos normas vectoriales $\|\cdot\|_a$ y $\|\cdot\|_b$ en $\mathbb{K}^n$ se dicen equivalentes si existen constantes positivas $C_1, C_2 > 0$ tales que:

$$C_1\|v\|_a \leq \|v\|_b \leq C_2\|v\|_a$$

para todo $v \in \mathbb{K}^n$.

Esto significa que ambas normas definen la misma topología en $\mathbb{K}^n$, es decir, los conjuntos abiertos y cerrados son los mismos para ambas normas, y por lo tanto, las propiedades de convergencia, continuidad y demás conceptos topológicos son equivalentes bajo ambas normas.

Ahora veamos la definición de norma matricial.

Definición 1.5.3 [Norma matricial]

Una norma matricial es una función que asigna a cada matriz $A \in \mathbb{K}^{m \times n}$ un número real no negativo, y que satisface las siguientes propiedades:

$$\begin{aligned} \|\cdot\| : \mathbb{K}^{m \times n} &\rightarrow \mathbb{R}_{\geq 0} \\ A &\mapsto \|A\| \end{aligned}$$

- **Positividad:** $\|A\| \geq 0$ para todo $A \in \mathbb{K}^{m \times n}$, y $\|A\| = 0$ si y solo si $A = 0$.
- **Definitud:** $\|A\| = 0$ si y solo si $A = 0$.
- **Homogeneidad:** $\|\alpha A\| = |\alpha| \cdot \|A\|$ para todo $A \in \mathbb{K}^{m \times n}$ y todo escalar $\alpha \in \mathbb{K}$.
- **Desigualdad triangular:** $\|A + B\| \leq \|A\| + \|B\|$ para todo $A, B \in \mathbb{K}^{m \times n}$.
- **Submultiplicatividad:** $\|AB\| \leq \|A\| \cdot \|B\|$ para todo $A \in \mathbb{K}^{m \times p}$ y todo $B \in \mathbb{K}^{p \times n}$.

Algunas normas particulares son las siguientes (para vectores):

- **Normas p-ésimas:** Para $1 \leq p < \infty$, la norma p-ésima de un vector $v \in \mathbb{K}^n$ se define como:

$$\|v\|_p = \left(\sum_{i=1}^n |v_i|^p \right)^{\frac{1}{p}}$$

- **Norma p-1-ésima:** Para $p = 1$, la norma p-1-ésima de un vector $v \in \mathbb{K}^n$ se define como:

$$\|v\|_1 = \sum_{i=1}^n |v_i|$$

- **Norma p-2-ésima o euclídea:** Para $p = 2$, la norma p-2-ésima de un vector $v \in \mathbb{K}^n$ se define como:

$$\|v\|_2 = \sqrt{\sum_{i=1}^n |v_i|^2}$$

- **Norma p-infinito-ésima:** Para $p = \infty$, la norma p-infinito-ésima de un vector $v \in \mathbb{K}^n$ se define como:

$$\|v\|_\infty = \lim_{p \rightarrow \infty} \|v\|_p = \max_{1 \leq i \leq n} |v_i|$$

1.6 Normas subordinadas

Definamos ahora la norma subordinada de una matriz, que es una norma matricial que se define a partir de una norma vectorial.

Definición 1.6.1 [Norma subordinada de una matriz]

Sea $A \in \mathbb{K}^{m \times n}$ una matriz, y sea $p \in [1, \infty]$. La norma subordinada de A con respecto a la norma p -ésima se define como:

$$\|A\|_p = \sup_{v \neq 0} \frac{\|Av\|_p}{\|v\|_p} = \sup_{v \neq 0} \left\| A \frac{v}{\|v\|_p} \right\|_p = \sup_{\|v\|_p=1} \|Av\|_p$$

Veamos que se cumplen las propiedades de una norma matricial para la norma subordinada de una matriz.

- **Norma de una matriz nula:** Para la matriz nula $0 \in \mathbb{K}^{m \times n}$, se cumple que $\|0\|_p = 0$ para cualquier $p \in [1, \infty]$, ya que $Av = 0$ para cualquier vector v , lo que implica que $\|Av\|_p = 0$ y por lo tanto, el supremum es cero.
- **Norma bajo escala:** Para cualquier matriz $A \in \mathbb{K}^{m \times n}$ y cualquier escalar $\alpha \in \mathbb{K}$, se cumple que $\|\alpha A\|_p = |\alpha| \cdot \|A\|_p$, lo que se deduce directamente de la homogeneidad de la norma vectorial.
- **Norma bajo la suma:** Para cualquier matriz $A, B \in \mathbb{K}^{m \times n}$, se cumple que $\|A+B\|_p \leq \|A\|_p + \|B\|_p$, lo que se deduce directamente de la desigualdad triangular de la norma vectorial.
- **Norma bajo el producto:** Para cualquier matriz $A \in \mathbb{K}^{m \times p}$ y cualquier matriz $B \in \mathbb{K}^{p \times n}$, se cumple que $\|AB\|_p \leq \|A\|_p \cdot \|B\|_p$, lo que se deduce directamente de la submultiplicatividad de la norma matricial.

Otra forma de probar esto es usando que:

$$\begin{aligned} \|AB\|_p &= \sup_{\|v\|_p=1} \|ABv\|_p = \sup_{\|v\|_p=1} \left(\frac{\|ABv\|_p \|Bv\|_p}{\|Bv\|_p} \right) = \sup_{\|v\|_p=1} \left(\left\| A \frac{Bv}{\|Bv\|_p} \right\|_p \cdot \|Bv\|_p \right) \leq \\ &\quad \sup_{\|v\|_p=1} \|Av\|_p \cdot \sup_{\|v\|_p=1} \|Bv\|_p = \|A\|_p \cdot \|B\|_p \end{aligned}$$

Y como se ha demostrado que se cumplen las propiedades de una norma matricial, entonces la norma subordinada de una matriz es una norma matricial válida.

Veamos ahora algunas propiedades de las matrices de covarianzas, tras haber definido las normas necesarias.

Proposición 1.6.1 [Matriz de covarianza es h.d.p.]

Si X es una matriz de datos en m variables y n medidas con $n \gg m$:

$$X = (x_1, \dots, x_n) \text{ (} m \text{ variables) } n \text{ medidas}$$

Siendo μ las medidas o promedios y $\tilde{x}_i = x_i - \mu_i$, entonces la matriz de covarianza de X se define como:

$$C = \tilde{X}^t \tilde{X} \in \mathbb{R}^{m \times m}$$

Demostración. Tomando $\tilde{X} = (\tilde{x}_1, \dots, \tilde{x}_n)$, entonces C es una matriz hermítica definida positiva, ya que en primer lugar es simétrica:

$$C^t = (\tilde{X}^t \tilde{X})^t = \tilde{X}^t \tilde{X} = C$$

Y como pertenece a $\mathbb{R}^{m \times m}$, entonces C es hermítica (ya que en $\mathbb{R}$, la conjugación no afecta a los elementos de la matriz).

Ahora para ver que es h.d.p., tenemos que comprobar que $sp(C) \subseteq \mathbb{R}_{>0}$ (ya sabemos que es real). Para ello, tomemos $\lambda \in \sigma(C)$ un autovalor de C , y sea v un autovector asociado a λ :

$$Cv = \lambda v \implies \tilde{X}^t \tilde{X}v = \lambda v \implies v^t \tilde{X}^t \tilde{X}v = \lambda v^t v = \lambda \|v\|^2 = \lambda \implies$$

$$(\tilde{X}v)^t (\tilde{X}v) = \|\tilde{X}v\|_2^2 = \lambda \|v\|_2^2 \implies$$

Usando ahora que $v^t v = \langle v, v \rangle = \|v\|_2^2$, entonces en particular, $\|v\|_2^2 = 1$, por lo que $\|v\|_2^2 = v^* v = 1$, y por lo tanto:

$$\lambda = \|\tilde{X}v\|_2^2 \geq 0$$

□

Algunas normas matriciales particulares son las siguientes (normas subordinadas):

- **Norma p-ésima subordinada:** La norma p-ésima subordinada de una matriz $A \in \mathbb{K}^{m \times n}$ se define como (que es la norma p-ésima subordinada):

$$\|A\|_p = \sup_{\|v\|_p=1} \|Av\|_p$$

- **Norma 1:** La norma 1 de una matriz $A \in \mathbb{K}^{m \times n}$ se define como (que es la norma 1 subordinada):

$$\|A\|_1 = \sup_{\|v\|_1=1} \|Av\|_1$$

- **Norma 2 o espectral:** La norma 2 de una matriz $A \in \mathbb{K}^{m \times n}$ se define como (que es la norma 2 subordinada):

$$\|A\|_2 = \sup_{\|v\|_2=1} \|Av\|_2$$

- **Norma infinito:** La norma infinito de una matriz $A \in \mathbb{K}^{m \times n}$ se define como (que es la norma infinito subordinada):

$$\|A\|_\infty = \sup_{\|v\|_\infty=1} \|Av\|_\infty$$

Teorema 1.6.1 [Calculo simplificado de normas subordinadas]

Sea $A \in \mathbb{K}^{m \times n}$ una matriz, entonces sus normas subordinadas se pueden calcular de la siguiente forma:

- La norma 1 subordinada de A es igual al máximo valor absoluto de la suma de los elementos de cada columna de A . Es decir:

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|$$

- La norma infinito subordinada de A es igual al máximo valor absoluto de la suma de los elementos de cada fila de A . Es decir:

$$\|A\|_\infty = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|$$

- La norma 2 subordinada de A es igual a la raíz cuadrada del máximo autovalor de $A^* A$. Es decir:

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^* A)} = \sqrt{\rho(A^* A)}$$

Demostración. Las dos primeras formulas son triviales de demostrar, ya que se pueden obtener directamente de la definición de la norma subordinada y de la forma en que se calcula el producto Av .

Para la tercera formula, hagamos los siguientes cálculos:

$$\begin{aligned}\|A\|_2^2 &= \left(\sup_{\|v\|_2=1} \|Av\|_2 \right)^2 = \sup_{\|v\|_2=1} \|Av\|_2^2 = \sup_{\|v\|_2=1} (Av)^*(Av) = \sup_{\|v\|_2=1} v^* A^* A v \\ &\stackrel{H=A^*A \text{ es hermítica}}{=} \sup_{\|v\|_2=1} v^* H v \stackrel{\text{Schur}}{=} \sup_{\|v\|_2=1} v^* U D U^* v \stackrel{z=U^*v}{=} \sup_{\|z\|_2=1} z^* D z =^*\end{aligned}$$

Ahora hemos usado que como U es una matriz unitaria, entonces $\|z\|_2 = \|v\|_2 = 1$, por lo que el supremum se puede tomar sobre z en lugar de sobre v , con fórmula $\|z\|_2^2 = z^* z = v^* U U^* v = v^* v = \|v\|_2^2$.

Continuando con el cálculo, y denotando:

$$\begin{aligned}D &= \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{pmatrix} \Rightarrow \\ z^* D z &= (\bar{z}_1 \quad \bar{z}_2 \quad \cdots \quad \bar{z}_n) \cdot \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{pmatrix} \cdot \begin{pmatrix} z_1 \\ z_2 \\ \vdots \\ z_n \end{pmatrix} = \sum_{i=1}^n \lambda_i |z_i|^2\end{aligned}$$

Y ahora podemos usar que como $\|z\|_2^2 = 1$, entonces $\sum_{i=1}^n |z_i|^2 = 1$, por lo que $z^* D z$ es una combinación convexa de los autovalores de H (y de D por tanto), lo que implica que el supremum de $z^* D z$ es igual al máximo autovalor de D , que es el máximo autovalor de H . Por lo tanto:

$$=^* \lambda_{\max}(D) = \lambda_{\max}(H) = \lambda_{\max}(A^* A) \Rightarrow \|A\|_2 = \sqrt{\lambda_{\max}(A^* A)}$$

Y si denotamos el operador $\rho(M)$ como el máximo valor absoluto de los autovalores de M , podemos tener el resultado como $\|A\|_2 = \sqrt{\rho(A^* A)}$. $\square$

Definición 1.6.2 [Norma de Frobenius]

La norma de Frobenius de una matriz $A \in \mathbb{K}^{m \times n}$ se define como:

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2}$$

1.7 Potencias de matrices

Veamos algunas propiedades de las potencias de matrices, que son muy útiles para el cálculo de autovalores y autovectores.

Teorema 1.7.1 [Convergencia a 0 de las potencias de una matriz con espectro menor que 1]

Si $A \in \mathbb{C}^{n \times n}$, entonces son equivalentes las siguientes afirmaciones:

1. A tiende a 0, es decir:

$$\lim_{k \rightarrow \infty} A^k = 0$$

2. La imagen de todo vector bajo A^k tiende a 0, es decir:

$$\lim_{k \rightarrow \infty} A^k v = 0 \quad \forall v \in \mathbb{C}^n$$

3. El espectro de A está acotado por 1, es decir:

$$\rho(A) < 1$$

4. Existe una norma matricial $\|\cdot\|$ tal que $\|A\| < 1$.

Demostración. Veamos las implicaciones por separado: **(1) $\Rightarrow$ (2):** Si $A^k \rightarrow 0$, entonces para cualquier vector $v \in \mathbb{C}^n$, se cumple que:

$$\|A^k v\| \leq \|A^k\| \cdot \|v\| \rightarrow 0$$

(2) $\Rightarrow$ (3): Si hubiera un autovalor λ de A tal que $|\lambda| \geq 1$, entonces tomando un autovector asociado a λ , se tendría que:

$$A^k v = \lambda^k v \implies \|A^k v\| = |\lambda|^k \|v\| \not\rightarrow 0$$

Lo que contradice la hipótesis, por lo que todos los autovalores de A deben tener módulo menor que 1, es decir, $\rho(A) < 1$.

También se puede usar que $\|A^k v\| = \|\lambda|^k \|v\|$ para cualquier autovalor λ y su autovector asociado v , por lo que como debe converger a 0 para todo v , entonces $|\lambda|^k \|v\| \rightarrow 0$ para todo autovalor λ , lo que implica que $|\lambda| < 1$ para todo autovalor λ .

□

1.8 Condicionamiento de matrices

Veamos un teorema importante sobre sistemas de ecuaciones lineales

Teorema 1.8.1 [Existencia de solución única para sistemas de ecuaciones lineales]

Si $A \in \mathbb{C}^{n \times n}$ es una matriz cuadrada, entonces el sistema de ecuaciones lineales $Ax = b$ tiene una solución única para cada $b \in \mathbb{C}^n$ si y solo si A es invertible. Es decir:

$$\text{El sistema } Ax = b \text{ tiene solución única para cada } b \in \mathbb{C}^n \iff A \text{ es invertible} \iff \det(A) \neq 0$$

Ahora nos podemos preguntar como de estable es la solución de un sistema de ecuaciones lineales ante pequeñas perturbaciones en los datos.

Si modificamos $\bar{b} = b + \delta$ podemos ver que el error de b es:

$$E_b = \frac{\|\bar{b} - b\|}{\|b\|} = \frac{\|\delta\|}{\|b\|}$$

Ahora podemos definir $\bar{x} = A^{-1}\bar{b} = x + \epsilon$, y por tanto podemos hacer el siguiente despeje:

$$A\bar{x} = \bar{b} \iff A(x + \epsilon) = b + \delta \iff A\epsilon = \delta \implies \epsilon = A^{-1}\delta$$

Y por tanto el error de x es:

$$\begin{aligned} E_x &= \frac{\|\bar{x} - x\|}{\|x\|} = \frac{\|\epsilon\|}{\|x\|} = \frac{\|A^{-1}\delta\|}{\|x\|} \leq \frac{\|A^{-1}\| \cdot \|\delta\|}{\|x\|} = \frac{\|A^{-1}\| \cdot \|b\|}{\|x\|} \cdot \frac{\|\delta\|}{\|b\|} = \\ &= \frac{\|A^{-1}\| \cdot \|b\|}{\|x\|} \cdot E_b = \frac{\|A^{-1}\| \cdot \|Ax\|}{\|x\|} \cdot E_b \leq \|A^{-1}\| \cdot \|A\| \cdot E_b = \text{cond}(A) \cdot E_b \end{aligned}$$

Donde $\text{cond}(A) = \|A^{-1}\| \cdot \|A\|$ es el número de condición de la matriz A , el cual si es muy grande, significara que el sistema de ecuaciones lineales es muy sensible a pequeñas perturbaciones en los datos, lo que se conoce como un sistema mal condicionado. Por otro lado, si $\text{cond}(A)$ es pequeño, entonces el sistema de ecuaciones lineales es estable ante pequeñas perturbaciones en los datos, lo que se conoce como un sistema bien condicionado.

2 Resolución de sistemas lineales

2.1 Introducción a los sistemas lineales

Sea $A \in \mathbb{K}^{n \times n}$ y $b \in \mathbb{K}^n$. Un sistema lineal es la búsqueda de $x \in \mathbb{K}^n$ tal que $S \equiv Ax = b$. En este apartado se estudiarán diferentes métodos para resolver sistemas lineales, así como sus propiedades y análisis de convergencia.

Es fácil ver que si A es invertible, entonces el sistema tiene una única solución dada por $x = A^{-1}b$. Sin embargo, calcular la inversa de una matriz puede ser computacionalmente costoso y numéricamente inestable. Por ello, se han desarrollado diversos métodos para resolver sistemas lineales sin necesidad de calcular la inversa de la matriz.

Teorema 2.1.1 [Metodo de Cramer]

Sea el sistema $S \equiv Ax = b$ con $A \in \mathbb{K}^{n \times n}$ invertible. Entonces, si denotamos:

$$A_i = \begin{bmatrix} a_{11} & \cdots & a_{1,i-1} & b_1 & a_{1,i+1} & \cdots & a_{1n} \\ a_{21} & \cdots & a_{2,i-1} & b_2 & a_{2,i+1} & \cdots & a_{2n} \\ \vdots & & \vdots & \vdots & \vdots & & \vdots \\ a_{n1} & \cdots & a_{n,i-1} & b_n & a_{n,i+1} & \cdots & a_{nn} \end{bmatrix} = (a_1, \dots, a_{i-1}, b, a_{i+1}, \dots, a_n)$$

Dónde a_j es la j -ésima columna de A , entonces la solución del sistema es:

$$x_i = \frac{\det(A_i)}{\det(A)} \quad \forall i = 1, \dots, n$$

Sin embargo, el método de Cramer es computacionalmente ineficiente para matrices grandes, ya que el cálculo de determinantes tiene una complejidad factorial. Por ello, se utilizan otros métodos como el método de Gauss, que es mucho más eficiente y estable para resolver sistemas lineales, se pueden apreciar los tiempos necesarios en la siguiente tabla:

n	10	100	10^3
Cramer	10^8	10^{162}	10^{2573}
Gauss	800	10^6	10^9

Siendo n el tamaño de la matriz A , el metodo de Cramer tiene una complejidad de $O(n^2 \cdot n!)$ mientras que el método de Gauss tiene una complejidad de $O(n^3)$.

En los siguientes apartados se estudiarán diferentes métodos para resolver sistemas lineales, así como sus propiedades y análisis de convergencia.

Un caso particular de sistemas lineales es el caso de sistemas diagonales, que tienen esta forma:

$$\begin{pmatrix} a_{11} & 0 & \cdots & 0 \\ 0 & a_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & a_{nn} \end{pmatrix} \cdot x = b$$

De lo que se deduce trivialmente que la solución es $x_i = \frac{b_i}{a_{ii}}$ para $i = 1, \dots, n$.

Estos sistemas diagonales tiene una complejidad de $O(n)$, ya que se necesitan n operaciones para calcular la solución.

Otro sistema particular es el sistema triangular superior, que tiene esta forma:

$$\begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ 0 & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & a_{nn} \end{pmatrix} \cdot x = b$$

En este caso, se puede resolver el sistema mediante sustitución hacia atrás, comenzando por la última ecuación y avanzando hacia la primera, es decir:

$$x_i = \frac{1}{a_{ii}} \left(b_i - \sum_{j=i+1}^n a_{ij}x_j \right) \quad \forall i \in \{n, n-1, \dots, 1\}$$

Analogamente, un sistema triangular inferior tiene esta forma:

$$\begin{pmatrix} a_{11} & 0 & \cdots & 0 \\ a_{21} & a_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix} \cdot x = b$$

Y se puede resolver mediante sustitución hacia adelante, comenzando por la primera ecuación y avanzando hacia la última, es decir:

$$x_i = \frac{1}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij}x_j \right) \quad \forall i \in \{1, 2, \dots, n\}$$

Estos sistemas triangulares tienen una complejidad de $O(n^2)$, ya que se necesitan n operaciones para calcular cada x_i , y hay n variables.

Ahora veamos algunos metodos de resolución de sistemas lineales más generales.

Proposición 2.1.1 [Método de eliminación Gaussiana]

El método de eliminación Gaussiana es un algoritmo para resolver sistemas lineales que consiste en transformar la matriz A en una matriz triangular superior mediante operaciones elementales de fila, es decir:

$$Ax = b \longrightarrow Tx = b'$$

Para pasar a una matriz triangular superior T , usaremos una matriz E cuyo determinante no sea nula, de tal forma que tengamos el siguiente sistema equivalente:

$$\underbrace{E \cdot A}_T x = \underbrace{E \cdot b}_{b'}$$

Para ver quien es esta matriz E , se pueden usar matrices de permutación para intercambiar filas, matrices de escala para multiplicar una fila por un escalar distinto de cero, y matrices de eliminación para sumar un múltiplo de una fila a otra fila. Denotemos:

$$E = E_k \cdot E_{k-1} \cdots E_1$$

Siendo E_i una matriz elemental que representa una de las operaciones mencionadas anteriormente, y siendo:

$$E_i \cdot A_{i-1} = A_i \quad b_i = E_i \cdot b_{i-1} \longrightarrow A_i x = b_i$$

Y por tanto el algoritmo se basara en llegar a un k que cumpla:

$$A_k = E_k \cdot E_{k-1} \cdots E_1 \cdot A = E \cdot A = T$$

Ahora veamos como encontrar una matriz E_i que nos permita hacer cada una de las operaciones elementales descritas anteriormente:

- **Multiplicar una fila por un escalar distinto de cero:** Para multiplicar la fila i por un escalar $\lambda \neq 0$, se puede usar la matriz de escala E_i que tiene la forma:

$$E_i = \begin{pmatrix} 1 & \cdots & 0 \\ 0 & \ddots & \cdots & 0 \\ \vdots & 0 & \lambda & 0 \\ 0 & 0 & \cdots & 1 \end{pmatrix}$$

Donde el elemento en la posición (i, i) es λ y el resto de los elementos son 1 en la diagonal y 0 en el resto de la matriz, y transforma A_{i-1} en A_i multiplicando la fila i por λ :

$$E_i \cdot A_{i-1} = \begin{pmatrix} 1 & 0 & \cdots & 0 \\ 0 & \ddots & \cdots & 0 \\ \vdots & 0 & \lambda & 0 \\ 0 & 0 & \cdots & 1 \end{pmatrix} \cdot \begin{pmatrix} a_i^T \\ \vdots \\ a_i^T \\ \vdots \\ a_n^T \end{pmatrix} = \begin{pmatrix} a_i^T \\ \vdots \\ \lambda a_i^T \\ \vdots \\ a_n^T \end{pmatrix}$$

- **Intercambiar dos filas:** Para intercambiar las filas i y j , se puede usar la matriz de permutación E_i que tiene la forma:

$$E_i = \begin{pmatrix} 1 & \cdots & 0 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & \cdots & 1 \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 1 & \cdots & 0 \end{pmatrix}$$

Donde el elemento en la posición (i, j) es 1, el elemento en la posición (j, i) es 1, y el resto de los elementos son 1 en la diagonal y 0 en el resto de la matriz, y transforma A_{i-1} en A_i

intercambiando las filas i y j :

$$E_i \cdot A_{i-1} = \begin{pmatrix} 1 & 0 & \cdots & 0 & \cdots & 0 \\ 0 & \ddots & \vdots & \ddots & \vdots & \vdots \\ \vdots & 0 & 0 & \cdots & 1 & 0 \\ 0 & \cdots & 1 & \cdots & 0 & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \vdots \\ 0 & \cdots & 0 & \cdots & 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} a_1^T \\ \vdots \\ a_i^T \\ \vdots \\ a_j^T \\ \vdots \\ a_n^T \end{pmatrix} = \begin{pmatrix} a_1^T \\ \vdots \\ a_j^T \\ \vdots \\ a_i^T \\ \vdots \\ a_n^T \end{pmatrix}$$

- **Suma de dos filas:** Para sumar una fila i a otra fila j , se puede usar la matriz de eliminación E_i que tiene la forma:

$$E_i = \begin{pmatrix} 1 & \cdots & 0 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 1 & \cdots & 1 \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & \cdots & 1 \end{pmatrix}$$

Donde el elemento en la posición (j, i) es 1, el elemento en la posición (j, j) es 1, y el resto de los elementos son 1 en la diagonal y 0 en el resto de la matriz, y transforma A_{i-1} en A_i sumando la fila i a la fila j :

$$E_i \cdot A_{i-1} = \begin{pmatrix} 1 & 0 & \cdots & 0 & \cdots & 0 \\ 0 & \ddots & \vdots & \ddots & \vdots & \vdots \\ 0 & \cdots & 1 & \cdots & 1 & 0 \\ 0 & \cdots & 0 & \cdots & 1 & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \vdots \\ 0 & \cdots & 0 & \cdots & 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} a_1^T \\ \vdots \\ a_i^T \\ \vdots \\ a_j^T \\ \vdots \\ a_n^T \end{pmatrix} = \begin{pmatrix} a_1^T \\ \vdots \\ a_i^T + a_j^T \\ \vdots \\ a_j^T \\ \vdots \\ a_n^T \end{pmatrix}$$

Tras comprobar esto, veamos como aplicarlo a un sistema lineal, suponiendo que $\det(A) \neq 0$, entonces el sistema tiene una única solución, y podemos aplicar el método de eliminación Gaussiana para resolverlo.

1. Como $\det(A) \neq 0$, entonces $\exists i \in \{1, \dots, n\}$ tal que $a_{i1} \neq 0$, entonces podemos usar la matriz de permutación E_1 para intercambiar la fila i con la fila 1, y obtener una nueva matriz A_1 con un elemento a no nulo en la posición $(1, 1)$:

$$E_1 \cdot A = A_1 = \left(\begin{array}{c|c} a & \beta^T \\ \hline \alpha & A_{n-1} \end{array} \right)$$

2. Despues, multiplicamos la fila 1 por $\frac{1}{a}$ usando la matriz de escala E_2 , y obtenemos una nueva matriz A_2 con un elemento 1 en la posición $(1, 1)$:

$$E_2 \cdot A_1 = A_2 = \left(\begin{array}{c|c} 1 & \frac{\beta^T}{a} \\ \hline \alpha & A_{n-1} \end{array} \right)$$

3. Finalmente, sumamos un múltiplo de la fila 1 a cada una de las filas $2, \dots, n$ según los elementos de α usando las matrices de eliminación $E_{l1}, \dots, E_{ln}$, las cuales componen E_3 , y obtenemos una nueva matriz A_3 con ceros en la primera columna excepto en la posición $(1,1)$:

$$E_n \cdots E_3 \cdot A_2 = A_n = \left(\begin{array}{c|c} 1 & \frac{\beta^T}{a} \\ \hline 0 & A_{n-1} - \frac{\alpha \cdot \beta^T}{a} \end{array} \right)$$

4. Si ahora denotamos $B_{n-1} = A_{n-1} - \frac{\alpha \cdot \beta^T}{a}$, entonces podemos repetir este proceso con la matriz B_{n-1} , y así sucesivamente hasta obtener una matriz triangular superior T :

$$E_k \cdots E_3 \cdot A_2 = T$$

Tras aplicar estos pasos, obtenemos una matriz triangular superior T y un vector b' tal que el sistema $Tx = b'$ es equivalente al sistema original $Ax = b$. Luego, podemos resolver el sistema triangular superior $Tx = b'$ mediante sustitución hacia atrás para obtener la solución del sistema original.

Teorema 2.1.2 [Descomposición Gaussiana]

Sea $A \in \mathbb{K}^{n \times n}$ arbitraria, entonces $\exists E \in \mathbb{K}^{n \times n}$ con $\det(E) \neq 0$ tal que:

$$E \cdot A = T$$

Donde T es una matriz triangular superior.

Demostración. La demostración es seguir el proceso descrito en el método de eliminación Gaussiana, aplicando operaciones elementales de fila para transformar la matriz A en una matriz triangular superior T , visto en la proposición anterior. □

Observación 2.1.1

Si además $\det(A) = 0$, entonces podemos encontrar T cuya diagonal esté compuesta por 0 y 1.

Demostración. Para ver esto, como $\det(T) = \det(E) \cdot \det(A)$, entonces $\det(T) = 0$, lo que implica que al menos un elemento de la diagonal de T es 0 (recordemos que el determinante de una matriz triangular es el producto de los elementos de su diagonal).

El proceso de eliminación gaussiana seguirá igual hasta llegar a una columna j tal que este compuesta de ceros, en esa situación, pasamos a la siguiente submatriz A_{n-j} , y repetimos el proceso hasta llegar a una matriz triangular superior T cuya diagonal este compuesta por 0 y 1 (los 0 vienen de las columnas compuestas por ceros, y los 1 vienen de las columnas con elementos no nulos en la diagonal, que se convierten en 1 al multiplicar la fila por el inverso del elemento no nulo). □

2.2 Factorización LU

Teorema 2.2.1 [Factorización LU]

Sea $A \in \mathbb{K}^{n \times n}$, entonces $\exists L \in \mathbb{K}^{n \times n}$ una matriz triangular inferior con 1 en la diagonal, y $\exists U \in \mathbb{K}^{n \times n}$ una matriz triangular superior tal que:

$$A = LU$$

Notese que con esta descomposición:

$$\det(A) = \det(L) \cdot \det(U) = 1 \cdot \prod_{i=1}^n u_{ii} = \prod_{i=1}^n u_{ii}$$

Lo que implica que:

$$\det(A) \neq 0 \iff u_{ii} \neq 0 \forall i = 1, \dots, n$$

$$\iff$$

$$\det(A) = 0 \iff \exists i \in \{1, \dots, n\} : u_{ii} = 0$$

Esta descomposición es muy útil para resolver sistemas lineales, ya que si $A = LU$, entonces el sistema $Ax = b$ se puede transformar en $LUx = b$.

Proposición 2.2.1 [Resolución de sistemas lineales con la factorización LU]

Si $A = LU$, entonces el sistema $Ax = b$ se puede resolver en dos pasos:

1. Descomponemos A en L y U , por lo que:

$$Ax = b \longrightarrow LUx = b$$

2. Denotamos $Ux = w \in \mathbb{K}^n$.

3. Resolvemos aplicando el método de remonte:

$$Lw = b \longrightarrow \exists! w \in \mathbb{K}^n : w = L^{-1}b$$

4. Resolvemos también aplicando el método de remonte:

$$Ux = w \longrightarrow \exists! x \in \mathbb{K}^n : x = U^{-1}w$$

Además, podemos resumir el cálculo de x como:

$$x = U^{-1}L^{-1}b$$

Para ver como hacer la factorización veamos que:

$$A_n = \left(\begin{array}{c|c} a_{11} & \beta^T \\ \hline \alpha & A_{n-1} \end{array} \right) = L_n \cdot U_n = \left(\begin{array}{c|c} 1 & 0 \\ \hline v & L_{n-1} \end{array} \right) \cdot \left(\begin{array}{c|c} u_{11} & w^T \\ \hline 0 & U_{n-1} \end{array} \right) = \left(\begin{array}{c|c} u_{11} & w^T \\ \hline vu_{11} & vw^T + L_{n-1}U_{n-1} \end{array} \right)$$

De lo que deducimos que:

$$u_{11} = a_{11} \quad w = \beta \quad v = \frac{\alpha}{a_{11}} \quad vw^T + L_{n-1}U_{n-1} = A_{n-1}$$

De lo que podemos definir:

$$L_{n-1}U_{n-1} = A_{n-1} - \frac{\alpha \cdot \beta^T}{a_{11}} = B_{n-1}$$

Notese que necesariamente $a_{11} \neq 0$ para poder hacer esta factorización, lo que implica que $\det(A) \neq 0$.

Observación 2.2.1

Notese que:

$$\exists A^{-1} \Leftrightarrow \exists L^{-1} \text{ y } U^{-1}$$

Notese que la primera iteración tiene coste $(n-1) + 2(n-1)^2$, y la 2 iteración tiene coste $\frac{(n-2)+2(n-2)^2}{\frac{2}{3}n^3}$, y así sucesivamente, por lo que el coste total de la factorización es $O(n^3)$.

Lema 2.2.1 [Inversas de matrices triangulares]

Si T es una matriz triangular superior/inferior e invertible, entonces T^{-1} es una matriz triangular superior/inferior.

Teorema 2.2.2 [Permisibilidad de la factorización LU]

Sea $A \in \mathbb{K}^{n \times n}$ una matriz cuyos menores principales dominantes cumplen que $\delta_k = \det(A_k) \neq 0$ para $k = 1, \dots, n-1$, siendo $A_k = (a_{ij})_{i,j=1}^k$. Sea además $\delta_n = \det(A)$. Entonces, A admite una factorización $A = LU$, donde L es una matriz triangular inferior con unos en su diagonal principal y U es una matriz triangular superior.

Además, si $\delta_n = 0$, entonces el último elemento de la diagonal de U es nulo, es decir, $u_{nn} = 0$.

Demostración. Dividiremos la demostración en dos partes: primero estableceremos la existencia de la factorización por inducción y, a continuación, analizaremos su unicidad.

Existencia. Demostraremos la existencia por inducción sobre n .

1. **Caso base** ($k = 1$): Si $\delta_1 = a_{11} \neq 0$, podemos realizar la primera iteración de la factorización tomando:

$$A_1 = (a_{11}) \quad L_1 = (1) \quad U_1 = (a_{11})$$

Como $A_1 = L_1 U_1$, el caso base se cumple de manera trivial.

2. **Paso inductivo:** Supongamos que el resultado es cierto para $k-1$, es decir, existe la descomposición $A_{k-1} = L_{k-1} U_{k-1}$. Queremos construir L_k y U_k tales que $A_k = L_k U_k$. Particionamos la matriz A_k por bloques de la siguiente forma:

$$A_k = \left(\begin{array}{c|c} A_{k-1} & b_k \\ \hline c_k^T & a_{kk} \end{array} \right)$$

donde $b_k \in \mathbb{K}^{k-1}$ es un vector columna y $c_k^T \in \mathbb{K}^{1 \times (k-1)}$ es un vector fila. Buscamos L_k y U_k con la misma estructura:

$$L_k U_k = \left(\begin{array}{c|c} L_{k-1} & 0 \\ \hline l_k^T & 1 \end{array} \right) \left(\begin{array}{c|c} U_{k-1} & u_k \\ \hline 0 & u_{kk} \end{array} \right) = \left(\begin{array}{c|c} L_{k-1} U_{k-1} & L_{k-1} u_k \\ \hline l_k^T U_{k-1} & l_k^T u_k + u_{kk} \end{array} \right)$$

Igualando los bloques de esta matriz con los de A_k , obtenemos el siguiente sistema de ecuaciones matriciales:

- (a) $L_{k-1}U_{k-1} = A_{k-1}$, lo cual es cierto por hipótesis de inducción.
- (b) $L_{k-1}u_k = b_k$. Puesto que L_{k-1} es triangular inferior con unos en la diagonal, $\det(L_{k-1}) = 1 \neq 0$. Por tanto, el vector columna u_k existe y es único: $u_k = L_{k-1}^{-1}b_k$.
- (c) $l_k^T U_{k-1} = c_k^T$. Por hipótesis, $\det(U_{k-1}) = \det(A_{k-1}) = \delta_{k-1} \neq 0$. Así, la matriz U_{k-1} es invertible y el vector fila l_k^T existe y es único: $l_k^T = c_k^T U_{k-1}^{-1}$.
- (d) $l_k^T u_k + u_{kk} = a_{kk}$, lo que nos permite despejar el escalar u_{kk} :

$$u_{kk} = a_{kk} - l_k^T u_k$$

Para verificar el valor de u_{kk} , empleamos la propiedad del determinante de matrices triangulares por bloques. Como $A_k = L_k U_k$:

$$\delta_k = \det(A_k) = \det(L_k) \det(U_k) = (1) \cdot (\det(U_{k-1}) \cdot u_{kk}) = \delta_{k-1} u_{kk}$$

De aquí se deduce que $u_{kk} = \frac{\delta_k}{\delta_{k-1}}$. Para $k < n$, por hipótesis $\delta_k \neq 0$, por lo que $u_{kk} \neq 0$.

Para el caso final $k = n$, tenemos $u_{nn} = \frac{\delta_n}{\delta_{n-1}}$. Es evidente que si la matriz original es singular ($\delta_n = \det(A) = 0$), entonces obligatoriamente $u_{nn} = 0$.

Por el principio de inducción, la existencia de la factorización queda demostrada para todo n .

Unicidad. Probaremos la unicidad de la factorización exclusivamente para el caso en el que la matriz es invertible, es decir, $\delta_n = \det(A) \neq 0$.

Supongamos, por reducción al absurdo, que existen dos factorizaciones distintas para A :

$$A = L_1 U_1 = L_2 U_2$$

Como $\det(A) \neq 0$, todas las matrices involucradas son invertibles. Multiplicando por la izquierda por L_1^{-1} y por la derecha por U_2^{-1} , obtenemos:

$$L_1^{-1} A U_2^{-1} = L_1^{-1} (L_1 U_1) U_2^{-1} \implies U_1 U_2^{-1} = L_1^{-1} L_2$$

Sabemos que el producto y la inversa de matrices triangulares inferiores (respectivamente superiores) da como resultado una matriz del mismo tipo. Además, las inversas y productos de matrices con unos en la diagonal conservan esos unos. Por lo tanto, en la igualdad:

$$\underbrace{U_1 U_2^{-1}}_{\text{Triangular superior}} = \underbrace{L_1^{-1} L_2}_{\text{Triangular inferior}}$$

la única forma de que una matriz sea simultáneamente triangular superior e inferior es que sea una matriz diagonal. Dado que $L_1^{-1} L_2$ tiene necesariamente unos en su diagonal principal, dicha matriz diagonal debe ser la identidad I . En consecuencia:

$$L_1^{-1} L_2 = I \implies L_1 = L_2 \quad \text{y} \quad U_1 U_2^{-1} = I \implies U_1 = U_2$$

lo cual contradice la suposición inicial de que las factorizaciones eran distintas. La unicidad queda así demostrada si $\delta_n \neq 0$.

Si, por el contrario, $\delta_n = 0$, entonces A es singular y $u_{nn} = 0$. En este escenario, la matriz U no es invertible y los sistemas para hallar los elementos de L pierden su solución única, lo que implica que existen infinitas matrices L válidas para completar la factorización. Por tanto, no hay unicidad en el caso singular. $\square$

Teorema 2.2.3 [Factorización LUP]

Sea $A \in \mathbb{K}^{n \times n}$ arbitraria, entonces $\exists L, U, P \in \mathbb{K}^{n \times n}$ con L una matriz triangular inferior con 1 en la diagonal, U una matriz triangular superior, y P una matriz de permutación tal que:

$$PA = LU$$

Demostración. Veamos los siguientes pasos para demostrar este teorema:

1. Veamos como encontrar las matrices L , U y P para la factorización LUP.

$$P_1 \underbrace{\left(\begin{array}{c|c} a_{11} & w^T \\ \hline \alpha & A_{n-1} \end{array} \right)}_{A_n} = \left(\begin{array}{c|c} 1 & 0 \\ \hline v & I_{n-1} \end{array} \right) \cdot \left(\begin{array}{c|c} a & \tilde{w}^T \\ \hline 0 & B_{n-1} \end{array} \right) = L_1 \cdot U_1$$

2. Ahora dependiendo del valor de a , tenemos dos casos:

$a = 0$ En este caso tenemos que $v = 0$ y también $B_{n-1} = A_{n-1}$, dejando así la primera permutación $P_1 = I_n$, quedando:

$$\left(\begin{array}{c|c} 1 & 0 \\ \hline 0 & I_{n-1} \end{array} \right) \cdot \left(\begin{array}{c|c} 0 & w^T \\ \hline 0 & A_{n-1} \end{array} \right)$$

$a \neq 0$ En este caso $\exists i \in \{1, \dots, n\}$ tal que $a_{i1} \neq 0$, entonces podemos usar la matriz de permutación P_1 para intercambiar la fila i con la fila 1, y obtener una nueva matriz A_1 con un elemento a no nulo en la posición $(1, 1)$, denotando finalmente $v = \frac{\alpha}{a_{i1}}$ y $B_{n-1} = A_{n-1} - \frac{\alpha \cdot w^T}{a_{i1}}$, quedando:

$$\left(\begin{array}{c|c} 1 & 0 \\ \hline v & I_{n-1} \end{array} \right) \cdot \left(\begin{array}{c|c} a_{i1} & \tilde{w}^T \\ \hline 0 & B_{n-1} \end{array} \right)$$

3. Ahora podemos definir la siguiente permutación P_2 como:

$$\begin{aligned} P_2 P_1 A &= \left(\begin{array}{c|c} 1 & 0 \\ \hline 0 & \widetilde{P_2} \end{array} \right) \cdot \left(\begin{array}{c|c} 1 & 0 \\ \hline v & I_{n-1} \end{array} \right) \cdot \left(\begin{array}{c|c} a_{i1} & \tilde{w}^T \\ \hline 0 & B_{n-1} \end{array} \right) = \\ &= \left(\begin{array}{c|c} 1 & 0 \\ \hline \widetilde{P_2} v & \widetilde{P_2} \end{array} \right) \cdot \left(\begin{array}{c|c} a_{i1} & \tilde{w}^T \\ \hline 0 & B_{n-1} \end{array} \right) = \left(\begin{array}{c|c} 1 & 0 \\ \hline \widetilde{P_2} v & L_{n-1} \end{array} \right) \cdot \left(\begin{array}{c|c} a_{i1} & \tilde{w}^T \\ \hline 0 & U_{n-1} \end{array} \right) \end{aligned}$$

Y así sucesivamente, hasta llegar a la factorización LUP completa.

Notese también que:

$$\widetilde{P_2} v \tilde{w}^T + \widetilde{P_2} B_{n-1} = \widetilde{P_2} v \tilde{w}^T + L_{n-1} U_{n-1} \implies \widetilde{P_2} B_{n-1} = L_{n-1} U_{n-1}$$

□

2.3 Factorización de Cholesky**Teorema 2.3.1** [Factorización de Cholesky]

Sea $A \in \mathbb{K}^{n \times n}$ una matriz h.d.p. (hermitiana definida positiva), entonces $\exists B \in \mathbb{K}^{n \times n}$ una matriz triangular inferior tal que:

$$A = BB^*$$

Además si imponemos que $b_{ii} > 0$ para todo $i = 1, \dots, n$, entonces la factorización es única.

Demostración. Como A es h.d.p., entonces $\delta_k = \det(A_k) > 0$ para todo $k = 1, \dots, n$, siendo estos todos los determinantes menores de A . Por lo tanto, por la factorización LU, A admite una factorización LU, es decir, $\exists L \in \mathbb{K}^{n \times n}$ una matriz triangular inferior con 1 en la diagonal, y $\exists U \in \mathbb{K}^{n \times n}$ una matriz triangular superior tal que:

$$A = LU$$

Además, $u_{11} = \delta_1 > 0$, y $u_{kk} = \frac{\delta_k}{\delta_{k-1}} > 0$ para todo $k = 2, \dots, n$, por lo que U tiene elementos positivos en la diagonal.

Ahora definimos:

$$D = \begin{pmatrix} \sqrt{u_{11}} & 0 & \cdots & 0 \\ 0 & \sqrt{u_{22}} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sqrt{u_{nn}} \end{pmatrix} \iff D^{-1} = \begin{pmatrix} \frac{1}{\sqrt{u_{11}}} & 0 & \cdots & 0 \\ 0 & \frac{1}{\sqrt{u_{22}}} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \frac{1}{\sqrt{u_{nn}}} \end{pmatrix}$$

Y por tanto:

$$A = LU = \underbrace{LD}_B \cdot \underbrace{D^{-1}U}_C = BC$$

Siendo B una matriz triangular inferior con elementos positivos en la diagonal, y C una matriz triangular superior con elementos positivos en la diagonal, y además:

$$b_{ii} = c_{ii} = \sqrt{u_{ii}} > 0 \quad \forall i = 1, \dots, n$$

Ahora veamos que $C = B^*$, lo que implica que $A = BB^*$:

$$A = BC \underset{A \text{ h.d.p.}}{=} A^* = (BC)^* = C^*B^* \implies B^{-1}|BC = C^*B^* \implies C = B^{-1}C^*B^*|B^{*-1} \implies$$

$$\underbrace{CB^{*-1}}_{\text{triang. superior}} = \underbrace{B^{-1}C^*}_{\text{triang. inferior}} \implies CB^{*-1} = B^{-1}C^* = D = I$$

Siendo además los elementos de la diagonal de B^{*-1} iguales a $\delta_{ii} = \sqrt{u_{ii}} \frac{1}{\sqrt{u_{ii}}} = 1 \forall i$. Deduciendo finalmente que $C = B^*$, y por lo tanto $A = BB^*$.

□

3 Métodos iterativos para resolver sistemas lineales

3.1 Motivación

Si tenemos un sistema lineal $Ax = b$ con $A \in \mathbb{R}^{n \times n}$, $b \in \mathbb{R}^n$ y $x \in \mathbb{R}^n$, suficientemente grande, el método de eliminación gaussiana puede resultar ineficiente, al tener coste $O(n^3)$ en términos de tiempo⁹. En estos casos, los métodos iterativos pueden ser una alternativa más adecuada.

La idea de este tipo de metodos va a ser escoger una matriz M :

$$A = M - N$$

Que cumpla que M es fácil de invertir, y que sea similar a A (preferiblemente, $M = A$). Entonces, el sistema $Ax = b$ se puede reescribir como:

$$Mx = Nx + b \implies x = M^{-1}Nx + M^{-1}b \xrightarrow{\text{Notación}} x_k = Bx_{k-1} + C$$

Por lo que podemos utilizar esta ultima expresión para generar una sucesión de aproximaciones a la solución del sistema, partiendo de una aproximación inicial x_0 , la cual convergera a la solución del sistema:

$$\lim_{k \rightarrow \infty} x_k = \xi$$

3.2 Convergencia de métodos iterativos

Definición 3.2.1 [Convergencia de métodos iterativos]

El metodo iterativo () se dice que converge si la sucesión de aproximaciones x_k converge a la solución exacta ξ del sistema lineal $Ax = b$, es decir:*

$$\lim_{k \rightarrow \infty} x_k = \xi \quad \forall x_0 \in \mathbb{R}^n$$

Notese que B no se calcula de forma explicita, sino que se utiliza:

$$\begin{cases} w = Nx_{k-1} + b \\ Mx_k = w \end{cases}$$

Notese el caso particular de $M = A$, que se conoce como método de iteración de Richardson, y que es el método iterativo mas simple, ya que la primera iteración nos devuelve $x_1 = \xi$, es decir, la solución exacta del sistema. Sin embargo, este método no es eficiente, ya que requiere resolver el sistema $Ax = b$ en cada iteración, lo cual es tan costoso como resolver el sistema original.

Veamos ahora algunos criterios de convergencia.

Proposición 3.2.1 [Error en métodos iterativos]

Teniendo un metodo iterativo, podemos definir el error:

$$e_k = x_k - \xi = Bx_{k-1} + C - \underbrace{\xi}_{*} = Bx_{k-1} + C - B\xi - C = B(x_{k-1} - \xi) = Be_{k-1} = B^k e_0$$

Donde el paso (*) se ha realizado utilizando:

$$A\xi = b \implies (M - N)\xi = b \implies M\xi = N\xi + b \implies \xi = M^{-1}N\xi + M^{-1}b = B\xi + C$$

Por lo que el error converge a 0 si y solo si:

$$\lim_{k \rightarrow \infty} \|e_k\| = 0 \iff \lim_{k \rightarrow \infty} \|B^k e_0\| = 0 \iff \|B\| < 1 \iff \rho(B) < 1$$

Proposición 3.2.2 [Criterios de parada]

Para determinar cuándo detener el proceso iterativo, se pueden usar los siguientes criterios:

- **Criterio de iteraciones:** Detener después de un número fijo de iteraciones K_{max} .
- **Criterio de error:** Detener cuando el error estimado $\|e_k\|$ sea menor que una tolerancia predefinida $\varepsilon = TOL$. Esto no se puede aplicar directamente, ya que no conocemos el error real, pero se pueden usar varias posibilidades para estimar el error, el cual se define como:

$$E_k = \frac{\|e_k\|}{\|\xi\|} = \frac{\|x_k - \xi\|}{\|\xi\|}$$

Por ello veamos distintos métodos para estimar el error real:

- **Error relativo:** Se puede usar el error relativo entre iteraciones consecutivas como una estimación del error real, es decir:

$$\|e_k\| \approx \widetilde{E}_k = \frac{\|x_k - x_{k-1}\|}{\|x_k\|}$$

- **Error de residuos:** Se puede usar el residuo del sistema lineal como una estimación del error real, es decir, si definimos el residuo:

$$r_k = b_k - b = Ax_k - bAx_k - A\xi = A(x_k - \xi) = Ae_k$$

Y por tanto podemos estimar el error real como:


$$\|e_k\| \approx \overline{E}_k = \frac{\|b_k - b\|}{\|b\|} = \frac{\|r_k\|}{\|b\|} = \frac{\|A(x_k - \xi)\|}{\|A\xi\|} \approx \frac{\|x_k - \xi\|}{\|\xi\|} = E_k$$

3.3 Método de Jacobi y método de Gauss-Seidel

Teorema 3.3.1 [Metodo de Jacobi]

Sea la descomposición de $A = M - N$, y sea tambien su dscomposición en bloques:

$$A = D - E - F$$



Es decir, que:

$$D = \text{diag}(a_{11}, a_{22}, \dots, a_{nn})$$

$$E = (e_{ij})_{i,j=1}^n, \quad \begin{cases} e_{ij} = a_{ij} & \text{si } i > j \\ e_{ij} = 0 & \text{si } i \leq j \end{cases}$$

$$F = (f_{ij})_{i,j=1}^n, \quad \begin{cases} f_{ij} = a_{ij} & \text{si } i < j \\ f_{ij} = 0 & \text{si } i \geq j \end{cases}$$

El método de Jacobi se define como el método iterativo generado por la matriz $M = D$, es decir:

$$\begin{cases} x_0 \in \mathbb{K}^n \\ Dx_k = (E + F)x_{k-1} + b \quad k \in \mathbb{N} \end{cases}$$

Y la matriz del método de Jacobi es:

$$J = \underbrace{D^{-1}}_{M^{-1}} \underbrace{(E + F)}_N = D^{-1}(D - A) = I - D^{-1}A$$

Para que el método este bien planteado, es necesario que D sea invertible, es decir, que $a_{ii} \neq 0$ para todo $i = 1, \dots, n$, si alguno es cero pero $\det(D) \neq 0$, entonces permutamos.

Para iterar definimos el operador de iteración del método de Jacobi:

$$x_i^{(k)} = \left(b_i - \sum_{j \neq i} a_{ij} x_j^{(k-1)} \right) / a_{ii} \quad i \in \{1, \dots, n\}$$

Que tiene complejidad $O(n^2)$, ya que cada iteración requiere calcular n sumas de $n - 1$ elementos.

Veamos ahora varios criterios de convergencia del método de Jacobi.

Proposición 3.3.1 [Convergencia del método de Jacobi]

El método de Jacobi converge si:

$$\rho(J) < 1$$

Ejemplo

Tengamos el sistema:

$$\begin{pmatrix} -1 & 3 \\ -2 & 1 \end{pmatrix} x = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$$

Podemos tomar:

$$M = D = \begin{pmatrix} -1 & 0 \\ 0 & 1 \end{pmatrix} \text{ y } N = E + F = \begin{pmatrix} 0 & -3 \\ 2 & 0 \end{pmatrix}$$

Si definimos ahora:

$$J = D^{-1}(E + F) = \begin{pmatrix} 0 & 3 \\ 2 & 0 \end{pmatrix} \implies \det(J - \lambda I) = \begin{vmatrix} -\lambda & 3 \\ 2 & -\lambda \end{vmatrix} = \lambda^2 - 6 = 0 \implies \lambda = \pm\sqrt{6} > 1$$

Por lo que el método de Jacobi no converge para este sistema lineal.

Definición 3.3.1 [Matriz d.e.d.]

Una matriz $A \in \mathbb{K}^{n \times n}$ es diagonal estrictamente dominante (d.e.d.) si:

$$|a_{ii}| > \sum_{j \neq i} |a_{ij}| \quad \forall i = 1, \dots, n$$

Lema 3.3.1

Sea A una matriz d.e.d., entonces:

$$\exists A^{-1}$$

Demostración. Supongamos que A no es invertible, entonces el sistema $Ax = 0$ tiene infinitas soluciones. Sea $x \neq 0$ solución del sistema, por lo que $\exists i \in \{1, \dots, n\}$ tal que $|x_i| = \max_j |x_j| > 0$. Entonces:

$$a_{ii}x_i + \sum_{j \neq i} a_{ij}x_j = 0 \implies -a_{ii}x_i = \sum_{j \neq i} a_{ij}x_j \implies |a_{ii}||x_i| \leq \sum_{j \neq i} |a_{ij}||x_j| \implies$$

$$|a_{ii}| \leq \sum_{j \neq i} |a_{ij}| \frac{\|x_j\|}{\|x_i\|} \implies |a_{ii}| \leq \sum_{j \neq i} |a_{ij}| \implies \text{Contradicción!!}$$

Por lo que necesariamente A es invertible. □

Teorema 3.3.2 [Convergencia del método de Jacobi para matrices d.e.d.]

Sea A una matriz d.e.d., entonces el método de Jacobi converge.

Demostración. Para ver que converge, comprobemos que $\rho(J) < 1$. Para ello, probemos por absurdo que si $\exists \lambda \in \sigma(J)$ tal que $|\lambda| \geq 1$, entonces se llega a una contradicción, ahora:

$$\det(J - \lambda I) = 0 = \det(D^{-1}(E + F) - \lambda D^{-1}D) = \det(D^{-1}) \det(E + F - \lambda D) \implies$$

Como $\det(D^{-1}) \neq 0$, al ser A d.e.d., entonces:

$$\det(E + F - \lambda D) = 0 \implies \underbrace{(E + F - \lambda D)}_B \text{ no es d.e.d.} \implies \exists k \in \{1, \dots, n\} : \|b_{kk}\| \leq \sum_{j \neq k} \|b_{kj}\| \implies$$

Ahora como $b_{kk} = -\lambda a_{kk}$ y $b_{kj} = -a_{kj}$, entonces:


$$|a_{kk}| \leq |\lambda| |a_{kk}| \leq \sum_{j \neq k} |a_{kj}| \implies |a_{kk}| \leq \sum_{j \neq k} |a_{kj}| \implies \text{Contradicción!!}$$

Por lo que necesariamente $\rho(J) < 1$, y el método de Jacobi converge. $\square$

Veamos ahora otro método iterativo, el método de Gauss-Seidel.

Teorema 3.3.3 [Método de Gauss-Seidel]

Usando la misma descomposición de A que en el método de Jacobi, es decir, $A = D - E - F$, que dejaba:



El método de Gauss-Seidel se define como el método iterativo generado por:

$$\begin{cases} x_0 \in \mathbb{K}^n \\ a_{ii}x_i^{(k)} = b_i - \underbrace{\sum_{j < i} a_{ij}x_j^{(k)}}_{Ex_k} - \underbrace{\sum_{j > i} a_{ij}x_j^{(k-1)}}_{Fx_{k-1}} \quad i = 1, \dots, n, k \in \mathbb{N} \end{cases}$$

Y la convergencia estará dada según la distancia al resultado:

$$\|x_k - \xi\| = d_k \sim \rho(J)^k$$

La complejidad de este método sigue siendo $O(n^2)$, al igual que el método de Jacobi, ya que cada iteración requiere calcular n sumas de $n - 1$ elementos.

Notese que se pueden juntar en la notación $D - E$ y F , para obtener $A = M - N$ con $M = D - E$ y $N = F$, por lo que la matriz del método de Gauss-Seidel es:

$$(D - E)x_k = Fx_{k-1} + b \implies x_k = (D - E)^{-1}Fx_{k-1} + (D - E)^{-1}b$$

Que cambiando la notación, se puede escribir como:

$$x_k = Lx_{k-1} + C \quad \text{con} \quad L = (D - E)^{-1}F \quad \text{y} \quad C = (D - E)^{-1}b$$

Donde ahora el radio espectral del método de Gauss-Seidel es:

$$\rho(L) = \rho((D - E)^{-1}F)$$

Notese que el método de Gauss-Seidel no siempre es mejor que el método de Jacobi, muchas veces lo será pero no siempre.

3.4 Métodos de relajación

La idea de los métodos de relajación es modificar los métodos mediante parametros que nos ayuden a mejorar la convergencia. Normalmente usaremos $\omega \in \mathbb{R}$ como parametro de relajación, cuyo significado es el siguiente:

$$x_k = \omega \bar{x}_k + (1 - \omega)x_{k-1}$$

Teorema 3.4.1 [Método de relajación de Jacobi]

El método de relajación de Jacobi se define como el método iterativo, con un punto $\omega \in \mathbb{R}$:

$$\begin{cases} x_0 \in \mathbb{K}^n \\ \frac{D}{\omega}x_k = D\bar{x}_k + \frac{1-\omega}{\omega}Dx_{k-1} = \left(E + F + \frac{1-\omega}{\omega}D\right)x_{k-1} + b \quad k \in \mathbb{N} \end{cases}$$

De lo que sacamos la matriz del método de relajación de Jacobi:

$$J_R = \omega D^{-1} \left(E + F + \frac{1-\omega}{\omega}D \right)$$

Y su convergencia estará dada por el radio espectral de esta matriz, es decir:

$$\rho(J_R) < 1$$

Notese que si $\omega = 1$, entonces el método de relajación de Jacobi coincide con el método de Jacobi, por lo que el método de relajación de Jacobi es una generalización del método de Jacobi.

El método tambien se puede ver de la forma $A = M - N$ con:

$$M = \frac{D}{\omega}$$

$$N = \left(E + F + \frac{1-\omega}{\omega}D \right)$$

De donde queda:

$$A = M - N = \frac{D}{\omega} - \left(E + F + \frac{1-\omega}{\omega}D \right) = D - E - F$$

Sin embargo este método no es muy utilizado en la práctica, ya que no se sabe a priori qué valor de ω es el óptimo para cada sistema lineal, por lo que se suele utilizar el método de relajación de Gauss-Seidel.

Teorema 3.4.2 [Método de relajación de Gauss-Seidel]

El método de relajación de Gauss-Seidel se define como el método iterativo, con un punto $\omega \in [0, 1]$, y multiplicando $\frac{D}{\omega}$ a ambos lados de la ecuación del método de Gauss-Seidel:

$$\begin{cases} x_0 \in \mathbb{K}^n \\ \frac{D}{\omega}x_k = Ex_k + Fx_{k-1} + b + \frac{1-\omega}{\omega}Dx_{k-1} \implies \\ \left(\frac{D}{\omega} - E\right)x_k = \left(F + \frac{1-\omega}{\omega}D\right)x_{k-1} + b \end{cases}$$

De lo que sacamos la matriz del método de relajación de Gauss-Seidel:

$$L_R = \underbrace{(D - \omega E)}_M \underbrace{((1 - \omega)D + \omega F)}_N$$

Y su convergencia estará dada por el radio espectral de esta matriz, es decir:

$$\rho(L_R) < 1$$

Notese de nuevo que si $\omega = 1$, entonces el método de relajación de Gauss-Seidel coincide con el método de Gauss-Seidel, por lo que el método de relajación de Gauss-Seidel es una generalización del método de Gauss-Seidel.

Teorema 3.4.3 [Convergencia del método de relajación de Gauss-Seidel]

Si $\omega \notin (0, 2)$ entonces el método de relajación de Gauss-Seidel no converge.

Demostración. Veamos:

$$\det(L_R) = \det\left(\left(\frac{D}{\omega} - E\right)^{-1}\right) \cdot \det\left(F + \frac{1 - \omega}{\omega} D\right) = \frac{\overbrace{\det(F + \frac{1 - \omega}{\omega} D)}^{\Delta}}{\det(\frac{D}{\omega} - E)} =$$

$$\frac{\left(\frac{1 - \omega}{\omega}\right)^n \det(D)}{\left(\frac{1}{\omega}\right)^n \det(D)} = (1 - \omega)^n$$

Ahora, recordemos que $\det(L_R) = \prod_{\lambda \in \sigma(L_R)} \lambda$, por lo que igualando:

$$\prod_{\lambda \in \sigma(L_R)} \lambda = (1 - \omega)^n \implies$$

$$\|1 - \omega\|^n = \|(1 - \omega)^n\| = \left\| \prod_{\lambda \in \sigma(L_R)} \lambda \right\| = \prod_{\lambda \in \sigma(L_R)} \|\lambda\| \leq \rho(L_R)^n \implies \|1 - \omega\| \leq \rho(L_R)$$

Por lo que finalmente:

$$\begin{cases} \rho \geq \omega - 1 \implies \boxed{\omega \geq 2 \implies \rho \geq 1 \implies \text{Divergencia}} \\ \rho \geq 1 - \omega \implies \boxed{\omega \leq 0 \implies \rho \geq 1 \implies \text{Divergencia}} \end{cases}$$

□

Ahora veamos un caso en el que este método converge.

Teorema 3.4.4 [Convergencia del método de relajación de Gauss-Seidel para matrices d.e.d.]

Si A es una matriz d.e.d., entonces el método de relajación de Gauss-Seidel converge para todo $\omega \in (0, 1]$.

Demostración. Supongamos que $\exists \lambda \in \sigma(L_R)$ tal que $|\lambda| \geq 1$, por lo que $\rho(L_R) \geq 1$ y el método no converge. Entonces:

$$\begin{aligned} \det(L_R - \lambda I) = 0 &\implies \\ 0 = \det\left(\left(\frac{D}{\omega} - E\right)^{-1} \left(F + \left(\frac{1-\omega}{\omega}\right) D\right) - \lambda \underbrace{\left(\frac{D}{\omega} - E\right)^{-1} \left(\frac{D}{\omega} - E\right)}_I\right) = \\ &\det\left(F + \left(\frac{1-\omega}{\omega}\right) D - \lambda \left(\frac{D}{\omega} - E\right)\right) = \det(B) \end{aligned}$$

Por lo que esta nueva matriz B no es d.e.d., por lo que $\exists k \in \{1, \dots, n\}$ tal que:

$$\begin{aligned} b_{kk} &\leq \sum_{j \neq k} |b_{kj}| \implies \\ \left| \frac{1-\omega-\lambda}{\omega} a_{kk} \right| &\leq \underbrace{\sum_{i=k+1}^n |-a_{ki}|}_F + \underbrace{\sum_{i=1}^{k-1} |-\lambda a_{ki}|}_E = \sum_{i=k+1}^n |a_{ki}| + |\lambda| \sum_{i=1}^{k-1} |a_{ki}| \leq |\lambda| \sum_{i \neq k} |a_{ki}| \implies \\ |a_{kk}| &\leq \left| \frac{\lambda\omega}{1-\omega-\lambda} \right| \sum_{i \neq k} |a_{ki}| \leq \sum_{i \neq k} |a_{ki}| \implies A \text{ no es d.e.d.} !! \end{aligned}$$

□

Veamos un nuevo teorema que no demostraremos, pero que es interesante conocer.

Teorema 3.4.5 [Criterio de convergencia para métodos iterativos]

Sea $A = M - N$ una matriz h.d.p.

Ahora podemos definir:

$$B = M^* + N^* \quad \text{ó} \quad B = M + N^* \quad \text{ó} \quad B = M^* + N$$

Si B es h.d.p., entonces $\rho(M^{-1}N) < 1$, por lo que el método iterativo generado por M converge.

Teorema 3.4.6 [Convergencia del método de relajación de Gauss-Seidel para matrices h.d.p.]

Sea A una matriz h.d.p. y $\omega \in (0, 2)$ entonces el método de relajación de Gauss-Seidel converge.

Observación 3.4.1

Notese que si $\omega = 1$, entonces el método de relajación de Gauss-Seidel coincide con el método de Gauss-Seidel, por lo que el método de Gauss-Seidel también converge para matrices h.d.p.

Demostración. Veamos que se cumple el teorema anterior, para ello definamos:

$$B = M^* + N = \left(\frac{D}{\omega} - E\right)^* + \left(F + \frac{1-\omega}{\omega} D\right) = \frac{D^*}{\omega} - E^* + F + \frac{1-\omega}{\omega} D$$

Ahora podemos usar que como A es h.d.p., entonces $D^* = D$, al ser matrices diagonales. Además, como A es h.d.p., podemos deducir que las matrices triangulares $E^* = F$ y $F^* = E$, al transponer al hacer la traspuesta de A . Todo esto se aprecia en la siguiente igualdad:

$$\begin{aligned} A &= \textcolor{green}{D} - \textcolor{red}{E} - \textcolor{blue}{F} = \\ &= A^* = \textcolor{green}{D}^* - \textcolor{blue}{E}^* - \textcolor{red}{F}^* \end{aligned}$$

Por lo que llegamos a que:

$$B = \frac{2-\omega}{\omega}D - E^* + F = \frac{2-\omega}{\omega}D$$

Para que B sea h.d.p., es necesario que $\frac{2-\omega}{\omega} > 0$, lo cual se cumple para todo $\omega \in (0, 2)$, por lo que B es h.d.p., y por el teorema anterior, el método de relajación de Gauss-Seidel converge al tener $\rho(L_R) < 1$. $\square$

4 Interpolación polinómica

4.1 Motivación e Introducción

En diversas ramas de las matemáticas aplicadas, la física y la ingeniería, es frecuente encontrarse con el siguiente problema fundamental en el análisis numérico:

Dado un conjunto discreto de $n + 1$ puntos distintos $\{x_0, x_1, \dots, x_n\}$ (llamados comúnmente nodos) y un conjunto de valores correspondientes $\{y_0, y_1, \dots, y_n\}$, se desea encontrar una función continua f que pase exactamente por todos ellos, es decir, que cumpla la condición de interpolación $f(x_i) = y_i$ para todo $i = 0, 1, \dots, n$.

Estos valores y_i pueden provenir de mediciones experimentales, de muestreos estadísticos, o bien pueden ser evaluaciones de una función matemática muy compleja que deseamos aproximar por una función mucho más sencilla de manipular, derivar e integrar.

Para lograr esto, una de las herramientas más robustas y elementales es la **interpolación polinómica**. Esta técnica consiste en restringir la búsqueda de la función f al conjunto de los polinomios. El objetivo será encontrar un polinomio p de grado a lo sumo n que satisfaga las condiciones de interpolación.

Definición 4.1.1 [Espacio de polinomios]

Se define el espacio vectorial de polinomios con coeficientes reales como el conjunto:

$$\mathbb{R}[x] = \{p(x) = a_0 + a_1x + a_2x^2 + \dots + a_kx^k : a_i \in \mathbb{R}, k \in \mathbb{N}\}$$

En el contexto de la interpolación, trabajaremos con un subespacio de dimensión finita, el espacio de polinomios de grado menor o igual a n , el cual denotamos por:

$$\mathcal{P}_n = \{p(x) = a_0 + a_1x + a_2x^2 + \dots + a_nx^n : a_i \in \mathbb{R}\}$$

Fijémonos en un par de casos particulares para comprender la estructura de estos espacios: Si tomamos $n = 0$, obtenemos el espacio de los polinomios constantes:

$$\mathcal{P}_0 = \{p(x) = a_0 : a_0 \in \mathbb{R}\}$$

Este espacio tiene una correspondencia directa (un isomorfismo) con los números reales, es decir, $\mathcal{P}_0 \cong \mathbb{R}$.

Si generalizamos esto para cualquier n , notamos que un polinomio $p \in \mathcal{P}_n$ queda unívocamente determinado por sus $n + 1$ coeficientes $(a_0, a_1, \dots, a_n)$. Por lo tanto, estableciendo la base canónica $\{1, x, x^2, \dots, x^n\}$, podemos afirmar que el espacio de polinomios de grado a lo sumo n es isomorfo al espacio euclídeo de dimensión $n + 1$:

$$\mathcal{P}_n \cong \mathbb{R}^{n+1}$$

4.2 Planteamiento formal del problema

Formalicemos matemáticamente el problema que intentamos resolver.

Definición 4.2.1 [Problema de la interpolación polinómica]

Sean dados:

- *Un conjunto de $n + 1$ nodos $\{x_i\}_{i=0}^n \subset [a, b]$ estrictamente distintos entre sí, es decir, $x_i \neq$*

$$x_j \iff i \neq j.$$

- Un conjunto de $n + 1$ valores $\{y_i\}_{i=0}^n \subset \mathbb{R}$.

El problema consiste en encontrar un único polinomio $p \in \mathcal{P}_n$ que satisfaga las $n + 1$ condiciones de interpolación:

$$p(x_i) = y_i \quad \forall i \in \{0, 1, \dots, n\}$$

Dado que buscamos un polinomio de la forma $p(x) = a_0 + a_1x + a_2x^2 + \dots + a_nx^n$, el problema se reduce a encontrar los $n + 1$ coeficientes incógnita $a_0, a_1, \dots, a_n$. Al evaluar el polinomio en cada nodo x_i e igualarlo a su respectivo valor y_i , obtenemos un sistema lineal de $n + 1$ ecuaciones con $n + 1$ incógnitas:

$$\begin{cases} a_0 + a_1x_0 + a_2x_0^2 + \dots + a_nx_0^n = y_0 \\ a_0 + a_1x_1 + a_2x_1^2 + \dots + a_nx_1^n = y_1 \\ \vdots \\ a_0 + a_1x_n + a_2x_n^2 + \dots + a_nx_n^n = y_n \end{cases}$$

Este sistema se puede expresar de forma elegante y compacta mediante notación matricial:

$$\underbrace{\begin{bmatrix} 1 & x_0 & x_0^2 & \dots & x_0^n \\ 1 & x_1 & x_1^2 & \dots & x_1^n \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \dots & x_n^n \end{bmatrix}}_{X \in \mathcal{M}_{(n+1) \times (n+1)}} \cdot \underbrace{\begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{bmatrix}}_{a \in \mathbb{R}^{n+1}} = \underbrace{\begin{bmatrix} y_0 \\ y_1 \\ \vdots \\ y_n \end{bmatrix}}_{y \in \mathbb{R}^{n+1}}$$

La matriz de coeficientes X de este sistema se conoce como **Matriz de Vandermonde**. El problema analítico consiste ahora en garantizar que esta matriz sea invertible, lo que aseguraría que exista una y solo una solución para el vector de coeficientes a .

$$\exists! a = X^{-1}y \implies \exists! p \in \mathcal{P}_n \text{ que interpola los datos.}$$

Ejemplo

Veamos la aplicación directa de este método resolviendo un caso particular de grado 2 (una parábola). Supongamos que disponemos de la siguiente tabla de datos experimentales:

Índice i	0	1	2
Nodo x_i	0	1	3
Valor y_i	-3	4	5

Como tenemos 3 puntos ($n = 2$), buscamos un polinomio $p \in \mathcal{P}_2$ de la forma $p(x) = a_0 + a_1x + a_2x^2$. Evaluando en los nodos, planteamos el sistema de ecuaciones:

$$\begin{cases} p(0) = -3 \implies a_0 + a_1(0) + a_2(0^2) = -3 \\ p(1) = 4 \implies a_0 + a_1(1) + a_2(1^2) = 4 \\ p(3) = 5 \implies a_0 + a_1(3) + a_2(3^2) = 5 \end{cases}$$

Expresado en forma matricial (Matriz de Vandermonde):

$$\begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 1 \\ 1 & 3 & 9 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} -3 \\ 4 \\ 5 \end{bmatrix}$$

Resolviendo el sistema, de la primera ecuación deducimos inmediatamente que $a_0 = -3$. Sustituyendo este valor en las dos ecuaciones restantes obtenemos:

$$\begin{cases} a_1 + a_2 = 7 \\ 3a_1 + 9a_2 = 8 \end{cases}$$

Multiplicando la primera por -3 y sumándola a la segunda, se llega a $6a_2 = -13$, por lo que $a_2 = -13/6$. Sustituyendo en la primera, $a_1 = 7 - (-13/6) = 55/6$. Así, el polinomio interpolador único es:

$$p(x) = -3 + \frac{55}{6}x - \frac{13}{6}x^2$$

4.3 Existencia y unicidad: El determinante de Vandermonde

Para garantizar rigurosamente que el sistema planteado siempre tiene una solución única, debemos analizar el determinante de la matriz X . Por propiedades del álgebra lineal, una matriz cuadrada es invertible si y solo si su determinante es no nulo.

Se puede demostrar por inducción que el determinante de una matriz de Vandermonde X viene dado por el producto de todas las diferencias posibles entre los nodos x_i , tomando los índices mayores menos los menores:

$$\det(X) = \prod_{0 \leq j < i \leq n} (x_i - x_j)$$

De esta expresión analítica extraemos una conclusión vital: para que $\det(X) \neq 0$, ninguno de los factores $(x_i - x_j)$ puede ser cero. Esto equivale a exigir que no haya dos nodos iguales:

$$\det(X) \neq 0 \iff x_i \neq x_j \quad \forall i \neq j$$

Por lo tanto, **si todos los nodos x_i son distintos entre sí**, la matriz de Vandermonde es invariablemente invertible. Esto garantiza formalmente la **existencia y unicidad** del polinomio interpolador en $\mathcal{P}_n$. Sin embargo, cabe destacar que aunque el método de resolución directa mediante la matriz de Vandermonde es teóricamente impecable, desde el punto de vista computacional puede resultar inestable y costoso para valores grandes de n , lo que motivará el estudio de alternativas como los polinomios de Lagrange o el método de diferencias divididas de Newton.

4.4 Polinomios de Lagrange

En la sección anterior vimos que el uso directo de la matriz de Vandermonde puede ser computacionalmente ineficiente. Para sortear este problema, introducimos una base alternativa para el espacio $\mathcal{P}_n$, lo que nos permitirá construir el polinomio interpolador de forma directa sin necesidad de resolver ningún sistema de ecuaciones. Esta es la base de Lagrange.

Definición 4.4.1 [Polinomios base de Lagrange]

Dado un conjunto de $n+1$ nodos $\{x_i\}_{i=0}^n$ estrictamente distintos, definimos el k -ésimo polinomio base de Lagrange, denotado como $L_k(x)$, como aquel polinomio de grado n que cumple la propiedad de la delta de Kronecker en los nodos:

$$L_k(x_j) = \delta_{kj} = \begin{cases} 1 & \text{si } k = j \\ 0 & \text{si } k \neq j \end{cases}$$

Para lograr que $L_k(x)$ se anule en todos los nodos x_j excepto en x_k , su numerador debe ser el producto de los factores $(x - x_j)$ para $j \neq k$. Para garantizar que $L_k(x_k) = 1$, normalizamos dividiendo por ese mismo producto evaluado en x_k . Así, obtenemos la fórmula explícita:

$$L_k(x) = \prod_{\substack{j=0 \\ j \neq k}}^n \frac{x - x_j}{x_k - x_j}$$

El uso de esta base polinómica para resolver el problema de interpolación se conoce como **Interpolación de Lagrange**. Es especialmente útil para interpolar funciones continuas, construyendo los pares de datos de la forma $(x_i, f(x_i))$ y buscando un polinomio que aproxime a la función original.

Teorema 4.4.1 [Existencia y unicidad del polinomio de Lagrange]

Dado un conjunto de puntos $\{(x_i, y_i)\}_{i=0}^n$ con abscisas distintas, existe un único polinomio $p \in \mathcal{P}_n$ tal que $p(x_i) = y_i$ para todo $i = 0, 1, \dots, n$. Dicho polinomio se puede expresar linealmente mediante la fórmula de Lagrange:

$$p(x) = \sum_{i=0}^n y_i L_i(x)$$

Demostración. Comprobemos primero la **existencia**. Para ver que el polinomio $p(x)$ definido por la suma anterior es efectivamente el polinomio interpolador, basta con evaluarlo en un nodo genérico x_k :

$$p(x_k) = \sum_{i=0}^n y_i L_i(x_k) = y_0 \underbrace{L_0(x_k)}_0 + \dots + y_k \underbrace{L_k(x_k)}_1 + \dots + y_n \underbrace{L_n(x_k)}_0 = y_k$$

Esto demuestra que satisface las condiciones de interpolación. Además, está bien definido porque los denominadores de $L_i(x)$ nunca se anulan, ya que por hipótesis $x_i \neq x_j$ si $i \neq j$.

Para demostrar la **unicidad**, procedemos por reducción al absurdo. Supongamos que existen dos polinomios distintos $p, q \in \mathcal{P}_n$ que interpolan los mismos datos, es decir:

$$p(x_i) = q(x_i) = y_i \quad \forall i \in \{0, 1, \dots, n\}$$

Definimos el polinomio diferencia $d(x) = p(x) - q(x)$. Al ser la resta de dos polinomios de grado a lo sumo n , resulta que $d \in \mathcal{P}_n$. Evaluando en los nodos obtenemos:

$$d(x_i) = p(x_i) - q(x_i) = y_i - y_i = 0 \quad \forall i = 0, 1, \dots, n$$

Esto significa que el polinomio $d(x)$, de grado a lo sumo n , tiene al menos $n + 1$ raíces distintas. Por el Teorema Fundamental del Álgebra, el único polinomio que cumple esto es el polinomio nulo. Por consiguiente, $d(x) \equiv 0$, lo que implica que $p(x) \equiv q(x)$, demostrando que el polinomio interpolador es verdaderamente único. $\square$

4.5 Error de interpolación

Una vez construido el polinomio interpolador p_n para una función f , es natural preguntarse cuán buena es esta aproximación en los puntos que no pertenecen al conjunto de nodos (es decir, para $x \neq x_i$).

Definición 4.5.1

El error de interpolación de la función f aproximada mediante el polinomio de Lagrange p_n de grado

n se define como la función:

$$E_n(x) = f(x) - p_n(x)$$

Ejemplo

Para ilustrar que aumentar el grado del polinomio no siempre reduce el error en todo el intervalo (fenómeno de Runge), tomemos la función de Runge:


$$f(x) = \frac{\sin(x)}{1+x^2}$$

y utilicemos una malla de nodos equiespaciados:

$$x_i \in \{-3, -2, -1, 0, 1, 2, 3\}, \quad y_i = f(x_i).$$

Al simplificar el polinomio interpolador de Lagrange de grado 6, obtenemos:

$$p_6(x) = 0.5770157x - 0.1678665x^3 + 0.0115862x^5.$$



Para poder acotar analíticamente este error, presentamos el siguiente teorema fundamental. Para simplificar la notación, definiremos primero el **polinomio nodal** $\omega(x)$ de grado $n+1$ como:

$$\omega(x) = \prod_{i=0}^n (x - x_i) = (x - x_0)(x - x_1) \cdots (x - x_n)$$

Teorema 4.5.1 [Fórmula del error de interpolación]

Sea $f \in C^{n+1}([a, b])$ y sea $\{x_i\}_{i=0}^n \subset [a, b]$ un conjunto de nodos distintos. Sea $p_n \in \mathcal{P}_n$ el polinomio que interpola a f en dichos nodos.

Para cualquier punto $x \in [a, b]$, existe un número ξ_x perteneciente al intervalo abierto delimitado por el valor mínimo y máximo de los datos (es decir, en el intervalo más pequeño que contiene a $x, x_0, \dots, x_n$) tal que:

$$E_n(x) = f(x) - p_n(x) = \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \prod_{i=0}^n (x - x_i) = \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \omega(x)$$

A partir de esto, si podemos acotar la derivada $(n+1)$ -ésima de la función en el intervalo, podemos establecer una cota superior absoluta para el error:

$$|E_n(x)| \leq \frac{\max_{t \in [a, b]} |f^{(n+1)}(t)|}{(n+1)!} \prod_{i=0}^n |x - x_i|$$

Demostración. Fijemos un punto arbitrario $x \in [a, b]$. Si x coincide con alguno de los nodos x_i , la fórmula se cumple trivialmente pues ambos lados valen 0 (ya que $p_n(x_i) = f(x_i)$ y $\omega(x_i) = 0$).

Asumamos entonces que $x \neq x_i$ para todo i . Definamos una nueva variable t y construyamos la siguiente función auxiliar $F(t)$:

$$F(t) = (f(t) - p_n(t)) \omega(x) - (f(x) - p_n(x)) \omega(t)$$

Analicemos las propiedades fundamentales de esta función $F(t)$:

1. Regularidad: Como $f \in C^{n+1}([a, b])$ y tanto p_n como ω son polinomios (y por tanto infinitamente derivables), se sigue que $F \in C^{n+1}([a, b])$.
2. Raíces en los nodos: Evaluando $F(t)$ en cualquier nodo $t = x_i$, recordamos que $f(x_i) - p_n(x_i) = 0$ y $\omega(x_i) = 0$. Por lo tanto:

$$F(x_i) = 0 \cdot \omega(x) - (f(x) - p_n(x)) \cdot 0 = 0 \quad \forall i = 0, \dots, n$$

3. Raíz en el punto fijado: Si evaluamos $F(t)$ en $t = x$, obtenemos:

$$F(x) = (f(x) - p_n(x))\omega(x) - (f(x) - p_n(x))\omega(x) = 0$$

Por lo tanto, la función $F(t)$ tiene al menos $n + 2$ raíces distintas en el intervalo. Por el Teorema de Rolle, entre cada par de raíces de $F(t)$ debe existir al menos una raíz de su derivada $F'(t)$. Esto significa que $F'(t)$ tiene al menos $n + 1$ raíces.

Aplicando el Teorema de Rolle de forma reiterada: $F''(t)$ tendrá n raíces, $F'''(t)$ tendrá $n - 1$ raíces, y así sucesivamente. Tras derivar $n + 1$ veces, existirá al menos un punto, que llamaremos ξ_x , estrictamente contenido en el intervalo abarcado por los nodos y x , donde la derivada $(n + 1)$ -ésima se anula:

$$F^{(n+1)}(\xi_x) = 0$$

Ahora, derivemos analíticamente la expresión de $F(t)$ $n + 1$ veces respecto a la variable t . Notemos que x actúa como una constante:

$$F^{(n+1)}(t) = \left(f^{(n+1)}(t) - p_n^{(n+1)}(t) \right) \omega(x) - (f(x) - p_n(x)) \omega^{(n+1)}(t)$$

Sabemos dos cosas clave:

- $p_n(t)$ es un polinomio de grado n , por lo que su derivada $(n + 1)$ -ésima es estrictamente cero: $p_n^{(n+1)}(t) = 0$.
- $\omega(t) = t^{n+1} + \dots$ es un polinomio mónico de grado $n + 1$. Derivándolo $n + 1$ veces obtenemos la constante factorial: $\omega^{(n+1)}(t) = (n + 1)!$.

Sustituyendo esto en la derivada:

$$F^{(n+1)}(t) = f^{(n+1)}(t)\omega(x) - (f(x) - p_n(x))(n + 1)!$$

Finalmente, evaluando en el punto ξ_x donde sabemos que se anula:

$$0 = f^{(n+1)}(\xi_x)\omega(x) - E_n(x) \cdot (n + 1)!$$

Despejando el término del error $E_n(x)$, llegamos exactamente a la demostración de la fórmula de nuestro teorema:

$$E_n(x) = \frac{f^{(n+1)}(\xi_x)}{(n + 1)!} \omega(x) = \frac{f^{(n+1)}(\xi_x)}{(n + 1)!} \prod_{i=0}^n (x - x_i)$$

□

4.6 Método de Newton

Aunque el método de Lagrange es excelente desde el punto de vista teórico para demostrar la existencia y unicidad del polinomio interpolador, presenta un inconveniente práctico importante: si decidimos añadir un nuevo nodo de interpolación a nuestro conjunto de datos, debemos recalcular todos los polinomios base $L_i(x)$ desde cero.

Para resolver este problema computacional, el **Método de Newton** propone construir el polinomio interpolador de forma progresiva o incremental. Es decir, construiremos el polinomio de grado n reciclando el polinomio de grado $n - 1$ y añadiéndole un término corrector. Para estructurar este cálculo, necesitamos introducir la herramienta de las diferencias divididas.

4.6.1 Diferencias divididas

Definición 4.6.1 [Diferencias divididas]

Dada una función f (o un conjunto de datos empíricos) evaluada en un conjunto de nodos distintos $\{x_i\}_{i=0}^n$, definimos las diferencias divididas de forma recursiva según su orden:

- **Orden 0:** Coinciden con las evaluaciones de la función en los nodos.

$$f[x_i] = f(x_i) = y_i$$

- **Orden 1:** Tasan la tasa de variación media entre dos nodos.

$$f[x_i, x_j] = \frac{f[x_j] - f[x_i]}{x_j - x_i} \quad \text{para } i \neq j$$

- **Orden k :** En general, la diferencia dividida de orden k evaluada en los nodos $x_i, x_{i+1}, \dots, x_{i+k}$ se define a partir de las diferencias de orden $k-1$:

$$f[x_i, x_{i+1}, \dots, x_{i+k}] = \frac{f[x_{i+1}, x_{i+2}, \dots, x_{i+k}] - f[x_i, x_{i+1}, \dots, x_{i+k-1}]}{x_{i+k} - x_i}$$

Ejemplo

Si queremos calcular explícitamente las diferencias divididas iterando sobre los primeros tres nodos x_0, x_1, x_2 , el proceso algebraico es el siguiente:

$$\text{Orden 0: } f[x_0] = y_0$$

$$\text{Orden 1: } f[x_0, x_1] = \frac{y_1 - y_0}{x_1 - x_0}$$

$$\text{Orden 2: } f[x_0, x_1, x_2] = \frac{f[x_1, x_2] - f[x_0, x_1]}{x_2 - x_0} = \frac{\frac{y_2 - y_1}{x_2 - x_1} - \frac{y_1 - y_0}{x_1 - x_0}}{x_2 - x_0}$$

Una propiedad fundamental que simplifica notablemente el cálculo y la teoría subyacente es la invariancia ante permutaciones.

Proposición 4.6.1 [Simetría de las diferencias divididas]

Las diferencias divididas son funciones simétricas respecto a sus argumentos. Es decir, el valor numérico de una diferencia dividida depende únicamente del conjunto de nodos sobre los que se evalúa, y no del orden en el que se enumeran. Por ejemplo, para el orden 1:

$$f[x_0, x_1] = \frac{f(x_1) - f(x_0)}{x_1 - x_0} = \frac{f(x_0) - f(x_1)}{x_0 - x_1} = f[x_1, x_0]$$

En general, si σ es cualquier permutación del conjunto de índices $\{0, 1, \dots, k\}$, se cumple rigurosamente que:

$$f[x_0, x_1, \dots, x_k] = f[x_{\sigma(0)}, x_{\sigma(1)}, \dots, x_{\sigma(k)}]$$

4.6.2 Construcción del Polinomio de Newton

La idea central del método de Newton es construir una sucesión de polinomios $\{p_0, p_1, \dots, p_n\}$ donde cada $p_k \in \mathcal{P}_k$ interpola a la función en los primeros $k + 1$ nodos, apoyándose en el polinomio anterior.

Definición 4.6.2 [Construcción progresiva de Newton]

Dado el problema de interpolación en los nodos $\{x_i\}_{i=0}^n$, construimos el polinomio paso a paso:

- **Paso $n = 0$:** El polinomio $p_0 \in \mathcal{P}_0$ es una constante que interpola en x_0 .

$$p_0(x) = f[x_0]$$

Si utilizamos este polinomio para aproximar un punto genérico x , cometemos un error que podemos expresar algebraicamente usando diferencias divididas:

$$E_0(x) = f(x) - p_0(x) = f(x) - f(x_0) = \frac{f(x) - f(x_0)}{x - x_0}(x - x_0) = f[x, x_0](x - x_0)$$

- **Paso $n = 1$:** Buscamos un polinomio $p_1 \in \mathcal{P}_1$ que interpole en x_0 y x_1 . Lo planteamos sumando un término corrector lineal a $p_0(x)$:

$$p_1(x) = p_0(x) + \alpha(x - x_0) = f[x_0] + \alpha(x - x_0)$$

Para que interpole en x_1 , forzamos que $p_1(x_1) = f[x_1]$:

$$f[x_1] = f[x_0] + \alpha(x_1 - x_0) \implies \alpha = \frac{f[x_1] - f[x_0]}{x_1 - x_0} = f[x_0, x_1]$$

Sustituyendo el coeficiente α , obtenemos la forma final y su error asociado:

$$p_1(x) = p_0(x) + f[x_0, x_1](x - x_0)$$

$$E_1(x) = f(x) - p_1(x) = f[x_0, x_1, x](x - x_0)(x - x_1)$$

- **Paso General (Inducción):** La estructura observada sugiere que el polinomio de grado n se obtiene sumando al polinomio de grado $n - 1$ un término proporcional al producto de las distancias a los nodos previos, ponderado por la diferencia dividida de orden n .

Teorema 4.6.1 [Fórmula de Interpolación de Newton]

Sea $\{x_i, y_i\}_{i=0}^n$ un conjunto de datos para un problema de interpolación. El único polinomio $p_n \in \mathcal{P}_n$ que satisface $p_n(x_i) = y_i$ para todo $i = 0, \dots, n$ puede expresarse en la forma de Newton:

$$p_n(x) = p_{n-1}(x) + f[x_0, x_1, \dots, x_n] \prod_{j=0}^{n-1} (x - x_j)$$

Desarrollando la recursión, la forma canónica del polinomio de Newton es:

$$p_n(x) = f[x_0] + \sum_{k=1}^n \left(f[x_0, \dots, x_k] \prod_{j=0}^{k-1} (x - x_j) \right)$$

Además, el error exacto de interpolación en un punto cualquiera x viene dado por:

$$E_n(x) = f(x) - p_n(x) = f[x_0, x_1, \dots, x_n, x] \prod_{j=0}^n (x - x_j)$$

Demostración. Procederemos por inducción matemática sobre el número de nodos. Ya hemos validado los casos base $n = 0$ y $n = 1$ en la definición previa.

Asumamos como hipótesis de inducción que el teorema es cierto para n , es decir, que $p_n(x)$ interpola los primeros $n + 1$ puntos y que el error asociado cumple:

$$f(x) = p_n(x) + f[x_0, x_1, \dots, x_n, x] \prod_{j=0}^n (x - x_j) \quad (1)$$

Queremos construir el polinomio $p_{n+1} \in \mathcal{P}_{n+1}$ que interpole un nodo adicional x_{n+1} . Proponemos la estructura aditiva:

$$p_{n+1}(x) = p_n(x) + q_{n+1}(x)$$

Como $p_n(x)$ ya interpola correctamente en los nodos $x_0, \dots, x_n$, necesitamos que el término corrector $q_{n+1}(x)$ no altere esos valores. Por tanto, $q_{n+1}(x_i) = 0$ para $i = 0, \dots, n$. Dado que q_{n+1} es un polinomio de grado a lo sumo $n + 1$ con $n + 1$ raíces conocidas, debe ser obligatoriamente de la forma:

$$q_{n+1}(x) = \alpha \prod_{j=0}^n (x - x_j)$$

Para determinar la constante α , imponemos la condición de interpolación en el nuevo nodo x_{n+1} :

$$p_{n+1}(x_{n+1}) = f(x_{n+1}) \implies f(x_{n+1}) = p_n(x_{n+1}) + \alpha \prod_{j=0}^n (x_{n+1} - x_j)$$

Despejando α :

$$\alpha = \frac{f(x_{n+1}) - p_n(x_{n+1})}{\prod_{j=0}^n (x_{n+1} - x_j)}$$

Si evaluamos la ecuación (1) de nuestra hipótesis de error exactamente en el nodo $x = x_{n+1}$, obtenemos:

$$f(x_{n+1}) - p_n(x_{n+1}) = f[x_0, x_1, \dots, x_n, x_{n+1}] \prod_{j=0}^n (x_{n+1} - x_j)$$

Sustituyendo esto en la expresión de α , los productos se cancelan algebraicamente y concluimos de forma exacta que:

$$\alpha = f[x_0, x_1, \dots, x_n, x_{n+1}]$$

Por consiguiente, el polinomio queda verificado:

$$p_{n+1}(x) = p_n(x) + f[x_0, x_1, \dots, x_n, x_{n+1}] \prod_{j=0}^n (x - x_j)$$

Para completar la demostración, el nuevo error de interpolación usando propiedades de diferencias divididas

resulta ser:

$$\begin{aligned}
 E_{n+1}(x) &= f(x) - p_{n+1}(x) \\
 &= f(x) - p_n(x) - f[x_0, \dots, x_{n+1}] \prod_{j=0}^n (x - x_j) \\
 &= (f[x_0, \dots, x_n, x] - f[x_0, \dots, x_{n+1}]) \prod_{j=0}^n (x - x_j) \\
 &= f[x_0, \dots, x_{n+1}, x] \prod_{j=0}^{n+1} (x - x_j)
 \end{aligned}$$

Lo cual confirma la validez del teorema para el paso $n + 1$, concluyendo la demostración. $\square$

4.7 Splines

Como hemos visto, la interpolación polinómica global (utilizando un único polinomio de grado n para todos los puntos) presenta problemas severos de oscilación en los extremos del intervalo cuando n es grande, un comportamiento conocido como el fenómeno de Runge. Para mitigar esto, en lugar de usar un solo polinomio de grado elevado, dividiremos el intervalo en pequeños segmentos y usaremos polinomios de grado bajo en cada uno, exigiendo que se unan de forma suave. A estas funciones definidas a trozos se les llama **Splines**.

Definición 4.7.1 [Partición de un intervalo]

Dado un intervalo cerrado $[a, b] \subset \mathbb{R}$, una partición Δ de dicho intervalo es un conjunto ordenado de $n + 1$ puntos (llamados nodos) tal que:

$$a = x_0 < x_1 < x_2 < \dots < x_n = b$$

Denotaremos la longitud de cada subintervalo como $h_i = x_i - x_{i-1}$ para $i = 1, \dots, n$.

Definición 4.7.2 [Función spline]

Dada una partición Δ y un conjunto de datos $\{(x_i, y_i)\}_{i=0}^n$, una función spline de orden $k \in \mathbb{N}$ es una función $S : [a, b] \rightarrow \mathbb{R}$ que satisface las siguientes tres condiciones:

1. **Regularidad global:** $S \in C^{k-1}([a, b])$. Es decir, la función y sus primeras $k - 1$ derivadas son continuas en todo el intervalo $[a, b]$.
2. **Estructura local:** $S|_{[x_{i-1}, x_i]} \in \mathcal{P}_k$ para cada $i = 1, \dots, n$. Es decir, en cada subintervalo, S se comporta exactamente como un polinomio de grado menor o igual a k .
3. **Condición de interpolación:** $S(x_i) = y_i$ para todo $i = 0, 1, \dots, n$.

Comúnmente, a esta función se le denota como S_k para explicitar su orden.

Veamos los casos elementales más utilizados en la práctica numérica:

Spline lineal (Orden $k = 1$):


Una función S es un spline de orden 1 si es continua globalmente ($S \in C^0([a, b])$) y en cada tramo es

un polinomio de grado 1 (una recta). Geométricamente, esto equivale a unir los puntos de interpolación mediante segmentos de recta.

Gráficamente, si tomamos la siguiente tabla de datos empíricos:

x_i	1	2	4	5	6
y_i	3	-2	0	-1	4

El spline lineal resultante se visualiza de la siguiente forma:



Spline cuadrático (Orden $k = 2$):

En este caso, $S \in C^1([a, b])$ (función y primera derivada continuas) y está formado por arcos de parábola ($\mathcal{P}_2$) en cada subintervalo. La transición entre una parábola y otra en los nodos x_i se realiza sin cambios bruscos de pendiente.

Spline cúbico (Orden $k = 3$):

Es el tipo de spline más utilizado en ingeniería y diseño gráfico. Requiere que $S \in C^2([a, b])$ (continuidad de función, primera y segunda derivada) y utiliza polinomios cúbicos ($\mathcal{P}_3$) en cada tramo.

Analicemos los grados de libertad de un spline cúbico. Como tenemos n subintervalos y un polinomio de grado 3 en cada uno, disponemos de $4n$ coeficientes desconocidos.

- **Interpolación:** Que la curva pase por los extremos de cada intervalo aporta $2n$ ecuaciones.
- **Continuidad en los nodos interiores (C^0, C^1, C^2):** En los $n - 1$ nodos interiores, igualamos el valor, la derivada primera y la derivada segunda de los polinomios adyacentes. Esto aporta $3(n - 1)$ ecuaciones.

En total tenemos $2n + 3n - 3 = 5n - 3$ ecuaciones. ¡Pero esperábamos $4n$! Un análisis correcto nos dice que evaluar la función en todos los puntos da $n + 1$ ecuaciones, y la continuidad interna da $3(n - 1)$, sumando $4n - 2$ ecuaciones. Faltan exactamente **dos ecuaciones** adicionales para que el sistema tenga solución única. Estas provienen de las condiciones de contorno:

- **Frontera Natural:** Se impone que la curvatura en los extremos sea nula, es decir, $S''(x_0) = S''(x_n) = 0$.
- **Frontera Sujeta (Clamped):** Se especifican las pendientes inicial y final empíricamente, $S'(x_0) = \alpha$ y $S'(x_n) = \beta$.
- **Frontera Periódica:** Útil para curvas cerradas, obliga a que $S'(x_0) = S'(x_n)$ y $S''(x_0) = S''(x_n)$.

4.7.1 Construcción del Spline Cúbico Natural

Para determinar unívocamente un spline cúbico $S(x)$ interpolante en los nodos $x_0, x_1, \dots, x_n$ (con valores asociados $y_0, y_1, \dots, y_n$), resulta altamente ineficiente resolver un sistema de $4n$ ecuaciones. En su lugar, el método estándar consiste en parametrizar el problema utilizando las derivadas segundas del spline en los nodos.

Sea $h_i = x_i - x_{i-1}$ la longitud del i -ésimo subintervalo. El desarrollo se estructura en los siguientes pasos lógicos:

1. **Definición de Momentos:** Para cada nodo $i = 0, 1, \dots, n$, definimos unas incógnitas auxiliares llamadas *momentos*, que representan la curvatura en el nodo:

$$m_i = S''(x_i)$$

Si imponemos la condición de **Frontera Natural**, la curvatura en los extremos debe ser nula. Por tanto, sabemos a priori que $m_0 = m_n = 0$.

2. **Construcción analítica del polinomio por integración:** Dado que el spline $S(x)$ está formado por polinomios cúbicos en cada tramo $x \in [x_{i-1}, x_i]$, su derivada segunda $S''(x)$ debe ser un polinomio de grado 1 (una recta). Esta recta debe interpolar los momentos (x_{i-1}, m_{i-1}) y (x_i, m_i) . Su ecuación exacta es:

$$S''(x) = m_{i-1} \frac{x_i - x}{h_i} + m_i \frac{x - x_{i-1}}{h_i}$$

Para hallar la expresión de $S(x)$, integramos dos veces respecto a x . La primera integración nos da la pendiente $S'(x)$:

$$S'(x) = -m_{i-1} \frac{(x_i - x)^2}{2h_i} + m_i \frac{(x - x_{i-1})^2}{2h_i} + C_1$$

Integrando una segunda vez, obtenemos el valor de la función. Para facilitar el manejo algebraico, expresaremos las constantes de integración como una combinación lineal en función de $(x_i - x)$ y $(x - x_{i-1})$:

$$S(x) = m_{i-1} \frac{(x_i - x)^3}{6h_i} + m_i \frac{(x - x_{i-1})^3}{6h_i} + A(x_i - x) + B(x - x_{i-1})$$

Para determinar las constantes A y B , aplicamos las condiciones de interpolación en los extremos del intervalo, es decir, $S(x_{i-1}) = y_{i-1}$ y $S(x_i) = y_i$:

- Evaluando en x_{i-1} : $y_{i-1} = m_{i-1} \frac{h_i^3}{6h_i} + Ah_i \implies A = \frac{y_{i-1}}{h_i} - \frac{m_{i-1}h_i}{6}$
- Evaluando en x_i : $y_i = m_i \frac{h_i^3}{6h_i} + Bh_i \implies B = \frac{y_i}{h_i} - \frac{m_i h_i}{6}$

Sustituyendo A y B , la expresión final y unívoca del spline en el tramo i es:

$$\begin{aligned} S_i(x) = & \frac{m_{i-1}}{6h_i}(x_i - x)^3 + \frac{m_i}{6h_i}(x - x_{i-1})^3 \\ & + \left(\frac{y_{i-1}}{h_i} - \frac{m_{i-1}h_i}{6} \right) (x_i - x) + \left(\frac{y_i}{h_i} - \frac{m_i h_i}{6} \right) (x - x_{i-1}) \end{aligned} \quad (2)$$

3. **Condición de continuidad para la primera derivada (C^1):** La ecuación (2) garantiza que la función pasa por los puntos y que su curvatura es continua. Sin embargo, para que el spline sea suave, debemos forzar que las pendientes de dos tramos adyacentes coincidan en los nodos interiores. Es decir, para cada $i = 1, \dots, n-1$:

$$S'_i(x_i) = S'_{i+1}(x_i)$$

Derivando la expresión analítica (2) y evaluando en el nodo x_i para el tramo izquierdo (usando h_i) y el tramo derecho (usando h_{i+1}), obtenemos:

$$S'_i(x_i) = \frac{h_i}{6}m_{i-1} + \frac{h_i}{3}m_i + \frac{y_i - y_{i-1}}{h_i}$$

$$S'_{i+1}(x_i) = -\frac{h_{i+1}}{3}m_i - \frac{h_{i+1}}{6}m_{i+1} + \frac{y_{i+1} - y_i}{h_{i+1}}$$

Igualando ambas expresiones y agrupando las incógnitas (los momentos m) a un lado de la igualdad, deducimos la relación fundamental del spline cúbico:

$$\frac{h_i}{6}m_{i-1} + \frac{h_i + h_{i+1}}{3}m_i + \frac{h_{i+1}}{6}m_{i+1} = \frac{y_{i+1} - y_i}{h_{i+1}} - \frac{y_i - y_{i-1}}{h_i} \quad (3)$$

4. **Formulación matricial del sistema:** Para mejorar el condicionamiento numérico, multiplicamos toda la ecuación (3) por el factor $\frac{6}{h_i + h_{i+1}}$, obteniendo la forma adimensional clásica:

$$\underbrace{\frac{h_i}{h_i + h_{i+1}}}_{\mu_i} m_{i-1} + 2m_i + \underbrace{\frac{h_{i+1}}{h_i + h_{i+1}}}_{\lambda_i} m_{i+1} = 6f[x_{i-1}, x_i, x_{i+1}]$$

Donde $f[\dots]$ denota la segunda diferencia dividida de Newton. Al aplicar esto a los $n - 1$ nodos interiores, y recordando que $m_0 = 0$ y $m_n = 0$, se genera un sistema lineal tridiagonal $\Lambda m = d$:

$$\begin{bmatrix} 2 & \lambda_1 & 0 & \cdots & 0 \\ \mu_2 & 2 & \lambda_2 & \cdots & 0 \\ 0 & \mu_3 & 2 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & \lambda_{n-1} \\ 0 & 0 & \cdots & \mu_{n-1} & 2 \end{bmatrix} \begin{bmatrix} m_1 \\ m_2 \\ m_3 \\ \vdots \\ m_{n-2} \\ m_{n-1} \end{bmatrix} = \begin{bmatrix} d_1 \\ d_2 \\ d_3 \\ \vdots \\ d_{n-2} \\ d_{n-1} \end{bmatrix}$$

Notemos que $\mu_i + \lambda_i = 1$. Como el elemento en la diagonal es 2, y la suma de los valores absolutos de los elementos extradiagonales es $|\mu_i| + |\lambda_i| = 1 < 2$, la matriz Λ es **diagonal estrictamente dominante**. Esto garantiza matemáticamente, mediante el Teorema de Gershgorin, que la matriz es no singular e invertible. Por ende, el sistema tiene una solución única para los momentos m_i , lo que demuestra la existencia y unicidad del spline cúbico natural.

Ejemplo

Apliquemos la teoría resolviendo a mano un spline cúbico natural para el siguiente conjunto de datos empíricos:

x_i	0	1	3
y_i	0	1	1

Tenemos $n = 2$ tramos. Los momentos en las fronteras son $m_0 = m_2 = 0$. Nuestra única incógnita es m_1 . Las longitudes de los intervalos son $h_1 = 1 - 0 = 1$ y $h_2 = 3 - 1 = 2$.

1. **Ecuaciones de la curvatura (S''):** Conociendo que los momentos son rectas que unen los valores $\{0, m_1, 0\}$, planteamos S'' :

$$S''(x) = \begin{cases} m_1 x & \text{si } x \in [0, 1] \\ -\frac{m_1}{2}(x - 3) & \text{si } x \in [1, 3] \end{cases}$$

2. **Integración a Velocidad (S'):** Integramos obteniendo constantes a_1 y a_2 :

$$S'(x) = \begin{cases} \frac{m_1}{2}x^2 + a_1 & \text{si } x \in [0, 1] \\ -\frac{m_1}{4}(x-3)^2 + a_2 & \text{si } x \in [1, 3] \end{cases}$$

3. **Integración a Posición (S):** Integramos nuevamente. En el segundo tramo, agruparemos la constante a_2 respecto a $(x-1)$ para facilitar la evaluación:

$$S(x) = \begin{cases} \frac{m_1}{6}x^3 + a_1x + b_1 & \text{si } x \in [0, 1] \\ -\frac{m_1}{12}(x-3)^3 + a_2(x-1) + b_2 & \text{si } x \in [1, 3] \end{cases}$$

4. **Forzar la Interpolación:** En $x=0$: $S(0)=0 \implies b_1=0$

$$\text{En } x=1 \text{ (Tramo 1): } S(1)=1 \implies \frac{m_1}{6} + a_1 = 1 \implies a_1 = 1 - \frac{m_1}{6}$$

$$\text{En } x=1 \text{ (Tramo 2): } S(1)=1 \implies -\frac{m_1}{12}(-8) + b_2 = 1 \implies \frac{2m_1}{3} + b_2 = 1 \implies b_2 = 1 - \frac{2m_1}{3}$$

$$\text{En } x=3: S(3)=1 \implies 0 + a_2(2) + b_2 = 1 \implies 2a_2 + 1 - \frac{2m_1}{3} = 1 \implies a_2 = \frac{m_1}{3}$$

5. **Imponer la continuidad de la primera derivada en $x=1$:** Para encontrar m_1 , exigimos que la curva no tenga un "pico" en $x=1$, es decir, los límites laterales de S' deben coincidir:

$$S'(1^-) = S'(1^+) \implies \frac{m_1}{2} + a_1 = -\frac{m_1}{4}(-2)^2 + a_2 \implies \frac{m_1}{2} + a_1 = -m_1 + a_2$$

Sustituyendo los valores de a_1 y a_2 :


$$\frac{m_1}{2} + \left(1 - \frac{m_1}{6}\right) = -m_1 + \frac{m_1}{3}$$

Resolviendo la ecuación llegamos a que $m_1 = -1$.

6. **Resultado final:** Sustituyendo $m_1 = -1$ en nuestras constantes ($a_1 = 7/6$, $a_2 = -1/3$, $b_2 = 5/3$), obtenemos las funciones cúbicas exactas del Spline:

$$S(x) = \begin{cases} -\frac{1}{6}x^3 + \frac{7}{6}x & \text{si } x \in [0, 1] \\ \frac{1}{12}(x-3)^3 - \frac{1}{3}(x-1) + \frac{5}{3} & \text{si } x \in [1, 3] \end{cases}$$

Gráficamente, hemos sustituido una trayectoria poligonal por curvas fluidas perfectas:



5 Diferenciación Numérica

5.1 Motivación e Introducción

En la práctica matemática y en la ingeniería, es extremadamente común enfrentarse al problema de calcular la derivada de una función $f(x)$ sin disponer de su expresión analítica explícita. Este escenario surge típicamente cuando la función subyacente es el resultado de un experimento físico, una simulación computacional compleja o una serie temporal de datos, presentándose únicamente como un conjunto discreto de valores tabulados:

$$\begin{array}{c|c} x_i & f(x_i) \\ \hline x_0 & f(x_0) \\ x_1 & f(x_1) \\ \vdots & \vdots \\ x_n & f(x_n) \end{array} \longrightarrow \text{¿Cómo estimar } f'(x), f''(x), \dots, f^{(m)}(x)?$$

El objetivo de la **diferenciación numérica** es aproximar las derivadas continuas de f utilizando combinaciones algebraicas de sus valores discretos. Para simplificar el desarrollo teórico y mejorar la estabilidad de los algoritmos, asumiremos que los nodos (puntos de evaluación) forman una **mallla uniforme o equiespaciada**. Es decir, la distancia entre dos puntos consecutivos es una constante $h > 0$, denominada "paso de mallla" o "tamaño de paso":

$$x_i = x_0 + ih \quad \text{para } i = 0, 1, \dots, n \implies h = x_{i+1} - x_i$$

Existen dos enfoques matemáticos fundamentales para construir estas aproximaciones:

- A. **Mediante Interpolación Polinómica:** Consiste en hallar un polinomio $p_n(x)$ que interpole los datos y tomar su derivada analítica $p'_n(x)$ como aproximación de $f'(x)$.
- B. **Mediante Desarrollos de Taylor:** Consiste en expandir la función $f(x)$ en series de Taylor alrededor del punto de interés y truncar algebraicamente la serie para despejar las derivadas. Es el método más sistemático y utilizado en la práctica (método de Diferencias Finitas).

5.2 Aproximación por interpolación polinómica

Idea fundamental: Sabemos por la teoría de interpolación que cualquier función suficientemente suave puede expresarse como un polinomio interpolador de grado n más un término de error:

$$f(x) = p_n(x) + E_n(x)$$

Donde, utilizando la base de Lagrange, tenemos:

$$p_n(x) = \sum_{i=0}^n f(x_i) L_i(x) \quad \text{y} \quad E_n(x) = \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \prod_{i=0}^n (x - x_i)$$


Si diferenciamos esta identidad respecto a x , obtenemos la relación exacta para la derivada:

$$f'(x) = p'_n(x) + E'_n(x) = \sum_{i=0}^n f(x_i) L'_i(x) + E'_n(x)$$

Al descartar el término del error $E'_n(x)$, la derivada del polinomio nos proporciona nuestra aproximación numérica.

Ejemplo

Derivemos la fórmula de aproximación más básica usando interpolación lineal ($n = 1$) con dos nodos adyacentes x_i y x_{i+1} .



El polinomio interpolador de Lagrange de grado 1 es la recta secante que une ambos puntos:

$$p_1(x) = f(x_i) \frac{x - x_{i+1}}{x_i - x_{i+1}} + f(x_{i+1}) \frac{x - x_i}{x_{i+1} - x_i}$$

Sustituyendo el paso de malla $h = x_{i+1} - x_i$, y notando que $x_i - x_{i+1} = -h$:

$$p_1(x) = -\frac{f(x_i)}{h}(x - x_{i+1}) + \frac{f(x_{i+1})}{h}(x - x_i)$$

Calculando su derivada, que por ser una recta es constante (su pendiente):

$$f'(x) \approx p_1'(x) = -\frac{f(x_i)}{h} + \frac{f(x_{i+1})}{h} = \frac{f(x_{i+1}) - f(x_i)}{h}$$

Esta expresión es el límite del cociente incremental sin llevar el límite a cero.

5.3 Aproximación mediante Desarrollos de Taylor

El enfoque basado en series de Taylor permite construir de manera sistemática fórmulas de diferencias finitas de diversos órdenes de precisión, brindando además una expresión analítica rigurosa para el término del error.

Ejemplo

1. Diferencia Progresiva (hacia adelante):

Asumamos que $f \in C^2([a, b])$. Evaluamos la serie de Taylor de f en el nodo siguiente $x_{i+1} = x_i + h$, centrada en x_i :

$$f(x_{i+1}) = f(x_i) + hf'(x_i) + \frac{h^2}{2}f''(\eta) \quad \text{para algún } \eta \in (x_i, x_{i+1})$$

Despejando $f'(x_i)$ algebraicamente:

$$f'(x_i) = \underbrace{\frac{f(x_{i+1}) - f(x_i)}{h}}_{\text{Aproximación}} - \underbrace{\frac{h}{2}f''(\eta)}_{\text{Error}}$$

Dado que el error es proporcional a h , decimos que este método tiene **precisión de primer orden**, y se denota como un error de $\mathcal{O}(h)$.

2. Diferencia Regresiva (hacia atrás):

De manera simétrica, si expandimos Taylor hacia el nodo anterior $x_{i-1} = x_i - h$:

$$f(x_{i-1}) = f(x_i) - hf'(x_i) + \frac{h^2}{2}f''(\xi) \quad \text{para algún } \xi \in (x_{i-1}, x_i)$$

Despejando $f'(x_i)$:

$$f'(x_i) = \underbrace{\frac{f(x_i) - f(x_{i-1}))}{h}}_{\text{Aproximación}} + \underbrace{\frac{h}{2}f''(\xi)}_{\text{Error}}$$

Nuevamente, la precisión es de primer orden, $\mathcal{O}(h)$.

5.4 Diferencias Centradas y Derivadas de Orden Superior

Las diferencias progresivas y regresivas arrastran un error de truncamiento $\mathcal{O}(h)$. Podemos obtener una aproximación mucho más precisa combinando ambas expansiones para cancelar los términos de error de menor orden.

Supongamos que $f \in C^3([a, b])$. Expandimos en Taylor hasta el tercer orden:

$$\begin{aligned} \text{(I)} \quad f(x_{i+1}) &= f(x_i) + hf'(x_i) + \frac{h^2}{2}f''(x_i) + \frac{h^3}{6}f'''(\eta_1) \\ \text{(II)} \quad f(x_{i-1}) &= f(x_i) - hf'(x_i) + \frac{h^2}{2}f''(x_i) - \frac{h^3}{6}f'''(\eta_2) \end{aligned}$$

Primera Derivada (Diferencia Centrada):

Si restamos la ecuación (II) de la ecuación (I), el término problemático de la segunda derivada (h^2) se cancela exactamente:

$$f(x_{i+1}) - f(x_{i-1}) = 2hf'(x_i) + \frac{h^3}{6}[f'''(\eta_1) + f'''(\eta_2)]$$

Por el Teorema del Valor Intermedio aplicado a funciones continuas, la media aritmética de derivadas en dos puntos puede expresarse como la derivada en un único punto $\zeta \in (x_{i-1}, x_{i+1})$. Así, $f'''(\eta_1) + f'''(\eta_2) = 2f'''(\zeta)$. Sustituyendo y despejando:

$$f'(x_i) = \frac{f(x_{i+1}) - f(x_{i-1}))}{2h} - \frac{h^2}{6}f'''(\zeta)$$

Al cancelar el término dominante del error, hemos logrado una **precisión de segundo orden** $\mathcal{O}(h^2)$. Esto significa que si reducimos el paso h a la mitad, el error de esta aproximación no se reduce a la mitad, sino a la cuarta parte.

Segunda Derivada:

Para hallar una aproximación numérica de $f''(x_i)$, requerimos que $f \in C^4([a, b])$ e incluimos el término de cuarto orden en Taylor. Esta vez, en lugar de restar, sumamos la ecuación (I) y la ecuación (II). Los términos que contienen derivadas impares (f' y f''') se cancelan por el cambio de signo:

$$f(x_{i+1}) + f(x_{i-1}) = 2f(x_i) + h^2f''(x_i) + \frac{h^4}{24}[f^{(4)}(\eta_1) + f^{(4)}(\eta_2)]$$

Aplicando nuevamente el Teorema del Valor Intermedio para consolidar el término del error y despejando la segunda derivada, obtenemos la **diferencia central de segundo orden**:

$$f''(x_i) = \frac{f(x_{i+1}) - 2f(x_i) + f(x_{i-1}))}{h^2} - \frac{h^2}{12}f^{(4)}(\zeta)$$

El error de esta aproximación también es de orden $\mathcal{O}(h^2)$.

6 Integración Numérica

6.1 Motivación e Introducción

El Cálculo Fundamental nos enseña que la integral definida de una función representa el área bajo su curva. Sin embargo, en la práctica científica e ingenieril, calcular analíticamente $S = \int_a^b f(x)dx$ mediante la regla de Barrow a menudo es imposible. Esto ocurre por dos motivos principales:

1. La función $f(x)$ no posee una primitiva expresable mediante funciones elementales (ej. $f(x) = e^{-x^2}$, fundamental en estadística).
2. No disponemos de la expresión analítica de $f(x)$, sino únicamente de un conjunto discreto de datos empíricos tomados en ciertos puntos (nodos):

$$\begin{array}{c|c} x_i & f(x_i) \\ \hline x_0 & f(x_0) \\ x_1 & f(x_1) \\ \vdots & \vdots \\ x_n & f(x_n) \end{array} \longrightarrow S = \int_a^b f(x)dx = \underbrace{\quad}_{\text{Fórmula aproximada}} + \underbrace{\quad}_E$$

Error de truncamiento

El objetivo de la **integración numérica** (o cuadratura numérica) es diseñar algoritmos que nos permitan calcular $\tilde{S}$ con la mayor precisión posible, acotando matemáticamente el error E cometido.

6.2 Aproximación mediante Interpolación (Fórmulas de Newton-Cotes)

La estrategia más natural para abordar este problema es sustituir la función original $f(x)$ por un polinomio interpolador $p_n(x)$ que pase por los nodos dados, ya que los polinomios son trivialmente integrables. Cuando los nodos de interpolación están **equiespaciados**, las fórmulas resultantes se conocen como la familia de **Fórmulas de Newton-Cotes**.

Basándonos en la teoría de interpolación, podemos expresar la función como la suma del polinomio de Lagrange y su término de error:

$$\underbrace{f(x)}_{\in C^{n+1}[a,b]} = \underbrace{p_n(x)}_{\text{Polinomio de Lagrange}} + \underbrace{E_n(x)}_{\text{Error de interpolación}}$$

Donde la base de Lagrange y el error vienen dados por:

$$p_n(x) = \sum_{i=0}^n f(x_i) L_i(x), \quad L_i(x) = \prod_{\substack{j=0 \\ j \neq i}}^n \frac{x - x_j}{x_i - x_j}$$

$$E_n(x) = \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \prod_{i=0}^n (x - x_i)$$

Integrando esta igualdad en el intervalo $[a, b]$, la integral exacta se descompone en la aproximación numérica más el error integral:

$$S = \int_a^b f(x)dx = \underbrace{\int_a^b p_n(x)dx}_{\tilde{S}_n} + \underbrace{\int_a^b E_n(x)dx}_E$$

Dado que la integral es un operador lineal, podemos intercambiar el sumatorio y la integral en el término $\tilde{S}_n$:


$$\tilde{S}_n = \int_a^b \left(\sum_{i=0}^n f(x_i) L_i(x) \right) dx = \sum_{i=0}^n f(x_i) \underbrace{\int_a^b L_i(x)dx}_{c_i}$$

Los valores c_i se denominan **pesos de cuadratura**. Nótese que los pesos c_i dependen únicamente de la geometría de los nodos y del intervalo, no de la función f . La fórmula general de cuadratura queda entonces como una combinación lineal de las evaluaciones de la función:

$$\tilde{S}_n = \sum_{i=0}^n c_i f(x_i)$$

Es crucial distinguir entre dos grandes clases de fórmulas de Newton-Cotes:

- **Fórmulas Cerradas:** Los extremos del intervalo de integración coinciden con los primeros y últimos nodos de interpolación ($x_0 = a$ y $x_n = b$).
- **Fórmulas Abiertas:** Los nodos de interpolación son estrictamente interiores al intervalo (a, b) . Son útiles cuando la función tiene una singularidad integrable en los extremos.



Veamos en detalle las fórmulas fundamentales derivadas de este principio.

6.3 Regla del Punto Medio (Rectángulo Centrado)

El caso más elemental de las fórmulas de integración de Newton-Cotes surge cuando decidimos aproximar nuestra función $f(x)$ utilizando un polinomio de grado $n = 0$. Geométricamente, esto equivale a sustituir la curva real por una línea recta horizontal.

La pregunta inmediata es: ¿a qué altura debemos trazar esta línea horizontal para minimizar el error? Si elegimos el valor de la función en el extremo izquierdo $f(a)$ o en el derecho $f(b)$, estaríamos utilizando la regla de los rectángulos clásica, la cual es muy imprecisa. Sin embargo, si evaluamos la función exactamente en el **punto medio** del intervalo, el área que calculamos de más por un lado tiende a compensarse con el área que nos falta por el otro (especialmente si la función es casi lineal en ese tramo).

Dado que el punto de evaluación no coincide con los límites de integración a y b , esta se clasifica como una **fórmula abierta**.

6.3.1 Construcción de la fórmula aproximada

Para formalizar esta idea, definimos el nodo central y la semi-amplitud del intervalo:

$$x_0 = \frac{a+b}{2} \quad \text{y} \quad h = \frac{b-a}{2}$$

Notemos que, con esta notación, el intervalo original $[a, b]$ se puede reescribir simétricamente como $[x_0 - h, x_0 + h]$. Nuestro polinomio interpolador de grado cero es simplemente la constante evaluada en el centro:

$$p_0(x) = f(x_0)$$

La integral aproximada, que denotaremos como $\tilde{S}_0$, es el área de un rectángulo de base $2h$ (la anchura total del intervalo) y altura $f(x_0)$. Analíticamente, la integral de una constante sale fuera del operador:

$$\tilde{S}_0 = \int_a^b p_0(x) dx = \int_{x_0-h}^{x_0+h} f(x_0) dx = f(x_0) \int_{x_0-h}^{x_0+h} 1 dx = f(x_0) [x]_{x_0-h}^{x_0+h}$$

Al evaluar los límites, obtenemos $(x_0 + h) - (x_0 - h) = 2h$. Por lo tanto, la fórmula de la Regla del Punto Medio es:

$$\boxed{\tilde{S}_0 = 2hf(x_0)}$$

6.3.2 Deducción del término del error

El verdadero reto en el análisis numérico no es hallar la fórmula, sino acotar matemáticamente el error exacto E que cometemos al usarla. Sabemos que el error total es la diferencia entre la integral real y nuestra aproximación:

$$E = \int_{x_0-h}^{x_0+h} f(x) dx - 2hf(x_0)$$

Para hallar una expresión manejable de este error, utilizaremos un recurso analítico muy elegante: parametrizaremos el error. En lugar de calcular el error de golpe en todo el intervalo de anchura h , definiremos una función $\varphi(r)$ que calcule el error en un subintervalo dinámico $[x_0 - r, x_0 + r]$, donde el "radio" r crece desde 0 hasta h :

$$\varphi(r) = \underbrace{\int_{x_0-r}^{x_0+r} f(x) dx}_{\text{Integral real en el subintervalo}} - \underbrace{2rf(x_0)}_{\text{Área del rectángulo interior}}$$

Estudiemos las propiedades de esta función:

1. **Condición inicial:** Si el radio es nulo ($r = 0$), el intervalo no tiene anchura. La integral de un punto es cero, y el área del rectángulo es cero. Por tanto, $\varphi(0) = 0$.
2. **Condición final:** Si expandimos el radio al máximo ($r = h$), recuperamos exactamente el error total de nuestro método. Por tanto, nuestro objetivo final es hallar $E = \varphi(h)$.

Para desentrañar $\varphi(r)$, vamos a derivarla respecto a la variable r . Para el término integral, debemos usar la **Regla de Leibniz** (una generalización del Teorema Fundamental del Cálculo), la cual establece que la derivada de una integral con límites dependientes de la variable se calcula evaluando la función en los límites y multiplicando por la derivada (regla de la cadena) de dichos límites:

$$\frac{d}{dr} \int_{a(r)}^{b(r)} f(x) dx = f(b(r)) \cdot b'(r) - f(a(r)) \cdot a'(r)$$

Aplicando esto a nuestra función $\varphi(r)$, donde el límite superior es $(x_0 + r)$ con derivada 1, y el límite inferior es $(x_0 - r)$ con derivada -1 :

$$\varphi'(r) = \left[f(x_0 + r) \cdot (1) - f(x_0 - r) \cdot (-1) \right] - 2f(x_0)$$

$$\varphi'(r) = f(x_0 + r) + f(x_0 - r) - 2f(x_0)$$

Si evaluamos esta primera derivada en $r = 0$, obtenemos $f(x_0) + f(x_0) - 2f(x_0) = 0$. Así que también sabemos que $\varphi'(0) = 0$.

Derivamos por segunda vez respecto a r (ahora utilizando simplemente la regla de la cadena convencional sobre f):

$$\varphi''(r) = f'(x_0 + r) \cdot (1) + f'(x_0 - r) \cdot (-1) = f'(x_0 + r) - f'(x_0 - r)$$

De nuevo, si evaluamos en cero, $\varphi''(0) = f'(x_0) - f'(x_0) = 0$.

Es aquí donde entra en juego la **Fórmula de Taylor**. Queremos expresar las derivadas evaluadas en puntos desplazados ($x_0 \pm r$) en función de la información central en x_0 . El desarrollo de Taylor de primer orden con el resto de Lagrange para la función f' nos dice:

$$\begin{cases} f'(x_0 + r) = f'(x_0) + f''(\xi_1) \cdot (r), & \text{donde } \xi_1 \in (x_0, x_0 + r) \\ f'(x_0 - r) = f'(x_0) + f''(\xi_2) \cdot (-r), & \text{donde } \xi_2 \in (x_0 - r, x_0) \end{cases}$$

Sustituyendo estas dos expresiones de Taylor en nuestra segunda derivada $\varphi''(r)$:

$$\varphi''(r) = [f'(x_0) + rf''(\xi_1)] - [f'(x_0) - rf''(\xi_2)]$$

Los términos $f'(x_0)$ se cancelan algebraicamente, dejándonos con:

$$\varphi''(r) = rf''(\xi_1) + rf''(\xi_2) = 2r \left(\frac{f''(\xi_1) + f''(\xi_2)}{2} \right)$$

Analicemos el factor entre paréntesis. Representa exactamente la **media aritmética** de la segunda derivada evaluada en dos puntos distintos del intervalo. Por el **Teorema de Bolzano** (o Teorema del Valor Intermedio), si asumimos que f'' es una función continua, esta debe obligatoriamente tomar todos los valores comprendidos entre su mínimo y su máximo. Por ende, existe algún punto intermedio $\theta_r \in (x_0 - r, x_0 + r)$ donde la función toma exactamente este valor medio:

$$\varphi''(r) = 2rf''(\theta_r)$$

6.3.3 Integración y Error Final

Ahora que tenemos la segunda derivada del error simplificada, el último paso es deshacer el camino integrando dos veces desde 0 hasta r .

Para la primera integración, utilizamos el hecho de que $\varphi'(0) = 0$:

$$\int_0^r \varphi''(s)ds = \varphi'(r) - \varphi'(0) \implies \varphi'(r) = \int_0^r 2sf''(\theta_s)ds$$

Dado que $f''(\theta_s)$ es continua, el *Teorema del Valor Medio Generalizado para Integrales* nos permite extraer f'' de la integral, evaluada en un nuevo punto genérico θ válido para todo el intervalo:

$$\varphi'(r) \approx f''(\theta) \int_0^r 2sds = f''(\theta) \left[s^2 \right]_0^r = f''(\theta)r^2$$

Integramos por segunda vez desde 0 hasta h , recordando que $\varphi(0) = 0$:

$$E = \varphi(h) = \int_0^h \varphi'(r)dr \approx f''(\theta) \int_0^h r^2dr = f''(\theta) \left[\frac{r^3}{3} \right]_0^h = \frac{f''(\theta)}{3}h^3$$

Finalmente, en la literatura matemática es común expresar este error en función de la anchura total del intervalo. Recordando nuestra definición inicial de que el intervalo completo es $b - a$, sabemos que $h = \frac{b-a}{2}$. Si sustituimos esto en la fórmula:

$$h^3 = \left(\frac{b-a}{2} \right)^3 = \frac{(b-a)^3}{8}$$

Al multiplicar esto por el $\frac{1}{3}$ de nuestra integración, obtenemos el denominador 24. Por tanto, el error de truncamiento exacto de la Regla del Punto Medio se presenta como:


$$\boxed{E_{\text{P.Medio}} = \frac{f''(\theta)}{3}h^3 = \frac{f''(\theta)}{24}(b-a)^3} \quad \text{para algún } \theta \in (a, b)$$

Este resultado es extraordinario: a pesar de aproximar la función con un polinomio de grado 0 (constante), el error depende de la segunda derivada (f''). Esto demuestra analíticamente que **la regla del punto medio integra de forma perfecta e impecable cualquier línea recta** (polinomio de grado 1), ya que la segunda derivada de una recta es cero, anulando el término del error.

6.4 Regla del Trapecio

La **Regla del Trapecio** constituye la primera fórmula *cerrada* de la familia de Newton-Cotes, correspondiente al uso de un polinomio interpolador de grado $n = 1$. En lugar de aproximar la función mediante una constante horizontal, en este método aproximaremos $f(x)$ mediante una función lineal (una recta secante) que conecta directamente los puntos extremos del intervalo de integración: $(x_0, f(x_0))$ y $(x_1, f(x_1))$, donde $x_0 = a$ y $x_1 = b$.

Definimos la amplitud del intervalo completo como $h = b - a$. Geométricamente, al proyectar esta recta secante sobre el eje de abscisas, el área aproximada bajo la curva corresponde exactamente al área de un trapecio, lo que da nombre al método.



6.4.1 Deducción analítica de la fórmula

Aunque la fórmula del área de un trapecio es bien conocida en geometría elemental, procedamos a demostrarla integrando la base polinómica de Lagrange. El polinomio interpolador lineal es:

$$p_1(x) = f(a)L_0(x) + f(b)L_1(x) = f(a)\frac{x-b}{a-b} + f(b)\frac{x-a}{b-a}$$

Nuestra integral aproximada $\tilde{S}_1$ se obtiene integrando este polinomio en el intervalo $[a, b]$. Calculemos los pesos de cuadratura c_0 y c_1 :

$$c_0 = \int_a^b \frac{x-b}{a-b} dx = \frac{1}{-(b-a)} \left[\frac{(x-b)^2}{2} \right]_a^b = -\frac{1}{h} \left(0 - \frac{(a-b)^2}{2} \right) = -\frac{1}{h} \left(-\frac{h^2}{2} \right) = \frac{h}{2}$$

$$c_1 = \int_a^b \frac{x-a}{b-a} dx = \frac{1}{b-a} \left[\frac{(x-a)^2}{2} \right]_a^b = \frac{1}{h} \left(\frac{(b-a)^2}{2} - 0 \right) = \frac{1}{h} \left(\frac{h^2}{2} \right) = \frac{h}{2}$$

Como ambos pesos resultan ser idénticos ($c_0 = c_1 = h/2$), al sustituirlos en la combinación lineal recuperamos la célebre Regla del Trapecio:

$$\boxed{\tilde{S}_1 = \int_a^b p_1(x) dx = \frac{h}{2} (f(a) + f(b))}$$

6.4.2 Análisis del error de truncamiento

Para acotar el error E , integramos el término del error de la interpolación de Lagrange de grado 1:

$$E = \int_a^b E_1(x) dx = \int_a^b \frac{f''(\xi_x)}{2!} (x-a)(x-b) dx$$

Donde ξ_x es un punto desconocido en (a, b) que depende de x . Esta dependencia impide extraer $f''(\xi_x)$ directamente de la integral. Para sortear esta dificultad, recurrimos a un resultado fundamental del cálculo integral:

Teorema 6.4.1 [Teorema del Valor Medio Ponderado para Integrales]

Sean $h, g \in C[a, b]$. Si la función peso $g(x)$ no cambia de signo en todo el intervalo $[a, b]$ (es decir, $g(x) \geq 0$ o $g(x) \leq 0 \forall x$), entonces existe un punto $\theta \in (a, b)$ tal que:

$$\int_a^b h(x)g(x)dx = h(\theta) \int_a^b g(x)dx$$

Observemos nuestra función polinómica $g(x) = (x-a)(x-b)$. Puesto que x siempre es mayor que a y menor que b dentro del intervalo de integración, el primer factor es positivo y el segundo es negativo. Por lo tanto, el producto siempre satisface que $(x-a)(x-b) \leq 0$. Como no cambia de signo, el teorema es aplicable tomando $h(x) = f''(\xi_x)/2$:

$$E = \frac{f''(\theta)}{2} \int_a^b (x-a)(x-b)dx \quad \text{para algún } \theta \in (a, b)$$

Para resolver la integral restante de forma limpia, aplicamos el cambio de variable $t = x - a \implies dt = dx$. Los nuevos límites de integración serán de 0 a $b - a$, es decir, de 0 a h :

$$\int_a^b (x-a)(x-b)dx = \int_0^h t(t-h)dt = \int_0^h (t^2 - ht)dt = \left[\frac{t^3}{3} - h\frac{t^2}{2} \right]_0^h = \frac{h^3}{3} - \frac{h^3}{2} = -\frac{h^3}{6}$$

Multiplicando este resultado por la constante que extrajimos gracias al teorema, obtenemos la expresión exacta del error:

$$E = \frac{f''(\theta)}{2} \left(-\frac{h^3}{6} \right) = \boxed{-\frac{f''(\theta)}{12} h^3}$$

6.4.3 Comparación conceptual

Es sumamente instructivo comparar este resultado con el obtenido en la fórmula abierta del punto medio. Si consideramos un mismo intervalo de integración de anchura total $L = b - a$, tenemos que $h = L$ para el trapecio.

- Error del Trapecio (Cerrada): $E_T = -\frac{f''(\theta)}{12} L^3$
- Error del Punto Medio (Abierta): $E_M = +\frac{f''(\theta)}{24} L^3$

De esta observación se extraen dos conclusiones geométricas fascinantes:

1. **Signos opuestos:** Si una función es convexa ($f'' > 0$), el trapecio sobreestima el área (error negativo, aproximación mayor que la real), mientras que el punto medio la subestima (error positivo).
2. **Magnitud:** El coeficiente del trapecio ($1/12$) es el doble que el del punto medio ($1/24$). Magnitudinalmente, ¡la evaluación en un solo punto bien elegido (el centro) es el doble de precisa que la evaluación en los dos extremos!


6.5 Regla de Simpson

Si continuamos aumentando el orden de nuestra aproximación llegamos a $n = 2$, dando lugar a la **Regla de Simpson** (o regla de Simpson 1/3). Esta es una fórmula *cerrada* en la que utilizaremos tres nodos equiespaciados para construir un polinomio interpolador cuadrático (una parábola) que se adapte a la curvatura de la función.

Los tres nodos elegidos son los extremos del intervalo y su punto medio exacto:

$$x_0 = a, \quad x_1 = \frac{a+b}{2}, \quad x_2 = b$$

La distancia uniforme entre nodos adyacentes es la semi-amplitud del intervalo: $h = \frac{b-a}{2}$.



6.5.1 Deducción analítica de los pesos de cuadratura

Para hallar la fórmula de la Regla de Simpson, debemos integrar el polinomio interpolador $p_2(x) = \sum_{i=0}^2 f(x_i)L_i(x)$. El cálculo directo en el intervalo $[a, b]$ es algebraicamente tedioso. Para simplificarlo drásticamente, aplicamos una traslación del sistema de coordenadas centrando el origen en el nodo medio x_1 .

Bajo este nuevo sistema local de variable $t = x - x_1$, el intervalo de integración $[a, b]$ se transforma en $[-h, h]$, y los nodos relativos son $t_0 = -h$, $t_1 = 0$, y $t_2 = h$. Procedemos a integrar los polinomios base de Lagrange $L_i(t)$ en este dominio simétrico para hallar los pesos c_i :

Cálculo de c_0 :

$$L_0(t) = \frac{(t-0)(t-h)}{(-h-0)(-h-h)} = \frac{t^2 - ht}{2h^2}$$

$$c_0 = \int_{-h}^h \frac{t^2 - ht}{2h^2} dt = \frac{1}{2h^2} \left[\frac{t^3}{3} - h \frac{t^2}{2} \right]_{-h}^h$$

Al evaluar, notamos que el término par t^2 evaluado simétricamente se anula ($\frac{h^3}{2} - \frac{h^3}{2} = 0$), dejando solo la contribución del término impar:

$$c_0 = \frac{1}{2h^2} \left(\frac{h^3}{3} - \frac{(-h)^3}{3} \right) = \frac{1}{2h^2} \left(\frac{2h^3}{3} \right) = \frac{h}{3}$$

Cálculo de c_1 :

$$L_1(t) = \frac{(t-(-h))(t-h)}{(0-(-h))(0-h)} = \frac{t^2 - h^2}{-h^2}$$

$$c_1 = \int_{-h}^h \frac{h^2 - t^2}{h^2} dt = \frac{1}{h^2} \left[h^2 t - \frac{t^3}{3} \right]_{-h}^h = \frac{1}{h^2} \left(2h^3 - \frac{2h^3}{3} \right) = \frac{1}{h^2} \left(\frac{4h^3}{3} \right) = \frac{4h}{3}$$

Cálculo de c_2 : Por pura simetría geométrica respecto al centro, la contribución del nodo derecho debe ser idéntica a la del nodo izquierdo. Por ende, $c_2 = c_0 = h/3$.

Reagrupando nuestra combinación lineal original $\tilde{S}_2 = c_0 f(x_0) + c_1 f(x_1) + c_2 f(x_2)$, extraemos el factor común $h/3$ y obtenemos la clásica **Regla de Simpson**:

$$\tilde{S}_2 = \frac{h}{3} [f(a) + 4f(x_1) + f(b)]$$

6.5.2 El milagro de la simetría: Análisis del error

El análisis del error de la Regla de Simpson revela uno de los resultados más hermosos del análisis numérico. Si procediéramos de manera estándar acotando el error del polinomio de Lagrange $E_2(x)$, esperaríamos que el error de integración dependiera de la tercera derivada, $f'''(\theta)$, al ser un método de interpolación cuadrático.

Sin embargo, recordemos el término del error de Lagrange:

$$E = \int_a^b \frac{f'''(\xi_x)}{3!} (x - x_0)(x - x_1)(x - x_2) dx$$

Si trasladamos esto a nuestro sistema simétrico $[-h, h]$, el producto nodal es $t(t+h)(t-h) = t(t^2 - h^2) = t^3 - th^2$. ¡Esta es una **función impar**! Si asumiéramos que f''' es constante, la integral de una función impar en un intervalo simétrico es **exactamente cero**.

Esto significa que el término dominante del error se anula completamente por cancelación geométrica. Para encontrar el verdadero error remanente, debemos recurrir a un desarrollo de Taylor de orden superior (extendiendo la función auxiliar $\varphi(r)$ hasta la cuarta derivada). Tras una rigurosa derivación analítica, el término dominante sobrevive en el cuarto orden:

$$E_{\text{Simpson}} = -\frac{h^5}{90} f^{(4)}(\theta) \quad \text{para algún } \theta \in (a, b)$$

Consecuencia Fundamental (Grado de Precisión):

Hemos utilizado un polinomio de grado $n = 2$ (una parábola) para aproximar la función. Sin embargo, observando la fórmula del error, vemos que este depende de $f^{(4)}(\theta)$.

¿Qué ocurre si integramos un polinomio de grado 3 (un polinomio cúbico)? La cuarta derivada de cualquier polinomio cúbico es invariablemente nula ($f^{(4)}(x) = 0$). Por lo tanto, el error es cero. De forma asombrosa, **la Regla de Simpson integra polinomios cúbicos de manera exacta**, exhibiendo lo que se conoce en la literatura como un grado de precisión superior al esperado por su número de nodos.

6.6 Tabla Resumen de Fórmulas Simples

Método	Fórmula $\tilde{S}$	h	Error Global (En función de $L = b - a$)
Punto Medio (Abierta, $n = 0$)	$L \cdot f(\frac{a+b}{2})$	$L/2$	$\frac{f''(\theta)}{24} L^3$
Trapezio (Cerrada, $n = 1$)	$\frac{L}{2} [f(a) + f(b)]$	L	$-\frac{f''(\theta)}{12} L^3$
Simpson (Cerrada, $n = 2$)	$\frac{L}{6} [f(a) + 4f(x_1) + f(b)]$	$L/2$	$-\frac{f^{(4)}(\theta)}{2880} L^5$

6.7 Fórmulas Compuestas de Integración


Las fórmulas simples de Newton-Cotes (como el Trapecio o Simpson) presentan un límite operativo evidente: si el intervalo de integración $[a, b]$ es muy extenso, la aproximación de la función mediante un único

polinomio global de bajo grado resultará muy deficiente. Por otro lado, incrementar el grado n del polinomio global para todo el intervalo no es una solución viable, ya que desencadena el fenómeno de Runge (oscilaciones violentas en los extremos).

Para remediar esta situación y lograr una precisión arbitrariamente alta, recurrimos a las **Fórmulas Compuestas**. La estrategia de "divide y vencerás" consiste en particionar el intervalo macroscópico $[a, b]$ en n subintervalos uniformes (o "paneles") de ancho constante h :

$$h = \frac{b-a}{n} \implies x_i = a + i \cdot h \quad \text{para } i = 0, 1, \dots, n$$

Posteriormente, aplicamos una regla de cuadratura simple de bajo orden de forma aislada en cada pequeña franja.



Amparándonos en la propiedad de aditividad del operador integral respecto al dominio, podemos expresar la integral total como la suma exacta de las integrales en cada subintervalo:

$$S = \int_a^b f(x)dx = \sum_{i=0}^{n-1} \int_{x_i}^{x_{i+1}} f(x)dx = \sum_{i=0}^{n-1} (\tilde{S}_i + E_i) = \underbrace{\sum_{i=0}^{n-1} \tilde{S}_i}_{\tilde{S}_{\text{Compuesta}}} + \underbrace{\sum_{i=0}^{n-1} E_i}_{E_{\text{Total}}}$$

Veamos cómo se concretan las sumas para los dos métodos cerrados vistos anteriormente.

6.7.1 Regla del Trapecio Compuesta

Si aplicamos la fórmula simple del trapecio en cada subintervalo $[x_i, x_{i+1}]$, tenemos:

$$\tilde{S}_T = \frac{h}{2}[f(x_0) + f(x_1)] + \frac{h}{2}[f(x_1) + f(x_2)] + \dots + \frac{h}{2}[f(x_{n-1}) + f(x_n)]$$

Analizando la topología de la suma, observamos que los nodos de las fronteras globales (x_0 y x_n) pertenecen a un solo trapecio, por lo que aparecen una única vez. Sin embargo, todos los nodos interiores ($x_1, \dots, x_{n-1}$) actúan como límite derecho de un trapecio y límite izquierdo del siguiente, siendo evaluados dos veces. Factorizando $h/2$, obtenemos la forma computacional óptima:

$$\tilde{S}_T = \frac{h}{2} \left[f(a) + 2 \sum_{i=1}^{n-1} f(x_i) + f(b) \right]$$

Para determinar el error total E_T , sumamos los errores locales. Sabiendo que el error del trapecio simple es $-h^3 f''(\theta_i)/12$ para algún θ_i local:

$$E_T = \sum_{i=0}^{n-1} \left(-\frac{h^3}{12} f''(\theta_i) \right) = -\frac{h^3}{12} \sum_{i=0}^{n-1} f''(\theta_i)$$

Para simplificar este sumatorio, asumimos que $f \in C^2([a, b])$. Al ser continua, la media aritmética de n evaluaciones de f'' debe estar comprendida entre el mínimo y el máximo de f'' en $[a, b]$. Por el Teorema del Valor Intermedio, existe un punto global $\theta \in (a, b)$ tal que:

$$\frac{1}{n} \sum_{i=0}^{n-1} f''(\theta_i) = f''(\theta) \implies \sum_{i=0}^{n-1} f''(\theta_i) = n f''(\theta)$$

Sustituyendo esto y recordando que $n \cdot h = b - a$:

$$E_T = -\frac{h^3}{12} n f''(\theta) = -\frac{h^2}{12} (nh) f''(\theta) = \boxed{-\frac{b-a}{12} h^2 f''(\theta)}$$

Se concluye que el error global de la Regla del Trapecio Compuesta desciende a $\mathcal{O}(h^2)$.

6.7.2 Regla de Simpson Compuesta

Para aplicar la Regla de Simpson a trozos, es condición esencial que el número total de subintervalos n sea **par**. Esto se debe a que Simpson requiere tres nodos por panel (un inicio, un medio y un fin). Agruparemos los subintervalos de dos en dos, definiendo $n/2$ bloques de ancho $2h$.

Si aplicamos la regla de Simpson al primer bloque (nodos x_0, x_1, x_2), al segundo (x_2, x_3, x_4), y así sucesivamente:

$$\tilde{S}_S = \frac{h}{3} [f(x_0) + 4f(x_1) + f(x_2)] + \frac{h}{3} [f(x_2) + 4f(x_3) + f(x_4)] + \dots$$

Aquí la superposición crea un patrón alternante distintivo:

- Los extremos globales (x_0 y x_n) aparecen una vez (coeficiente 1).
- Los nodos de índice impar ($x_1, x_3, x_5 \dots$) son siempre los nodos centrales de cada bloque parabólico (coeficiente 4).
- Los nodos interiores de índice par ($x_2, x_4, x_6 \dots$) son las fronteras compartidas donde termina una parábola y comienza la siguiente, por lo que su coeficiente es $1 + 1 = 2$.

$$\tilde{S}_S = \frac{h}{3} \left[f(a) + 4 \sum_{j=1,3,5\dots}^{n-1} f(x_j) + 2 \sum_{k=2,4,6\dots}^{n-2} f(x_k) + f(b) \right]$$

Procediendo con la misma técnica rigurosa para el error, sumamos los errores de los $n/2$ bloques. El error simple de Simpson en un bloque es $-h^5 f^{(4)}(\theta_j)/90$:

$$E = -\frac{h^3}{12} \sum_{i=0}^{n-1} f''(\theta_i) = -\frac{h^3}{12} n f''(\theta) = -\frac{(b-a)h^2}{12} f''(\theta)$$


6.7.3 Fórmula de los trapecios compuesta (cerrada)

Podemos tomar ahora la fórmula de los trapecios compuesta, pero ahora con n mayor a 1, y con $h = \frac{b-a}{n}$. De esta forma, obtenemos la siguiente fórmula de aproximación de la integral:

$$\begin{aligned} \tilde{S} &= \frac{h}{2} (f(a) + f(b) + 2 \sum_{i=1}^{n-1} f(x_i)) \\ E &= \sum_{i=0}^{n-1} E_i = -\frac{h^3}{12} \sum_{i=0}^{n-1} f''(\theta_i) = -\frac{h^3}{12} n f''(\theta) = -\frac{(b-a)h^3}{12n^2} f''(\theta) \end{aligned}$$

6.7.4 Fórmula de Simpson compuesta (cerrada)

Ahora dividiremos el intervalo $[a, b]$ en n subintervalos, con $n = 2m$ par, siendo m el número de bloques de Simpson que vamos a utilizar, y cada uno contiene 3 puntos, el inicial, el final y el del medio. Nótese que el final de cada bloque coincide con el inicial del siguiente bloque. así, nos queda que $h = \frac{b-a}{n} = \frac{b-a}{2m}$, y la fórmula de aproximación de la integral es la siguiente:



$$\tilde{S} = \frac{h}{3} \left[\sum_{i=0}^m \left(\underbrace{f(x_{2(i-1)})}_{\text{pares}} + 4 \underbrace{f(x_{2i-1})}_{\text{impares}} + \underbrace{f(x_{2i})}_{\text{pares}} \right) \right] = \frac{h}{3} \left[\sum_{k=0}^{m-1} f(x_{2k}) + 4 \sum_{i=1}^m f(x_{2i-1}) + \sum_{i=1}^m f(x_{2i}) \right] =$$

$$\boxed{\tilde{S} = \frac{h}{3} \left[f(a) + f(b) + 2 \sum_{i=1}^{m-1} f(x_{2i}) + 4 \sum_{i=1}^m f(x_{2i-1}) \right]}$$

Y deja el error:

$$E = \sum_{i=1}^m E_i = - \sum_{i=1}^m \frac{h^5}{90} f^{(4)}(\theta_i) = - \frac{h^5}{90} \frac{1}{m} \sum_{i=1}^m f^{(4)}(\theta_i) = - \frac{(b-a)^5 n f^{(4)}(\theta)}{90 n^5 2} =$$

$$\boxed{E = - \frac{(b-a)^5 f^{(4)}(\theta)}{180 n^4}}$$

6.7.5 Comparación de ratios de error

Es interesante comparar el error cometido por la fórmula de los trapecios compuesta, con el error cometido por la fórmula de Simpson compuesta. Para ello, vamos a comparar el ratio entre ambos errores:

$$R = \frac{|E_{\text{Simp}}|}{|E_{\text{Trp}}|} = \frac{\frac{(b-a)^5 f^{(4)}(\theta_s) 12 n^2}{180 n^4 (b-a)^3 |f''(\theta_t)|} (b-a)^2 |f^{(4)}(\theta_s)|}{15 n^2 |f''(\theta_t)|} =$$

Que queda aproximadamente:

$$\tilde{R} = \frac{(b-a)^2}{15 n^2}$$

Nótese que en la practica se suele usar la formula de los trapecios para evitar el posible "ruido" que puede introducir la fórmula de Simpson, ya que esta última utiliza más puntos de interpolación, y por tanto es más sensible a posibles errores en la evaluación de la función f en esos puntos.

6.8 Tabla resumen

Veamos una tabla resumen con los distintos métodos de aproximación de la integral, y sus respectivos errores:

Método	Fórmula de aproximación	h	Error
Rectángulos	$2hf(x_0)$	$\frac{b-a}{2}$	$\frac{f''(\theta)}{3}h^3$
Trapecios	$\frac{h}{2}(f(a) + f(b))$	$b - a$	$-\frac{f''(\theta)}{12}h^3$
Trapecio abierto	$\frac{3}{2}hf(x_0) + f(x_1)$	$\frac{b-a}{3}$	$\frac{3}{4}f''(\theta)h^3$
Simpson cerrado	$\frac{h}{3}(f(a) + 4f(x_1) + f(b))$	$\frac{b-a}{2}$	$-\frac{h^5}{90}f^{(4)}(\theta)$
Trapecio compuesto	$\frac{h}{2}(f(a) + 2\sum_{i=1}^{n-1}f(x_i) + f(b))$	$\frac{b-a}{n}$	$-\frac{(b-a)h^2}{12}f''(\theta)$
Simpson compuesto	$\frac{h}{3}\left[f(a) + f(b) + 2\sum_{i=1}^{m-1}f(x_{2i}) + 4\sum_{i=1}^m f(x_{2i-1})\right]$	$\frac{b-a}{n}$	$-\frac{(b-a)^5 f^{(4)}(\theta)}{180n^4}$

$$E_S = \sum_{j=1}^{n/2} \left(-\frac{h^5}{90} f^{(4)}(\theta_j) \right) = -\frac{h^5}{90} \sum_{j=1}^{n/2} f^{(4)}(\theta_j)$$

Aplicando el Teorema del Valor Intermedio sobre los $n/2$ términos:

$$\sum_{j=1}^{n/2} f^{(4)}(\theta_j) = \left(\frac{n}{2} \right) f^{(4)}(\theta)$$

Sustituyendo y factorizando $(n \cdot h) = b - a$:

$$E_S = -\frac{h^5}{90} \left(\frac{n}{2} \right) f^{(4)}(\theta) = -\frac{h^4}{180} (nh) f^{(4)}(\theta) = \boxed{-\frac{b-a}{180} h^4 f^{(4)}(\theta)}$$

Gracias a la composición, el error desciende vertiginosamente, siendo proporcional a la cuarta potencia del paso de malla, $\mathcal{O}(h^4)$, lo que convierte a la regla de Simpson compuesta en uno de los métodos más eficientes y ubicuos del cálculo numérico general.

7 Resolución de ecuaciones no lineales

7.1 Motivación

Nuestro objetivo es partir de una función:

$$f : [a, b] \subset \mathbb{R} \rightarrow \mathbb{R}$$

Continua, y encontrar sus raíces, es decir, los puntos $\xi_i \in [a, b]$:

$$f(\xi_i) = 0$$

7.2 Raíces aisladas

Definición 7.2.1 [Raíz aislada]

Se dice que ξ es una raíz aislada de f si existe un entorno U de ξ tal que ξ es la única raíz de f en U , es decir, si $\exists \epsilon > 0$ tal que:

$$f(x) \neq 0 \quad \forall x \in (\xi - \epsilon, \xi + \epsilon) \setminus \{\xi\}$$

Observación 7.2.1

Si una función es derivable, entonces todas sus raíces son aisladas.


Teorema 7.2.1 [Algoritmo general]

Veamos los pasos a seguir:

1. Aislamos las raíces, mediante intervalos encajados, de tal forma que:

$$\forall i \exists! \xi_i \in (a_i, b_i)$$

Esto se puede apreciar en la siguiente figura:



2. Aproximar ξ_i en cada intervalo (a_i, b_i) , mediante un método numérico iterativo, es decir:

$$\begin{cases} x_0 \in (a_i, b_i) \\ x_{n+1} = h(x_n) \end{cases} \quad \forall n \in \mathbb{N} \quad \implies \lim_{n \rightarrow \infty} x_n = \xi_i$$

7.3 Separación de raíces

Recordemos algunos teoremas que nos servirán para separar raíces.

Teorema 7.3.1 [Teorema de Bolzano]

Si f es continua en $[a, b]$ y $f(a)f(b) < 0$, entonces existe $\xi \in (a, b)$ tal que $f(\xi) = 0$.

Teorema 7.3.2 [Teorema de Rolle]

Si f es continua en $[a, b]$, derivable en (a, b) y $f(a) = f(b)$, entonces existe $\xi \in (a, b)$ tal que $f'(\xi) = 0$.

Teorema 7.3.3 [Teorema del valor medio]

Si f es continua en $[a, b]$ y derivable en (a, b) , entonces existe $\xi \in (a, b)$ tal que:

$$f'(\xi) = \frac{f(b) - f(a)}{b - a}$$

Ahora veamos un teorema importante para separar y caracterizar raíces.

Teorema 7.3.4 [Teorema de existencia y unicidad de raíces]

Si f es continua en $[a, b]$, derivable en (a, b) y $f(a)f(b) < 0$, y además $f'(x)$ tiene un signo constante en (a, b) , entonces:

$$\begin{cases} f \in C^0([a, b]) \\ f \in C^1((a, b)) \\ f(a)f(b) < 0 \\ f'(x) \neq 0 \quad \forall x \in (a, b) \end{cases} \implies \exists! \xi \in (a, b) \text{ tal que } f(\xi) = 0$$

Veamos como demostrarlo.

Demostración. Veamos la existencia y la unicidad por separado:

- **Existencia:** Como se cumplen las hipótesis del teorema de Bolzano, entonces existe $\xi \in (a, b)$ tal que $f(\xi) = 0$.
- **Unicidad:** Supongamos que existen dos raíces distintas $\xi_1, \xi_2 \in (a, b)$, con $\xi_1 < \xi_2$. Entonces, por el teorema de Rolle, existe $\xi \in (\xi_1, \xi_2) \subset (a, b)$ tal que $f'(\xi) = 0$, lo cual contradice la hipótesis de que $f'(x) \neq 0$ para todo $x \in (a, b)$. Por lo tanto, no pueden existir dos raíces distintas, es decir, la raíz es única.

□

Teorema 7.3.5 [Teorema de separación de raíces]

Si f es continua en $[a, b]$, derivable en (a, b) y $f(a)f(b) < 0$, y además $f'(x)$ tiene n raíces distintas

en (a, b) , entonces f tiene a lo sumo $n + 1$ raíces en (a, b) , es decir:

$$\begin{cases} f \in C^0([a, b]) \\ f \in C^1((a, b)) \\ f(a)f(b) < 0 \\ f'(x) \text{ tiene } n \text{ raíces distintas en } (a, b) \end{cases} \implies f \text{ tiene a lo sumo } n + 1 \text{ raíces en } (a, b)$$

Demostración. Primero ordenemos las raíces de f' de menor a mayor, es decir, $a < \xi_1 < \xi_2 < \dots < \xi_n < b$. Entonces, si ahora tomamos los intervalos $[a, \xi_1], [\xi_1, \xi_2], \dots, [\xi_n, b]$, en cada uno de estos intervalos, f' no cambia de signo, y por tanto por el teorema de Rolle en cada intervalo, no podemos tener más de una raíz de f . Por lo tanto, en total, f puede tener a lo sumo $n + 1$ raíces en (a, b) . $\square$

Corolario 7.3.1

Si tenemos una función $f \in C^2([a, b])$ tal que $f''(x) > 0$ para todo $x \in (a, b)$, entonces f tiene a lo sumo dos raíces en (a, b) .

Demostración. Si $f''(x) > 0$ para todo $x \in (a, b)$, entonces f' es estrictamente creciente en (a, b) , lo que implica que f' tiene a lo sumo una raíz en (a, b) . Por lo tanto, por el teorema de separación de raíces, f tiene a lo sumo dos raíces en (a, b) . $\square$

7.4 Raíces de polinomios


Veamos un teorema interesante sobre las raíces de los polinomios.

Teorema 7.4.1 [Cota de las raíces de un polinomio]

Si $P(x) = a_n x^n + a_{n-1} x^{n-1} + \dots + a_1 x + a_0$ es un polinomio con $a_0 \neq 0 \neq a_n$, entonces todas sus raíces ξ satisfacen:

$$\begin{cases} \lambda = \max_{i \neq n} \left| \frac{a_i}{a_n} \right| \\ \mu = \max_{i \neq 0} \left| \frac{a_i}{a_0} \right| \end{cases} \implies \frac{1}{1 + \mu} < |\xi| < 1 + \lambda$$

Es decir, las raíces están fuera del disco de centro 0 y radio $\frac{1}{1+\mu}$, y dentro del disco de centro 0 y radio $1 + \lambda$.



Ejemplo

Sea el polinomio:

$$p(x) = x^{100} - x^{50} + 20x^{20} + 30$$

Donde tenemos que:

$$\begin{cases} a_n = 1 \implies \lambda = \max(\frac{1}{1}, \frac{20}{1}, \frac{30}{1}) = 30 \\ a_0 = 30 \implies \mu = \max(\frac{1}{30}, \frac{1}{30}, \frac{20}{30}) = \frac{2}{3} \end{cases}$$

Por lo tanto, las raíces de p están fuera del disco de centro 0 y radio $\frac{1}{1+\frac{2}{3}} = \frac{3}{5}$, y dentro del disco de centro 0 y radio $1 + 30 = 31$.

Teorema 7.4.2 [Regla de Descartes]

Sea $p_n \in \mathcal{P}_n$, con sus terminos siendo $\{a_n\}_{i=0}^n$.

Esta regla se basa en contar los cambios de signo, siendo esta cantidad m , y dejando que la cantidad de raíces positivas es:

$$\begin{cases} m \text{ es par: } \{m, m-2, \dots, 0\} \\ m \text{ es impar: } \{m, m-2, \dots, 1\} \end{cases}$$

Por ejemplo con el polinomio anterior que era:

$$p(x) = x^{100} - x^{50} + 20x^{20} + 30$$

Tenemos la siguiente sucesión de terminos:

$$\underbrace{30}_{+} \xrightarrow{0} \underbrace{20}_{+} \xrightarrow{+1} \underbrace{-1}_{-} \xrightarrow{+1} \underbrace{1}_{+}$$

En este caso, ha habido 2 cambios en los signos de las raíces, por lo que como es una cantidad par, habrá 2 ó 0 raíces positivas del polinomio.

Si ahora cambiamos al polinomio:

$$p(x) = x^{100} - x^{50} + 20x^{20} - 30$$

Tenemos la siguiente sucesión de términos:

$$\underbrace{-30}_{-} \xrightarrow{+1} \underbrace{20}_{+} \xrightarrow{+1} \underbrace{-1}_{-} \xrightarrow{+1} \underbrace{1}_{+}$$

Ahora habría 3 cambios de signos, por lo que puede haber 3 ó 1 raíces positivas del polinomio.

Para ver cuantas raíces negativas hay, basta con evaluar el polinomio en $-x$, es decir:

$$q(x) = p(-x) = (-1)^n a_n x^n + (-1)^{n-1} a_{n-1} x^{n-1} + \dots + (-1)^0 a_0$$

En nuestro caso, el polinomio se quedaría igual, es decir:

$$q(x) = p(-x) = x^{100} - x^{50} + 20x^{20} - 30$$

Por lo tanto, el número de cambios de signos en q es el mismo que en p , por lo que también habría 3 ó 1 raíces negativas del polinomio.

7.5 Métodos numéricos

Los métodos numéricos son iterativos.

En este caso ya hemos conseguido separar la única raíz ξ de f en un intervalo $[a, b]$, mediante la siguiente iteración:

$$\begin{cases} x_0 \in (a, b) \\ x_{n+1} = h(x_n) \quad \forall n \in \mathbb{N} \end{cases} \implies \lim_{n \rightarrow \infty} x_n = \xi \iff \text{el método converge}$$

Siendo el error en la i -ésima iteración:

$$e_i = |x_i - \xi|$$

Definición 7.5.1 [Orden de un método numérico]

Se existe una constante $M > 0$ y un número $\alpha > 0$ tal que:

$$e_{i+1} \leq M e_i^\alpha \quad \forall i \in \mathbb{N}$$

Entonces se dice que el método numérico tiene orden α . En particular, distinguimos:

- **Orden 1:** Si $\alpha = 1$, entonces el método es de orden 1, y se dice que el método es linealmente.
- **Orden entre 1 y 2:** Si $1 < \alpha < 2$, entonces el método es de orden entre 1 y 2, y se dice que el método es superlineal.
- **Orden 2:** Si $\alpha = 2$, entonces el método es de orden 2, y se dice que el método es cuadrático.

Teorema 7.5.1 [Método de la bisección]

Si f es continua en $[a, b]$, y $f(a)f(b) < 0$, entonces el método de la bisección converge a la única raíz

ξ de f en (a, b) de la siguiente forma:

1. Sea $x_0 = \frac{a+b}{2}$.
2. Calculamos $f(x_0)$, y si $f(x_0) = 0$, entonces hemos encontrado la raíz, es decir, $\xi = x_0$. Si no, proseguiremos al siguiente paso.
- 3.1 Si $f(a)f(x_0) < 0$, entonces la raíz ξ se encuentra en el intervalo (a, x_0) , por lo que actualizamos $b = x_0$. Repetir.
- 3.2 Si $f(x_0)f(b) < 0$, entonces la raíz ξ se encuentra en el intervalo (x_0, b) , por lo que actualizamos $a = x_0$. Repetir.

Como cada vez dividimos el intervalo por la mitad, el error se puede calcular como:

$$e_i = \frac{b-a}{2^{i+1}} \xrightarrow{i \rightarrow \infty} 0$$

Y como:

$$e_{i+1} = \frac{1}{2} e_i$$

Dejando así que es un método lineal, al tener $\alpha = 1$ y $M = \frac{1}{2} < 1$.

7.6 Métodos del punto fijo

Definición 7.6.1 [Aplicación contractiva]

Se dice que una función $f : [a, b] \rightarrow \mathbb{R}$ es una aplicación contractiva si existe una constante $M \in [0, 1)$ tal que:

$$|f(x) - f(y)| \leq M|x - y| \quad \forall x, y \in [a, b]$$

A la constante M se le llama constante de contracción o constante de Lipschitz.

Corolario 7.6.1 [Continuidad de las aplicaciones contractivas]

Si f es una aplicación contractiva en $[a, b]$, entonces f es continua en $[a, b]$.

Una pregunta natural sería como encontrar la constante de contracción M de una aplicación contractiva f . Para ello, usaremos el teorema de Rolle. Definamos la siguiente función auxiliar:

$$F : [a, b] \rightarrow \mathbb{R} \\ z \mapsto F(z) = f(z) - \frac{f(x)(y-z) + f(y)(z-x)}{y-x}$$

Siendo $x, y \in [a, b]$ con $x < y$. Nótese que:

$$\begin{cases} F(x) = f(x) - \frac{f(x)(y-x) + f(y)(x-x)}{y-x} = 0 \\ F(y) = f(y) - \frac{f(x)(y-y) + f(y)(y-x)}{y-x} = 0 \end{cases}$$

Esta función es claramente C^1 en $[a, b]$, por lo que por el teorema de Rolle, existe $c \in (x, y)$ tal que $F'(c) = 0$. Calculando la derivada de F , tenemos:

$$F'(c) = f'(c) - \frac{-f(x) + f(y)}{y-x} = 0 \implies f(y) - f(x) = f'(c)(y-x) \implies |f(y) - f(x)| = |f'(c)||y-x| \leq \|f'\|_{\infty}|y-x|$$

Y así, finalmente, la constante M será:

$$M = \|f'\|_\infty$$

Ejemplo

Sea la función;

$$f(x) = e^x - \sin(x)$$

Con dominio $x \in [0, \frac{\pi}{2}]$. Calculemos entonces sus derivadas:

$$\begin{cases} f'(x) = e^x - \cos(x) \\ f''(x) = e^x + \sin(x) \end{cases}$$

Como la 2 derivada es siempre positiva, entonces f' es estrictamente creciente, y por tanto, el máximo de f' en $[0, \frac{\pi}{2}]$ se encuentra en el extremo derecho del intervalo, es decir:

$$\|f'\|_\infty = f'(\frac{\pi}{2}) = e^{\frac{\pi}{2}}$$

Que es una mejor aproximacion a simplemente acotar:

$$\|f'\|_\infty = \|e^x - \cos(x)\|_\infty \leq \|e^x\|_\infty + \|\cos(x)\|_\infty = e^{\frac{\pi}{2}} + 1$$

7.6.1 Teorema de Banach

Teorema 7.6.1 [Teorema de Banach]

Sea h una aplicación que cumple:

1. $h : [a, b] \rightarrow [a, b]$, es decir, deja el intervalo $[a, b]$ invariante.
2. h es contractiva con $M < 1$.

Entonces la aplicación:

$$\begin{cases} x_0 \in [a, b] \\ \vdots \\ x_i = h(x_{i-1}) \\ \xi = h(\xi) \end{cases}$$

Tiene un único punto fijo $\xi \in [a, b]$, y toda sucesión $\{x_i\}_{i=0}^\infty$ con $x_0 \in [a, b]$ converge a ξ . Además, el error:

$$E_i = |x_i - \xi| \leq \frac{M^i}{1-M} |x_1 - x_0| \leq \frac{M^i}{1-M} (b-a)$$

También es interesante destacar la relación entre un error y el siguiente:

$$E_{i+1} \leq M E_i \quad \forall i \in \mathbb{N}$$

De lo que deducimos que el **orden** del método es $\alpha = 1$, es decir, es un método lineal.

Una forma de poder aplicar el teorema de Banach para encontrar los 0 de una función f es la siguiente:

1. Sumamos: $x + f(x) = x$ y denotamos $h(x) = x + f(x)$. Ahora aplicamos el teorema de Banach a h , ya que buscamos su punto fijo $h(\xi) = \xi \implies x + f(x) = x \implies f(x) = 0$.

- Ahora intentamos aplicar el teorema de Banach, para ello, necesitamos un intervalo invariante $[a, b]$ y buscar $M = \|1 + f'\|_\infty < 1$.

En muchas situaciones, nos podemos encontrar con que M es un poco mayor que 1, o que el intervalo no es invariante, pero podemos multiplicar por una constante α que haga que M sea menor que 1, o que el intervalo sea invariante, es decir, podemos intentar aplicar el teorema de Banach a la función $h(x) = x + \alpha f(x)$, ya que las raíces no cambian de $f(x)$ a $\alpha f(x)$.

7.6.2 Criterios de parada

Ahora es interesante plantearnos cuales pueden ser los criterios de parada para este método. Para ello, fijamos una tolerancia $\epsilon \ll 1$ y despejamos:

$$E_n \leq \epsilon \implies \frac{M^n}{1-M} |x_1 - x_0| \leq |\epsilon| \implies M^n \leq \frac{(1-M)\epsilon}{|x_1 - x_0|} \implies n \log(M) \leq \log\left(\frac{(1-M)\epsilon}{|x_1 - x_0|}\right) \implies$$

$$n = \left\lceil \frac{\log\left(\frac{(1-M)\epsilon}{|x_1 - x_0|}\right)}{\log(M)} \right\rceil$$

7.6.3 Salvar el método

Si el método no converge, es decir, si $M \geq 1$, entonces podemos intentar salvarlo de distintas formas.

- Multiplicando por una constante α que haga que el intervalo sea invariante, es decir, podemos intentar aplicar el teorema de Banach a la función $h(x) = x + \alpha f(x)$, ya que las raíces no cambian de $f(x)$ a $\alpha f(x)$.
- Buscar una función $\Phi \in C^0([a, b])$ y cuya única raíz sea 0, por lo que:

$$f(x) = 0 \iff \Phi(f(x)) = 0$$

Y así el método quedaría:

$$x_i = x_{i-1} + \Phi(f(x_{i-1})) = \tilde{h}(x_{i-1})$$

Por lo que nuestro objetivo es encontrar una función Φ tal que $\tilde{h}$ sea contractiva, es decir, que $\|\tilde{h}'\|_\infty < 1$.

- Encontrar una función de signo constante en $[a, b]$, es decir, una función φ tal que $\varphi(x) > 0$ o $\varphi(x) < 0$ para todo $x \in [a, b]$, por lo que:

$$f(x) = 0 \iff \varphi(x)f(x) = 0$$

Y así el método quedaría:

$$x_i = x_{i-1} + \varphi(x_{i-1})f(x_{i-1}) = \bar{h}(x_{i-1})$$

- Buscar una función invertible (monótona) $\psi \in C^0([a, b])$ tal que si ahora descomponemos:

$$f(x) = g(x) - s(x) = 0 \implies g(x) = s(x) \implies \psi(g(x)) = \psi(s(x))$$

Por lo que si tomamos ψ como la función inversa de g , es decir, $\psi = g^{-1}$, entonces el método quedaría:

$$x_i = \psi(s(x_{i-1})) = \hat{h}(x_{i-1})$$

Ejemplo

Podemos intentar aplicar esto al ejercicio **3.a** de la hoja **6**, el cual nos pide hallar las raíces de la función:

$$f(x) = x^3 - x - 1 = 0$$

Donde al haber 1 cambio de signo, habrá una única raíz positiva. Calculando:

$$\begin{cases} f(0) = -1 < 0 \\ f(1) = -1 < 0 \\ f(2) = 5 > 0 \end{cases} \implies \exists! \xi \in (1, 2) \text{ tal que } f(\xi) = 0$$

Si tomamos directamente $h(x) = x + f(x) = x^3 - 1$, entonces $h'(x) = 3x^2$, y como $h'(1) = 3 > 1$ y $h'(2) = 12 > 1$, entonces el método no converge.

Si intentamos el método **1** buscar una constante α tal que $h(x) = x + \alpha f(x)$, entonces $h'(x) = 1 + \alpha(3x^2 - 1)$, y como $h'(1) = 1 + 2\alpha$ y $h'(2) = 1 + 11\alpha$, entonces para que el método converja, necesitamos que $|1 + 2\alpha| < 1$ y $|1 + 11\alpha| < 1$, lo que implica que $\alpha \in (-1, 0)$ y $\alpha \in (-\frac{2}{11}, 0)$, por lo que el método convergería para cualquier $\alpha \in (-\frac{2}{11}, 0)$.

Otra idea sería aplicar el método **4**, descomponiendo f como $f(x) = g(x) - s(x)$, con $g(x) = x^3$ y $s(x) = x + 1$. Entonces, si tomamos $\psi = g^{-1}$, es decir, $\psi(x) = \sqrt[3]{x}$, entonces el método quedaría:

$$x_i = \psi(s(x_{i-1})) = \sqrt[3]{x_{i-1} + 1} = \hat{h}(x_{i-1})$$

Derivando ahora llegamos a que $\hat{h}'(x) = \frac{1}{3\sqrt[3]{(x+1)^2}} > 0$, por lo que $\hat{h}$ es monótona, y además, como:

$$1 \leq \hat{h}(1) = \sqrt[3]{2} \leq \hat{h}(2) = \sqrt[3]{3} \leq 2$$

Y además la derivada es menor que 1, ya que la segunda derivada es $\hat{h}''(x) = -\frac{2}{9\sqrt[3]{(x+1)^5}} < 0$, por lo que $\hat{h}'$ es decreciente, y por lo tanto, $M = \|\hat{h}'\|_\infty = \hat{h}'(1) = \frac{1}{3\sqrt[3]{4}} < 1$.

Por lo tanto, $\hat{h}$ es una aplicación contractiva (ya que $M < 1$ y $\hat{h}([1, 2]) \subset [1, 2]$), y por lo tanto, el método converge a la raíz ξ de f .

Si ahora nos planteamos cuantas iteraciones necesitamos para que el error sea menor que $\epsilon = 10^{-5}$, entonces:

$$E_n \leq \frac{M^n}{1-M} |x_1 - x_0| \underset{|x_1 - x_0| \leq b-a=1}{\leq} \frac{M^n}{1-M} < 10^{-5} \implies n \log_{10}(M) < -5 + \log_{10}(1-M) \implies$$


$$n > \frac{-5 + \log_{10}(1-M)}{\log_{10}(M)} \implies n = \left\lceil \frac{-5 + \log_{10}(1 - \frac{1}{3\sqrt[3]{4}})}{\log_{10}(\frac{1}{3\sqrt[3]{4}})} \right\rceil$$

Ejemplo

Sea ahora la ecuación:

$$x = -\ln(x) \implies f(x) = x + \ln(x) = 0$$

Dibujando obtenemos:



Ahora podemos plantearnos directamente el método iterativo:

$$x_i = -\ln(x_{i-1}) = h(x_{i-1})$$

Pero no funcionaría. Podemos intentar entonces pasar a la exponencial, es decir:

$$e^{-x} = x \implies x_i = e^{-x_{i-1}} = \hat{h}(x_{i-1})$$

Que sí converge ya que $\hat{h}'(x) = -e^{-x}$, y como $-e^{-x} \in (-1, 0)$ para todo $x > 0$, entonces $\|\hat{h}'\|_\infty < 1$. Por lo tanto, el método converge a la raíz ξ de f .

Teorema 7.6.2 [Estabilidad de puntos fijos]

Si tenemos que ξ es un punto fijo de $h \in \mathcal{C}^1([a, b])$, es decir, $h(\xi) = \xi$, con la sucesión $x_i = h(x_{i-1})$ y $x_0 \in [a, b]$.

Entonces, si $|h'(\xi)| < 1$, entonces ξ es un punto fijo estable, es decir, existe un intervalo I con $\xi \in I \subset [a, b]$ tal que para todo $x_0 \in I$, la sucesión $\{x_i\}_{i=0}^\infty$ converge a ξ .

Si la derivada es mayor que 1, es decir, $|h'(\xi)| > 1$, entonces ξ es un punto fijo inestable, es decir, no puede existir un intervalo I con $\xi \in I \subset [a, b]$ tal que para todo $x_0 \in I$, la sucesión $\{x_i\}_{i=0}^\infty$ converge a ξ .

7.7 Método de Newton

El método de Newton es un método iterativo para encontrar raíces de funciones, y es de orden 2, es decir, es un método cuadrático:

$$e_i = |x_i - \xi| \leq C e_{i-1}^2 \quad \forall i \in \mathbb{N}$$

Teorema 7.7.1

Sean:

1. $f \in \mathcal{C}^2([a, b])$ que cumple que $f(x) = 0$ para algún único $\xi \in (a, b)$.
2. $\varphi : [a, b] \rightarrow \mathbb{R}$ continua de un solo signo

Entonces $\varphi(x)f(x) = 0$ tiene la misma raíz ξ , y tenemos la aplicación:

$$x_i = x_{i-1} - \varphi(x_{i-1})f(x_{i-1})$$

Ahora podemos empezar a hacer los siguientes despejes:

1. Restar el error a ambos lados:

$$x_i - \xi = x_{i-1} - \xi - \varphi(x_{i-1})f(x_{i-1})$$

- 2.

$$0 = f(\xi) = f(x_{i-1} - (x_{i-1} - \xi)) \underset{\text{Taylor}}{=} f(x_{i-1}) - f'(x_{i-1})(x_{i-1} - \xi) + \frac{f''(\eta)}{2} \underbrace{(x_{i-1} - \xi)^2}_{e_{i-1}^2}$$

3. Despejando $x_{i-1} - \xi$:

$$x_{i-1} - \xi = \frac{f(x_{i-1})}{f'(x_{i-1})} + \frac{f''(\eta)}{2f'(x_{i-1})}e_{i-1}^2$$

4. Reordenando:

$$x_i - \xi = \frac{1}{2} \frac{f''(\eta)}{f'(x_{i-1})}e_{i-1}^2 + \underbrace{\frac{f(x_{i-1})}{f'(x_{i-1})} + \varphi(x_{i-1})f(x_{i-1})}_{=0}$$

5. Por lo tanto, el error se puede acotar como:

$$e_i = |x_i - \xi| \leq \frac{1}{2} \left| \frac{f''(\eta)}{f'(x_{i-1})} \right| e_{i-1}^2 \leq C e_{i-1}^2$$

Siendo:

$$C = \frac{1}{2} \left\| \frac{f''}{f'} \right\|_{\infty}$$

6. Por lo tanto, el método queda:

$$x_i = x_{i-1} - \frac{f(x_{i-1})}{f'(x_{i-1})}$$

Observación 7.7.1

Veamos 3 observaciones interesantes sobre el método de Newton:

- Si $\varphi(x)$ es de un signo entonces $f'(x)$ es de un signo.
- La segunda derivada está siempre acotada, ya que f'' es continua en un intervalo compacto, por lo que C es una constante finita.
- Aunque se cumplan las 2 proposiciones anteriores, el método de Newton no tiene por qué converger.

Teorema 7.7.2 [Método de Newton]

Sea $f \in \mathcal{C}^2([a, b])$ tal que $f(a)f(b) < 0$, f' es de un solo signo en $[a, b]$, y f'' es de un solo signo en $[a, b]$.

Si ahora definimos un $c \in \{a, b\}$ tal que $f(c)f''(c) > 0$, entonces el método de Newton con $x_0 = c$

converge a la raíz ξ de f en (a, b) :

$$\begin{cases} x_0 = c \\ x_i = x_{i-1} - \frac{f(x_{i-1})}{f'(x_{i-1})} \end{cases}$$

Part II

Ejercicios

Índice de Ejercicios

Hoja 1: Resolución de ecuaciones no lineales	91
--	----

Hoja de Ejercicios 1: Resolución de ecuaciones no lineales

Ejercicio 1

Prof

Enunciado: Utilizar el método de la bisección para aproximar una raíz de la ecuación

$$\sqrt{x} \sin x - x^3 + 2 = 0$$

en el intervalo $[1, 2]$ con un error menor que $\frac{1}{30}$.

Desarrollo: Sea

$$f(x) = \sqrt{x} \sin x - x^3 + 2.$$

Como f es continua en $[1, 2]$, y

$$f(1) = \sqrt{1} \cdot \sin 1 - 1 + 2 = \sin 1 + 1 > 0, \quad f(2) = \sqrt{2} \cdot \sin 2 - 8 + 2 < 0,$$

por el teorema de Bolzano existe $\xi \in (1, 2)$ tal que $f(\xi) = 0$. Luego la ecuación tiene al menos una raíz positiva.

Tomamos $a_0 = 1$ y $b_0 = 2$. Para $n \in \mathbb{N}$, definimos

$$x_0 = \frac{a_0 + b_0}{2} = \frac{3}{2}, \quad E_0 = \frac{b_0 - a_0}{2} = \frac{1}{2}.$$

Ahora calculamos $f(x_0)$:

$$f\left(\frac{3}{2}\right) = \sqrt{\frac{3}{2}} \cdot \sin\left(\frac{3}{2}\right) - \left(\frac{3}{2}\right)^3 + 2 < 0,$$

Usando para aproximar el seno su cota por 1. Por tanto, $f(a_0)f(x_0) < 0$, y tomamos $a_1 = a_0$ y $b_1 = x_0$.

Para $n = 1$, tenemos:

$$x_1 = \frac{a_1 + b_1}{2} = \frac{5}{4}, \quad E_1 = \frac{b_1 - a_1}{2} = \frac{1}{4}.$$

Y continuaríamos así sucesivamente, hasta que $E_n < \frac{1}{30}$. En este caso, se obtiene $n = 5$ como mínimo.

Ejercicio 2

Enunciado: Comprobar que se puede aplicar el teorema del Punto Fijo a las siguientes funciones en los intervalos dados:

(a) $f(x) = \frac{\cos x}{8} + \frac{x^2}{4}$ en $\left[0, \frac{\pi}{2}\right]$.

(b) $g(x) = x - \frac{x^2 + 1}{5}$ en $[0, 1]$.

Desarrollo:

Enunciado: Determinar un intervalo y una función para poder aplicar el método del Punto Fijo a las siguientes ecuaciones:

(a) $x^3 - x - 1 = 0$.

(b) $4 - x - \tan(x) = 0$.

(c) $x = -\ln(x)$.

Determinar, en cada caso, el número de iteraciones necesario para que el error cometido sea inferior a 10^{-5} .

Desarrollo: Veamos cada caso por separado:

(a) Para este caso, podemos aproximar las raíces de la siguiente forma, calculando μ y λ :

$$\begin{cases} \mu = \max \left\{ \frac{1}{3}, \frac{1}{3}, 1 \right\} = 1, \\ \lambda = \max \{1, 1, 3\} = 3. \end{cases}$$

Dejando así la aproximación de la raíz en el intervalo:

$$\frac{1}{1+\mu} \leq |z| \leq \lambda + 1 \implies \frac{1}{2} \leq |z| \leq 4.$$

Ahora podemos aplicar Descartes para hallar la cantidad de raíces positivas y negativas. Como $p(x)$ tiene 3 cambios de signo, entonces $p(x)$ tiene 3 o 1 raíz positiva. Como $p(-x)$ no tiene cambios de signo, entonces $p(x)$ no tiene raíces negativas.

Tomando las derivadas, podemos ver que $p'(x) = 3x^2 - 2x + 3$ tiene 0 o 2 raíces, y como la 2 derivada $p''(x) = 6x - 2$ tiene una raíz a la izquierda del intervalo, entonces $p'(x)$ es siempre creciente y por tanto siempre positiva, al ser $p''(\frac{1}{2}) = 1 > 0$. Por tanto, $p(x)$ es siempre creciente y por tanto tiene una única raíz positiva.

Si calculamos distintos valores de f :

$$\begin{cases} f(0) = -1 < 0, \\ f(1) = -1 < 0, \\ f(2) = 3 > 0, \end{cases} \implies \xi \in (1, 2).$$

Ahora aplicaremos la variante con un factor α : consideramos

$$h_\alpha(x) = x + \alpha f(x), \quad f(x) = x^3 - x - 1.$$

Elegimos $\alpha < 0$ suficientemente pequeño en valor absoluto para que:

- $h_\alpha([1, 2]) \subset [1, 2]$ (invarianza),
- $\|h'_\alpha\|_{[1, 2]} < 1$ (contractividad).

Como $f'(x) = 3x^2 - 1 \in [2, 11]$ en $[1, 2]$, tenemos

$$h'_\alpha(x) = 1 + \alpha f'(x) \in [1 + 2\alpha, 1 + 11\alpha].$$

Para asegurar $|1 + \alpha f'(x)| < 1$ para todo x basta tomar

$$-\frac{2}{11} < \alpha < 0.$$

Además, como $f(1) = -1$ y $f(2) = 5$, la imagen está contenida en

$$h_\alpha([1, 2]) \subseteq [1 + \alpha \min f, 2 + \alpha \max f] = [1 - \alpha, 2 + 5\alpha].$$

Para que esto quede en $[1, 2]$ necesitamos $2 + 5\alpha \geq 1$, es decir $\alpha \geq -0.2$. Combinando ambas condiciones tomamos, por ejemplo, $\alpha = -0.1$.

Con $\alpha = -0.1$ se cumple:

- $h_{-0.1}([1, 2]) \subset [1, 2]$ porque $1 - \alpha = 1.1$ y $2 + 5\alpha = 1.5$, luego la imagen queda en $[1.1, 1.5] \subset [1, 2]$.
- $h'_{-0.1}(x) = 1 - 0.1(3x^2 - 1) \in [-0.1, 0.8]$, por tanto

$$M := \|h'_{-0.1}\|_{[1, 2]} = \max\{|-0.1|, |0.8|\} = 0.8 < 1.$$

Por tanto podemos aplicar Banach en $[1, 2]$ con la iteración

$$x_{n+1} = h_{-0.1}(x_n) = x_n - 0.1(x_n^3 - x_n - 1).$$

Tomando $x_0 = \frac{3}{2}$ (el punto medio) obtenemos

$$x_1 = x_0 - 0.1f(x_0) = 1.5 - 0.1 \cdot 0.875 = 1.4125, \quad |x_1 - x_0| = 0.0875.$$

Usando la cota de error de Banach:

$$|x_n - \xi| \leq \frac{M^n}{1 - M} |x_1 - x_0| = \frac{0.8^n}{0.2} \cdot 0.0875 = 0.4375 \cdot 0.8^n.$$

Queremos $0.4375 \cdot 0.8^n < 10^{-5}$, es decir

$$0.8^n < \frac{10^{-5}}{0.4375} \approx 2.2857 \times 10^{-5}.$$

De aquí

$$n > \frac{\log(2.2857 \times 10^{-5})}{\log(0.8)} \approx 47.9,$$

luego se requieren al menos $n = 48$ iteraciones para que el error sea menor que 10^{-5} .

Ejercicio 4

Prof

Enunciado: Se considera la ecuación

$$x^2 - 1 - \sin x = 0.$$

- Probar que dicha ecuación tiene, al menos, una raíz positiva.
- Encontrar un intervalo en el que la iteración

$$x_n = \sqrt{1 + \sin x_{n-1}}, \quad n \in \mathbb{N}$$

converja, para cualquier valor inicial x_0 de dicho intervalo, a una raíz positiva de la ecuación anterior. ¿Cuántos pasos deben darse, a partir de $x_0 = \frac{\pi}{2}$, para obtener una aproximación de la raíz con un error inferior a la milésima?

Desarrollo: Sea

$$f(x) = x^2 - 1 - \sin x.$$

(a) Como f es continua en $[1, \frac{3}{2}]$, y

$$f(1) = 1 - 1 - \sin 1 = -\sin 1 < 0, \quad f\left(\frac{3}{2}\right) = \frac{9}{4} - 1 - \sin\left(\frac{3}{2}\right) > 0,$$

por el teorema de Bolzano existe $\xi \in (1, \frac{3}{2})$ tal que $f(\xi) = 0$. Luego la ecuación tiene al menos una raíz positiva.

(b) Reescribimos la ecuación como

$$x = \varphi(x), \quad \varphi(x) = \sqrt{1 + \sin x}.$$

Tomamos $I = [1, \frac{\pi}{2}]$. Para $x \in I$, se tiene

$$\varphi(x) \in [\sqrt{1 + \sin 1}, \sqrt{2}] \subset [1, \frac{\pi}{2}],$$

luego $\varphi(I) \subset I$.

Además,

$$\varphi'(x) = \frac{\cos x}{2\sqrt{1 + \sin x}},$$

y en I vale

$$|\varphi'(x)| \leq \frac{\cos 1}{2\sqrt{1 + \sin 1}} =: q < 1 \quad (q \approx 0.2).$$

Por tanto, φ es contractiva en I y la iteración

$$x_n = \varphi(x_{n-1})$$

converge a la **única** raíz positiva ζ para todo $x_0 \in I$.

Con $x_0 = \frac{\pi}{2}$, se tiene $x_1 = \sqrt{2}$ y

$$|x_n - \zeta| \leq \frac{q^n}{1 - q} |x_1 - x_0|.$$

Usando $q \approx 0.2$ y

$$|x_1 - x_0| = \left| \sqrt{2} - \frac{\pi}{2} \right| \approx 0.1566,$$

pedimos

$$\frac{0.2^n}{0.8} \cdot 0.1566 < 10^{-3}.$$

Se obtiene $n = 4$ como mínimo.

Ejercicio 5

Enunciado: Se considera la función

$$g(x) = \sin^2(x), \quad x \in [0, \pi].$$

Aplicar el teorema del Punto Fijo a la función

$$f(x) = \frac{2 + \sin 2x}{2}$$

en el intervalo $[1.6, 2]$ para determinar el valor del punto ζ para el que se verifica que

$$\int_0^\zeta g(t) dt = 1$$

de forma que el error cometido sea inferior a 10^{-4} .

Desarrollo:

Ejercicio 6

Enunciado: Sea $F : \mathbb{R} \setminus \{0\} \rightarrow \mathbb{R}$ definida como

$$F(x) = x - \frac{1}{x} - e^{-x}.$$

- (a) Dibujar la gráfica de F y determinar el número de raíces reales de la ecuación $F(x) = 0$, localizando cada raíz entre dos enteros consecutivos.
- (b) Para cada una de las funciones siguientes:

$$f_1(x) = 1 + xe^{-x}, \quad f_2(x) = \ln\left(\frac{x}{x-1}\right), \quad f_3(x) = (x-1)e^x$$

consideramos el siguiente método iterativo: dado $x_0 \in \mathbb{R}$ arbitrario sea

$$x_n = f_i(x_{n-1}), \quad n \in \mathbb{N} \quad (i = 1, 2, 3).$$

Estudiar cuáles de estas sucesiones convergen hacia alguna de las raíces de la ecuación $F(x) = 0$.

- (c) Elegir intervalos y puntos iniciales adecuados para que el método de Newton converja a cada una de las raíces.

Desarrollo:

Ejercicio 7

Prof

Enunciado: Dados un número natural n y un número positivo α , una forma de calcular las raíces reales n -ésimas de α sin usar radicales es aplicar el método de Newton a la ecuación

$$x^n - \alpha = 0.$$

Encontrar un intervalo y un valor inicial para los que el método sea convergente.

Desarrollo: Si tomamos $f(x) = x^n - \alpha$, entonces $f'(x) = nx^{n-1}$. Podemos distinguir dos casos:

- Si $\alpha < 1$, entonces $f(0) = -\alpha < 0$ y $f(1) = 1 - \alpha > 0$, luego existe una raíz $\xi \in (0, 1)$. Ahora como $f' > 0$ excepto en $x = 0$, y $f''(x) = n(n-1)x^{n-2} > 0$ excepto en $x = 0$, entonces podemos tomar $I = [0, 1]$ y $x_0 = 1$, ya que $f(x_0)f''(x_0) > 0$.

- Si $\alpha > 1$, entonces $f(1) = 1 - \alpha < 0$ y $f(\alpha) = \alpha^n - \alpha > 0$, luego existe una raíz $\xi \in (1, \alpha)$. Ahora como $f' > 0$ excepto en $x = 0$, y $f''(x) = n(n-1)x^{n-2} > 0$ excepto en $x = 0$, entonces podemos tomar $I = [1, \alpha]$ y $x_0 = \alpha$, ya que $f(x_0)f''(x_0) > 0$.

Así, de forma general, podemos tomar $I = [\min\{1, \alpha\}, \max\{1, \alpha\}]$ y $x_0 = \max\{1, \alpha\}$ para que el método de Newton converja a la raíz ξ .

Ejercicio 8

Enunciado: Demostrar que la ecuación

$$e^x \ln(x) + x^3 - 2 = 0$$

tiene una única raíz positiva. Determinar un intervalo y un valor inicial para los que el método de Newton converja a dicha raíz.

Desarrollo:

Ejercicio 9

Enunciado:

(a) Demostrar que la ecuación

$$\cos x - 3x = \frac{\pi}{2}$$

tiene una única raíz real.

(b) Determinar un intervalo y un valor inicial para los que el método de Newton converja a dicha raíz.

Desarrollo:

Ejercicio 10

Enunciado: Calcular las raíces de la ecuación

$$x^3 - x^2 + 3x = 3.$$

Desarrollo:

Ejercicio 11

Enunciado: Calcular las raíces del polinomio

$$P(x) = 5x^5 - 17x^4 - 79x^3 + 269x^2 - 34x - 24.$$

Desarrollo:

Ejercicio 12

Enunciado: Calcular las raíces reales de la ecuación algebraica

$$2x^4 - x^3 + 2x^2 - 7x + 3 = 0.$$

Desarrollo:

Ejercicio 13

Enunciado: Se considera la ecuación algebraica

$$x^5 + x^4 + 5x^3 + 2x^2 - 13x - 10 = 0.$$

- (a) Determinar el número de raíces positivas.
- (b) Encontrar una raíz racional negativa.
- (c) Hallar el número de raíces reales y complejas de la ecuación anterior.
- (d) Determinar un intervalo donde se pueda aplicar el método de Newton para aproximar la raíz positiva más pequeña, así como los dos primeros términos de la sucesión $\{x_n\}_{n=0}^{\infty}$ que determina dicho método.

Desarrollo:

Part III

Exámenes

Índice de Exámenes

Examen 1: Final (20 de diciembre de 2022)	99
---	----

Examen 1: Final (20 de diciembre de 2022)

Empezar cada ejercicio en una cara nueva. Solo se empleará papel y bolígrafo. El examen dura 3 horas. Una vez comenzado, no se podrá salir en los primeros 45 minutos.

Ejercicio 1

Enunciado: Sea $A := (a_{ij})_{i,j=1}^n \in \mathcal{M}_n(\mathbb{R})$ una matriz inversible.

- a) Probar que si $A = L_1 U_1 = L_2 U_2$, con L_1 y L_2 triangulares inferiores (los elementos en la diagonal pueden ser arbitrarios, la condición $\ell_{ii} = 1$ no es necesaria) y U_1, U_2 triangulares superiores, entonces existe una matriz diagonal $D = \text{diag}(d_1, \dots, d_n)$ inversible tal que $L_2 = L_1 D$ y $U_2 = D^{-1} U_1$.

Indicación: Usar el hecho de que la inversa de una matriz triangular inversible también es triangular.

- b) Probar que si A admite factorización LU (con $\ell_{ii} = 1$, $i = 1, 2, \dots, n$), entonces todos sus menores principales $\delta_k := \det(A_k) \neq 0$, $k = 1, 2, \dots, n-1$, donde $A_k = (a_{ij})_{i,j=1}^k$.

Indicación: Primero concluir que para factorizar A_2 es necesario que $\delta_1 \neq 0$. Segundo, usar inducción: representar A_{k+1} como matriz compuesta por bloques a partir de A_k y factorizándola concluir que $\delta_k \neq 0$.

Desarrollo:

Ejercicio 2

Enunciado: Se considera el método iterativo de Jacobi para resolver el sistema lineal $Au = b$ dados $A := (a_{ij})_{i,j=1}^n \in \mathcal{M}_n(\mathbb{R})$ y $b \in \mathbb{R}^n$:

$$u^0 = 0, \quad u^k = Ju^{k-1} + D^{-1}b, \quad k = 1, 2, \dots$$

donde la matriz A se descompone de forma: $A = D - E - F$ (D es diagonal y E, F son triangulares inferior y superior, respectivamente) y $J = D^{-1}(E + F)$. La matriz A verifica:

$$|a_{ii}| > \alpha \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}|, \quad \alpha > 1, \quad i = 1, 2, \dots, n,$$
$$|a_{ii}| > \gamma > 0, \quad i = 1, 2, \dots, n.$$

- a) Probar que $\|J\|_\infty < \frac{1}{\alpha}$. *Indicación:* La norma infinito: $\|J\|_\infty := \max_{i \in \{1, \dots, n\}} \sum_{j=1}^n |J_{ij}|$. Representar J en términos de A .

- b) Sea $\xi \in \mathbb{R}^n$ la solución del sistema lineal $Au = b$. Probar que:

$$\xi = J\xi + D^{-1}b.$$

Sea $e^k = u^k - \xi$ el error de aproximación en el k -ésimo paso. Demostrar que

$$e^k = J^k e^0, \quad k = 0, 1, 2, \dots$$

- c) Usando el apartado (a) y la ecuación anterior del (b) probar:

$$\|\xi\|_\infty < \frac{\alpha \|b\|_\infty}{\gamma(\alpha - 1)}.$$

d) Deducir de lo anterior que

$$\|e^k\|_\infty < \frac{\|b\|_\infty}{\gamma \alpha^{k-1}(\alpha - 1)}, \quad k = 0, 1, 2, \dots$$

e) En particular, se considera el sistema $Au = b$ siendo:

$$A = \begin{pmatrix} 1.3 & 0.1 & -0.2 & 0.3 \\ 0.3 & -1.9 & 0.4 & 0.2 \\ -0.4 & 0.1 & 1.1 & 0.0 \\ 0.1 & 0.2 & -0.3 & 1.3 \end{pmatrix}, \quad b = \begin{pmatrix} 7 \\ -2 \\ 10 \\ 1 \end{pmatrix}.$$

Utilizar la cota del error de (d) para determinar un número k de iteraciones tal que el error cometido en norma infinito, al aplicar el método de Jacobi, sea inferior a 10^{-6} .

Indicación: Dejar el resultado indicado, es decir, poner que $k > \dots$.

Desarrollo:

Ejercicio 3

Prof

Enunciado: Se desea aproximar el valor de la siguiente integral impropia:

$$S = \int_0^\infty e^{-x^2} dx,$$

mediante la fórmula de los trapecios compuesta con un error menor que 10^{-2} . Para ello, seguimos el siguiente proceso. Se divide la integral en dos partes:

$$S = A + B, \quad \text{donde} \quad A = \int_0^6 e^{-x^2} dx, \quad B = \int_6^\infty e^{-x^2} dx.$$

El valor de A se aproxima por la fórmula del trapecio compuesta $A = A_{\text{trp.comp}} + E$, donde E es el error de la aproximación. En este caso

$$S = A_{\text{trp.comp}} + E_{\text{total}},$$

donde el error total $E_{\text{total}} = E + B$ debería estar por debajo de 10^{-2} .

a) Probar que $B < \frac{10^{-2}}{2}$.

Indicación: Probar y usar $e^{-x^2} < e^{-x}$ para $x > 1$. Además $e^{-6} \approx 0.0025$.

b) Determinar un número m de intervalos para aproximar A por la fórmula de trapecios compuesta con un error menor que $\frac{10^{-2}}{2}$.

Indicación: Usar la fórmula del error:

$$E = -\frac{(b-a)h^2}{12} f''(\theta),$$

donde $h = \frac{b-a}{m}$ y $\theta \in [a, b]$.

Desarrollo: Veamos cada apartado por separado:

a) Para calcular B se puede usar la desigualdad indicada en la enunciación:

$$B = \int_6^\infty e^{-x^2} dx < \int_6^\infty e^{-x} dx = -e^{-x} \Big|_6^\infty = e^{-6} \approx 0.0025 < \frac{10^{-2}}{2}.$$

b) Para calcular el número de intervalos necesarios para que el error sea menor que $\frac{10^{-2}}{2}$, se puede usar la fórmula del error indicada en la enunciación:

$$E = -\frac{(b-a)h^2}{12} f''(\theta) = -\frac{6h^2}{12} f''(\theta) = -\frac{h^2}{2} f''(\theta).$$

Para calcular $f''(\theta)$, se puede usar la función dada en la integral:

$$f(x) = e^{-x^2} \implies f' = -2xe^{-x^2} \implies f'' = (4x^2 - 2)e^{-x^2}.$$

Por lo tanto, el error se puede acotar por (usando $h = \frac{b-a}{n}$):

$$E = \left| -\frac{(b-a)h^2}{12} f''(\theta) \right| = \frac{h^2}{2} |f''(\theta)| \leq \frac{36}{2n^2} \|f''\|_\infty = \frac{18}{n^2} \|f''\|_\infty.$$

Ahora para calcular $\|f''\|_\infty$, se puede usar la 3 derivada de f :

$$f''' = (12x - 8x^3)e^{-x^2} \implies f''' = 0 \implies x = 0, \sqrt{\frac{3}{2}}.$$

Ahora, como $f'''(1) > 0$, entonces f'' es creciente en $[0, \sqrt{\frac{3}{2}}]$ y decreciente en $[\sqrt{\frac{3}{2}}, 6]$. Por lo tanto, el máximo de $|f''|$ se encuentra en $\sqrt{\frac{3}{2}}$, dejando así:

$$\|f''\|_\infty = |f''(\sqrt{\frac{3}{2}})|$$

También se podría haber acotado:

$$\|f''\|_\infty \leq \|e^{-x^2}\|_\infty 2\|1 - 2x^2\|_\infty = 2.$$

Ejercicio 4

Prof

Enunciado: Se desea aproximar $\sqrt[3]{21}$ mediante el método del punto fijo:

$$x_0 = 2, \quad x_n = f(x_{n-1}), \quad n = 1, 2, 3, \dots$$

$$\text{con } f = \frac{1}{21} \left(20x + \frac{21}{x^2} \right).$$

a) Encontrar un intervalo $[a, b]$ que contenga a 2, en el que se pueda aplicar el teorema del Punto Fijo de Banach para garantizar la convergencia de la sucesión $\{x_n\}_{n=0}^\infty$.

Indicación: Conviene esbozar la función y luego asegurar que $f : [a, b] \rightarrow [a, b]$. Encontrar un intervalo con $f'(x) > 0$, tal que $a \leq 2 \leq b$, $f(a) \geq a$ y $f(b) \leq b$. Encontrar una constante $0 \leq M < 1$ tal que:

$$|f(x) - f(y)| \leq M|x - y|, \quad \forall x, y \in [a, b].$$

b) Concluir que cualquier sucesión con $x_0 \in [a, b]$ converge a un único punto fijo $\xi \in [a, b]$. Probar que $\xi = \sqrt[3]{21}$.

- c) Determinar un número n de iteraciones para que el error cometido en la aproximación sea menor que 10^{-3} , es decir $E_n = |x_n - \xi| < 10^{-3}$.

Indicación: Dejar el resultado indicado, es decir, poner que $n > \dots$.

Desarrollo: Veamos cada apartado por separado:

- a) Sea la recursión que usaremos:

$$\begin{cases} x_0 = 2 \in [a, b], \\ x_n = h(x_{n-1}) = \frac{1}{21} \left(20x_{n-1} + \frac{21}{x_{n-1}^2} \right), \quad \forall n \in \mathbb{N}. \end{cases}$$

De lo que deducimos:

$$h = \frac{1}{21} \left(20x + \frac{21}{x^2} \right) = \frac{20}{21}x + \frac{1}{x^2} \implies h' = \frac{20}{21} - \frac{2}{x^3} > 0 \iff x > \sqrt[3]{\frac{21}{10}} \approx 1.28.$$

Suele ser útil para encontrar el intervalo establecer que x_0 sea el punto inicial o final del intervalo, es decir, $a = 2$ o $b = 2$. Para comprobar cual nos conviene, calculemos los valores de h para 1, 2, 3 que serian los puntos que limitarían los intervalos $[1, 2]$ y $[2, 3]$:

$$\begin{cases} h(1) = \frac{1}{21}(20 + 21) = \frac{41}{21} > 2, \\ h(2) = \frac{1}{21} \left(40 + \frac{21}{4} \right) \rightarrow \begin{cases} \geq \frac{1}{21} \left(40 + \frac{20}{4} \right) = \frac{45}{21} > 2, \\ \leq \frac{1}{21} \left(40 + \frac{24}{4} \right) = \frac{46}{21} < 3, \end{cases} \\ h(3) = \frac{1}{21} \left(60 + \frac{21}{9} \right) \rightarrow \begin{cases} \geq \frac{1}{21} \left(60 + \frac{18}{9} \right) = \frac{62}{21} > 2, \\ \leq \frac{1}{21} \left(60 + \frac{27}{9} \right) = \frac{63}{21} = 3. \end{cases} \end{cases}$$

Dejando así claro que $h(1) > 2$, $h(2) \in (2, 3)$ y $h(3) \in (2, 3)$. Por lo tanto, el intervalo que nos interesa es $[2, 3]$ (el $[1, 2]$ no es adecuado porque $h(1) > 2$). Ahora, para calcular la norma de la derivada:

$$h'' = \frac{6}{x^4} > 0 \implies h' \text{ es creciente} \implies \|h'\|_\infty = \max_{x \in [2, 3]} h'(x) = h'(3) = \frac{20}{21} - \frac{2}{27} = \frac{520}{567} < 1.$$

- b) Despejando en la función h se obtiene:

$$\xi = h(\xi) \implies \xi = \frac{1}{21} \left(20\xi + \frac{21}{\xi^2} \right) \implies 21\xi = 20\xi + \frac{21}{\xi^2} \implies \xi^3 = 21 \implies \xi = \sqrt[3]{21}.$$

- c) Para calcular el número de iteraciones necesario para que el error sea menor que 10^{-3} , se puede usar la siguiente cota del error:

$$E_n \leq \frac{M^n}{1-M} |x_1 - x_0| \leq \frac{M^n}{1-M} \underbrace{(b-a)}_{=1} < 10^{-3} \implies n > \frac{\ln(10^{-3}(1-M))}{\ln(M)}.$$

Poniendolo como cota superior entera:

$$n = \left\lceil \frac{\ln(10^{-3}(1-M))}{\ln(M)} \right\rceil.$$

Se podría seguir calculando usando el valor numérico de M , y que $\ln(10^{-3}(1-M)) = -3 + \ln(1-M)$, pero lo importante es dejar la expresión indicada. También se podría usar que como $\ln(M) < 0$, entonces $\ln(M) = -\ln(M^{-1})$ y así cambiar el signo del numerador.

Ejercicio 5

Enunciado: Escribir un código de Matlab para la iteración del ejercicio 4 anterior. El código debe implementar como mucho 100 iteraciones y parar si $E_n = |x_n - x_{n-1}| < 10^{-7}$.

Desarrollo:

Part IV

Apéndice

Índice de Apéndice

Apéndice A: Normas comunes	105
Apéndice B: Agradecimientos	107
B.1 Varios compañeros	107

Apéndice A: Normas comunes

Definición A.0.1 [Norma euclídea de un vector]

Dado un vector $x \in \mathbb{R}^n$, su norma euclídea se define como

$$\|x\|_2 = \sqrt{x_1^2 + x_2^2 + \cdots + x_n^2}.$$

Definición A.0.2 [Norma 1 de un vector]

Dado un vector $x \in \mathbb{R}^n$, su norma 1 se define como

$$\|x\|_1 = \sum_{i=1}^n |x_i|.$$

Definición A.0.3 [Norma infinito de un vector]

Dado un vector $x \in \mathbb{R}^n$, su norma infinito se define como

$$\|x\|_\infty = \max_{1 \leq i \leq n} |x_i|.$$

Definición A.0.4 [Norma p de un vector]

Dado un vector $x \in \mathbb{R}^n$ y $p \geq 1$, su norma p se define como

$$\|x\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}.$$

Definición A.0.5 [Norma 1 de una matriz]

Dada una matriz $A \in \mathbb{R}^{m \times n}$, su norma 1 se define como

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|.$$

Es decir, el máximo de las sumas absolutas de las columnas.

Definición A.0.6 [Norma infinito de una matriz]

Dada una matriz $A \in \mathbb{R}^{m \times n}$, su norma infinito se define como

$$\|A\|_{\infty} = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|.$$

Es decir, el máximo de las sumas absolutas de las filas.

Definición A.0.7 [Norma de Frobenius]

Dada una matriz $A \in \mathbb{R}^{m \times n}$, su norma de Frobenius se define como

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2}.$$

Definición A.0.8 [Norma 2 o espectral de una matriz]

Dada una matriz $A \in \mathbb{R}^{m \times n}$, su norma 2 (o espectral) se define como

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)},$$

donde $\lambda_{\max}(A^T A)$ es el mayor valor propio de $A^T A$. Equivalentemente, es el mayor valor singular de A .

Definición A.0.9 [Norma p subordinada de una matriz]

Dada una matriz $A \in \mathbb{R}^{m \times n}$ y una norma vectorial $\|\cdot\|_p$, la norma p subordinada de A se define como

$$\|A\|_p = \sup_{\|x\|_p=1} \|Ax\|_p.$$

Apéndice B: Agradecimientos

Queremos expresar nuestro más sincero agradecimiento a todas las personas que han hecho posible la realización de este trabajo.

B.1 Varios compañeros

Por su inestimable ayuda en la revisión del contenido teórico y por sus valiosas sugerencias que han enriquecido significativamente este trabajo, queremos agradecer a los siguientes compañeros:

- Daniel Pozo Ranchal
- Alba Cervantes Menéndez
- Teresa Marín Marín (especial gratitud por su ayuda en la revisión de la redacción)
- Marta Simó Álvarez
- Jesus Sancho Hagen
- Jorge San Pedro Solanas

This work is licensed under a Creative Commons “Attribution-NonCommercial-NoDerivs 3.0 Unported” license.

