



UNIVERSIDAD
COMPLUTENSE
MADRID

NOMBRE ASIGNATURA ¹

CIENCIAS MATEMÁTICAS E INGENIERÍA INFORMÁTICA

Autores:

Pau Frangi Mahiques, Diego Rodríguez Cubero y Jaime Nieto
Petinal

Primer Cuatrimestre 2025-2026

¹Basado en los apuntes de NOMBRE PROFESOR

Introducción

Estos apuntes han sido elaborados por Pau Frangi Mahiques, Diego Rodríguez Cubero y Jaime Nieto Petinal, estudiantes de 3.º del Doble Grado en Matemáticas e Ingeniería Informática, con el objetivo de ofrecer un material claro, cohesionado y útil para el estudio de la asignatura de ASIGNATURA.

El contenido está basado en las clases del profesor/a NOMBRE PROFESOR, a quien agradecemos su dedicación y claridad expositiva.

El documento está organizado para acompañar el progreso del curso: DESCRIBIR CONTENIDOS. Se incluyen asimismo ejercicios seleccionados y exámenes resueltos, así como material gráfico y esquemas realizados con TikZ para apoyar la intuición geométrica.

Nuestro propósito es doble: por un lado, facilitar la preparación continuada de la asignatura mediante una exposición sistemática, con resultados claramente enunciados y, cuando procede, demostraciones o esbozos de demostración; por otro, servir como referencia rápida para técnicas de cálculo habituales. Aunque hemos procurado la máxima precisión, este material puede contener erratas u omisiones.

Invitamos encarecidamente a los estudiantes que cursen la asignatura en el futuro a ampliar, mejorar o complementar estos apuntes. Cualquier corrección, propuesta o contribución será bienvenida. Para ello, pueden:

- Ponerse en contacto con nosotros mediante nuestros perfiles de GitHub, enlazados en la portada y en el pie de página.
- Podeis mandarnos un correo electrónico a:
 - Diego Rodríguez Cubero: diegorocux3x@gmail.com.
 - Pau Frangi Mahiques: pau.frangi@gmail.com.
 - Jaime Nieto Petinal: jaimenietopetinal1@gmail.com.
- Abrir una incidencia (*issue*) o enviar una contribución (*pull request*) en el repositorio del proyecto.

Estos apuntes reflejan la materia cursada y quedan finalizados conforme al curso ya completado. A partir de aquí, invitamos a futuros alumnos a proponer mejoras, correcciones o ampliaciones; las contribuciones serán valoradas y, en su caso, incorporadas en ediciones posteriores. Agradecemos de antemano toda colaboración que ayude a hacerlos más claros, completos y útiles para la comunidad, ya sea puliendo detalles, corrigiendo erratas o añadiendo contenido relevante, ya sea teórico, ejemplos, ejercicios, exámenes resueltos o material gráfico.

Índice General

Índice General	2
I Teoría	3
1 Métodos iterativos para resolver sistemas lineales	4
1.1 Motivación	4
1.2 Convergencia de métodos iterativos	4
II Ejercicios	10
Hoja 1: Hoja 1	11
Hoja 2: Método de Gauss Jordan	14
III Exámenes	20
Examen 1: Primer examen	21
IV Apéndice	22
Apéndice A: Normas comunes	23
Apéndice B: Agradecimientos	25
B.1 Varios compañeros	25

Part I

Teoría

Índice de Teoría

1	Métodos iterativos para resolver sistemas lineales	4
1.1	Motivación	4
1.2	Convergencia de métodos iterativos	4

1 Métodos iterativos para resolver sistemas lineales

1.1 Motivación

Si tenemos un sistema lineal $Ax = b$ con $A \in \mathbb{R}^{n \times n}$, $b \in \mathbb{R}^n$ y $x \in \mathbb{R}^n$, suficientemente grande, el método de eliminación gaussiana puede resultar ineficiente, al tener coste $O(n^3)$ en términos de tiempo⁹. En estos casos, los métodos iterativos pueden ser una alternativa más adecuada.

La idea de este tipo de metodos va a ser escoger una matriz M :

$$A = M - N$$

Que cumpla que M es fácil de invertir, y que sea similar a A (preferiblemente, $M = A$). Entonces, el sistema $Ax = b$ se puede reescribir como:

$$Mx = Nx + b \implies x = M^{-1}Nx + M^{-1}b \xrightarrow{\text{Notación}} x_k = Bx_{k-1} + C$$

Por lo que podemos utilizar esta ultima expresión para generar una sucesión de aproximaciones a la solución del sistema, partiendo de una aproximación inicial x_0 , la cual convergera a la solución del sistema:

$$\lim_{k \rightarrow \infty} x_k = \xi$$

1.2 Convergencia de métodos iterativos

Definición 1.2.1 [Convergencia de métodos iterativos]

El metodo iterativo () se dice que converge si la sucesión de aproximaciones x_k converge a la solución exacta ξ del sistema lineal $Ax = b$, es decir:*

$$\lim_{k \rightarrow \infty} x_k = \xi \quad \forall x_0 \in \mathbb{R}^n$$

Notese que B no se calcula de forma explicita, sino que se utiliza:

$$\begin{cases} w = Nx_{k-1} + b \\ Mx_k = w \end{cases}$$

Notese el caso particular de $M = A$, que se conoce como método de iteración de Richardson, y que es el método iterativo mas simple, ya que la primera iteración nos devuelve $x_1 = \xi$, es decir, la solución exacta del sistema. Sin embargo, este método no es eficiente, ya que requiere resolver el sistema $Ax = b$ en cada iteración, lo cual es tan costoso como resolver el sistema original.

Veamos ahora algunos criterios de convergencia.

Proposición 1.2.1 [Error en métodos iterativos]

Teniendo un metodo iterativo, podemos definir el error:

$$e_k = x_k - \xi = Bx_{k-1} + C - \underbrace{\xi}_{*} = Bx_{k-1} + C - B\xi - C = B(x_{k-1} - \xi) = Be_{k-1} = B^k e_0$$

Donde el paso (*) se ha realizado utilizando:

$$A\xi = b \implies (M - N)\xi = b \implies M\xi = N\xi + b \implies \xi = M^{-1}N\xi + M^{-1}b = B\xi + C$$

Por lo que el error converge a 0 si y solo si:

$$\lim_{k \rightarrow \infty} \|e_k\| = 0 \iff \lim_{k \rightarrow \infty} \|B^k e_0\| = 0 \iff \|B\| < 1 \iff \rho(B) < 1$$

Proposición 1.2.2 [Criterios de parada]

Para determinar cuándo detener el proceso iterativo, se pueden usar los siguientes criterios:

- **Criterio de iteraciones:** Detener después de un número fijo de iteraciones K_{max} .
- **Criterio de error:** Detener cuando el error estimado $\|e_k\|$ sea menor que una tolerancia predefinida $\varepsilon = TOL$. Esto no se puede aplicar directamente, ya que no conocemos el error real, pero se pueden usar varias posibilidades para estimar el error, el cual se define como:

$$E_k = \frac{\|e_k\|}{\|\xi\|} = \frac{\|x_k - \xi\|}{\|\xi\|}$$

Por ello veamos distintos métodos para estimar el error real:

- **Error relativo:** Se puede usar el error relativo entre iteraciones consecutivas como una estimación del error real, es decir:

$$\|e_k\| \approx \widetilde{E}_k = \frac{\|x_k - x_{k-1}\|}{\|x_k\|}$$

- **Error de residuos:** Se puede usar el residuo del sistema lineal como una estimación del error real, es decir, si definimos el residuo:

$$r_k = b_k - b = Ax_k - bAx_k - A\xi = A(x_k - \xi) = Ae_k$$


Y por tanto podemos estimar el error real como:

$$\|e_k\| \approx \overline{E}_k = \frac{\|b_k - b\|}{\|b\|} = \frac{\|r_k\|}{\|b\|} = \frac{\|A(x_k - \xi)\|}{\|A\xi\|} \approx \frac{\|x_k - \xi\|}{\|\xi\|} = E_k$$

Teorema 1.2.1 [Metodo de Jacobi]

Sea la descomposición de $A = M - N$, y sea tambien su dscomposición en bloques:

$$A = D - E - F$$



Es decir, que:

$$D = \text{diag}(a_{11}, a_{22}, \dots, a_{nn})$$

$$E = (e_{ij})_{i,j=1}^n, \quad \begin{cases} e_{ij} = a_{ij} & \text{si } i > j \\ e_{ij} = 0 & \text{si } i \leq j \end{cases}$$

$$F = (f_{ij})_{i,j=1}^n, \quad \begin{cases} f_{ij} = a_{ij} & \text{si } i < j \\ f_{ij} = 0 & \text{si } i \geq j \end{cases}$$

El método de Jacobi se define como el método iterativo generado por la matriz $M = D$, es decir:

$$\begin{cases} x_0 \in \mathbb{K}^n \\ Dx_k = (E + F)x_{k-1} + b \quad k \in \mathbb{N} \end{cases}$$

Y la matriz del método de Jacobi es:

$$J = \underbrace{D^{-1}}_{M^{-1}} \underbrace{(E + F)}_N = D^{-1}(D - A) = I - D^{-1}A$$

Para que el método este bien planteado, es necesario que D sea invertible, es decir, que $a_{ii} \neq 0$ para todo $i = 1, \dots, n$, si alguno es cero pero $\det(D) \neq 0$, entonces permutamos.

Para iterar definimos el operador de iteración del método de Jacobi:

$$x_i^{(k)} = \left(b_i - \sum_{j \neq i} a_{ij} x_j^{(k-1)} \right) / a_{ii} \quad i \in \{1, \dots, n\}$$

Que tiene complejidad $O(n^2)$, ya que cada iteración requiere calcular n sumas de $n - 1$ elementos.

Veamos ahora varios criterios de convergencia del método de Jacobi.

Proposición 1.2.3 [Convergencia del método de Jacobi]

El método de Jacobi converge si:

$$\rho(J) < 1$$

Ejemplo

Tengamos el sistema:

$$\begin{pmatrix} -1 & 3 \\ -2 & 1 \end{pmatrix} x = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$$

Podemos tomar:

$$M = D = \begin{pmatrix} -1 & 0 \\ 0 & 1 \end{pmatrix} \text{ y } N = E + F = \begin{pmatrix} 0 & -3 \\ 2 & 0 \end{pmatrix}$$

Si definimos ahora:

$$J = D^{-1}(E + F) = \begin{pmatrix} 0 & 3 \\ 2 & 0 \end{pmatrix} \implies \det(J - \lambda I) = \begin{vmatrix} -\lambda & 3 \\ 2 & -\lambda \end{vmatrix} = \lambda^2 - 6 = 0 \implies \lambda = \pm\sqrt{6} > 1$$

Por lo que el método de Jacobi no converge para este sistema lineal.

Definición 1.2.2 [Matriz d.e.d.]

Una matriz $A \in \mathbb{K}^{n \times n}$ es diagonal estrictamente dominante (d.e.d.) si:

$$|a_{ii}| > \sum_{j \neq i} |a_{ij}| \quad \forall i = 1, \dots, n$$

Lema 1.2.1

Sea A una matriz d.e.d., entonces:

$$\exists A^{-1}$$

Demostración. Supongamos que A no es invertible, entonces el sistema $Ax = 0$ tiene infinitas soluciones. Sea $x \neq 0$ solución del sistema, por lo que $\exists i \in \{1, \dots, n\}$ tal que $|x_i| = \max_j |x_j| > 0$. Entonces:

$$a_{ii}x_i + \sum_{j \neq i} a_{ij}x_j = 0 \implies -a_{ii}x_i = \sum_{j \neq i} a_{ij}x_j \implies |a_{ii}||x_i| \leq \sum_{j \neq i} |a_{ij}||x_j| \implies$$

$$|a_{ii}| \leq \sum_{j \neq i} |a_{ij}| \frac{\|x_j\|}{\|x_i\|} \implies |a_{ii}| \leq \sum_{j \neq i} |a_{ij}| \implies \text{Contradicción!!}$$

Por lo que necesariamente A es invertible. □

Teorema 1.2.2 [Convergencia del método de Jacobi para matrices d.e.d.]

Sea A una matriz d.e.d., entonces el método de Jacobi converge.

Demostración. Para ver que converge, comprobemos que $\rho(J) < 1$. Para ello, probemos por absurdo que si $\exists \lambda \in \sigma(J)$ tal que $|\lambda| \geq 1$, entonces se llega a una contradicción, ahora:

$$\det(J - \lambda I) = 0 = \det(D^{-1}(E + F) - \lambda D^{-1}D) = \det(D^{-1}) \det(E + F - \lambda D) \implies$$

Como $\det(D^{-1}) \neq 0$, al ser A d.e.d., entonces:

$$\det(E + F - \lambda D) = 0 \implies \underbrace{(E + F - \lambda D)}_B \text{ no es d.e.d.} \implies \exists k \in \{1, \dots, n\} : \|b_{kk}\| \leq \sum_{j \neq k} \|b_{kj}\| \implies$$

Ahora como $b_{kk} = -\lambda a_{kk}$ y $b_{kj} = -a_{kj}$, entonces:


$$|a_{kk}| \leq |\lambda| |a_{kk}| \leq \sum_{j \neq k} |a_{kj}| \implies |a_{kk}| \leq \sum_{j \neq k} |a_{kj}| \implies \text{Contradicción!!}$$

Por lo que necesariamente $\rho(J) < 1$, y el método de Jacobi converge. $\square$

Veamos ahora otro método iterativo, el método de Gauss-Seidel.

Teorema 1.2.3 [Método de Gauss-Seidel]

Usando la misma descomposición de A que en el método de Jacobi, es decir, $A = D - E - F$, que dejaba:



El método de Gauss-Seidel se define como el método iterativo generado por:

$$\begin{cases} x_0 \in \mathbb{K}^n \\ a_{ii}x_i^{(k)} = b_i - \underbrace{\sum_{j < i} a_{ij}x_j^{(k)}}_{Ex_k} - \underbrace{\sum_{j > i} a_{ij}x_j^{(k-1)}}_{Fx_{k-1}} \quad i = 1, \dots, n, k \in \mathbb{N} \end{cases}$$

Y la convergencia estará dada según la distancia al resultado:

$$\|x_k - \xi\| = d_k \sim \rho(J)^k$$

La complejidad de este método sigue siendo $O(n^2)$, al igual que el método de Jacobi, ya que cada iteración requiere calcular n sumas de $n - 1$ elementos.

Notese que se pueden juntar en la notación $D - E$ y F , para obtener $A = M - N$ con $M = D - E$ y $N = F$, por lo que la matriz del método de Gauss-Seidel es:

$$(D - E)x_k = Fx_{k-1} + b \implies x_k = (D - E)^{-1}Fx_{k-1} + (D - E)^{-1}b$$

Que cambiando la notación, se puede escribir como:

$$x_k = Lx_{k-1} + C \quad \text{con} \quad L = (D - E)^{-1}F \quad \text{y} \quad C = (D - E)^{-1}b$$

Donde ahora el radio espectral del método de Gauss-Seidel es:

$$\rho(L) = \rho((D - E)^{-1}F)$$

Notese que el método de Gauss-Seidel no siempre es mejor que el método de Jacobi, muchas veces lo será pero no siempre.

Part II

Ejercicios

Índice de Ejercicios

Hoja 1: Hoja 1	11
Hoja 2: Método de Gauss Jordan	14

Hoja de Ejercicios 1: Hoja 1

Ejercicio 1

Enunciado:

Desarrollo:

Ejercicio 2

Enunciado:

Desarrollo:

Ejercicio 3

Enunciado:

Desarrollo:

Ejercicio 4

Enunciado:

Desarrollo:

Ejercicio 5

Enunciado:

Desarrollo:

Ejercicio 6

Enunciado:

Desarrollo:

Ejercicio 7

Enunciado:

Desarrollo:

Ejercicio 8

Enunciado:

Desarrollo:

Ejercicio 9

Enunciado:

Desarrollo:

Ejercicio 10

Enunciado:

Desarrollo:

Ejercicio 11

Enunciado:

Desarrollo:

Ejercicio 12

Enunciado:

Desarrollo:

Ejercicio 13

Enunciado:

Desarrollo:

Ejercicio 14

Enunciado:

Desarrollo:

Ejercicio 15

Enunciado:

Desarrollo:

Ejercicio 16

Enunciado:

Desarrollo:

Ejercicio 17

Enunciado: Sea $A \in M_n$ una matriz hermítica (resp. simétrica) definida positiva.

- a) Probar que existe $B \in M_n$ hermítica (resp. simétrica) definida positiva tal que $A = B^2$.
- b) Demostrar que si $\text{cond}_2(A) > 1$ entonces $\text{cond}_2(B) < \text{cond}_2(A)$.

Desarrollo: a) Primero podemos aplicar el teorema de Schur para descomponer $A = UTU^*$, donde U es una matriz unitaria (resp. ortogonal) y T es triangular superior. Luego, como A es h.d.p., T debe ser diagonal con entradas positivas. Por lo tanto, podemos definir $\sqrt{D}$ como la matriz diagonal con las raíces cuadradas de las entradas de $D = T$:

$$A = U\sqrt{D}\sqrt{D}U^* = (U\sqrt{D}U^*)^2 = B^2$$

Por tanto, $B = U\sqrt{D}U^*$ es la matriz que buscamos, y es hermítica (resp. simétrica) y definida positiva, ya que $\sqrt{D}$ es diagonal con entradas positivas y U es unitaria (resp. ortogonal).

b) Ahora, como U es unitaria (resp. ortogonal) y $\sqrt{D}$ es diagonal con entradas positivas, B también es hermítica (resp. simétrica) y definida positiva, y además:

$$\text{cond}_2(B) = \|B\|_2 \|B^{-1}\|_2 = \|U\sqrt{D}U^*\|_2 \|(U\sqrt{D}U^*)^{-1}\|_2 = \|\sqrt{D}\|_2 \|\sqrt{D}^{-1}\|_2 = \sqrt{\text{cond}_2(A)}$$

Otra forma es darse cuenta de que:

$$\|A\|_2^2 = \rho(A^*A) = \rho(A^2) = \rho^2(A) = \lambda_{\max}^2(A)$$

Y la de su inversa:

$$\|A^{-1}\|_2^2 = \rho((A^{-1})^*A^{-1}) = \rho((A^{-1})^2) = \rho^2(A^{-1}) = \lambda_{\max}^2(A^{-1}) = \lambda_{\min}^{-2}(A)$$

Y por tanto su condición es:

$$\text{cond}_2(A) = \|A\|_2 \|A^{-1}\|_2 = \frac{\lambda_{\max}(A)}{\lambda_{\min}(A)}$$

Análogamente para B , su condición es:

$$\text{cond}_2(B) = \|B\|_2 \|B^{-1}\|_2 = \frac{\lambda_{\max}(B)}{\lambda_{\min}(B)} = \frac{\sqrt{\lambda_{\max}(A)}}{\sqrt{\lambda_{\min}(A)}} = \sqrt{\text{cond}_2(A)}$$

Por tanto, si $\text{cond}_2(A) > 1$ entonces $\text{cond}_2(B) < \text{cond}_2(A)$, ya que:

$$\sqrt{\text{cond}_2(A)} < \text{cond}_2(A) \iff \text{cond}_2(A) > 1$$

Hoja de Ejercicios 2: Método de Gauss Jordan

Ejercicio 1

Enunciado: Sea $A \in M_n$ una matriz invertible.

- Adaptar el método de Gauss Jordan para calcular $\widetilde{M}$ que cumpla que $\widetilde{M}A = I$.
- Usando el apartado anterior, explicar como calcular A^{-1} con el método de Gauss Jordan.

Desarrollo: Veamos ambas partes por separado:

- Primero, según el método de Gauss Jordan, podemos realizar operaciones elementales sobre las filas de A para llevarla a la forma escalonada reducida, es decir, encontrar matrices E y T (triangular superior) tal que $EA = T$. Luego, podemos aplicar operaciones elementales sobre las filas de T para llevarla a la forma identidad, es decir, encontrar matrices R y I tal que $RT = I$. Combinando ambas partes, tenemos que $R(EA) = I$, lo que implica que $\widetilde{M} = RE$ cumple la condición $\widetilde{M}A = I$.

Para el cálculo de R , podremos ir descomponiéndola como el producto de n matrices elementales, cada una de las cuales corresponde a una operación elemental sobre las filas de T , y de manera análoga al método de Gauss, vamos a ir aplicando estas operaciones sobre la última columna de T , dejando una submatriz con la que repetir el proceso:

$$R_1 \underbrace{T_0}_{=T} = \left(\begin{array}{c|c} I & -\beta \\ \hline 0 & 1 \end{array} \right) \left(\begin{array}{c|c} T_1 & \beta \\ \hline 0 & 1 \end{array} \right) = \left(\begin{array}{c|c} T_1 & 0 \\ \hline 0 & 1 \end{array} \right)$$

Y podemos repetir el proceso con T_1 y así sucesivamente hasta llegar a la forma identidad, obteniendo R como el producto de las matrices elementales correspondientes a cada operación elemental sobre las filas de T .

- Para calcular A^{-1} con el método de Gauss Jordan, podemos aplicar el método de Gauss Jordan a la matriz, primero escogiendo un número distinto de cero en cada columna, de la forma α_{ij} donde $i \geq j$, que debe existir al ser A invertible, y luego eliminando los elementos de esa columna, y así sucesivamente hasta llegar a la forma identidad. Veamos una iteración del proceso:

$$\left(\begin{array}{c|c|c} I & \alpha_1 & \beta_1 \\ \hline 0 & 1 & \beta_2 \\ \hline 0 & \alpha_2 & \beta_3 \end{array} \right) \xrightarrow{R_i} \left(\begin{array}{c|c|c} I & 0 & \beta'_1 \\ \hline 0 & 1 & \beta'_2 \\ \hline 0 & 0 & \beta'_3 \end{array} \right)$$

Notese que si realizamos este proceso sobre la matriz aumentada $[A|I]$, al llegar a la forma identidad en la parte izquierda, la parte derecha de la matriz aumentada se habrá transformado en A^{-1} , es decir, $[I|A^{-1}]$.

Esto es debido a que las operaciones elementales sobre las filas de A se corresponden con multiplicar A por matrices elementales, y estas mismas operaciones aplicadas a la parte derecha de la matriz aumentada se corresponden con multiplicar I por las mismas matrices elementales, lo que da como resultado A^{-1} al llegar a la forma identidad en la parte izquierda, ya que al haber multiplicado A por las matrices elementales correspondientes a cada operación elemental sobre las filas de A , se habrá obtenido la forma identidad, lo que implica que I se habrá multiplicado por las mismas matrices elementales, dando como resultado $A^{-1} = R_n \cdots R_1 EA = R_n \cdots R_1 E = \widetilde{M}$.

En resumen, para calcular A^{-1} con el método de Gauss Jordan, podemos aplicar el método de Gauss Jordan a la matriz aumentada $[A|I]$, realizando operaciones elementales sobre las filas de A para llevarla a la forma identidad, y aplicando las mismas operaciones elementales sobre las filas de I para obtener A^{-1} en la parte derecha de la matriz aumentada.

Ejercicio 2

Enunciado:

Desarrollo:

Ejercicio 3

Enunciado:

Desarrollo:

Ejercicio 4

Enunciado:

Desarrollo:

Ejercicio 5

Enunciado:

Desarrollo:

Ejercicio 6

Enunciado:

Desarrollo:

Ejercicio 7

Enunciado: Algoritmo para la resolución de sistemas tridiagonales. Se considera el sistema lineal $Ax = d$ para una matriz tridiagonal

$$A = \begin{pmatrix} b_1 & c_1 & & & \\ a_2 & b_2 & c_2 & & \\ & \ddots & \ddots & \ddots & \\ & & a_{n-1} & b_{n-1} & c_{n-1} \\ & & & a_n & b_n \end{pmatrix}.$$

- a) Llamando $\delta_0 = 1$ y δ_k al menor principal de orden k de A ($k = 1, 2, \dots, n$), probar, desarrollando el determinante por la última columna, que $\delta_1 = b_1$ y

$$\delta_k = b_k \delta_{k-1} - a_k c_{k-1} \delta_{k-2}, \quad k = 2, 3, \dots, n.$$

- b) Definimos las sucesiones

$$\begin{cases} m_1 = b_1 \\ m_k = b_k - \frac{c_{k-1}}{m_{k-1}} a_k, \quad k = 2, 3, \dots, n \end{cases} \quad \text{y} \quad \begin{cases} g_1 = \frac{d_1}{m_1} \\ g_k = \frac{d_k - g_{k-1} a_k}{m_k}, \quad k = 2, 3, \dots, n. \end{cases}$$

Probar que $m_k = \frac{\delta_k}{\delta_{k-1}}$ y deducir que si $\delta_k \neq 0$, $k = 1, 2, \dots, n$, entonces $m_k \neq 0$ y, por tanto, los números m_k y g_k , $k = 1, 2, \dots, n$, están bien definidos.

c) Demostrar que la solución del sistema viene dada por

$$\begin{cases} x_n = g_n \\ x_k = g_k - \frac{c_k}{m_k} x_{k+1}, \quad k = n-1, n-2, \dots, 1. \end{cases}$$

d) Comprobar que

$$\begin{pmatrix} 1 & & & & \\ \frac{a_2}{m_1} & 1 & & & \\ & \ddots & \ddots & & \\ & & \frac{a_{n-1}}{m_{n-2}} & 1 & \\ & & & \frac{a_n}{m_{n-1}} & 1 \end{pmatrix} \begin{pmatrix} m_1 & c_1 & & & \\ & m_2 & c_2 & & \\ & & \ddots & \ddots & \\ & & & m_{n-1} & c_{n-1} \\ & & & & m_n \end{pmatrix}$$

es la factorización LU de la matriz A .

Desarrollo: Podemos aplicar la descomposición LU a la matriz tridiagonal A , obteniendo matrices L y U de la forma:

$$A = LU = \begin{pmatrix} 1 & 0 & 0 & \cdots & 0 \\ \frac{a_2}{m_1} & 1 & 0 & \cdots & 0 \\ 0 & \frac{a_3}{m_2} & 1 & \cdots & 0 \\ \vdots & & & \ddots & \\ 0 & 0 & 0 & \frac{a_n}{m_{n-1}} & 1 \end{pmatrix} \begin{pmatrix} m_1 & c_1 & 0 & \cdots & 0 \\ 0 & m_2 & c_2 & \cdots & 0 \\ 0 & 0 & m_3 & \cdots & 0 \\ \vdots & & & \ddots & c_{n-1} \\ 0 & 0 & 0 & 0 & m_n \end{pmatrix}$$

Donde m_k se define como dicta el en el enunciado del ejercicio. Este resultado se prueba trivialmente por inducción sobre n , comprobando que la multiplicación de las matrices L y U da como resultado la matriz A .

Ahora lo que podemos hacer es aplicar la descomposición LU al sistema lineal $Ax = d$, obteniendo:

$$Ax = d \implies LUx = d \xRightarrow[Ux=w]{} Lw = d$$

Donde w es un vector que se obtiene al resolver el sistema lineal $Lw = d$. Este sistema se resuelve fácilmente por remonte.

Ahora podemos definir $x_n = \frac{w_n}{m_n}$, y luego ir definiendo x_k para $k = n-1, n-2, \dots, 1$ de la forma $x_{k-1} = \frac{w_{k-1} - c_{k-1}x_k}{m_{k-1}}$. De esta forma, obtenemos la solución del sistema lineal $Ax = d$ de la forma que dicta el enunciado del ejercicio.

Por último, para probar la relación entre m_k y δ_k , podemos observar que δ_k se puede calcular como el producto de los elementos de la diagonal de la matriz U , es decir, $\delta_k = m_1 m_2 \cdots m_k$. Por lo tanto, $m_k = \frac{\delta_k}{\delta_{k-1}}$, lo que implica que si $\delta_k \neq 0$ para $k = 1, 2, \dots, n$, entonces $m_k \neq 0$ para $k = 1, 2, \dots, n$, y por tanto, los números m_k y g_k están bien definidos.

En resumen, el algoritmo para la resolución de sistemas tridiagonales consiste en aplicar la descomposición LU a la matriz tridiagonal A , obteniendo las matrices L y U , y luego resolver el sistema lineal $Lw = d$ por remonte, y finalmente obtener la solución del sistema lineal $Ax = d$ utilizando las fórmulas dadas en el enunciado del ejercicio.

Ejercicio 8

Enunciado:

Desarrollo:

Ejercicio 9

Enunciado:

Desarrollo:

Ejercicio 10

Enunciado:

Desarrollo:

Ejercicio 11

Enunciado:

Desarrollo:

Ejercicio 12

Enunciado:

Desarrollo:

Ejercicio 13

Enunciado:

Desarrollo:

Ejercicio 14

Enunciado:

Desarrollo:

Ejercicio 15

Enunciado:

Desarrollo:

Ejercicio 16

Enunciado:

Desarrollo:

Ejercicio 17

Enunciado:

Desarrollo:

Part III

Exámenes

Índice de Exámenes

Examen 1: Primer examen	21
-----------------------------------	----

Examen 1: Primer examen

Part IV

Apéndice

Índice de Apéndice

Apéndice A: Normas comunes	23
Apéndice B: Agradecimientos	25
B.1 Varios compañeros	25

Apéndice A: Normas comunes

Definición A.0.3 [Norma euclídea de un vector]

Dado un vector $x \in \mathbb{R}^n$, su norma euclídea se define como

$$\|x\|_2 = \sqrt{x_1^2 + x_2^2 + \cdots + x_n^2}.$$

Definición A.0.4 [Norma 1 de un vector]

Dado un vector $x \in \mathbb{R}^n$, su norma 1 se define como

$$\|x\|_1 = \sum_{i=1}^n |x_i|.$$

Definición A.0.5 [Norma infinito de un vector]

Dado un vector $x \in \mathbb{R}^n$, su norma infinito se define como

$$\|x\|_\infty = \max_{1 \leq i \leq n} |x_i|.$$

Definición A.0.6 [Norma p de un vector]

Dado un vector $x \in \mathbb{R}^n$ y $p \geq 1$, su norma p se define como

$$\|x\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}.$$

Definición A.0.7 [Norma 1 de una matriz]

Dada una matriz $A \in \mathbb{R}^{m \times n}$, su norma 1 se define como

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|.$$

Es decir, el máximo de las sumas absolutas de las columnas.

Definición A.0.8 [Norma infinito de una matriz]

Dada una matriz $A \in \mathbb{R}^{m \times n}$, su norma infinito se define como

$$\|A\|_{\infty} = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|.$$

Es decir, el máximo de las sumas absolutas de las filas.

Definición A.0.9 [Norma de Frobenius]

Dada una matriz $A \in \mathbb{R}^{m \times n}$, su norma de Frobenius se define como

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2}.$$

Definición A.0.10 [Norma 2 o espectral de una matriz]

Dada una matriz $A \in \mathbb{R}^{m \times n}$, su norma 2 (o espectral) se define como

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)},$$

donde $\lambda_{\max}(A^T A)$ es el mayor valor propio de $A^T A$. Equivalentemente, es el mayor valor singular de A .

Definición A.0.11 [Norma p subordinada de una matriz]

Dada una matriz $A \in \mathbb{R}^{m \times n}$ y una norma vectorial $\|\cdot\|_p$, la norma p subordinada de A se define como

$$\|A\|_p = \sup_{\|x\|_p=1} \|Ax\|_p.$$

Apéndice B: Agradecimientos

Queremos expresar nuestro más sincero agradecimiento a todas las personas que han hecho posible la realización de este trabajo.

B.1 Varios compañeros

Por su inestimable ayuda en la revisión del contenido teórico y por sus valiosas sugerencias que han enriquecido significativamente este trabajo, queremos agradecer a los siguientes compañeros:

- Daniel Pozo Ranchal
- Alba Cervantes Menéndez
- Teresa Marín Marín
- Marta Simó Álvarez
- Jesus Sancho Hagen
- Jorge San Pedro Solanas

This work is licensed under a Creative Commons “Attribution-NonCommercial-NoDerivs 3.0 Unported” license.

