



UNIVERSIDAD
COMPLUTENSE
MADRID

NOMBRE ASIGNATURA ¹

CIENCIAS MATEMÁTICAS E INGENIERÍA INFORMÁTICA

Autores:

Pau Frangi Mahiques, Diego Rodríguez Cubero y Jaime Nieto
Petinal

Primer Cuatrimestre 2025-2026

¹Basado en los apuntes de NOMBRE PROFESOR

Introducción

Estos apuntes han sido elaborados por Pau Frangi Mahiques, Diego Rodríguez Cubero y Jaime Nieto Petinal, estudiantes de 3.º del Doble Grado en Matemáticas e Ingeniería Informática, con el objetivo de ofrecer un material claro, cohesionado y útil para el estudio de la asignatura de ASIGNATURA.

El contenido está basado en las clases del profesor/a NOMBRE PROFESOR, a quien agradecemos su dedicación y claridad expositiva.

El documento está organizado para acompañar el progreso del curso: DESCRIBIR CONTENIDOS. Se incluyen asimismo ejercicios seleccionados y exámenes resueltos, así como material gráfico y esquemas realizados con TikZ para apoyar la intuición geométrica.

Nuestro propósito es doble: por un lado, facilitar la preparación continuada de la asignatura mediante una exposición sistemática, con resultados claramente enunciados y, cuando procede, demostraciones o esbozos de demostración; por otro, servir como referencia rápida para técnicas de cálculo habituales. Aunque hemos procurado la máxima precisión, este material puede contener erratas u omisiones.

Invitamos encarecidamente a los estudiantes que cursen la asignatura en el futuro a ampliar, mejorar o complementar estos apuntes. Cualquier corrección, propuesta o contribución será bienvenida. Para ello, pueden:

- Ponerse en contacto con nosotros mediante nuestros perfiles de GitHub, enlazados en la portada y en el pie de página.
- Podeis mandarnos un correo electrónico a:
 - Diego Rodríguez Cubero: diegorocux3x@gmail.com.
 - Pau Frangi Mahiques: pau.frangi@gmail.com.
 - Jaime Nieto Petinal: jaimenietopetinal1@gmail.com.
- Abrir una incidencia (*issue*) o enviar una contribución (*pull request*) en el repositorio del proyecto.

Estos apuntes reflejan la materia cursada y quedan finalizados conforme al curso ya completado. A partir de aquí, invitamos a futuros alumnos a proponer mejoras, correcciones o ampliaciones; las contribuciones serán valoradas y, en su caso, incorporadas en ediciones posteriores. Agradecemos de antemano toda colaboración que ayude a hacerlos más claros, completos y útiles para la comunidad, ya sea puliendo detalles, corrigiendo erratas o añadiendo contenido relevante, ya sea teórico, ejemplos, ejercicios, exámenes resueltos o material gráfico.

Índice General

Índice General	2
I Teoría	3
1 Métodos iterativos para resolver sistemas lineales	4
1.1 Motivación	4
1.2 Convergencia de métodos iterativos	4
1.3 Método de Jacobi y método de Gauss-Seidel	5
1.4 Métodos de relajación	9
II Ejercicios	11
Hoja 1: Hoja 1	12
Hoja 2: Método de Gauss Jordan	15
Hoja 3: Hoja 4	21
III Exámenes	22
Examen 1: Primer examen	23
IV Apéndice	24
Apéndice A: Normas comunes	25
Apéndice B: Agradecimientos	27
B.1 Varios compañeros	27

Part I

Teoría

Índice de Teoría

1	Métodos iterativos para resolver sistemas lineales	4
1.1	Motivación	4
1.2	Convergencia de métodos iterativos	4
1.3	Método de Jacobi y método de Gauss-Seidel	5
1.4	Métodos de relajación	9

1 Métodos iterativos para resolver sistemas lineales

1.1 Motivación

Si tenemos un sistema lineal $Ax = b$ con $A \in \mathbb{R}^{n \times n}$, $b \in \mathbb{R}^n$ y $x \in \mathbb{R}^n$, suficientemente grande, el método de eliminación gaussiana puede resultar ineficiente, al tener coste $O(n^3)$ en términos de tiempo⁹. En estos casos, los métodos iterativos pueden ser una alternativa más adecuada.

La idea de este tipo de metodos va a ser escoger una matriz M :

$$A = M - N$$

Que cumpla que M es fácil de invertir, y que sea similar a A (preferiblemente, $M = A$). Entonces, el sistema $Ax = b$ se puede reescribir como:

$$Mx = Nx + b \implies x = M^{-1}Nx + M^{-1}b \xrightarrow{\text{Notación}} x_k = Bx_{k-1} + C$$

Por lo que podemos utilizar esta ultima expresión para generar una sucesión de aproximaciones a la solución del sistema, partiendo de una aproximación inicial x_0 , la cual convergera a la solución del sistema:

$$\lim_{k \rightarrow \infty} x_k = \xi$$

1.2 Convergencia de métodos iterativos

Definición 1.2.1 [Convergencia de métodos iterativos]

El metodo iterativo $(*)$ se dice que converge si la sucesión de aproximaciones x_k converge a la solución exacta ξ del sistema lineal $Ax = b$, es decir:

$$\lim_{k \rightarrow \infty} x_k = \xi \quad \forall x_0 \in \mathbb{R}^n$$

Notese que B no se calcula de forma explicita, sino que se utiliza:

$$\begin{cases} w = Nx_{k-1} + b \\ Mx_k = w \end{cases}$$

Notese el caso particular de $M = A$, que se conoce como método de iteración de Richardson, y que es el método iterativo mas simple, ya que la primera iteración nos devuelve $x_1 = \xi$, es decir, la solución exacta del sistema. Sin embargo, este método no es eficiente, ya que requiere resolver el sistema $Ax = b$ en cada iteración, lo cual es tan costoso como resolver el sistema original.

Veamos ahora algunos criterios de convergencia.

Proposición 1.2.1 [Error en métodos iterativos]

Teniendo un metodo iterativo, podemos definir el error:

$$e_k = x_k - \xi = Bx_{k-1} + C - \underbrace{\xi}_{*} = Bx_{k-1} + C - B\xi - C = B(x_{k-1} - \xi) = Be_{k-1} = B^k e_0$$

Donde el paso (*) se ha realizado utilizando:

$$A\xi = b \implies (M - N)\xi = b \implies M\xi = N\xi + b \implies \xi = M^{-1}N\xi + M^{-1}b = B\xi + C$$

Por lo que el error converge a 0 si y solo si:

$$\lim_{k \rightarrow \infty} \|e_k\| = 0 \iff \lim_{k \rightarrow \infty} \|B^k e_0\| = 0 \iff \|B\| < 1 \iff \rho(B) < 1$$

Proposición 1.2.2 [Criterios de parada]

Para determinar cuándo detener el proceso iterativo, se pueden usar los siguientes criterios:

- **Criterio de iteraciones:** Detener después de un número fijo de iteraciones K_{max} .
- **Criterio de error:** Detener cuando el error estimado $\|e_k\|$ sea menor que una tolerancia predefinida $\varepsilon = TOL$. Esto no se puede aplicar directamente, ya que no conocemos el error real, pero se pueden usar varias posibilidades para estimar el error, el cual se define como:

$$E_k = \frac{\|e_k\|}{\|\xi\|} = \frac{\|x_k - \xi\|}{\|\xi\|}$$

Por ello veamos distintos métodos para estimar el error real:

- **Error relativo:** Se puede usar el error relativo entre iteraciones consecutivas como una estimación del error real, es decir:

$$\|e_k\| \approx \widetilde{E}_k = \frac{\|x_k - x_{k-1}\|}{\|x_k\|}$$

- **Error de residuos:** Se puede usar el residuo del sistema lineal como una estimación del error real, es decir, si definimos el residuo:

$$r_k = b_k - b = Ax_k - bAx_k - A\xi = A(x_k - \xi) = Ae_k$$

Y por tanto podemos estimar el error real como:


$$\|e_k\| \approx \overline{E}_k = \frac{\|b_k - b\|}{\|b\|} = \frac{\|r_k\|}{\|b\|} = \frac{\|A(x_k - \xi)\|}{\|A\xi\|} \approx \frac{\|x_k - \xi\|}{\|\xi\|} = E_k$$

1.3 Método de Jacobi y método de Gauss-Seidel

Teorema 1.3.1 [Metodo de Jacobi]

Sea la descomposición de $A = M - N$, y sea tambien su dscomposición en bloques:

$$A = D - E - F$$



Es decir, que:

$$D = \text{diag}(a_{11}, a_{22}, \dots, a_{nn})$$

$$E = (e_{ij})_{i,j=1}^n, \quad \begin{cases} e_{ij} = a_{ij} & \text{si } i > j \\ e_{ij} = 0 & \text{si } i \leq j \end{cases}$$

$$F = (f_{ij})_{i,j=1}^n, \quad \begin{cases} f_{ij} = a_{ij} & \text{si } i < j \\ f_{ij} = 0 & \text{si } i \geq j \end{cases}$$

El método de Jacobi se define como el método iterativo generado por la matriz $M = D$, es decir:

$$\begin{cases} x_0 \in \mathbb{K}^n \\ Dx_k = (E + F)x_{k-1} + b \quad k \in \mathbb{N} \end{cases}$$

Y la matriz del método de Jacobi es:

$$J = \underbrace{D^{-1}}_{M^{-1}} \underbrace{(E + F)}_N = D^{-1}(D - A) = I - D^{-1}A$$

Para que el método este bien planteado, es necesario que D sea invertible, es decir, que $a_{ii} \neq 0$ para todo $i = 1, \dots, n$, si alguno es cero pero $\det(D) \neq 0$, entonces permutamos.

Para iterar definimos el operador de iteración del método de Jacobi:

$$x_i^{(k)} = \left(b_i - \sum_{j \neq i} a_{ij} x_j^{(k-1)} \right) / a_{ii} \quad i \in \{1, \dots, n\}$$

Que tiene complejidad $O(n^2)$, ya que cada iteración requiere calcular n sumas de $n - 1$ elementos.

Veamos ahora varios criterios de convergencia del método de Jacobi.

Proposición 1.3.1 [Convergencia del método de Jacobi]

El método de Jacobi converge si:

$$\rho(J) < 1$$

Ejemplo

Tengamos el sistema:

$$\begin{pmatrix} -1 & 3 \\ -2 & 1 \end{pmatrix} x = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$$

Podemos tomar:

$$M = D = \begin{pmatrix} -1 & 0 \\ 0 & 1 \end{pmatrix} \text{ y } N = E + F = \begin{pmatrix} 0 & -3 \\ 2 & 0 \end{pmatrix}$$

Si definimos ahora:

$$J = D^{-1}(E + F) = \begin{pmatrix} 0 & 3 \\ 2 & 0 \end{pmatrix} \implies \det(J - \lambda I) = \begin{vmatrix} -\lambda & 3 \\ 2 & -\lambda \end{vmatrix} = \lambda^2 - 6 = 0 \implies \lambda = \pm\sqrt{6} > 1$$

Por lo que el método de Jacobi no converge para este sistema lineal.

Definición 1.3.1 [Matriz d.e.d.]

Una matriz $A \in \mathbb{K}^{n \times n}$ es diagonal estrictamente dominante (d.e.d.) si:

$$|a_{ii}| > \sum_{j \neq i} |a_{ij}| \quad \forall i = 1, \dots, n$$

Lema 1.3.1

Sea A una matriz d.e.d., entonces:

$$\exists A^{-1}$$

Demostración. Supongamos que A no es invertible, entonces el sistema $Ax = 0$ tiene infinitas soluciones. Sea $x \neq 0$ solución del sistema, por lo que $\exists i \in \{1, \dots, n\}$ tal que $|x_i| = \max_j |x_j| > 0$. Entonces:

$$a_{ii}x_i + \sum_{j \neq i} a_{ij}x_j = 0 \implies -a_{ii}x_i = \sum_{j \neq i} a_{ij}x_j \implies |a_{ii}||x_i| \leq \sum_{j \neq i} |a_{ij}||x_j| \implies$$

$$|a_{ii}| \leq \sum_{j \neq i} |a_{ij}| \frac{\|x_j\|}{\|x_i\|} \implies |a_{ii}| \leq \sum_{j \neq i} |a_{ij}| \implies \text{Contradicción!!}$$

Por lo que necesariamente A es invertible. □

Teorema 1.3.2 [Convergencia del método de Jacobi para matrices d.e.d.]

Sea A una matriz d.e.d., entonces el método de Jacobi converge.

Demostración. Para ver que converge, comprobemos que $\rho(J) < 1$. Para ello, probemos por absurdo que si $\exists \lambda \in \sigma(J)$ tal que $|\lambda| \geq 1$, entonces se llega a una contradicción, ahora:

$$\det(J - \lambda I) = 0 = \det(D^{-1}(E + F) - \lambda D^{-1}D) = \det(D^{-1}) \det(E + F - \lambda D) \implies$$

Como $\det(D^{-1}) \neq 0$, al ser A d.e.d., entonces:

$$\det(E + F - \lambda D) = 0 \implies \underbrace{(E + F - \lambda D)}_B \text{ no es d.e.d.} \implies \exists k \in \{1, \dots, n\} : \|b_{kk}\| \leq \sum_{j \neq k} \|b_{kj}\| \implies$$

Ahora como $b_{kk} = -\lambda a_{kk}$ y $b_{kj} = -a_{kj}$, entonces:


$$|a_{kk}| \leq |\lambda| |a_{kk}| \leq \sum_{j \neq k} |a_{kj}| \implies |a_{kk}| \leq \sum_{j \neq k} |a_{kj}| \implies \text{Contradicción!!}$$

Por lo que necesariamente $\rho(J) < 1$, y el método de Jacobi converge. $\square$

Veamos ahora otro método iterativo, el método de Gauss-Seidel.

Teorema 1.3.3 [Método de Gauss-Seidel]

Usando la misma descomposición de A que en el método de Jacobi, es decir, $A = D - E - F$, que dejaba:



El método de Gauss-Seidel se define como el método iterativo generado por:

$$\begin{cases} x_0 \in \mathbb{K}^n \\ a_{ii}x_i^{(k)} = b_i - \underbrace{\sum_{j < i} a_{ij}x_j^{(k)}}_{Ex_k} - \underbrace{\sum_{j > i} a_{ij}x_j^{(k-1)}}_{Fx_{k-1}} \quad i = 1, \dots, n, k \in \mathbb{N} \end{cases}$$

Y la convergencia estará dada según la distancia al resultado:

$$\|x_k - \xi\| = d_k \sim \rho(J)^k$$

La complejidad de este método sigue siendo $O(n^2)$, al igual que el método de Jacobi, ya que cada iteración requiere calcular n sumas de $n - 1$ elementos.

Notese que se pueden juntar en la notación $D - E$ y F , para obtener $A = M - N$ con $M = D - E$ y $N = F$, por lo que la matriz del método de Gauss-Seidel es:

$$(D - E)x_k = Fx_{k-1} + b \implies x_k = (D - E)^{-1}Fx_{k-1} + (D - E)^{-1}b$$

Que cambiando la notación, se puede escribir como:

$$x_k = Lx_{k-1} + C \quad \text{con} \quad L = (D - E)^{-1}F \quad \text{y} \quad C = (D - E)^{-1}b$$

Donde ahora el radio espectral del método de Gauss-Seidel es:

$$\rho(L) = \rho((D - E)^{-1}F)$$

Notese que el método de Gauss-Seidel no siempre es mejor que el método de Jacobi, muchas veces lo será pero no siempre.

1.4 Métodos de relajación

La idea de los métodos de relajación es modificar los métodos mediante parametros que nos ayuden a mejorar la convergencia. Normalmente usaremos $\omega \in \mathbb{R}$ como parametro de relajación, cuyo significado es el siguiente:

$$x_k = \omega \bar{x}_k + (1 - \omega)x_{k-1}$$

Teorema 1.4.1 [Método de relajación de Jacobi]

El método de relajación de Jacobi se define como el método iterativo, con un punto $\omega \in \mathbb{R}$:

$$\begin{cases} x_0 \in \mathbb{K}^n \\ \frac{D}{\omega}x_k = D\bar{x}_k + \frac{1-\omega}{\omega}Dx_{k-1} = \left(E + F + \frac{1-\omega}{\omega}D\right)x_{k-1} + b \quad k \in \mathbb{N} \end{cases}$$

De lo que sacamos la matriz del método de relajación de Jacobi:

$$J_R = \omega D^{-1} \left(E + F + \frac{1-\omega}{\omega}D \right)$$

Y su convergencia estará dada por el radio espectral de esta matriz, es decir:

$$\rho(J_R) < 1$$

Notese que si $\omega = 1$, entonces el método de relajación de Jacobi coincide con el método de Jacobi, por lo que el método de relajación de Jacobi es una generalización del método de Jacobi.

El método tambien se puede ver de la forma $A = M - N$ con:

$$M = \frac{D}{\omega}$$

$$N = \left(E + F + \frac{1-\omega}{\omega}D \right)$$

De donde queda:

$$A = M - N = \frac{D}{\omega} - \left(E + F + \frac{1-\omega}{\omega}D \right) = D - E - F$$

Sin embargo este método no es muy utilizado en la práctica, ya que no se sabe a priori qué valor de ω es el óptimo para cada sistema lineal, por lo que se suele utilizar el método de relajación de Gauss-Seidel.

Teorema 1.4.2 [Método de relajación de Gauss-Seidel]

El método de relajación de Gauss-Seidel se define como el método iterativo, con un punto $\omega \in [0, 1]$, y multiplicando $\frac{D}{\omega}$ a ambos lados de la ecuación del método de Gauss-Seidel:

$$\begin{cases} x_0 \in \mathbb{K}^n \\ \frac{D}{\omega}x_k = Ex_k + Fx_{k-1} + b + \frac{1-\omega}{\omega}Dx_{k-1} \implies \\ \left(\frac{D}{\omega} - E\right)x_k = \left(F + \frac{1-\omega}{\omega}D\right)x_{k-1} + b \end{cases}$$

De lo que sacamos la matriz del método de relajación de Gauss-Seidel:

$$L_R = (D - \omega E)^{-1}((1 - \omega)D + \omega F)$$

Y su convergencia estará dada por el radio espectral de esta matriz, es decir:

$$\rho(L_R) < 1$$

Notese de nuevo que si $\omega = 1$, entonces el método de relajación de Gauss-Seidel coincide con el método de Gauss-Seidel, por lo que el método de relajación de Gauss-Seidel es una generalización del método de Gauss-Seidel.

Teorema 1.4.3 [Convergencia del método de relajación de Gauss-Seidel]

Si $\omega \notin (0, 2)$ entonces el método de relajación de Gauss-Seidel no converge.

Demostración. Veamos:

$$\det(L_R) = \det\left(\left(\frac{D}{\omega} - E\right)^{-1} \cdot \det\left(F + \frac{1 - \omega}{\omega} D\right)\right) = \frac{\overbrace{\det\left(F + \frac{1 - \omega}{\omega} D\right)}^{\Delta}}{\det\left(\frac{D}{\omega} - E\right)} =$$

$$\frac{\left(\frac{1 - \omega}{\omega}\right)^n \det(D)}{\left(\frac{1}{\omega}\right)^n \det(D)} = (1 - \omega)^n$$

Ahora, recordemos que $\det(L_R) = \prod_{\lambda \in \sigma(L_R)} \lambda$, por lo que igualando:

$$\prod_{\lambda \in \sigma(L_R)} \lambda = (1 - \omega)^n \implies$$

$$\|1 - \omega\|^n = \|(1 - \omega)^n\| = \left\| \prod_{\lambda \in \sigma(L_R)} \lambda \right\| = \prod_{\lambda \in \sigma(L_R)} \|\lambda\| \leq \rho(L_R)^n \implies \|1 - \omega\| \leq \rho(L_R)$$

Por lo que finalmente:

$$\begin{cases} \rho \geq \omega - 1 \implies \boxed{\omega \geq 2 \implies \rho \geq 1 \implies \text{Divergencia}} \\ \rho \geq 1 - \omega \implies \boxed{\omega \leq 0 \implies \rho \geq 1 \implies \text{Divergencia}} \end{cases}$$

□

Part II

Ejercicios

Índice de Ejercicios

Hoja 1: Hoja 1	12
Hoja 2: Método de Gauss Jordan	15
Hoja 3: Hoja 4	21

Hoja de Ejercicios 1: Hoja 1

Ejercicio 1

Enunciado:

Desarrollo:

Ejercicio 2

Enunciado:

Desarrollo:

Ejercicio 3

Enunciado:

Desarrollo:

Ejercicio 4

Enunciado:

Desarrollo:

Ejercicio 5

Enunciado:

Desarrollo:

Ejercicio 6

Enunciado:

Desarrollo:

Ejercicio 7

Enunciado:

Desarrollo:

Ejercicio 8

Enunciado:

Desarrollo:

Ejercicio 9

Enunciado:

Desarrollo:

Ejercicio 10

Enunciado:

Desarrollo:

Ejercicio 11

Enunciado:

Desarrollo:

Ejercicio 12

Enunciado:

Desarrollo:

Ejercicio 13

Enunciado:

Desarrollo:

Ejercicio 14

Enunciado:

Desarrollo:

Ejercicio 15

Enunciado:

Desarrollo:

Ejercicio 16

Enunciado:

Desarrollo:

Ejercicio 17

Enunciado: Sea $A \in M_n$ una matriz hermítica (resp. simétrica) definida positiva.

- a) Probar que existe $B \in M_n$ hermítica (resp. simétrica) definida positiva tal que $A = B^2$.
- b) Demostrar que si $\text{cond}_2(A) > 1$ entonces $\text{cond}_2(B) < \text{cond}_2(A)$.

Desarrollo: a) Primero podemos aplicar el teorema de Schur para descomponer $A = UTU^*$, donde U es una matriz unitaria (resp. ortogonal) y T es triangular superior. Luego, como A es h.d.p., T debe ser diagonal con entradas positivas. Por lo tanto, podemos definir $\sqrt{D}$ como la matriz diagonal con las raíces cuadradas de las entradas de $D = T$:

$$A = U\sqrt{D}\sqrt{D}U^* = (U\sqrt{D}U^*)^2 = B^2$$

Por tanto, $B = U\sqrt{D}U^*$ es la matriz que buscamos, y es hermítica (resp. simétrica) y definida positiva, ya que $\sqrt{D}$ es diagonal con entradas positivas y U es unitaria (resp. ortogonal).

b) Ahora, como U es unitaria (resp. ortogonal) y $\sqrt{D}$ es diagonal con entradas positivas, B también es hermítica (resp. simétrica) y definida positiva, y además:

$$\text{cond}_2(B) = \|B\|_2 \|B^{-1}\|_2 = \|U\sqrt{D}U^*\|_2 \|(U\sqrt{D}U^*)^{-1}\|_2 = \|\sqrt{D}\|_2 \|\sqrt{D}^{-1}\|_2 = \sqrt{\text{cond}_2(A)}$$

Otra forma es darse cuenta de que:

$$\|A\|_2^2 = \rho(A^*A) = \rho(A^2) = \rho^2(A) = \lambda_{\max}^2(A)$$

Y la de su inversa:

$$\|A^{-1}\|_2^2 = \rho((A^{-1})^*A^{-1}) = \rho((A^{-1})^2) = \rho^2(A^{-1}) = \lambda_{\max}^2(A^{-1}) = \lambda_{\min}^{-2}(A)$$

Y por tanto su condición es:

$$\text{cond}_2(A) = \|A\|_2 \|A^{-1}\|_2 = \frac{\lambda_{\max}(A)}{\lambda_{\min}(A)}$$

Análogamente para B , su condición es:

$$\text{cond}_2(B) = \|B\|_2 \|B^{-1}\|_2 = \frac{\lambda_{\max}(B)}{\lambda_{\min}(B)} = \frac{\sqrt{\lambda_{\max}(A)}}{\sqrt{\lambda_{\min}(A)}} = \sqrt{\text{cond}_2(A)}$$

Por tanto, si $\text{cond}_2(A) > 1$ entonces $\text{cond}_2(B) < \text{cond}_2(A)$, ya que:

$$\sqrt{\text{cond}_2(A)} < \text{cond}_2(A) \iff \text{cond}_2(A) > 1$$

Hoja de Ejercicios 2: Método de Gauss Jordan

Ejercicio 1

Enunciado: Sea $A \in M_n$ una matriz invertible.

- Adaptar el método de Gauss Jordan para calcular $\widetilde{M}$ que cumpla que $\widetilde{M}A = I$.
- Usando el apartado anterior, explicar como calcular A^{-1} con el método de Gauss Jordan.

Desarrollo: Veamos ambas partes por separado:

- Primero, según el método de Gauss Jordan, podemos realizar operaciones elementales sobre las filas de A para llevarla a la forma escalonada reducida, es decir, encontrar matrices E y T (triangular superior) tal que $EA = T$. Luego, podemos aplicar operaciones elementales sobre las filas de T para llevarla a la forma identidad, es decir, encontrar matrices R y I tal que $RT = I$. Combinando ambas partes, tenemos que $R(EA) = I$, lo que implica que $\widetilde{M} = RE$ cumple la condición $\widetilde{M}A = I$.

Para el cálculo de R , podremos ir descomponiéndola como el producto de n matrices elementales, cada una de las cuales corresponde a una operación elemental sobre las filas de T , y de manera análoga al método de Gauss, vamos a ir aplicando estas operaciones sobre la última columna de T , dejando una submatriz con la que repetir el proceso:

$$R_1 \underbrace{T_0}_{=T} = \left(\begin{array}{c|c} I & -\beta \\ \hline 0 & 1 \end{array} \right) \left(\begin{array}{c|c} T_1 & \beta \\ \hline 0 & 1 \end{array} \right) = \left(\begin{array}{c|c} T_1 & 0 \\ \hline 0 & 1 \end{array} \right)$$

Y podemos repetir el proceso con T_1 y así sucesivamente hasta llegar a la forma identidad, obteniendo R como el producto de las matrices elementales correspondientes a cada operación elemental sobre las filas de T .

- Para calcular A^{-1} con el método de Gauss Jordan, podemos aplicar el método de Gauss Jordan a la matriz, primero escogiendo un número distinto de cero en cada columna, de la forma α_{ij} donde $i \geq j$, que debe existir al ser A invertible, y luego eliminando los elementos de esa columna, y así sucesivamente hasta llegar a la forma identidad. Veamos una iteración del proceso:

$$\left(\begin{array}{c|c|c} I & \alpha_1 & \beta_1 \\ \hline 0 & 1 & \beta_2 \\ \hline 0 & \alpha_2 & \beta_3 \end{array} \right) \xrightarrow{R_i} \left(\begin{array}{c|c|c} I & 0 & \beta'_1 \\ \hline 0 & 1 & \beta'_2 \\ \hline 0 & 0 & \beta'_3 \end{array} \right)$$

Notese que si realizamos este proceso sobre la matriz aumentada $[A|I]$, al llegar a la forma identidad en la parte izquierda, la parte derecha de la matriz aumentada se habrá transformado en A^{-1} , es decir, $[I|A^{-1}]$.

Esto es debido a que las operaciones elementales sobre las filas de A se corresponden con multiplicar A por matrices elementales, y estas mismas operaciones aplicadas a la parte derecha de la matriz aumentada se corresponden con multiplicar I por las mismas matrices elementales, lo que da como resultado A^{-1} al llegar a la forma identidad en la parte izquierda, ya que al haber multiplicado A por las matrices elementales correspondientes a cada operación elemental sobre las filas de A , se habrá obtenido la forma identidad, lo que implica que I se habrá multiplicado por las mismas matrices elementales, dando como resultado $A^{-1} = R_n \cdots R_1 EA = R_n \cdots R_1 E = \widetilde{M}$.

En resumen, para calcular A^{-1} con el método de Gauss Jordan, podemos aplicar el método de Gauss Jordan a la matriz aumentada $[A|I]$, realizando operaciones elementales sobre las filas de A para llevarla a la forma identidad, y aplicando las mismas operaciones elementales sobre las filas de I para obtener A^{-1} en la parte derecha de la matriz aumentada.

Ejercicio 2

Enunciado:

Desarrollo:

Ejercicio 3

Enunciado:

Desarrollo:

Ejercicio 4

Enunciado:

Desarrollo:

Ejercicio 5

Enunciado:

Desarrollo:

Ejercicio 6

Enunciado:

Desarrollo:

Ejercicio 7

Enunciado: Algoritmo para la resolución de sistemas tridiagonales. Se considera el sistema lineal $Ax = d$ para una matriz tridiagonal

$$A = \begin{pmatrix} b_1 & c_1 & & & \\ a_2 & b_2 & c_2 & & \\ & \ddots & \ddots & \ddots & \\ & & a_{n-1} & b_{n-1} & c_{n-1} \\ & & & a_n & b_n \end{pmatrix}.$$

- a) Llamando $\delta_0 = 1$ y δ_k al menor principal de orden k de A ($k = 1, 2, \dots, n$), probar, desarrollando el determinante por la última columna, que $\delta_1 = b_1$ y

$$\delta_k = b_k \delta_{k-1} - a_k c_{k-1} \delta_{k-2}, \quad k = 2, 3, \dots, n.$$

- b) Definimos las sucesiones

$$\begin{cases} m_1 = b_1 \\ m_k = b_k - \frac{c_{k-1}}{m_{k-1}} a_k, \quad k = 2, 3, \dots, n \end{cases} \quad \text{y} \quad \begin{cases} g_1 = \frac{d_1}{m_1} \\ g_k = \frac{d_k - g_{k-1} a_k}{m_k}, \quad k = 2, 3, \dots, n. \end{cases}$$

Probar que $m_k = \frac{\delta_k}{\delta_{k-1}}$ y deducir que si $\delta_k \neq 0$, $k = 1, 2, \dots, n$, entonces $m_k \neq 0$ y, por tanto, los números m_k y g_k , $k = 1, 2, \dots, n$, están bien definidos.

c) Demostrar que la solución del sistema viene dada por

$$\begin{cases} x_n = g_n \\ x_k = g_k - \frac{c_k}{m_k} x_{k+1}, \quad k = n-1, n-2, \dots, 1. \end{cases}$$

d) Comprobar que

$$\begin{pmatrix} 1 & & & & \\ \frac{a_2}{m_1} & 1 & & & \\ & \ddots & \ddots & & \\ & & \frac{a_{n-1}}{m_{n-2}} & 1 & \\ & & & \frac{a_n}{m_{n-1}} & 1 \end{pmatrix} \begin{pmatrix} m_1 & c_1 & & & \\ & m_2 & c_2 & & \\ & & \ddots & \ddots & \\ & & & m_{n-1} & c_{n-1} \\ & & & & m_n \end{pmatrix}$$

es la factorización LU de la matriz A .

Desarrollo: Podemos aplicar la descomposición LU a la matriz tridiagonal A , obteniendo matrices L y U de la forma:

$$A = LU = \begin{pmatrix} 1 & 0 & 0 & \cdots & 0 \\ \frac{a_2}{m_1} & 1 & 0 & \cdots & 0 \\ 0 & \frac{a_3}{m_2} & 1 & \cdots & 0 \\ \vdots & & & \ddots & \\ 0 & 0 & 0 & \frac{a_n}{m_{n-1}} & 1 \end{pmatrix} \begin{pmatrix} m_1 & c_1 & 0 & \cdots & 0 \\ 0 & m_2 & c_2 & \cdots & 0 \\ 0 & 0 & m_3 & \cdots & 0 \\ \vdots & & & \ddots & c_{n-1} \\ 0 & 0 & 0 & 0 & m_n \end{pmatrix}$$

Donde m_k se define como dicta el en el enunciado del ejercicio. Este resultado se prueba trivialmente por inducción sobre n , comprobando que la multiplicación de las matrices L y U da como resultado la matriz A .

Ahora lo que podemos hacer es aplicar la descomposición LU al sistema lineal $Ax = d$, obteniendo:

$$Ax = d \implies LUx = d \xRightarrow[Ux=w]{} Lw = d$$

Donde w es un vector que se obtiene al resolver el sistema lineal $Lw = d$. Este sistema se resuelve fácilmente por remonte.

Ahora podemos definir $x_n = \frac{w_n}{m_n}$, y luego ir definiendo x_k para $k = n-1, n-2, \dots, 1$ de la forma $x_{k-1} = \frac{w_{k-1} - c_{k-1}x_k}{m_{k-1}}$. De esta forma, obtenemos la solución del sistema lineal $Ax = d$ de la forma que dicta el enunciado del ejercicio.

Por último, para probar la relación entre m_k y δ_k , podemos observar que δ_k se puede calcular como el producto de los elementos de la diagonal de la matriz U , es decir, $\delta_k = m_1 m_2 \cdots m_k$. Por lo tanto, $m_k = \frac{\delta_k}{\delta_{k-1}}$, lo que implica que si $\delta_k \neq 0$ para $k = 1, 2, \dots, n$, entonces $m_k \neq 0$ para $k = 1, 2, \dots, n$, y por tanto, los números m_k y g_k están bien definidos.

En resumen, el algoritmo para la resolución de sistemas tridiagonales consiste en aplicar la descomposición LU a la matriz tridiagonal A , obteniendo las matrices L y U , y luego resolver el sistema lineal $Lw = d$ por remonte, y finalmente obtener la solución del sistema lineal $Ax = d$ utilizando las fórmulas dadas en el enunciado del ejercicio.

Ejercicio 8

Enunciado:

Desarrollo:

Ejercicio 9

Enunciado:

Desarrollo:

Ejercicio 10

Enunciado:

Desarrollo:

Ejercicio 11

Enunciado:

Desarrollo:

Ejercicio 12

Enunciado:

Desarrollo:

Ejercicio 13

Enunciado:

Desarrollo:

Ejercicio 14

Enunciado:

Desarrollo:

Ejercicio 15

Enunciado:

Desarrollo:

Ejercicio 16

Enunciado:

Desarrollo:

Ejercicio 17

Enunciado:

Desarrollo:

Hoja de Ejercicios 3: Hoja 4

Ejercicio 1

Enunciado:

Desarrollo:

Ejercicio 2

Enunciado:

Desarrollo:

Ejercicio 3

Enunciado:

Desarrollo:

Ejercicio 4

Enunciado: Método de relajación para matrices de diagonal estrictamente dominante.

- a) Probar que si $0 < w \leq 1$ y $\lambda \in \mathbb{C}$ con $|\lambda| \geq 1$ entonces

$$\left| \frac{1 - w - \lambda}{\lambda w} \right| \geq 1.$$

Indicación: Utilizar que $|x - y| \geq ||x| - |y||$, $x, y \in \mathbb{C}$.

- b) Demostrar que si A es de diagonal estrictamente dominante entonces el método de relajación para A es convergente si $0 < w \leq 1$.
-

Desarrollo: El apartado a) está probado en clase, veamos el apartado b).
Probemoslo por absurdo, es decir, supongamos que:

$$\exists \lambda \in \sigma(L_R) \text{ tal que } |\lambda| \geq 1 \implies \rho(L_R) \geq 1.$$

Ahora entonces:

$$\det(L_R - \lambda I) = 0 = \det\left(\left(\frac{D}{\omega} - E\right)^{-1} \left(F + \left(\frac{1-\omega}{\omega}\right) D\right) - \lambda I\right)$$

Part III

Exámenes

Índice de Exámenes

Examen 1: Primer examen	23
-----------------------------------	----

Examen 1: Primer examen

Part IV

Apéndice

Índice de Apéndice

Apéndice A: Normas comunes	25
Apéndice B: Agradecimientos	27
B.1 Varios compañeros	27

Apéndice A: Normas comunes

Definición A.0.1 [Norma euclídea de un vector]

Dado un vector $x \in \mathbb{R}^n$, su norma euclídea se define como

$$\|x\|_2 = \sqrt{x_1^2 + x_2^2 + \cdots + x_n^2}.$$

Definición A.0.2 [Norma 1 de un vector]

Dado un vector $x \in \mathbb{R}^n$, su norma 1 se define como

$$\|x\|_1 = \sum_{i=1}^n |x_i|.$$

Definición A.0.3 [Norma infinito de un vector]

Dado un vector $x \in \mathbb{R}^n$, su norma infinito se define como

$$\|x\|_\infty = \max_{1 \leq i \leq n} |x_i|.$$

Definición A.0.4 [Norma p de un vector]

Dado un vector $x \in \mathbb{R}^n$ y $p \geq 1$, su norma p se define como

$$\|x\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}.$$

Definición A.0.5 [Norma 1 de una matriz]

Dada una matriz $A \in \mathbb{R}^{m \times n}$, su norma 1 se define como

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|.$$

Es decir, el máximo de las sumas absolutas de las columnas.

Definición A.0.6 [Norma infinito de una matriz]

Dada una matriz $A \in \mathbb{R}^{m \times n}$, su norma infinito se define como

$$\|A\|_{\infty} = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|.$$

Es decir, el máximo de las sumas absolutas de las filas.

Definición A.0.7 [Norma de Frobenius]

Dada una matriz $A \in \mathbb{R}^{m \times n}$, su norma de Frobenius se define como

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2}.$$

Definición A.0.8 [Norma 2 o espectral de una matriz]

Dada una matriz $A \in \mathbb{R}^{m \times n}$, su norma 2 (o espectral) se define como

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)},$$

donde $\lambda_{\max}(A^T A)$ es el mayor valor propio de $A^T A$. Equivalentemente, es el mayor valor singular de A .

Definición A.0.9 [Norma p subordinada de una matriz]

Dada una matriz $A \in \mathbb{R}^{m \times n}$ y una norma vectorial $\|\cdot\|_p$, la norma p subordinada de A se define como

$$\|A\|_p = \sup_{\|x\|_p=1} \|Ax\|_p.$$

Apéndice B: Agradecimientos

Queremos expresar nuestro más sincero agradecimiento a todas las personas que han hecho posible la realización de este trabajo.

B.1 Varios compañeros

Por su inestimable ayuda en la revisión del contenido teórico y por sus valiosas sugerencias que han enriquecido significativamente este trabajo, queremos agradecer a los siguientes compañeros:

- Daniel Pozo Ranchal
- Alba Cervantes Menéndez
- Teresa Marín Marín
- Marta Simó Álvarez
- Jesus Sancho Hagen
- Jorge San Pedro Solanas

This work is licensed under a Creative Commons “Attribution-NonCommercial-NoDerivs 3.0 Unported” license.

