



UNIVERSIDAD
COMPLUTENSE
MADRID

NOMBRE ASIGNATURA ¹

CIENCIAS MATEMÁTICAS E INGENIERÍA INFORMÁTICA

Autores:

Pau Frangi Mahiques, Diego Rodríguez Cubero y Jaime Nieto
Petinal

Primer Cuatrimestre 2025-2026

¹Basado en los apuntes de NOMBRE PROFESOR

Introducción

Estos apuntes han sido elaborados por Pau Frangi Mahiques, Diego Rodríguez Cubero y Jaime Nieto Petinal, estudiantes de 3.º del Doble Grado en Matemáticas e Ingeniería Informática, con el objetivo de ofrecer un material claro, cohesionado y útil para el estudio de la asignatura de ASIGNATURA.

El contenido está basado en las clases del profesor/a NOMBRE PROFESOR, a quien agradecemos su dedicación y claridad expositiva.

El documento está organizado para acompañar el progreso del curso: DESCRIBIR CONTENIDOS. Se incluyen asimismo ejercicios seleccionados y exámenes resueltos, así como material gráfico y esquemas realizados con TikZ para apoyar la intuición geométrica.

Nuestro propósito es doble: por un lado, facilitar la preparación continuada de la asignatura mediante una exposición sistemática, con resultados claramente enunciados y, cuando procede, demostraciones o esbozos de demostración; por otro, servir como referencia rápida para técnicas de cálculo habituales. Aunque hemos procurado la máxima precisión, este material puede contener erratas u omisiones.

Invitamos encarecidamente a los estudiantes que cursen la asignatura en el futuro a ampliar, mejorar o complementar estos apuntes. Cualquier corrección, propuesta o contribución será bienvenida. Para ello, pueden:

- Ponerse en contacto con nosotros mediante nuestros perfiles de GitHub, enlazados en la portada y en el pie de página.
- Podeis mandarnos un correo electrónico a:
 - Diego Rodríguez Cubero: diegorocux3x@gmail.com.
 - Pau Frangi Mahiques: pau.frangi@gmail.com.
 - Jaime Nieto Petinal: jaimenietopetinal1@gmail.com.
- Abrir una incidencia (*issue*) o enviar una contribución (*pull request*) en el repositorio del proyecto.

Estos apuntes reflejan la materia cursada y quedan finalizados conforme al curso ya completado. A partir de aquí, invitamos a futuros alumnos a proponer mejoras, correcciones o ampliaciones; las contribuciones serán valoradas y, en su caso, incorporadas en ediciones posteriores. Agradecemos de antemano toda colaboración que ayude a hacerlos más claros, completos y útiles para la comunidad, ya sea puliendo detalles, corrigiendo erratas o añadiendo contenido relevante, ya sea teórico, ejemplos, ejercicios, exámenes resueltos o material gráfico.

Índice General

Índice General	2
I Teoría	4
1 Matrices y sus propiedades	6
1.1 Tipos de matrices	6
1.2 Autovalores y autovectores	15
1.3 Teoremas importantes	17
1.4 Matrices hermiticas definidas positivas	21
1.5 Normas matriciales	22
1.6 Normas subordinadas	23
1.7 Potencias de matrices	26
1.8 Condicionamiento de matrices	27
2 Resolución de sistemas lineales	29
2.1 Introducción a los sistemas lineales	29
2.2 Factorización LU	33
2.3 Factorización de Cholesky	37
3 Métodos iterativos para resolver sistemas lineales	39
3.1 Motivación	39
3.2 Convergencia de métodos iterativos	39
3.3 Método de Jacobi y método de Gauss-Seidel	40
3.4 Métodos de relajación	44
4 Interpolación polinómica	48
4.1 Motivación	48
4.2 Problema de la interpolación polinómica	48
4.3 Polinomios de Lagrange	49
4.4 Error de interpolación	50
4.5 Método de Newton	52
4.5.1 Diferencias divididas	52
4.5.2 Definición del método de Newton	53
4.6 Splines	55
5 Diferenciación Numérica	62
5.1 Motivación	62
5.2 Aproximación por interpolación	62
5.3 Aproximación mediante Taylor	63
5.4 Diferencias centradas	64
5.5 Aplicaciones	64
6 Integración Numérica	65
6.1 Motivación	65
6.2 Aproximación por interpolación de Lagrange	65
II Ejercicios	67
Hoja 1: Interpolación e integración numérica	68

III	Exámenes	75
	Examen 1: Primer examen	76
IV	Apéndice	77
	Apéndice A: Normas comunes	78
	Apéndice B: Agradecimientos	80
	B.1 Varios compañeros	80

Part I

Teoría

Índice de Teoría

1	Matrices y sus propiedades	6
1.1	Tipos de matrices	6
1.2	Autovalores y autovectores	15
1.3	Teoremas importantes	17
1.4	Matrices hermiticas definidas positivas	21
1.5	Normas matriciales	22
1.6	Normas subordinadas	23
1.7	Potencias de matrices	26
1.8	Condicionamiento de matrices	27
2	Resolución de sistemas lineales	29
2.1	Introducción a los sistemas lineales	29
2.2	Factorización LU	33
2.3	Factorización de Cholesky	37
3	Métodos iterativos para resolver sistemas lineales	39
3.1	Motivación	39
3.2	Convergencia de métodos iterativos	39
3.3	Método de Jacobi y método de Gauss-Seidel	40
3.4	Métodos de relajación	44
4	Interpolación polinómica	48
4.1	Motivación	48
4.2	Problema de la interpolación polinómica	48
4.3	Polinomios de Lagrange	49
4.4	Error de interpolación	50
4.5	Método de Newton	52
4.6	Splines	55
5	Diferenciación Numérica	62
5.1	Motivación	62
5.2	Aproximación por interpolación	62
5.3	Aproximación mediante Taylor	63
5.4	Diferencias centradas	64

5.5	Aplicaciones	64
6	Integración Numérica	65
6.1	Motivación	65
6.2	Aproximación por interpolación de Lagrange	65

1 Matrices y sus propiedades

1.1 Tipos de matrices

Veamos algunos tipos de matrices que nos encontraremos a lo largo del curso:

Definición 1.1.1 [Matrices introductorias]

- **Matriz fila:** Una matriz que tiene una sola fila. Por ejemplo, la matriz $A = [a_1, a_2, a_3]$ es una matriz fila de tamaño 1×3 .
- **Matriz columna:** Una matriz que tiene una sola columna. Por ejemplo, la matriz $B = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix}$ es una matriz columna de tamaño 3×1 .
- **Matriz cuadrada:** Una matriz que tiene el mismo número de filas y columnas. Por ejemplo, la matriz $C = \begin{bmatrix} c_{11} & c_{12} \\ c_{21} & c_{22} \end{bmatrix}$ es una matriz cuadrada de tamaño 2×2 .
- **Matriz diagonal:** Una matriz cuadrada en la que todos los elementos fuera de la diagonal principal son cero. Por ejemplo, la matriz $D = \begin{bmatrix} d_{11} & 0 \\ 0 & d_{22} \end{bmatrix}$ es una matriz diagonal.
- **Matriz identidad:** Una matriz diagonal en la que todos los elementos de la diagonal principal son uno. Por ejemplo, la matriz $I = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$ es una matriz identidad de tamaño 2×2 .
- **Matriz nula:** Una matriz en la que todos los elementos son cero. Por ejemplo, la matriz $O = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}$ es una matriz nula de tamaño 2×2 .
- **Matriz transpuesta:** La matriz obtenida al intercambiar las filas por las columnas de una matriz dada. Si A es una matriz de tamaño $m \times n$, su transpuesta A^T será de tamaño $n \times m$. Por ejemplo, si $A = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}$, entonces su transpuesta es $A^T = \begin{bmatrix} a_{11} & a_{21} \\ a_{12} & a_{22} \end{bmatrix}$.
- **Matriz simétrica:** Una matriz cuadrada que es igual a su transpuesta. Es decir, $A = A^T$. Por ejemplo, la matriz $S = \begin{bmatrix} s_{11} & s_{12} \\ s_{12} & s_{22} \end{bmatrix}$ es simétrica.
- **Matriz antisimétrica:** Una matriz cuadrada que es igual a la negativa de su transpuesta. Es decir, $A = -A^T$. Por ejemplo, la matriz $T = \begin{bmatrix} 0 & t_{12} \\ -t_{12} & 0 \end{bmatrix}$ es antisimétrica.
- **Matriz triangular:** Una matriz cuadrada que tiene todos los elementos por encima (o por debajo) de la diagonal principal iguales a cero. Si los elementos por debajo de la diagonal son cero, se llama matriz triangular superior; si los elementos por encima son cero, se llama matriz triangular inferior. Por ejemplo, la matriz $U = \begin{bmatrix} u_{11} & u_{12} \\ 0 & u_{22} \end{bmatrix}$ es triangular superior.
- **Matriz ortogonal:** Una matriz cuadrada Q es ortogonal si su transpuesta es igual a su inversa, es decir, $Q^T = Q^{-1}$. Esto implica que $QQ^T = Q^TQ = I$, donde I es la matriz identidad. Tam-

bien se caracteriza porque sus columnas (y filas) forman un conjunto ortonormal en el espacio euclídeo. Por ejemplo, la matriz $Q = \begin{bmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$ es ortogonal.

- **Traspuesto conjugado:** Denotado como A^* , es la matriz obtenida al tomar la traspuesta de una matriz y luego tomar el conjugado complejo de cada uno de sus elementos. Por ejemplo, si $A = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}$, entonces su traspuesto conjugado es $A^* = \begin{bmatrix} \overline{a_{11}} & \overline{a_{21}} \\ \overline{a_{12}} & \overline{a_{22}} \end{bmatrix}$, donde $\overline{a_{ij}}$ denota el conjugado complejo de a_{ij} .
- **Matriz definida positiva/negativa:** Una matriz cuadrada A es definida positiva si para cualquier vector no nulo x , se cumple que $x^T A x > 0$. De manera similar, A es definida negativa si para cualquier vector no nulo x , se cumple que $x^T A x < 0$.
- **Matriz semidefinida positiva/negativa:** Una matriz cuadrada A es semidefinida positiva si para cualquier vector x , se cumple que $x^T A x \geq 0$. De manera similar, A es semidefinida negativa si para cualquier vector x , se cumple que $x^T A x \leq 0$.
- **Matriz indefinida:** Una matriz cuadrada A es indefinida si existen vectores x y y tales que $x^T A x > 0$ y $y^T A y < 0$.

Ahora definamos algunos tipos de matrices más avanzados:

Definición 1.1.2 [Matriz hermitiana]

Una matriz cuadrada A es hermitiana si es igual a su traspuesto conjugado, es decir, $A = A^*$. En el caso de matrices con entradas reales, una matriz hermitiana es simplemente una matriz simétrica, es decir:

$$A \in \mathbb{R}^{n \times n} \text{ es hermitiana} \iff A = A^T$$

Veamos un par de ejemplos de matrices hermitianas:

Ejemplo

- La matriz $A = \begin{bmatrix} 2 & 3+i \\ 3-i & 4 \end{bmatrix}$ es hermitiana, ya que su traspuesto conjugado es $A^* = \begin{bmatrix} 2 & 3-i \\ 3+i & 4 \end{bmatrix}$, que es igual a A .
- La matriz $B = \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}$ es hermitiana, ya que su traspuesto conjugado es $B^* = \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}$, que es igual a B .

Definición 1.1.3 [Matriz unitaria]

Una matriz cuadrada U es unitaria si su traspuesto conjugado es igual a su inversa, es decir, $U^* = U^{-1}$. Esto implica que $UU^* = U^*U = I$, donde I es la matriz identidad.

Veamos un par de ejemplos de matrices unitarias:

Ejemplo

- La matriz $U = \begin{bmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$ es unitaria, ya que su traspuesto conjugado es $U^* = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$, y se cumple que $UU^* = I$.
- La matriz $V = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$ es unitaria, ya que su traspuesto conjugado es $V^* = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$, y se cumple que $VV^* = I$.

Observación 1.1.1

Se puede apreciar que si U es una matriz unitaria compleja:

$$U^* = U^{-1} \implies U^*U = I \implies U^*U = \begin{pmatrix} u_1^* \\ \vdots \\ u_n^* \end{pmatrix} (u_1 \quad \dots \quad u_n) = \begin{pmatrix} u_1^*u_1 & \dots & u_1^*u_n \\ \vdots & \ddots & \vdots \\ u_n^*u_1 & \dots & u_n^*u_n \end{pmatrix} = \begin{pmatrix} 1 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & 1 \end{pmatrix}$$

De lo cual se deduce que los vectores columna de U forman un conjunto ortonormal en el espacio complejo, es decir, $u_i^*u_j = \delta_{ij}$, ya que el producto $u_i^*u_j$ representa el producto interno entre los vectores u_i y u_j en el espacio complejo, y hemos visto que $u_i^*u_j = 0$ si $i \neq j$ y $u_i^*u_i = \|u_i\|^2 = 1$.

Definición 1.1.4 [Matriz normal]

Una matriz cuadrada A es normal si conmuta con su traspuesto conjugado, es decir, si se cumple que $AA^* = A^*A$.

Veamos un par de ejemplos de matrices normales:

Ejemplo

- La matriz $A = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}$ es normal, ya que su traspuesto conjugado es $A^* = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}$, y se cumple que $AA^* = A^*A = \begin{bmatrix} 4 & 0 \\ 0 & 9 \end{bmatrix}$.
- La matriz $B = \begin{bmatrix} 1 & i \\ -i & 1 \end{bmatrix}$ es normal, ya que su traspuesto conjugado es $B^* = \begin{bmatrix} 1 & i \\ -i & 1 \end{bmatrix}$, y se cumple que $BB^* = B^*B = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$.

Observación 1.1.2

Notese que si A es hermitiana, entonces $A = A^*$, por lo que:

$$AA^* = AA = A^2 = A^*A$$

Por lo tanto, toda matriz hermitiana es normal.

Algo similar ocurre con las matrices unitarias, ya que si U es unitaria, entonces $U^* = U^{-1}$, por lo

que:

$$UU^* = UU^{-1} = I = U^{-1}U = U^*U$$

Por lo tanto, toda matriz unitaria es normal.

Proposición 1.1.1 [Producto de matrices triangulares]

Sean $A, B \in \mathbb{C}^{n \times n}$ dos matrices triangulares inferiores (superiores). Entonces, el producto $C = AB$ es también una matriz triangular inferior (superior).

Demostración. Podemos aplicar una inducción sencilla sobre el tamaño de las matrices.

Caso base: Para $n = 1$, las matrices son simplemente escalares, y el producto de dos escalares es un escalar, que puede considerarse como una matriz triangular inferior (superior) trivialmente.

Paso inductivo: Supongamos que la proposición es cierta para matrices de tamaño $(n-1) \times (n-1)$. Consideremos dos matrices triangulares inferiores $A, B \in \mathbb{C}^{n \times n}$:

$$A = \begin{array}{c|c} a_{11} & 0 \\ \hline \alpha & A_{(n-1)} \end{array}, \quad B = \begin{array}{c|c} b_{11} & 0 \\ \hline \beta & B_{(n-1)} \end{array}$$

Y su producto:

$$C = AB = \begin{array}{c|c} a_{11}b_{11} & 0 \\ \hline \alpha b_{11} + A_{(n-1)}\beta & A_{(n-1)}B_{(n-1)} \end{array}$$

Por la hipótesis inductiva, $A_{(n-1)}B_{(n-1)}$ es una matriz triangular inferior de tamaño $(n-1) \times (n-1)$. Además, el elemento en la posición $(n, 1)$ de C es $\alpha b_{11} + A_{(n-1)}\beta$, que es un vector columna. Por lo tanto, todos los elementos por encima de la diagonal principal de C son cero, lo que demuestra que C es una matriz triangular inferior.

Por lo tanto, por el principio de inducción matemática, la proposición es cierta para todas las matrices triangulares inferiores (superiores) de tamaño $n \times n$. $\square$

Definición 1.1.5 [Matriz banda]

Se define una matriz banda como una matriz cuadrada en la que los elementos no nulos se encuentran dentro de una franja diagonal alrededor de la diagonal principal. Esta franja está determinada por dos enteros no negativos k_1 y k_2 , que representan el número de subdiagonales y superdiagonales, respectivamente. Formalmente, una matriz $A \in \mathbb{R}^{n \times n}$ es una matriz banda si:

$$a_{ij} = 0 \quad \text{si } |i - j| > k$$

donde $k = \max(k_1, k_2)$.

Veamos un par de ejemplos de matrices banda:

Ejemplo

- Una matriz tridiagonal es una matriz banda con $k_1 = k_2 = 1$. Por ejemplo, la matriz $A =$

$$\begin{bmatrix} a_{11} & a_{12} & 0 & 0 \\ a_{21} & a_{22} & a_{23} & 0 \\ 0 & a_{32} & a_{33} & a_{34} \\ 0 & 0 & a_{43} & a_{44} \end{bmatrix} \text{ es tridiagonal.}$$

- Una matriz pentadiagonal es una matriz banda con $k_1 = k_2 = 2$. Por ejemplo, la matriz

$$B = \begin{bmatrix} b_{11} & b_{12} & b_{13} & 0 & 0 \\ b_{21} & b_{22} & b_{23} & b_{24} & 0 \\ b_{31} & b_{32} & b_{33} & b_{34} & b_{35} \\ 0 & b_{42} & b_{43} & b_{44} & b_{45} \\ 0 & 0 & b_{53} & b_{54} & b_{55} \end{bmatrix} \text{ es pentadiagonal.}$$

Definición 1.1.6 [Matriz de diagonal estrictamente dominante]

Una matriz cuadrada $A = [a_{ij}] \in \mathbb{R}^{n \times n}$ se dice que es de diagonal estrictamente dominante si para cada fila i se cumple que:

$$|a_{ii}| > \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}|$$

Es decir, el valor absoluto del elemento en la diagonal principal de cada fila es mayor que la suma de los valores absolutos de los demás elementos en esa fila.

Veamos un par de ejemplos de matrices de diagonal estrictamente dominante:

Ejemplo

- La matriz $A = \begin{bmatrix} 4 & 1 & 2 \\ 3 & 5 & 1 \\ 1 & 1 & 6 \end{bmatrix}$ es de diagonal estrictamente dominante, ya que:

$$|4| > |1| + |2|, \quad |5| > |3| + |1|, \quad |6| > |1| + |1|$$

- La matriz $B = \begin{bmatrix} 10 & 2 & 1 \\ 1 & 8 & 2 \\ 2 & 1 & 9 \end{bmatrix}$ es de diagonal estrictamente dominante, ya que:

$$|10| > |2| + |1|, \quad |8| > |1| + |2|, \quad |9| > |2| + |1|$$

Definición 1.1.7 [Traza de una matriz]

La traza de una matriz cuadrada $A = [a_{ij}] \in \mathbb{R}^{n \times n}$ se define como la suma de los elementos en la diagonal principal de la matriz. Matemáticamente, se expresa como:

$$\text{tr}(A) = \sum_{i=1}^n a_{ii}$$

donde a_{ii} son los elementos en la diagonal principal de la matriz A .

Veamos un par de ejemplos de cálculo de la traza de una matriz:

Ejemplo

- Para la matriz $A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}$, la traza es:

$$\text{tr}(A) = 1 + 5 + 9 = 15$$

- Para la matriz $B = \begin{bmatrix} 2 & 0 & 1 \\ 0 & 3 & 4 \\ 5 & 6 & 7 \end{bmatrix}$, la traza es:

$$\text{tr}(B) = 2 + 3 + 7 = 12$$

Proposición 1.1.2 [Propiedades de la traza]

Veamos algunas propiedades importantes de la traza de una matriz:

- **Linealidad:** La traza es una función lineal, es decir, para dos matrices cuadradas A y B del mismo tamaño y un escalar c , se cumple que:

$$\text{tr}(A + B) = \text{tr}(A) + \text{tr}(B)$$

$$\text{tr}(cA) = c \cdot \text{tr}(A)$$

- **Invarianza bajo trasposición:** La traza de una matriz es igual a la traza de su transpuesta:

$$\text{tr}(A) = \text{tr}(A^T)$$

- **Invarianza bajo conjugación:** La traza de una matriz es igual a la traza de su traspuesto conjugado:

$$\text{tr}(A) = \text{tr}(A^*)$$

- **Cyclicidad:** La traza del producto de dos matrices es invariante bajo el cambio de orden:

$$\text{tr}(AB) = \text{tr}(BA)$$

Las propiedades anteriores se prueban directamente a partir de la definición de traza y las propiedades básicas de las operaciones matriciales, veamos solo la última:

$$C = AB \implies c_{ii} = \sum_{k=1}^n a_{ik} b_{ki} \implies \text{tr}(C) = \sum_{i=1}^n c_{ii} = \sum_{i=1}^n \sum_{k=1}^n a_{ik} b_{ki}$$

$$D = BA \implies d_{ii} = \sum_{k=1}^n b_{ik} a_{ki} \implies \text{tr}(D) = \sum_{i=1}^n d_{ii} = \sum_{i=1}^n \sum_{k=1}^n b_{ik} a_{ki}$$

Cambiando el orden de las sumas en ambos casos, se llega a la igualdad:

$$\text{tr}(C) = \text{tr}(D)$$

Definición 1.1.8 [Rango de una matriz]

El rango de una matriz $A \in \mathbb{R}^{m \times n}$ es el número máximo de columnas linealmente independientes que tiene la matriz. Se denota como $\text{rg}(A)$. El rango también puede ser interpretado como la dimensión del espacio generado por las columnas de la matriz, o como el número de filas no nulas en la forma escalonada reducida por filas de la matriz.

Observación 1.1.3

Notese que el rango de una matriz A es igual al rango de su transpuesta A^T , es decir, $\text{rg}(A) = \text{rg}(A^T)$. Esto se debe a que el número de columnas linealmente independientes en A es igual al número de filas linealmente independientes en A^T , ya que las filas de A^T corresponden a las columnas de A .

Definición 1.1.9 [Determinante]

El determinante de una matriz cuadrada $A \in \mathbb{R}^{n \times n}$ es un valor escalar que se asocia a la matriz y que proporciona información sobre ciertas propiedades de la misma, como su invertibilidad y el volumen de transformación lineal que representa. El determinante se denota como $\det(A)$ o $|A|$, y se calcula como:

$$\det(A) = \sum_{\sigma \in S_n} \text{sgn}(\sigma) \prod_{i=1}^n a_{i,\sigma(i)}$$

donde S_n es el conjunto de todas las permutaciones de los números $1, 2, \dots, n$, y $\text{sgn}(\sigma)$ es el signo de la permutación σ .

Proposición 1.1.3 [Propiedades del determinante]

Veamos algunas propiedades importantes del determinante de una matriz:

- **Multiplicatividad:** El determinante del producto de dos matrices es igual al producto de sus determinantes:

$$\det(AB) = \det(A) \cdot \det(B)$$

- **Determinante de matrices diagonales:** El determinante de una matriz diagonal es igual al producto de los elementos en la diagonal principal:

$$\det(D) = \prod_{i=1}^n d_{ii}$$

- **Transposición:** El determinante de una matriz es igual al determinante de su transpuesta:

$$\det(A) = \det(A^T)$$

- **Escalar:** Si c es un escalar y A es una matriz cuadrada de tamaño $n \times n$, entonces:

$$\det(cA) = c^n \cdot \det(A)$$

- **Inversión:** Si A es una matriz invertible, entonces:

$$\det(A^{-1}) = \frac{1}{\det(A)}$$

Todas estas propiedades se pueden demostrar utilizando la definición del determinante y las propiedades básicas de las operaciones matriciales.

Proposición 1.1.4 [Determinante de una matriz unitaria]

Sea $U \in \mathbb{C}^{n \times n}$ una matriz unitaria. Entonces, el valor absoluto de su determinante es igual a 1, es decir:

$$|\det(U)| = 1$$

Demostración. Sea U una matriz unitaria, por definición, se cumple que $U^* = U^{-1}$. Aplicando la propiedad de multiplicatividad del determinante, tenemos:

$$UU^* = I \implies \det(UU^*) = \det(I) = 1 \implies \det(U) \cdot \det(U^*) = \det(U) \cdot \overline{\det(U)} = |\det(U)|^2 = 1$$

De donde se deduce que:

$$|\det(U)| = 1$$

□

Teorema 1.1.1 [Caracterización de las matrices invertibles]

Sea $A \in \mathbb{R}^{n \times n}$ una matriz cuadrada. Entonces, las siguientes afirmaciones son equivalentes:

1. A es invertible, es decir $\exists A^{-1}$ tal que $AA^{-1} = A^{-1}A = I$.
2. El determinante de A es diferente de cero, es decir, $\det(A) \neq 0$.
3. El espectro de A no contiene el valor cero, es decir, $0 \notin \sigma(A)$.

Demostración. Veamos las implicaciones:

2) $\iff$ 3) Sabemos que el espectro de una matriz A está dado por los valores propios de la matriz, que son las soluciones de la ecuación característica $\det(A - \lambda I) = 0$. Si $0 \in \sigma(A)$, entonces existe un valor propio $\lambda = 0$ tal que $\det(A - 0 \cdot I) = \det(A) = 0$. Por lo tanto, si $\det(A) \neq 0$, entonces $0 \notin \sigma(A)$, y viceversa.

1) $\implies$ 2) Si A es invertible, entonces existe una matriz A^{-1} tal que $AA^{-1} = I$. Aplicando la propiedad de multiplicatividad del determinante, tenemos:

$$\det(AA^{-1}) = \det(I) = 1 \implies \det(A) \cdot \det(A^{-1}) = 1 \implies \det(A) = (\det(A^{-1}))^{-1} \neq 0$$

De donde se deduce que $\det(A) \neq 0$.

2) $\implies$ 1) Si $\det(A) \neq 0$, entonces la ecuación característica $\det(A - \lambda I) = 0$ no tiene $\lambda = 0$ como solución, lo que implica que A no tiene un núcleo no trivial. Por lo tanto, la transformación lineal asociada a A es inyectiva y, dado que A es cuadrada, también es sobreyectiva. Por el teorema de la inversa, esto implica que A es invertible.

Otra forma de demostrarlo es utilizando la descomposición LU o la eliminación de Gauss. Si $\det(A) \neq$

0, entonces A puede ser reducida a la matriz identidad mediante operaciones elementales, es decir, $\exists E_1, E_2, \dots, E_k$ matrices elementales tales que:

$$AE = AE_1 E_2 \dots E_k = I$$

Donde $E = E_1 E_2 \dots E_k$ es una matriz invertible, ya que es el producto de matrices elementales. Por lo tanto, podemos escribir:

$$A = E^{-1} I = E^{-1}$$

Y se deduce que A es invertible, con $A^{-1} = E$.

□

Veamos ahora varias propiedades interesantes del calculo de determinantes.

Corolario 1.1.1 [Determinante de una matriz triangular]

El determinante de una matriz triangular (superior o inferior) es igual al producto de los elementos en la diagonal principal. Es decir, si A es una matriz triangular, entonces:

$$\det(A) = \prod_{i=1}^n a_{ii}$$

Esto se da ya que si en una permutacion tenemos un elemento fuera de la diagonal principal, entonces el producto de los elementos correspondientes a esa permutacion sera cero, ya que si el elemento esta por debajo de la diagonal principal (en una triangular superior) o por encima de la diagonal principal (en una triangular inferior), entonces ese elemento es cero, lo que hace que el producto de los elementos correspondientes a esa permutacion sea cero, esta en el otro lado de la diagonal, debe haber un elemento fuera de la diagonal principal, lo que hace que el producto de los elementos correspondientes a esa permutacion sea cero, y asi sucesivamente para todas las permutaciones que tengan un elemento fuera de la diagonal principal, lo que hace que el unico producto no nulo sea el producto de los elementos en la diagonal principal, que corresponde a la permutacion identidad.

Corolario 1.1.2

Sea $M = \left(\begin{array}{c|c} A & 0 \\ \hline 0 & B \end{array} \right)$ una matriz con "solo 2 esquinas", entonces ocurre lo siguiente:

$$\det(M) = \left| \begin{array}{c|c} A & 0 \\ \hline 0 & B \end{array} \right| = \left| \begin{array}{c|c} A & 0 \\ \hline 0 & I \end{array} \right| \cdot \left| \begin{array}{c|c} I & 0 \\ \hline 0 & B \end{array} \right| = \det(A) \cdot \det(B)$$

Corolario 1.1.3

Sea $M = \left(\begin{array}{c|c} A & C \\ \hline 0 & B \end{array} \right)$ una matriz con "solo 3 esquinas", entonces ocurre lo siguiente:

$$\left| \begin{array}{c|c} I & \Gamma \\ \hline 0 & I \end{array} \right| \cdot \left| \begin{array}{c|c} A & C \\ \hline 0 & B \end{array} \right| = \left| \begin{array}{c|c} A & C + \Gamma B \\ \hline 0 & B \end{array} \right|$$

Ahora si tomamos $\Gamma = -CB^{-1}$, entonces:

$$\left| \begin{array}{c|c} I & -CB^{-1} \\ \hline 0 & I \end{array} \right| \cdot \left| \begin{array}{c|c} A & C \\ \hline 0 & B \end{array} \right| = \left| \begin{array}{c|c} A & 0 \\ \hline 0 & B \end{array} \right|$$

Esto lo podemos hacer ya que si B no es invertible, entonces habria una combinación lineal de las filas de B que daría como resultado la fila nula, la cual al replicarse en la esquina inferior derecha de M haría que M no sea invertible, lo que implicaría que $\det(M) = 0$, y por lo tanto, $\det(A) \cdot \det(B) = 0$, lo que implica que $\det(B) = 0$.

Por lo tanto, si B es invertible, entonces podemos realizar la operación anterior para obtener una matriz con "solo 2 esquinas", y aplicar el resultado del corolario anterior para concluir que:

$$\det(M) = \det(A) \cdot \det(B)$$

Ya que el primer determinante $\left| \begin{array}{c|c} I & \Gamma \\ \hline 0 & I \end{array} \right|$ es igual a 1, por ser una matriz triangular superior con 1's en la diagonal principal.

1.2 Autovalores y autovectores

Para definir los autovalores y autovectores de una matriz, primero necesitamos definir el concepto de espectro de una matriz, y el polinomio característico de una matriz.

Definición 1.2.1 [Espectro de una matriz]

El espectro de una matriz cuadrada $A \in \mathbb{R}^{n \times n}$ es el conjunto de todos los valores propios de la matriz, es decir, el conjunto de todos los escalares λ para los cuales existe un vector no nulo v tal que:

$$Av = \lambda v$$

El espectro se denota como $\sigma(A) = sp(A)$.

Definición 1.2.2 [Polinomio característico de una matriz]

El polinomio característico de una matriz cuadrada $A \in \mathbb{R}^{n \times n}$ es un polinomio en la variable λ definido como:

$$p_A(\lambda) = \det(A - \lambda I)$$

donde I es la matriz identidad de tamaño $n \times n$.

Los valores propios de la matriz A son las raíces del polinomio característico, es decir, los valores de λ para los cuales $p_A(\lambda) = 0$.

Ahora sí, podemos definir formalmente los autovalores y autovectores de una matriz:

Definición 1.2.3 [Autovalores y autovectores de una matriz]

Dada una matriz cuadrada $A \in \mathbb{R}^{n \times n}$, un escalar λ se llama autovalor de A si existe un vector no nulo $v \in \mathbb{R}^n$ tal que:

$$Av = \lambda v$$

En este caso, el vector v se llama autovector asociado al autovalor λ .

El conjunto de todos los autovectores asociados a un autovalor λ forma un subespacio vectorial llamado espacio propio o eigenspace correspondiente a λ . Este espacio se denota como $E_\lambda = \{v \in \mathbb{R}^n : Av = \lambda v\}$.

Notese que a los autovalores también se les conoce como valores propios, y a los autovectores como vectores propios.

Una forma de calcular los autovalores de una matriz es utilizando el polinomio característico, ya que los autovalores son las raíces de dicho polinomio. Para calcular los autovectores asociados a un autovalor λ , se puede resolver el sistema de ecuaciones lineales dado por:

$$(A - \lambda I)v = 0$$

que corresponde a encontrar el núcleo de la matriz $A - \lambda I$. El espacio propio E_λ es precisamente el núcleo de esta matriz, y sus elementos son los autovectores asociados al autovalor λ .

Notese también que el espectro es el conjunto de autovalores, y que cada autovalor puede tener uno o más autovectores asociados, dependiendo de su multiplicidad algebraica y geométrica.

Definición 1.2.4 [Multiplicidad algebraica y geométrica de un autovalor]

Dado un autovalor λ de una matriz $A \in \mathbb{R}^{n \times n}$, se define la multiplicidad algebraica de λ como el número de veces que λ aparece como raíz del polinomio característico $p_A(\lambda)$.

Por otro lado, la multiplicidad geométrica de λ se define como la dimensión del espacio propio E_λ , es decir, el número máximo de autovectores linealmente independientes asociados al autovalor λ .

Es importante destacar que la multiplicidad geométrica de un autovalor siempre es menor o igual a su multiplicidad algebraica.

Definición 1.2.5 [Radio espectral de una matriz]

El radio espectral de una matriz cuadrada $A \in \mathbb{R}^{n \times n}$ se define como el máximo valor absoluto de los autovalores de la matriz. Matemáticamente, se expresa como:

$$\rho(A) = \max_{\lambda \in \sigma(A)} |\lambda|$$

El radio espectral proporciona información sobre el comportamiento asintótico de las potencias de la matriz A , ya que si $\rho(A) < 1$, entonces las potencias de A tienden a cero, mientras que si $\rho(A) > 1$, entonces las potencias de A crecen sin límite.

Veamos ahora como el espectro se mantiene ante la conmutación del producto de matrices.

Proposición 1.2.1

Si $A, B \in \mathbb{R}^{n \times n}$ son dos matrices cuadradas, entonces el espectro de AB es igual al espectro de BA , es decir:

$$\sigma(AB) = \sigma(BA)$$

Demostración. Para ver esto, veamos como $\forall \lambda \in \sigma(AB)$, entonces existe un vector no nulo v tal que:

$$BAv = \lambda v$$

Es decir, que λ es un autovalor de BA (la implicación contraria es análoga). Para ello distingamos dos casos:

$\lambda = 0$ En este caso:

$$0 \in \sigma(AB) \iff \det(AB) = 0 \det(BA) \iff 0 \in \sigma(BA)$$

$\lambda \neq 0$ En este caso, como $v \neq 0$ es un autovector asociado al autovalor λ de AB , entonces $ABv = \lambda v$. Multiplicando ambos lados por B , obtenemos:

$$BA(Bv) = B(ABv) = \lambda(Bv)$$

Por lo que Bv es un autovector asociado al autovalor λ de BA . Además, como v es un vector no nulo y $\lambda \neq 0$, entonces Bv también es un vector no nulo, lo que garantiza que $\lambda \in \sigma(BA)$, ya que además $\det(B) \neq 0$ (si B no es invertible, entonces $0 \in \sigma(B)$, lo que implica que $0 \in \sigma(BA)$, lo que contradice la suposición de que $\lambda \neq 0$).

□

Veamos ahora como el espectro de una matriz se traslada al de sus potencias.

Proposición 1.2.2

Si $A \in \mathbb{R}^{n \times n}$ es una matriz cuadrada, entonces el espectro de A^k es igual al conjunto de los autovalores de A elevados a la potencia k , es decir:

$$\sigma(A^k) = \{\lambda^k : \lambda \in \sigma(A)\}$$

Demostración. Para ver esto, veamos como $\forall \lambda \in \sigma(A)$, entonces existe un vector no nulo v tal que:

$$Av = \lambda v$$

Ahora apliquemos inducción sobre k para demostrar que $A^k v = \lambda^k v$:

- **Caso base:** Para $k = 1$, se cumple que $A^1 v = Av = \lambda v$, lo que es cierto por la definición de autovalor y autovector.
- **Paso inductivo:** Supongamos que para algún $k \geq 1$, se cumple que $A^k v = \lambda^k v$. Entonces, para $k + 1$, tenemos:

$$A^{k+1} v = A(A^k v) = A(\lambda^k v) = \lambda^k (Av) = \lambda^k (\lambda v) = \lambda^{k+1} v$$

Por lo tanto, por el principio de inducción matemática, se cumple que $A^k v = \lambda^k v$ para todo $k \geq 1$.

De donde se deduce que λ^k es un autovalor de A^k con el mismo autovector v . Además, como v es un vector no nulo, entonces λ^k también es un valor propio de A^k . Por lo tanto, se concluye que:

$$\sigma(A^k) = \{\lambda^k : \lambda \in \sigma(A)\}$$

□

1.3 Teoremas importantes

Teorema 1.3.1 [Descomposición QR]

Sea $A \in \mathbb{K}^{m \times n}$ una matriz de rango máximo.

Entonces existen una matriz unitaria (ortogonal) $Q \in \mathbb{K}^{m \times m}$ y una matriz triangular superior $R \in \mathbb{K}^{m \times n}$ tal que:

$$A = QR \iff Q^*A = R$$

$Q^{-1}=Q^*$

Antes de la demostración, conviene definir el operador de proyección ortogonal de un vector sobre otro.

Definición 1.3.1 [Proyección ortogonal de un vector sobre otro]

Dados dos vectores $u, a \in \mathbb{K}^n$, la proyección ortogonal de a sobre u se define como el vector:

$$p : \mathbb{K}^n \times \mathbb{K}^n \rightarrow \mathbb{K}^n$$

$$(u, a) \mapsto p(u, a) = \frac{\langle u, a \rangle}{\|u\|^2} u = \left\langle \frac{u}{\|u\|}, a \right\rangle \frac{u}{\|u\|}$$

Teniendo en cuenta que:

$$\langle u, a \rangle = u^* a = a^* u$$

$$\|u\|^2 = \langle u, u \rangle = u^* u$$

Demostración. Vamos a realizar una demostración constructiva utilizando el proceso de Gram-Schmidt para ortogonalizar las columnas de la matriz A , es decir, queremos contruir una base ortogonal tal que $Q = (q_1, q_2, \dots, q_n)$, y para ello haremos lo siguiente:

Iremos tomando vectores u_i que sean ortogonales entre sí, y luego los normalizaremos para obtener los vectores q_i que formarán la matriz unitaria Q .

Para el primer vector, tomamos $u_1 = a_1$, donde a_1 es la primera columna de A . Luego, normalizamos u_1 para obtener $q_1 = \frac{u_1}{\|u_1\|}$.

Ahora para obtener el segundo vector, tomamos $u_2 = a_2 - p(u_1, a_2)$, donde $p(u_1, a_2)$ es la proyección ortogonal de a_2 sobre u_1 . Luego, normalizamos u_2 para obtener $q_2 = \frac{u_2}{\|u_2\|}$.

Para el tercer vector, tomamos $u_3 = a_3 - p(u_1, a_3) - p(u_2, a_3)$, donde $p(u_1, a_3)$ y $p(u_2, a_3)$ son las proyecciones ortogonales de a_3 sobre u_1 y u_2 , respectivamente. Luego, normalizamos u_3 para obtener $q_3 = \frac{u_3}{\|u_3\|}$.


Continuando de esta manera, para el k -ésimo vector, tomamos:

$$u_k = a_k - \sum_{j=1}^{k-1} p(u_j, a_k)$$

Luego, normalizamos u_k para obtener $q_k = \frac{u_k}{\|u_k\|}$.

De esta forma, obtenemos una base ortonormal $Q = (q_1, q_2, \dots, q_n)$ que forma una matriz unitaria.

Todo esto se puede entender geoméricamente como ir proyectando cada columna de A sobre el espacio generado por las columnas anteriores, quitándole la parte que está en ese espacio, y luego normalizando el resultado para obtener un vector unitario, vease el siguiente dibujo:



Así, hemos construido la matriz unitaria Q a partir de las columnas de A , ya que los vectores q_i son ortonormales y forman una base del espacio generado por las columnas de A , es decir, de $\mathbb{K}^n$.

Gracias a esta construcción, podemos definir la matriz triangular superior R como:

$$R = Q^* A = \begin{pmatrix} q_1^* \\ q_2^* \\ \vdots \\ q_n^* \end{pmatrix} \cdot (a_1 \ a_2 \ \cdots \ a_n) = \begin{pmatrix} q_1^* a_1 & q_1^* a_2 & \cdots & q_1^* a_n \\ \mathbf{0} & q_2^* a_2 & \cdots & q_2^* a_n \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{0} & \mathbf{0} & \cdots & q_n^* a_n \end{pmatrix}$$

Estos 0 aparecen ya que:

$$q_m^* a_k = \langle q_m, a_k \rangle = \langle q_m, u_k + \sum_{j=1}^{k-1} p(u_j, a_k) \rangle = \langle q_m, u_k \rangle + \sum_{j=1}^{k-1} \langle q_m, p(u_j, a_k) \rangle$$

Y ahora:

$$\langle q_m, u_k \rangle = \begin{cases} 0 & \text{si } m < k \\ \|u_k\| & \text{si } m = k \end{cases}$$

Por lo que si $m > k$, entonces $q_m^* a_k = 0$, y si $m = k$, entonces $q_m^* a_k = \|u_k\|$.

De esta forma, obtenemos una matriz triangular superior R con los elementos de la diagonal principal dados por $\|u_k\|$, y los elementos por encima de la diagonal dados por $q_m^* a_k$ para $m < k$.

Finalmente, como Q es una matriz unitaria, se cumple que $Q^{-1} = Q^*$, por lo que podemos escribir:

$$A = QR \iff Q^* A = R$$

Y con esto, hemos demostrado la existencia de la descomposición QR para cualquier matriz de rango máximo. $\square$

Veamos ahora otra descomposición importante, la descomposición de Schur.

Teorema 1.3.2 [Descomposición de Schur]

Sea $A \in \mathbb{C}^{n \times n}$ una matriz cuadrada. Entonces, existe una matriz unitaria $U \in \mathbb{C}^{n \times n}$ y una matriz triangular superior $T \in \mathbb{C}^{n \times n}$ tal que:

$$A = UTU^* \underbrace{\iff}_{U^{-1}=U^*} U^*AU = T$$

Si además A es hermítica, entonces T es diagonal, es decir:

$$A = UDU^* \underbrace{\iff}_{U^{-1}=U^*} U^*AU = D$$

Demostración. Sea $\lambda \in sp(A)$ un autovalor de A , y sea v un autovector asociado a λ , al cual imponemos ser unitario, es decir, $\|v\| = 1$.

Ahora completamos a una base ortonormal $(v, w_2, w_3, \dots, w_n)$ de $\mathbb{C}^n$, y formamos la matriz unitaria $U_1 = (v, w_2, w_3, \dots, w_n)$.

La idea a partir de aquí es ir aplicando el proceso de Gram-Schmidt a las columnas de A para obtener una matriz triangular superior, pero en lugar de empezar con la primera columna, empezamos con la columna correspondiente al autovector v , que es la primera columna de U_1 , y finalmente obtendremos una matriz triangular superior T tal que $U_1^* A U_1 = T$.

La demostración no se va a realizar. $\square$

Veamos ahora varias proposiciones interesantes.

Corolario 1.3.1 [Determinante de una matriz triangular]

El determinante de una matriz triangular (superior o inferior) es igual al producto de los elementos en la diagonal principal. Es decir, si A es una matriz triangular, entonces:

$$\det(A) = \prod_{i=1}^n a_{ii}$$

Esto ya se probó anteriormente, solo lo recordamos, pero ahora lo podemos entender como una consecuencia directa de la descomposición de Schur, ya que si $A = UTU^*$, entonces:

$$\det(A) = \det(UTU^*) = \det(U) \cdot \det(T) \cdot \det(U^*) = |\det(U)|^2 \cdot \prod_{i=1}^n t_{ii} = \prod_{i=1}^n t_{ii}$$

Donde t_{ii} son los elementos de la diagonal principal de T , y se ha utilizado el hecho de que U es una matriz unitaria, por lo que $|\det(U)| = 1$.

Corolario 1.3.2 [Espectro de una matriz triangular]

El espectro de una matriz triangular (superior o inferior) es igual al conjunto de los elementos en la diagonal principal. Es decir, si A es una matriz triangular, entonces:

$$\sigma(A) = \{a_{11}, a_{22}, \dots, a_{nn}\}$$

Corolario 1.3.3 [Espectro de una matriz bajo la descomposición de Schur]

Si $A \in \mathbb{C}^{n \times n}$ es una matriz cuadrada, y $A = UTU^*$ es su descomposición de Schur, entonces el espectro de A es igual al conjunto de los elementos en la diagonal principal de T . Es decir:

$$\sigma(A) = \{t_{11}, t_{22}, \dots, t_{nn}\}$$

Esto se ve fácilmente tomando $\lambda \in \sigma(A)$ y v un autovector asociado a λ , entonces:

$$Av = UTU^*v \implies \lambda v = UTU^*v \implies \lambda U^*v = TU^*v \xRightarrow[u=U^*v \neq 0]{} \lambda u = Tu$$

Corolario 1.3.4 [La traza de una matriz es igual a la suma de sus autovalores]

Si $A \in \mathbb{C}^{n \times n}$ es una matriz cuadrada, y $A = UTU^*$ es su descomposición de Schur, entonces la traza de A es igual a la suma de los elementos en la diagonal principal de T , que a su vez es igual a la suma de los autovalores de A . Es decir:

$$tr(A) = tr(AUU^*) \underset{tr(AB)=tr(BA)}{=} tr(U^*AU) = tr(T) = \sum_{i=1}^n t_{ii} = \sum_{\lambda \in \sigma(A)} \lambda$$

Corolario 1.3.5 [Espectro de la inversa de una matriz]

Si $A \in \mathbb{C}^{n \times n}$ es una matriz cuadrada invertible, entonces el espectro de A^{-1} es igual al conjunto de los inversos de los elementos en la diagonal principal de T . Es decir:

$$\sigma(A) = \{\lambda_i\} \implies \sigma(A^{-1}) = \{\lambda_i^{-1}\} = \left\{\frac{1}{\lambda_i}\right\}$$

Esto se ve facilmente tomando $\lambda \in \sigma(A)$ y v un autovector asociado a λ , entonces:

$$Av = \lambda v \implies A^{-1}Av = A^{-1}\lambda v \implies v = \lambda A^{-1}v \implies A^{-1}v = \frac{1}{\lambda}v$$

Corolario 1.3.6 [Espectro de una matriz hermítica]

Si $A \in \mathbb{C}^{n \times n}$ es una matriz hermítica, entonces el espectro de A es un conjunto de números reales. Es decir:

$$A = A^* \implies \sigma(A) \subseteq \mathbb{R}$$

Esto se ve facilmente tomando $\lambda \in \sigma(A)$ y v un autovector asociado a λ , entonces:

$$Av = \lambda v \implies (Av)^* = (\lambda v)^* \implies v^* A^* = v^* \lambda^* \implies v^* A = \lambda^* v^* \implies v^* Av = \lambda^* \|v\|^2 \implies$$

$$v^* \lambda v = \lambda v^* v \implies \lambda \|v\|^2 = \lambda^* \|v\|^2 \implies \lambda = \lambda^*$$

De donde se deduce que como $\lambda^* = \lambda$, implica que λ es un número real.

1.4 Matrices hermiticas definidas positivas

Definición 1.4.1 [Matriz hermítica definida positiva]

Una matriz $A \in \mathbb{C}^{n \times n}$ se dice que es hermítica definida positiva, o h.d.p., si cumple las siguientes condiciones:

- A es hermítica, es decir, $A = A^*$.
- Para todo vector no nulo $x \in \mathbb{C}^n$, se cumple que $x^* Ax > 0$.

Proposición 1.4.1 [Espectro de una matriz h.d.p.]

Las siguientes afirmaciones son equivalentes para una matriz $A \in \mathbb{C}^{n \times n}$:

- A es hermítica definida positiva.
- A es hermítica y su espectro $\sigma(A)$ está contenido en el conjunto de los números reales positivos, es decir, $\sigma(A) \subseteq \mathbb{R}_{>0}$.

Demostración. Para demostrar la equivalencia, veamos cada implicación por separado:

(1) $\Rightarrow$ (2): Supongamos que A es hermítica definida positiva. Entonces, por definición, para todo vector no nulo $x \in \mathbb{C}^n$, se cumple que $x^* Ax > 0$. En particular, si tomamos un autovector v asociado a un

autovalor λ , entonces:

$$v^*Av = v^*(\lambda v) = \lambda v^*v = \lambda \|v\|^2 \implies \lambda = \frac{v^*Av}{\|v\|^2} > 0$$

Dado que v es un vector no nulo, entonces $\|v\|^2 > 0$, lo que implica que $\lambda > 0$. Por lo tanto, todos los autovalores de A son positivos, y como A es hermítica, su espectro está contenido en el conjunto de los números reales positivos.

(2) $\Rightarrow$ (1): Supongamos que A es hermítica y su espectro está contenido en el conjunto de los números reales positivos. Entonces, por la descomposición de Schur, existe una matriz unitaria U y una matriz triangular superior T tal que:

$$A = UTU^*$$

Donde los elementos de la diagonal principal de T , que son los autovalores de A , son todos positivos. Ahora, para cualquier vector no nulo $x \in \mathbb{C}^n$, tenemos:

$$x^*Ax = x^*UTU^*x = (U^*x)^*T(U^*x) = w^*Dw = \sum_{i=1}^n t_{ii}|w_i|^2 = \sum_{i=1}^n \lambda_i|w_i|^2$$

Notese que hemos podido tomar una matriz diagonal D en lugar de la matriz triangular T , ya que el producto w^*Tw solo depende de los elementos de la diagonal principal de T , que son los autovalores de A . Dado que $\lambda_i > 0$ para todo i , y que $w = U^*x$ es un vector no nulo (ya que U es una matriz unitaria), entonces al menos uno de los términos $|w_i|^2$ es positivo, lo que implica que la suma es estrictamente mayor que cero. Por lo tanto:

$$x^*Ax > 0$$

Por lo tanto, se concluye que A es hermítica definida positiva. $\square$

1.5 Normas matriciales

Empecemos recordando que es una norma vectorial.

Definición 1.5.1 [Norma vectorial general]

Una norma vectorial es una función que asigna a cada vector $v \in \mathbb{K}^n$ un número real no negativo, y que satisface las siguientes propiedades:

$$\begin{aligned} \|\cdot\| : \mathbb{K}^n &\rightarrow \mathbb{R}_{\geq 0} \\ v &\mapsto \|v\| \end{aligned}$$

- **Positividad:** $\|v\| \geq 0$ para todo $v \in \mathbb{K}^n$, y $\|v\| = 0$ si y solo si $v = 0$.
- **Definitud:** $\|v\| = 0$ si y solo si $v = 0$.
- **Homogeneidad:** $\|\alpha v\| = |\alpha| \cdot \|v\|$ para todo $v \in \mathbb{K}^n$ y todo escalar $\alpha \in \mathbb{K}$.
- **Desigualdad triangular:** $\|u + v\| \leq \|u\| + \|v\|$ para todo $u, v \in \mathbb{K}^n$.

Recordemos como se define la equivalencia entre normas vectoriales.

Definición 1.5.2 [Equivalencia entre normas vectoriales]

Dos normas vectoriales $\|\cdot\|_a$ y $\|\cdot\|_b$ en $\mathbb{K}^n$ se dicen equivalentes si existen constantes positivas $C_1, C_2 > 0$ tales que:

$$C_1\|v\|_a \leq \|v\|_b \leq C_2\|v\|_a$$

para todo $v \in \mathbb{K}^n$.

Esto significa que ambas normas definen la misma topología en $\mathbb{K}^n$, es decir, los conjuntos abiertos y cerrados son los mismos para ambas normas, y por lo tanto, las propiedades de convergencia, continuidad y demás conceptos topológicos son equivalentes bajo ambas normas.

Ahora veamos la definición de norma matricial.

Definición 1.5.3 [Norma matricial]

Una norma matricial es una función que asigna a cada matriz $A \in \mathbb{K}^{m \times n}$ un número real no negativo, y que satisface las siguientes propiedades:

$$\begin{aligned} \|\cdot\| : \mathbb{K}^{m \times n} &\rightarrow \mathbb{R}_{\geq 0} \\ A &\mapsto \|A\| \end{aligned}$$

- **Positividad:** $\|A\| \geq 0$ para todo $A \in \mathbb{K}^{m \times n}$, y $\|A\| = 0$ si y solo si $A = 0$.
- **Definitud:** $\|A\| = 0$ si y solo si $A = 0$.
- **Homogeneidad:** $\|\alpha A\| = |\alpha| \cdot \|A\|$ para todo $A \in \mathbb{K}^{m \times n}$ y todo escalar $\alpha \in \mathbb{K}$.
- **Desigualdad triangular:** $\|A + B\| \leq \|A\| + \|B\|$ para todo $A, B \in \mathbb{K}^{m \times n}$.
- **Submultiplicatividad:** $\|AB\| \leq \|A\| \cdot \|B\|$ para todo $A \in \mathbb{K}^{m \times p}$ y todo $B \in \mathbb{K}^{p \times n}$.

Algunas normas particulares son las siguientes (para vectores):

- **Normas p-ésimas:** Para $1 \leq p < \infty$, la norma p-ésima de un vector $v \in \mathbb{K}^n$ se define como:

$$\|v\|_p = \left(\sum_{i=1}^n |v_i|^p \right)^{\frac{1}{p}}$$

- **Norma p-1-ésima:** Para $p = 1$, la norma p-1-ésima de un vector $v \in \mathbb{K}^n$ se define como:

$$\|v\|_1 = \sum_{i=1}^n |v_i|$$

- **Norma p-2-ésima o euclídea:** Para $p = 2$, la norma p-2-ésima de un vector $v \in \mathbb{K}^n$ se define como:

$$\|v\|_2 = \sqrt{\sum_{i=1}^n |v_i|^2}$$

- **Norma p-infinito-ésima:** Para $p = \infty$, la norma p-infinito-ésima de un vector $v \in \mathbb{K}^n$ se define como:

$$\|v\|_\infty = \lim_{p \rightarrow \infty} \|v\|_p = \max_{1 \leq i \leq n} |v_i|$$

1.6 Normas subordinadas

Definamos ahora la norma subordinada de una matriz, que es una norma matricial que se define a partir de una norma vectorial.

Definición 1.6.1 [Norma subordinada de una matriz]

Sea $A \in \mathbb{K}^{m \times n}$ una matriz, y sea $p \in [1, \infty]$. La norma subordinada de A con respecto a la norma p -ésima se define como:

$$\|A\|_p = \sup_{v \neq 0} \frac{\|Av\|_p}{\|v\|_p} = \sup_{v \neq 0} \left\| A \frac{v}{\|v\|_p} \right\|_p = \sup_{\|v\|_p=1} \|Av\|_p$$

Veamos que se cumplen las propiedades de una norma matricial para la norma subordinada de una matriz.

- **Norma de una matriz nula:** Para la matriz nula $0 \in \mathbb{K}^{m \times n}$, se cumple que $\|0\|_p = 0$ para cualquier $p \in [1, \infty]$, ya que $Av = 0$ para cualquier vector v , lo que implica que $\|Av\|_p = 0$ y por lo tanto, el supremum es cero.
- **Norma bajo escala:** Para cualquier matriz $A \in \mathbb{K}^{m \times n}$ y cualquier escalar $\alpha \in \mathbb{K}$, se cumple que $\|\alpha A\|_p = |\alpha| \cdot \|A\|_p$, lo que se deduce directamente de la homogeneidad de la norma vectorial.
- **Norma bajo la suma:** Para cualquier matriz $A, B \in \mathbb{K}^{m \times n}$, se cumple que $\|A+B\|_p \leq \|A\|_p + \|B\|_p$, lo que se deduce directamente de la desigualdad triangular de la norma vectorial.
- **Norma bajo el producto:** Para cualquier matriz $A \in \mathbb{K}^{m \times p}$ y cualquier matriz $B \in \mathbb{K}^{p \times n}$, se cumple que $\|AB\|_p \leq \|A\|_p \cdot \|B\|_p$, lo que se deduce directamente de la submultiplicatividad de la norma matricial.

Otra forma de probar esto es usando que:

$$\begin{aligned} \|AB\|_p &= \sup_{\|v\|_p=1} \|ABv\|_p = \sup_{\|v\|_p=1} \left(\frac{\|ABv\|_p \|Bv\|_p}{\|Bv\|_p} \right) = \sup_{\|v\|_p=1} \left(\left\| A \frac{Bv}{\|Bv\|_p} \right\|_p \cdot \|Bv\|_p \right) \leq \\ &\quad \sup_{\|v\|_p=1} \|Av\|_p \cdot \sup_{\|v\|_p=1} \|Bv\|_p = \|A\|_p \cdot \|B\|_p \end{aligned}$$

Y como se ha demostrado que se cumplen las propiedades de una norma matricial, entonces la norma subordinada de una matriz es una norma matricial válida.

Veamos ahora algunas propiedades de las matrices de covarianzas, tras haber definido las normas necesarias.

Proposición 1.6.1 [Matriz de covarianza es h.d.p.]

Si X es una matriz de datos en m variables y n medidas con $n \gg m$:

$$X = (x_1, \dots, x_n) \text{ (} m \text{ variables) } n \text{ medidas}$$

Siendo μ las medidas o promedios y $\tilde{x}_i = x_i - \mu_i$, entonces la matriz de covarianza de X se define como:

$$C = \tilde{X}^t \tilde{X} \in \mathbb{R}^{m \times m}$$

Demostración. Tomando $\tilde{X} = (\tilde{x}_1, \dots, \tilde{x}_n)$, entonces C es una matriz hermítica definida positiva, ya que en primer lugar es simétrica:

$$C^t = (\tilde{X}^t \tilde{X})^t = \tilde{X}^t \tilde{X} = C$$

Y como pertenece a $\mathbb{R}^{m \times m}$, entonces C es hermítica (ya que en $\mathbb{R}$, la conjugación no afecta a los elementos de la matriz).

Ahora para ver que es h.d.p., tenemos que comprobar que $sp(C) \subseteq \mathbb{R}_{>0}$ (ya sabemos que es real). Para ello, tomemos $\lambda \in \sigma(C)$ un autovalor de C , y sea v un autovector asociado a λ :

$$Cv = \lambda v \implies \tilde{X}^t \tilde{X}v = \lambda v \implies v^t \tilde{X}^t \tilde{X}v = \lambda v^t v = \lambda \|v\|^2 = \lambda \implies$$

$$(\tilde{X}v)^t (\tilde{X}v) = \|\tilde{X}v\|_2^2 = \lambda \|v\|_2^2 \implies$$

Usando ahora que $v^t v = \langle v, v \rangle = \|v\|_2^2$, entonces en particular, $\|v\|_2^2 = 1$, por lo que $\|v\|_2^2 = v^* v = 1$, y por lo tanto:

$$\lambda = \|\tilde{X}v\|_2^2 \geq 0$$

□

Algunas normas matriciales particulares son las siguientes (normas subordinadas):

- **Norma p-ésima subordinada:** La norma p-ésima subordinada de una matriz $A \in \mathbb{K}^{m \times n}$ se define como (que es la norma p-ésima subordinada):

$$\|A\|_p = \sup_{\|v\|_p=1} \|Av\|_p$$

- **Norma 1:** La norma 1 de una matriz $A \in \mathbb{K}^{m \times n}$ se define como (que es la norma 1 subordinada):

$$\|A\|_1 = \sup_{\|v\|_1=1} \|Av\|_1$$

- **Norma 2 o espectral:** La norma 2 de una matriz $A \in \mathbb{K}^{m \times n}$ se define como (que es la norma 2 subordinada):

$$\|A\|_2 = \sup_{\|v\|_2=1} \|Av\|_2$$

- **Norma infinito:** La norma infinito de una matriz $A \in \mathbb{K}^{m \times n}$ se define como (que es la norma infinito subordinada):

$$\|A\|_\infty = \sup_{\|v\|_\infty=1} \|Av\|_\infty$$

Teorema 1.6.1 [Calculo simplificado de normas subordinadas]

Sea $A \in \mathbb{K}^{m \times n}$ una matriz, entonces sus normas subordinadas se pueden calcular de la siguiente forma:

- La norma 1 subordinada de A es igual al máximo valor absoluto de la suma de los elementos de cada columna de A . Es decir:

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|$$

- La norma infinito subordinada de A es igual al máximo valor absoluto de la suma de los elementos de cada fila de A . Es decir:

$$\|A\|_\infty = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|$$

- La norma 2 subordinada de A es igual a la raíz cuadrada del máximo autovalor de $A^* A$. Es decir:

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^* A)} = \sqrt{\rho(A^* A)}$$

Demostración. Las dos primeras formulas son triviales de demostrar, ya que se pueden obtener directamente de la definición de la norma subordinada y de la forma en que se calcula el producto Av .

Para la tercera formula, hagamos los siguientes cálculos:

$$\begin{aligned} \|A\|_2^2 &= \left(\sup_{\|v\|_2=1} \|Av\|_2 \right)^2 = \sup_{\|v\|_2=1} \|Av\|_2^2 = \sup_{\|v\|_2=1} (Av)^*(Av) = \sup_{\|v\|_2=1} v^* A^* A v \\ &\quad \underbrace{H=A^*A \text{ es hermítica}}_{\text{Schur}} = \sup_{\|v\|_2=1} v^* H v \underbrace{=}_{\text{Schur}} \sup_{\|v\|_2=1} v^* U D U^* v \underbrace{=}_{z=U^*v} \sup_{\|z\|_2=1} z^* D z =^* \end{aligned}$$

Ahora hemos usado que como U es una matriz unitaria, entonces $\|z\|_2 = \|v\|_2 = 1$, por lo que el supremum se puede tomar sobre z en lugar de sobre v , con fórmula $\|z\|_2^2 = z^* z = v^* U U^* v = v^* v = \|v\|_2^2$.

Continuando con el cálculo, y denotando:

$$\begin{aligned} D &= \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{pmatrix} \Rightarrow \\ z^* D z &= (\bar{z}_1 \quad \bar{z}_2 \quad \cdots \quad \bar{z}_n) \cdot \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{pmatrix} \cdot \begin{pmatrix} z_1 \\ z_2 \\ \vdots \\ z_n \end{pmatrix} = \sum_{i=1}^n \lambda_i |z_i|^2 \end{aligned}$$

Y ahora podemos usar que como $\|z\|_2^2 = 1$, entonces $\sum_{i=1}^n |z_i|^2 = 1$, por lo que $z^* D z$ es una combinación convexa de los autovalores de H (y de D por tanto), lo que implica que el supremum de $z^* D z$ es igual al máximo autovalor de D , que es el máximo autovalor de H . Por lo tanto:

$$=^* \lambda_{\max}(D) = \lambda_{\max}(H) = \lambda_{\max}(A^* A) \Rightarrow \|A\|_2 = \sqrt{\lambda_{\max}(A^* A)}$$

Y si denotamos el operador $\rho(M)$ como el máximo valor absoluto de los autovalores de M , podemos tener el resultado como $\|A\|_2 = \sqrt{\rho(A^* A)}$. $\square$

Definición 1.6.2 [Norma de Frobenius]

La norma de Frobenius de una matriz $A \in \mathbb{K}^{m \times n}$ se define como:

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2}$$

1.7 Potencias de matrices

Veamos algunas propiedades de las potencias de matrices, que son muy útiles para el cálculo de autovalores y autovectores.

Teorema 1.7.1 [Convergencia a 0 de las potencias de una matriz con espectro menor que 1]

Si $A \in \mathbb{C}^{n \times n}$, entonces son equivalentes las siguientes afirmaciones:

1. A tiende a 0, es decir:

$$\lim_{k \rightarrow \infty} A^k = 0$$

2. La imagen de todo vector bajo A^k tiende a 0, es decir:

$$\lim_{k \rightarrow \infty} A^k v = 0 \quad \forall v \in \mathbb{C}^n$$

3. El espectro de A está acotado por 1, es decir:

$$\rho(A) < 1$$

4. Existe una norma matricial $\|\cdot\|$ tal que $\|A\| < 1$.

Demostración. Veamos las implicaciones por separado: **(1) $\Rightarrow$ (2):** Si $A^k \rightarrow 0$, entonces para cualquier vector $v \in \mathbb{C}^n$, se cumple que:

$$\|A^k v\| \leq \|A^k\| \cdot \|v\| \rightarrow 0$$

(2) $\Rightarrow$ (3): Si hubiera un autovalor λ de A tal que $|\lambda| \geq 1$, entonces tomando un autovector asociado a λ , se tendría que:

$$A^k v = \lambda^k v \implies \|A^k v\| = |\lambda|^k \|v\| \not\rightarrow 0$$

Lo que contradice la hipótesis, por lo que todos los autovalores de A deben tener módulo menor que 1, es decir, $\rho(A) < 1$.

También se puede usar que $\|A^k v\| = \|\lambda|^k v\|$ para cualquier autovalor λ y su autovector asociado v , por lo que como debe converger a 0 para todo v , entonces $|\lambda|^k \|v\| \rightarrow 0$ para todo autovalor λ , lo que implica que $|\lambda| < 1$ para todo autovalor λ .

□

1.8 Condicionamiento de matrices

Veamos un teorema importante sobre sistemas de ecuaciones lineales

Teorema 1.8.1 [Existencia de solución única para sistemas de ecuaciones lineales]

Si $A \in \mathbb{C}^{n \times n}$ es una matriz cuadrada, entonces el sistema de ecuaciones lineales $Ax = b$ tiene una solución única para cada $b \in \mathbb{C}^n$ si y solo si A es invertible. Es decir:

$$\text{El sistema } Ax = b \text{ tiene solución única para cada } b \in \mathbb{C}^n \iff A \text{ es invertible} \iff \det(A) \neq 0$$

Ahora nos podemos preguntar como de estable es la solución de un sistema de ecuaciones lineales ante pequeñas perturbaciones en los datos.

Si modificamos $\bar{b} = b + \delta$ podemos ver que el error de b es:

$$E_b = \frac{\|\bar{b} - b\|}{\|b\|} = \frac{\|\delta\|}{\|b\|}$$

Ahora podemos definir $\bar{x} = A^{-1}\bar{b} = x + \epsilon$, y por tanto podemos hacer el siguiente despeje:

$$A\bar{x} = \bar{b} \iff A(x + \epsilon) = b + \delta \iff A\epsilon = \delta \implies \epsilon = A^{-1}\delta$$

Y por tanto el error de x es:

$$\begin{aligned} E_x &= \frac{\|\bar{x} - x\|}{\|x\|} = \frac{\|\epsilon\|}{\|x\|} = \frac{\|A^{-1}\delta\|}{\|x\|} \leq \frac{\|A^{-1}\| \cdot \|\delta\|}{\|x\|} = \frac{\|A^{-1}\| \cdot \|b\|}{\|x\|} \cdot \frac{\|\delta\|}{\|b\|} = \\ &= \frac{\|A^{-1}\| \cdot \|b\|}{\|x\|} \cdot E_b = \frac{\|A^{-1}\| \cdot \|Ax\|}{\|x\|} \cdot E_b \leq \|A^{-1}\| \cdot \|A\| \cdot E_b = \text{cond}(A) \cdot E_b \end{aligned}$$

Donde $\text{cond}(A) = \|A^{-1}\| \cdot \|A\|$ es el número de condición de la matriz A , el cual si es muy grande, significara que el sistema de ecuaciones lineales es muy sensible a pequeñas perturbaciones en los datos, lo que se conoce como un sistema mal condicionado. Por otro lado, si $\text{cond}(A)$ es pequeño, entonces el sistema de ecuaciones lineales es estable ante pequeñas perturbaciones en los datos, lo que se conoce como un sistema bien condicionado.

2 Resolución de sistemas lineales

2.1 Introducción a los sistemas lineales

Sea $A \in \mathbb{K}^{n \times n}$ y $b \in \mathbb{K}^n$. Un sistema lineal es la búsqueda de $x \in \mathbb{K}^n$ tal que $S \equiv Ax = b$. En este apartado se estudiarán diferentes métodos para resolver sistemas lineales, así como sus propiedades y análisis de convergencia.

Es fácil ver que si A es invertible, entonces el sistema tiene una única solución dada por $x = A^{-1}b$. Sin embargo, calcular la inversa de una matriz puede ser computacionalmente costoso y numéricamente inestable. Por ello, se han desarrollado diversos métodos para resolver sistemas lineales sin necesidad de calcular la inversa de la matriz.

Teorema 2.1.1 [Metodo de Cramer]

Sea el sistema $S \equiv Ax = b$ con $A \in \mathbb{K}^{n \times n}$ invertible. Entonces, si denotamos:

$$A_i = \begin{bmatrix} a_{11} & \cdots & a_{1,i-1} & b_1 & a_{1,i+1} & \cdots & a_{1n} \\ a_{21} & \cdots & a_{2,i-1} & b_2 & a_{2,i+1} & \cdots & a_{2n} \\ \vdots & & \vdots & \vdots & \vdots & & \vdots \\ a_{n1} & \cdots & a_{n,i-1} & b_n & a_{n,i+1} & \cdots & a_{nn} \end{bmatrix} = (a_1, \dots, a_{i-1}, b, a_{i+1}, \dots, a_n)$$

Dónde a_j es la j -ésima columna de A , entonces la solución del sistema es:

$$x_i = \frac{\det(A_i)}{\det(A)} \quad \forall i = 1, \dots, n$$

Sin embargo, el método de Cramer es computacionalmente ineficiente para matrices grandes, ya que el cálculo de determinantes tiene una complejidad factorial. Por ello, se utilizan otros métodos como el método de Gauss, que es mucho más eficiente y estable para resolver sistemas lineales, se pueden apreciar los tiempos necesarios en la siguiente tabla:

n	10	100	10^3
Cramer	10^8	10^{162}	10^{2573}
Gauss	800	10^6	10^9

Siendo n el tamaño de la matriz A , el metodo de Cramer tiene una complejidad de $O(n^2 \cdot n!)$ mientras que el método de Gauss tiene una complejidad de $O(n^3)$.

En los siguientes apartados se estudiarán diferentes métodos para resolver sistemas lineales, así como sus propiedades y análisis de convergencia.

Un caso particular de sistemas lineales es el caso de sistemas diagonales, que tienen esta forma:

$$\begin{pmatrix} a_{11} & 0 & \cdots & 0 \\ 0 & a_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & a_{nn} \end{pmatrix} \cdot x = b$$

De lo que se deduce trivialmente que la solución es $x_i = \frac{b_i}{a_{ii}}$ para $i = 1, \dots, n$.

Estos sistemas diagonales tiene una complejidad de $O(n)$, ya que se necesitan n operaciones para calcular la solución.

Otro sistema particular es el sistema triangular superior, que tiene esta forma:

$$\begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ 0 & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & a_{nn} \end{pmatrix} \cdot x = b$$

En este caso, se puede resolver el sistema mediante sustitución hacia atrás, comenzando por la última ecuación y avanzando hacia la primera, es decir:

$$x_i = \frac{1}{a_{ii}} \left(b_i - \sum_{j=i+1}^n a_{ij}x_j \right) \quad \forall i \in \{n, n-1, \dots, 1\}$$

Analogamente, un sistema triangular inferior tiene esta forma:

$$\begin{pmatrix} a_{11} & 0 & \cdots & 0 \\ a_{21} & a_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix} \cdot x = b$$

Y se puede resolver mediante sustitución hacia adelante, comenzando por la primera ecuación y avanzando hacia la última, es decir:

$$x_i = \frac{1}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij}x_j \right) \quad \forall i \in \{1, 2, \dots, n\}$$

Estos sistemas triangulares tienen una complejidad de $O(n^2)$, ya que se necesitan n operaciones para calcular cada x_i , y hay n variables.

Ahora veamos algunos metodos de resolución de sistemas lineales más generales.

Proposición 2.1.1 [Método de eliminación Gaussiana]

El método de eliminación Gaussiana es un algoritmo para resolver sistemas lineales que consiste en transformar la matriz A en una matriz triangular superior mediante operaciones elementales de fila, es decir:

$$Ax = b \longrightarrow Tx = b'$$

Para pasar a una matriz triangular superior T , usaremos una matriz E cuyo determinante no sea nula, de tal forma que tengamos el siguiente sistema equivalente:

$$\underbrace{E \cdot A}_T x = \underbrace{E \cdot b}_{b'}$$

Para ver quien es esta matriz E , se pueden usar matrices de permutación para intercambiar filas, matrices de escala para multiplicar una fila por un escalar distinto de cero, y matrices de eliminación para sumar un múltiplo de una fila a otra fila. Denotemos:

$$E = E_k \cdot E_{k-1} \cdots E_1$$

Siendo E_i una matriz elemental que representa una de las operaciones mencionadas anteriormente, y siendo:

$$E_i \cdot A_{i-1} = A_i \quad b_i = E_i \cdot b_{i-1} \longrightarrow A_i x = b_i$$

Y por tanto el algoritmo se basara en llegar a un k que cumpla:

$$A_k = E_k \cdot E_{k-1} \cdots E_1 \cdot A = E \cdot A = T$$

Ahora veamos como encontrar una matriz E_i que nos permita hacer cada una de las operaciones elementales descritas anteriormente:

- **Multiplicar una fila por un escalar distinto de cero:** Para multiplicar la fila i por un escalar $\lambda \neq 0$, se puede usar la matriz de escala E_i que tiene la forma:

$$E_i = \begin{pmatrix} 1 & \cdots & 0 \\ 0 & \ddots & \cdots & 0 \\ \vdots & 0 & \lambda & 0 \\ 0 & 0 & \cdots & 1 \end{pmatrix}$$

Donde el elemento en la posición (i, i) es λ y el resto de los elementos son 1 en la diagonal y 0 en el resto de la matriz, y transforma A_{i-1} en A_i multiplicando la fila i por λ :

$$E_i \cdot A_{i-1} = \begin{pmatrix} 1 & 0 & \cdots & 0 \\ 0 & \ddots & \cdots & 0 \\ \vdots & 0 & \lambda & 0 \\ 0 & 0 & \cdots & 1 \end{pmatrix} \cdot \begin{pmatrix} a_i^T \\ \vdots \\ a_i^T \\ \vdots \\ a_n^T \end{pmatrix} = \begin{pmatrix} a_i^T \\ \vdots \\ \lambda a_i^T \\ \vdots \\ a_n^T \end{pmatrix}$$

- **Intercambiar dos filas:** Para intercambiar las filas i y j , se puede usar la matriz de permutación E_i que tiene la forma:

$$E_i = \begin{pmatrix} 1 & \cdots & 0 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & \cdots & 1 \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 1 & \cdots & 0 \end{pmatrix}$$

Donde el elemento en la posición (i, j) es 1, el elemento en la posición (j, i) es 1, y el resto de los elementos son 1 en la diagonal y 0 en el resto de la matriz, y transforma A_{i-1} en A_i

intercambiando las filas i y j :

$$E_i \cdot A_{i-1} = \begin{pmatrix} 1 & 0 & \cdots & 0 & \cdots & 0 \\ 0 & \ddots & \vdots & \ddots & \vdots & \vdots \\ \vdots & 0 & 0 & \cdots & 1 & 0 \\ 0 & \cdots & 1 & \cdots & 0 & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \vdots \\ 0 & \cdots & 0 & \cdots & 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} a_1^T \\ \vdots \\ a_i^T \\ \vdots \\ a_j^T \\ \vdots \\ a_n^T \end{pmatrix} = \begin{pmatrix} a_1^T \\ \vdots \\ a_j^T \\ \vdots \\ a_i^T \\ \vdots \\ a_n^T \end{pmatrix}$$

- **Suma de dos filas:** Para sumar una fila i a otra fila j , se puede usar la matriz de eliminación E_i que tiene la forma:

$$E_i = \begin{pmatrix} 1 & \cdots & 0 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 1 & \cdots & 1 \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & \cdots & 1 \end{pmatrix}$$

Donde el elemento en la posición (j, i) es 1, el elemento en la posición (j, j) es 1, y el resto de los elementos son 1 en la diagonal y 0 en el resto de la matriz, y transforma A_{i-1} en A_i sumando la fila i a la fila j :

$$E_i \cdot A_{i-1} = \begin{pmatrix} 1 & 0 & \cdots & 0 & \cdots & 0 \\ 0 & \ddots & \vdots & \ddots & \vdots & \vdots \\ 0 & \cdots & 1 & \cdots & 1 & 0 \\ 0 & \cdots & 0 & \cdots & 1 & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \vdots \\ 0 & \cdots & 0 & \cdots & 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} a_1^T \\ \vdots \\ a_i^T \\ \vdots \\ a_j^T \\ \vdots \\ a_n^T \end{pmatrix} = \begin{pmatrix} a_1^T \\ \vdots \\ a_i^T + a_j^T \\ \vdots \\ a_j^T \\ \vdots \\ a_n^T \end{pmatrix}$$

Tras comprobar esto, veamos como aplicarlo a un sistema lineal, suponiendo que $\det(A) \neq 0$, entonces el sistema tiene una única solución, y podemos aplicar el método de eliminación Gaussiana para resolverlo.

1. Como $\det(A) \neq 0$, entonces $\exists i \in \{1, \dots, n\}$ tal que $a_{i1} \neq 0$, entonces podemos usar la matriz de permutación E_1 para intercambiar la fila i con la fila 1, y obtener una nueva matriz A_1 con un elemento a no nulo en la posición $(1, 1)$:

$$E_1 \cdot A = A_1 = \left(\begin{array}{c|c} a & \beta^T \\ \hline \alpha & A_{n-1} \end{array} \right)$$

2. Despues, multiplicamos la fila 1 por $\frac{1}{a}$ usando la matriz de escala E_2 , y obtenemos una nueva matriz A_2 con un elemento 1 en la posición $(1, 1)$:

$$E_2 \cdot A_1 = A_2 = \left(\begin{array}{c|c} 1 & \frac{\beta^T}{a} \\ \hline \alpha & A_{n-1} \end{array} \right)$$

3. Finalmente, sumamos un múltiplo de la fila 1 a cada una de las filas $2, \dots, n$ según los elementos de α usando las matrices de eliminación $E_{l1}, \dots, E_{ln}$, las cuales componen E_3 , y obtenemos una nueva matriz A_3 con ceros en la primera columna excepto en la posición $(1, 1)$:

$$E_n \cdots E_3 \cdot A_2 = A_n = \left(\begin{array}{c|c} 1 & \frac{\beta^T}{a} \\ \hline 0 & A_{n-1} - \frac{\alpha \cdot \beta^T}{a} \end{array} \right)$$

4. Si ahora denotamos $B_{n-1} = A_{n-1} - \frac{\alpha \cdot \beta^T}{a}$, entonces podemos repetir este proceso con la matriz B_{n-1} , y así sucesivamente hasta obtener una matriz triangular superior T :

$$E_k \cdots E_3 \cdot A_2 = T$$

Tras aplicar estos pasos, obtenemos una matriz triangular superior T y un vector b' tal que el sistema $Tx = b'$ es equivalente al sistema original $Ax = b$. Luego, podemos resolver el sistema triangular superior $Tx = b'$ mediante sustitución hacia atrás para obtener la solución del sistema original.

Teorema 2.1.2 [Descomposición Gaussiana]

Sea $A \in \mathbb{K}^{n \times n}$ arbitraria, entonces $\exists E \in \mathbb{K}^{n \times n}$ con $\det(E) \neq 0$ tal que:

$$E \cdot A = T$$

Donde T es una matriz triangular superior.

Demostración. La demostración es seguir el proceso descrito en el método de eliminación Gaussiana, aplicando operaciones elementales de fila para transformar la matriz A en una matriz triangular superior T , visto en la proposición anterior. □

Observación 2.1.1

Si además $\det(A) = 0$, entonces podemos encontrar T cuya diagonal esté compuesta por 0 y 1.

Demostración. Para ver esto, como $\det(T) = \det(E) \cdot \det(A)$, entonces $\det(T) = 0$, lo que implica que al menos un elemento de la diagonal de T es 0 (recordemos que el determinante de una matriz triangular es el producto de los elementos de su diagonal).

El proceso de eliminación gaussiana seguirá igual hasta llegar a una columna j tal que esta compuesta de ceros, en esa situación, pasamos a la siguiente submatriz A_{n-j} , y repetimos el proceso hasta llegar a una matriz triangular superior T cuya diagonal esté compuesta por 0 y 1 (los 0 vienen de las columnas compuestas por ceros, y los 1 vienen de las columnas con elementos no nulos en la diagonal, que se convierten en 1 al multiplicar la fila por el inverso del elemento no nulo). □

2.2 Factorización LU

Teorema 2.2.1 [Factorización LU]

Sea $A \in \mathbb{K}^{n \times n}$, entonces $\exists L \in \mathbb{K}^{n \times n}$ una matriz triangular inferior con 1 en la diagonal, y $\exists U \in \mathbb{K}^{n \times n}$ una matriz triangular superior tal que:

$$A = LU$$

Notese que con esta descomposición:

$$\det(A) = \det(L) \cdot \det(U) = 1 \cdot \prod_{i=1}^n u_{ii} = \prod_{i=1}^n u_{ii}$$

Lo que implica que:

$$\det(A) \neq 0 \iff u_{ii} \neq 0 \forall i = 1, \dots, n$$

$$\iff$$

$$\det(A) = 0 \iff \exists i \in \{1, \dots, n\} : u_{ii} = 0$$

Esta descomposición es muy útil para resolver sistemas lineales, ya que si $A = LU$, entonces el sistema $Ax = b$ se puede transformar en $LUx = b$.

Proposición 2.2.1 [Resolución de sistemas lineales con la factorización LU]

Si $A = LU$, entonces el sistema $Ax = b$ se puede resolver en dos pasos:

1. Descomponemos A en L y U , por lo que:

$$Ax = b \longrightarrow LUx = b$$

2. Denotamos $Ux = w \in \mathbb{K}^n$.

3. Resolvemos aplicando el método de remonte:

$$Lw = b \longrightarrow \exists! w \in \mathbb{K}^n : w = L^{-1}b$$

4. Resolvemos también aplicando el método de remonte:

$$Ux = w \longrightarrow \exists! x \in \mathbb{K}^n : x = U^{-1}w$$

Además, podemos resumir el cálculo de x como:

$$x = U^{-1}L^{-1}b$$

Para ver como hacer la factorización veamos que:

$$A_n = \left(\begin{array}{c|c} a_{11} & \beta^T \\ \hline \alpha & A_{n-1} \end{array} \right) = L_n \cdot U_n = \left(\begin{array}{c|c} 1 & 0 \\ \hline v & L_{n-1} \end{array} \right) \cdot \left(\begin{array}{c|c} u_{11} & w^T \\ \hline 0 & U_{n-1} \end{array} \right) = \left(\begin{array}{c|c} u_{11} & w^T \\ \hline vu_{11} & vw^T + L_{n-1}U_{n-1} \end{array} \right)$$

De lo que deducimos que:

$$u_{11} = a_{11} \quad w = \beta \quad v = \frac{\alpha}{a_{11}} \quad vw^T + L_{n-1}U_{n-1} = A_{n-1}$$

De lo que podemos definir:

$$L_{n-1}U_{n-1} = A_{n-1} - \frac{\alpha \cdot \beta^T}{a_{11}} = B_{n-1}$$

Notese que necesariamente $a_{11} \neq 0$ para poder hacer esta factorización, lo que implica que $\det(A) \neq 0$.

Observación 2.2.1

Notese que:

$$\exists A^{-1} \Leftrightarrow \exists L^{-1} \text{ y } U^{-1}$$

Notese que la primera iteración tiene coste $(n-1) + 2(n-1)^2$, y la 2 iteración tiene coste $\frac{(n-2)+2(n-2)^2}{\frac{2}{3}n^3}$, y así sucesivamente, por lo que el coste total de la factorización es $O(n^3)$.

Lema 2.2.1 [Inversas de matrices triangulares]

Si T es una matriz triangular superior/inferior e invertible, entonces T^{-1} es una matriz triangular superior/inferior.

Teorema 2.2.2 [Permisibilidad de la factorización LU]

Sea $A \in \mathbb{K}^{n \times n}$ una matriz cuyos menores principales dominantes cumplen que $\delta_k = \det(A_k) \neq 0$ para $k = 1, \dots, n-1$, siendo $A_k = (a_{ij})_{i,j=1}^k$. Sea además $\delta_n = \det(A)$. Entonces, A admite una factorización $A = LU$, donde L es una matriz triangular inferior con unos en su diagonal principal y U es una matriz triangular superior.

Además, si $\delta_n = 0$, entonces el último elemento de la diagonal de U es nulo, es decir, $u_{nn} = 0$.

Demostración. Dividiremos la demostración en dos partes: primero estableceremos la existencia de la factorización por inducción y, a continuación, analizaremos su unicidad.

Existencia. Demostraremos la existencia por inducción sobre n .

1. **Caso base** ($k = 1$): Si $\delta_1 = a_{11} \neq 0$, podemos realizar la primera iteración de la factorización tomando:

$$A_1 = (a_{11}) \quad L_1 = (1) \quad U_1 = (a_{11})$$

Como $A_1 = L_1 U_1$, el caso base se cumple de manera trivial.

2. **Paso inductivo:** Supongamos que el resultado es cierto para $k-1$, es decir, existe la descomposición $A_{k-1} = L_{k-1} U_{k-1}$. Queremos construir L_k y U_k tales que $A_k = L_k U_k$. Particionamos la matriz A_k por bloques de la siguiente forma:

$$A_k = \left(\begin{array}{c|c} A_{k-1} & b_k \\ \hline c_k^T & a_{kk} \end{array} \right)$$

donde $b_k \in \mathbb{K}^{k-1}$ es un vector columna y $c_k^T \in \mathbb{K}^{1 \times (k-1)}$ es un vector fila. Buscamos L_k y U_k con la misma estructura:

$$L_k U_k = \left(\begin{array}{c|c} L_{k-1} & 0 \\ \hline l_k^T & 1 \end{array} \right) \left(\begin{array}{c|c} U_{k-1} & u_k \\ \hline 0 & u_{kk} \end{array} \right) = \left(\begin{array}{c|c} L_{k-1} U_{k-1} & L_{k-1} u_k \\ \hline l_k^T U_{k-1} & l_k^T u_k + u_{kk} \end{array} \right)$$

Igualando los bloques de esta matriz con los de A_k , obtenemos el siguiente sistema de ecuaciones matriciales:

- (a) $L_{k-1}U_{k-1} = A_{k-1}$, lo cual es cierto por hipótesis de inducción.
- (b) $L_{k-1}u_k = b_k$. Puesto que L_{k-1} es triangular inferior con unos en la diagonal, $\det(L_{k-1}) = 1 \neq 0$. Por tanto, el vector columna u_k existe y es único: $u_k = L_{k-1}^{-1}b_k$.
- (c) $l_k^T U_{k-1} = c_k^T$. Por hipótesis, $\det(U_{k-1}) = \det(A_{k-1}) = \delta_{k-1} \neq 0$. Así, la matriz U_{k-1} es invertible y el vector fila l_k^T existe y es único: $l_k^T = c_k^T U_{k-1}^{-1}$.
- (d) $l_k^T u_k + u_{kk} = a_{kk}$, lo que nos permite despejar el escalar u_{kk} :

$$u_{kk} = a_{kk} - l_k^T u_k$$

Para verificar el valor de u_{kk} , empleamos la propiedad del determinante de matrices triangulares por bloques. Como $A_k = L_k U_k$:

$$\delta_k = \det(A_k) = \det(L_k) \det(U_k) = (1) \cdot (\det(U_{k-1}) \cdot u_{kk}) = \delta_{k-1} u_{kk}$$

De aquí se deduce que $u_{kk} = \frac{\delta_k}{\delta_{k-1}}$. Para $k < n$, por hipótesis $\delta_k \neq 0$, por lo que $u_{kk} \neq 0$.

Para el caso final $k = n$, tenemos $u_{nn} = \frac{\delta_n}{\delta_{n-1}}$. Es evidente que si la matriz original es singular ($\delta_n = \det(A) = 0$), entonces obligatoriamente $u_{nn} = 0$.

Por el principio de inducción, la existencia de la factorización queda demostrada para todo n .

Unicidad. Probaremos la unicidad de la factorización exclusivamente para el caso en el que la matriz es invertible, es decir, $\delta_n = \det(A) \neq 0$.

Supongamos, por reducción al absurdo, que existen dos factorizaciones distintas para A :

$$A = L_1 U_1 = L_2 U_2$$

Como $\det(A) \neq 0$, todas las matrices involucradas son invertibles. Multiplicando por la izquierda por L_1^{-1} y por la derecha por U_2^{-1} , obtenemos:

$$L_1^{-1} A U_2^{-1} = L_1^{-1} (L_1 U_1) U_2^{-1} \implies U_1 U_2^{-1} = L_1^{-1} L_2$$

Sabemos que el producto y la inversa de matrices triangulares inferiores (respectivamente superiores) da como resultado una matriz del mismo tipo. Además, las inversas y productos de matrices con unos en la diagonal conservan esos unos. Por lo tanto, en la igualdad:

$$\underbrace{U_1 U_2^{-1}}_{\text{Triangular superior}} = \underbrace{L_1^{-1} L_2}_{\text{Triangular inferior}}$$

la única forma de que una matriz sea simultáneamente triangular superior e inferior es que sea una matriz diagonal. Dado que $L_1^{-1} L_2$ tiene necesariamente unos en su diagonal principal, dicha matriz diagonal debe ser la identidad I . En consecuencia:

$$L_1^{-1} L_2 = I \implies L_1 = L_2 \quad \text{y} \quad U_1 U_2^{-1} = I \implies U_1 = U_2$$

lo cual contradice la suposición inicial de que las factorizaciones eran distintas. La unicidad queda así demostrada si $\delta_n \neq 0$.

Si, por el contrario, $\delta_n = 0$, entonces A es singular y $u_{nn} = 0$. En este escenario, la matriz U no es invertible y los sistemas para hallar los elementos de L pierden su solución única, lo que implica que existen infinitas matrices L válidas para completar la factorización. Por tanto, no hay unicidad en el caso singular. $\square$

Teorema 2.2.3 [Factorización LUP]

Sea $A \in \mathbb{K}^{n \times n}$ arbitraria, entonces $\exists L, U, P \in \mathbb{K}^{n \times n}$ con L una matriz triangular inferior con 1 en la diagonal, U una matriz triangular superior, y P una matriz de permutación tal que:

$$PA = LU$$

Demostración. Veamos los siguientes pasos para demostrar este teorema:

1. Veamos como encontrar las matrices L , U y P para la factorización LUP.

$$P_1 \underbrace{\left(\begin{array}{c|c} a_{11} & w^T \\ \alpha & A_{n-1} \end{array} \right)}_{A_n} = \left(\begin{array}{c|c} 1 & 0 \\ v & I_{n-1} \end{array} \right) \cdot \left(\begin{array}{c|c} a & \tilde{w}^T \\ 0 & B_{n-1} \end{array} \right) = L_1 \cdot U_1$$

2. Ahora dependiendo del valor de a , tenemos dos casos:

$a = 0$ En este caso tenemos que $v = 0$ y también $B_{n-1} = A_{n-1}$, dejando así la primera permutación $P_1 = I_n$, quedando:

$$\left(\begin{array}{c|c} 1 & 0 \\ 0 & I_{n-1} \end{array} \right) \cdot \left(\begin{array}{c|c} 0 & w^T \\ 0 & A_{n-1} \end{array} \right)$$

$a \neq 0$ En este caso $\exists i \in \{1, \dots, n\}$ tal que $a_{i1} \neq 0$, entonces podemos usar la matriz de permutación P_1 para intercambiar la fila i con la fila 1, y obtener una nueva matriz A_1 con un elemento a no nulo en la posición $(1, 1)$, denotando finalmente $v = \frac{\alpha}{a_{i1}}$ y $B_{n-1} = A_{n-1} - \frac{\alpha \cdot w^T}{a_{i1}}$, quedando:

$$\left(\begin{array}{c|c} 1 & 0 \\ v & I_{n-1} \end{array} \right) \cdot \left(\begin{array}{c|c} a_{i1} & \tilde{w}^T \\ 0 & B_{n-1} \end{array} \right)$$

3. Ahora podemos definir la siguiente permutación P_2 como:

$$\begin{aligned} P_2 P_1 A &= \left(\begin{array}{c|c} 1 & 0 \\ 0 & \widetilde{P_2} \end{array} \right) \cdot \left(\begin{array}{c|c} 1 & 0 \\ v & I_{n-1} \end{array} \right) \cdot \left(\begin{array}{c|c} a_{i1} & \tilde{w}^T \\ 0 & B_{n-1} \end{array} \right) = \\ &= \left(\begin{array}{c|c} 1 & 0 \\ \widetilde{P_2} v & \widetilde{P_2} \end{array} \right) \cdot \left(\begin{array}{c|c} a_{i1} & \tilde{w}^T \\ 0 & B_{n-1} \end{array} \right) = \left(\begin{array}{c|c} 1 & 0 \\ \widetilde{P_2} v & L_{n-1} \end{array} \right) \cdot \left(\begin{array}{c|c} a_{i1} & \tilde{w}^T \\ 0 & U_{n-1} \end{array} \right) \end{aligned}$$

Y así sucesivamente, hasta llegar a la factorización LUP completa.

Notese también que:

$$\widetilde{P_2} v \tilde{w}^T + \widetilde{P_2} B_{n-1} = \widetilde{P_2} v \tilde{w}^T + L_{n-1} U_{n-1} \implies \widetilde{P_2} B_{n-1} = L_{n-1} U_{n-1}$$

□

2.3 Factorización de Cholesky**Teorema 2.3.1** [Factorización de Cholesky]

Sea $A \in \mathbb{K}^{n \times n}$ una matriz h.d.p. (hermitiana definida positiva), entonces $\exists B \in \mathbb{K}^{n \times n}$ una matriz triangular inferior tal que:

$$A = BB^*$$

Además si imponemos que $b_{ii} > 0$ para todo $i = 1, \dots, n$, entonces la factorización es única.

Demostración. Como A es h.d.p., entonces $\delta_k = \det(A_k) > 0$ para todo $k = 1, \dots, n$, siendo estos todos los determinantes menores de A . Por lo tanto, por la factorización LU, A admite una factorización LU, es decir, $\exists L \in \mathbb{K}^{n \times n}$ una matriz triangular inferior con 1 en la diagonal, y $\exists U \in \mathbb{K}^{n \times n}$ una matriz triangular superior tal que:

$$A = LU$$

Además, $u_{11} = \delta_1 > 0$, y $u_{kk} = \frac{\delta_k}{\delta_{k-1}} > 0$ para todo $k = 2, \dots, n$, por lo que U tiene elementos positivos en la diagonal.

Ahora definimos:

$$D = \begin{pmatrix} \sqrt{u_{11}} & 0 & \cdots & 0 \\ 0 & \sqrt{u_{22}} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sqrt{u_{nn}} \end{pmatrix} \iff D^{-1} = \begin{pmatrix} \frac{1}{\sqrt{u_{11}}} & 0 & \cdots & 0 \\ 0 & \frac{1}{\sqrt{u_{22}}} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \frac{1}{\sqrt{u_{nn}}} \end{pmatrix}$$

Y por tanto:

$$A = LU = \underbrace{LD}_B \cdot \underbrace{D^{-1}U}_C = BC$$

Siendo B una matriz triangular inferior con elementos positivos en la diagonal, y C una matriz triangular superior con elementos positivos en la diagonal, y además:

$$b_{ii} = c_{ii} = \sqrt{u_{ii}} > 0 \quad \forall i = 1, \dots, n$$

Ahora veamos que $C = B^*$, lo que implica que $A = BB^*$:

$$A = BC \underset{A \text{ h.d.p.}}{=} A^* = (BC)^* = C^*B^* \implies B^{-1}|BC = C^*B^* \implies C = B^{-1}C^*B^*|B^{*-1} \implies$$

$$\underbrace{CB^{*-1}}_{\text{triang. superior}} = \underbrace{B^{-1}C^*}_{\text{triang. inferior}} \implies CB^{*-1} = B^{-1}C^* = D = I$$

Siendo además los elementos de la diagonal de B^{*-1} iguales a $\delta_{ii} = \sqrt{u_{ii}} \frac{1}{\sqrt{u_{ii}}} = 1 \forall i$. Deduciendo finalmente que $C = B^*$, y por lo tanto $A = BB^*$.

□

3 Métodos iterativos para resolver sistemas lineales

3.1 Motivación

Si tenemos un sistema lineal $Ax = b$ con $A \in \mathbb{R}^{n \times n}$, $b \in \mathbb{R}^n$ y $x \in \mathbb{R}^n$, suficientemente grande, el método de eliminación gaussiana puede resultar ineficiente, al tener coste $O(n^3)$ en términos de tiempo⁹. En estos casos, los métodos iterativos pueden ser una alternativa más adecuada.

La idea de este tipo de metodos va a ser escoger una matriz M :

$$A = M - N$$

Que cumpla que M es fácil de invertir, y que sea similar a A (preferiblemente, $M = A$). Entonces, el sistema $Ax = b$ se puede reescribir como:

$$Mx = Nx + b \implies x = M^{-1}Nx + M^{-1}b \xrightarrow{\text{Notación}} x_k = Bx_{k-1} + C$$

Por lo que podemos utilizar esta ultima expresión para generar una sucesión de aproximaciones a la solución del sistema, partiendo de una aproximación inicial x_0 , la cual convergera a la solución del sistema:

$$\lim_{k \rightarrow \infty} x_k = \xi$$

3.2 Convergencia de métodos iterativos

Definición 3.2.1 [Convergencia de métodos iterativos]

El metodo iterativo () se dice que converge si la sucesión de aproximaciones x_k converge a la solución exacta ξ del sistema lineal $Ax = b$, es decir:*

$$\lim_{k \rightarrow \infty} x_k = \xi \quad \forall x_0 \in \mathbb{R}^n$$

Notese que B no se calcula de forma explicita, sino que se utiliza:

$$\begin{cases} w = Nx_{k-1} + b \\ Mx_k = w \end{cases}$$

Notese el caso particular de $M = A$, que se conoce como método de iteración de Richardson, y que es el método iterativo mas simple, ya que la primera iteración nos devuelve $x_1 = \xi$, es decir, la solución exacta del sistema. Sin embargo, este método no es eficiente, ya que requiere resolver el sistema $Ax = b$ en cada iteración, lo cual es tan costoso como resolver el sistema original.

Veamos ahora algunos criterios de convergencia.

Proposición 3.2.1 [Error en métodos iterativos]

Teniendo un metodo iterativo, podemos definir el error:

$$e_k = x_k - \xi = Bx_{k-1} + C - \underbrace{\xi}_{*} = Bx_{k-1} + C - B\xi - C = B(x_{k-1} - \xi) = Be_{k-1} = B^k e_0$$

Donde el paso (*) se ha realizado utilizando:

$$A\xi = b \implies (M - N)\xi = b \implies M\xi = N\xi + b \implies \xi = M^{-1}N\xi + M^{-1}b = B\xi + C$$

Por lo que el error converge a 0 si y solo si:

$$\lim_{k \rightarrow \infty} \|e_k\| = 0 \iff \lim_{k \rightarrow \infty} \|B^k e_0\| = 0 \iff \|B\| < 1 \iff \rho(B) < 1$$

Proposición 3.2.2 [Criterios de parada]

Para determinar cuándo detener el proceso iterativo, se pueden usar los siguientes criterios:

- **Criterio de iteraciones:** Detener después de un número fijo de iteraciones K_{max} .
- **Criterio de error:** Detener cuando el error estimado $\|e_k\|$ sea menor que una tolerancia predefinida $\varepsilon = TOL$. Esto no se puede aplicar directamente, ya que no conocemos el error real, pero se pueden usar varias posibilidades para estimar el error, el cual se define como:

$$E_k = \frac{\|e_k\|}{\|\xi\|} = \frac{\|x_k - \xi\|}{\|\xi\|}$$

Por ello veamos distintos métodos para estimar el error real:

- **Error relativo:** Se puede usar el error relativo entre iteraciones consecutivas como una estimación del error real, es decir:

$$\|e_k\| \approx \widetilde{E}_k = \frac{\|x_k - x_{k-1}\|}{\|x_k\|}$$

- **Error de residuos:** Se puede usar el residuo del sistema lineal como una estimación del error real, es decir, si definimos el residuo:

$$r_k = b_k - b = Ax_k - bAx_k - A\xi = A(x_k - \xi) = Ae_k$$

Y por tanto podemos estimar el error real como:


$$\|e_k\| \approx \overline{E}_k = \frac{\|b_k - b\|}{\|b\|} = \frac{\|r_k\|}{\|b\|} = \frac{\|A(x_k - \xi)\|}{\|A\xi\|} \approx \frac{\|x_k - \xi\|}{\|\xi\|} = E_k$$

3.3 Método de Jacobi y método de Gauss-Seidel

Teorema 3.3.1 [Metodo de Jacobi]

Sea la descomposición de $A = M - N$, y sea tambien su dscomposición en bloques:

$$A = D - E - F$$



Es decir, que:

$$D = \text{diag}(a_{11}, a_{22}, \dots, a_{nn})$$

$$E = (e_{ij})_{i,j=1}^n, \quad \begin{cases} e_{ij} = a_{ij} & \text{si } i > j \\ e_{ij} = 0 & \text{si } i \leq j \end{cases}$$

$$F = (f_{ij})_{i,j=1}^n, \quad \begin{cases} f_{ij} = a_{ij} & \text{si } i < j \\ f_{ij} = 0 & \text{si } i \geq j \end{cases}$$

El método de Jacobi se define como el método iterativo generado por la matriz $M = D$, es decir:

$$\begin{cases} x_0 \in \mathbb{K}^n \\ Dx_k = (E + F)x_{k-1} + b \quad k \in \mathbb{N} \end{cases}$$

Y la matriz del método de Jacobi es:

$$J = \underbrace{D^{-1}}_{M^{-1}} \underbrace{(E + F)}_N = D^{-1}(D - A) = I - D^{-1}A$$

Para que el método este bien planteado, es necesario que D sea invertible, es decir, que $a_{ii} \neq 0$ para todo $i = 1, \dots, n$, si alguno es cero pero $\det(D) \neq 0$, entonces permutamos.

Para iterar definimos el operador de iteración del método de Jacobi:

$$x_i^{(k)} = \left(b_i - \sum_{j \neq i} a_{ij} x_j^{(k-1)} \right) / a_{ii} \quad i \in \{1, \dots, n\}$$

Que tiene complejidad $O(n^2)$, ya que cada iteración requiere calcular n sumas de $n - 1$ elementos.

Veamos ahora varios criterios de convergencia del método de Jacobi.

Proposición 3.3.1 [Convergencia del método de Jacobi]

El método de Jacobi converge si:

$$\rho(J) < 1$$

Ejemplo

Tengamos el sistema:

$$\begin{pmatrix} -1 & 3 \\ -2 & 1 \end{pmatrix} x = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$$

Podemos tomar:

$$M = D = \begin{pmatrix} -1 & 0 \\ 0 & 1 \end{pmatrix} \text{ y } N = E + F = \begin{pmatrix} 0 & -3 \\ 2 & 0 \end{pmatrix}$$

Si definimos ahora:

$$J = D^{-1}(E + F) = \begin{pmatrix} 0 & 3 \\ 2 & 0 \end{pmatrix} \implies \det(J - \lambda I) = \begin{vmatrix} -\lambda & 3 \\ 2 & -\lambda \end{vmatrix} = \lambda^2 - 6 = 0 \implies \lambda = \pm\sqrt{6} > 1$$

Por lo que el método de Jacobi no converge para este sistema lineal.

Definición 3.3.1 [Matriz d.e.d.]

Una matriz $A \in \mathbb{K}^{n \times n}$ es diagonal estrictamente dominante (d.e.d.) si:

$$|a_{ii}| > \sum_{j \neq i} |a_{ij}| \quad \forall i = 1, \dots, n$$

Lema 3.3.1

Sea A una matriz d.e.d., entonces:

$$\exists A^{-1}$$

Demostración. Supongamos que A no es invertible, entonces el sistema $Ax = 0$ tiene infinitas soluciones. Sea $x \neq 0$ solución del sistema, por lo que $\exists i \in \{1, \dots, n\}$ tal que $|x_i| = \max_j |x_j| > 0$. Entonces:

$$a_{ii}x_i + \sum_{j \neq i} a_{ij}x_j = 0 \implies -a_{ii}x_i = \sum_{j \neq i} a_{ij}x_j \implies |a_{ii}||x_i| \leq \sum_{j \neq i} |a_{ij}||x_j| \implies$$

$$|a_{ii}| \leq \sum_{j \neq i} |a_{ij}| \frac{\|x_j\|}{\|x_i\|} \implies |a_{ii}| \leq \sum_{j \neq i} |a_{ij}| \implies \text{Contradicción!!}$$

Por lo que necesariamente A es invertible. □

Teorema 3.3.2 [Convergencia del método de Jacobi para matrices d.e.d.]

Sea A una matriz d.e.d., entonces el método de Jacobi converge.

Demostración. Para ver que converge, comprobemos que $\rho(J) < 1$. Para ello, probemos por absurdo que si $\exists \lambda \in \sigma(J)$ tal que $|\lambda| \geq 1$, entonces se llega a una contradicción, ahora:

$$\det(J - \lambda I) = 0 = \det(D^{-1}(E + F) - \lambda D^{-1}D) = \det(D^{-1}) \det(E + F - \lambda D) \implies$$

Como $\det(D^{-1}) \neq 0$, al ser A d.e.d., entonces:

$$\det(E + F - \lambda D) = 0 \implies \underbrace{(E + F - \lambda D)}_B \text{ no es d.e.d.} \implies \exists k \in \{1, \dots, n\} : \|b_{kk}\| \leq \sum_{j \neq k} \|b_{kj}\| \implies$$

Ahora como $b_{kk} = -\lambda a_{kk}$ y $b_{kj} = -a_{kj}$, entonces:


$$|a_{kk}| \leq |\lambda| |a_{kk}| \leq \sum_{j \neq k} |a_{kj}| \implies |a_{kk}| \leq \sum_{j \neq k} |a_{kj}| \implies \text{Contradicción!!}$$

Por lo que necesariamente $\rho(J) < 1$, y el método de Jacobi converge. $\square$

Veamos ahora otro método iterativo, el método de Gauss-Seidel.

Teorema 3.3.3 [Método de Gauss-Seidel]

Usando la misma descomposición de A que en el método de Jacobi, es decir, $A = D - E - F$, que dejaba:



El método de Gauss-Seidel se define como el método iterativo generado por:

$$\begin{cases} x_0 \in \mathbb{K}^n \\ a_{ii}x_i^{(k)} = b_i - \underbrace{\sum_{j < i} a_{ij}x_j^{(k)}}_{Ex_k} - \underbrace{\sum_{j > i} a_{ij}x_j^{(k-1)}}_{Fx_{k-1}} \quad i = 1, \dots, n, k \in \mathbb{N} \end{cases}$$

Y la convergencia estará dada según la distancia al resultado:

$$\|x_k - \xi\| = d_k \sim \rho(J)^k$$

La complejidad de este método sigue siendo $O(n^2)$, al igual que el método de Jacobi, ya que cada iteración requiere calcular n sumas de $n - 1$ elementos.

Notese que se pueden juntar en la notación $D - E$ y F , para obtener $A = M - N$ con $M = D - E$ y $N = F$, por lo que la matriz del método de Gauss-Seidel es:

$$(D - E)x_k = Fx_{k-1} + b \implies x_k = (D - E)^{-1}Fx_{k-1} + (D - E)^{-1}b$$

Que cambiando la notación, se puede escribir como:

$$x_k = Lx_{k-1} + C \quad \text{con} \quad L = (D - E)^{-1}F \quad \text{y} \quad C = (D - E)^{-1}b$$

Donde ahora el radio espectral del método de Gauss-Seidel es:

$$\rho(L) = \rho((D - E)^{-1}F)$$

Notese que el método de Gauss-Seidel no siempre es mejor que el método de Jacobi, muchas veces lo será pero no siempre.

3.4 Métodos de relajación

La idea de los métodos de relajación es modificar los métodos mediante parametros que nos ayuden a mejorar la convergencia. Normalmente usaremos $\omega \in \mathbb{R}$ como parametro de relajación, cuyo significado es el siguiente:

$$x_k = \omega \bar{x}_k + (1 - \omega)x_{k-1}$$

Teorema 3.4.1 [Método de relajación de Jacobi]

El método de relajación de Jacobi se define como el método iterativo, con un punto $\omega \in \mathbb{R}$:

$$\begin{cases} x_0 \in \mathbb{K}^n \\ \frac{D}{\omega}x_k = D\bar{x}_k + \frac{1-\omega}{\omega}Dx_{k-1} = \left(E + F + \frac{1-\omega}{\omega}D\right)x_{k-1} + b \quad k \in \mathbb{N} \end{cases}$$

De lo que sacamos la matriz del método de relajación de Jacobi:

$$J_R = \omega D^{-1} \left(E + F + \frac{1-\omega}{\omega}D \right)$$

Y su convergencia estará dada por el radio espectral de esta matriz, es decir:

$$\rho(J_R) < 1$$

Notese que si $\omega = 1$, entonces el método de relajación de Jacobi coincide con el método de Jacobi, por lo que el método de relajación de Jacobi es una generalización del método de Jacobi.

El método tambien se puede ver de la forma $A = M - N$ con:

$$M = \frac{D}{\omega}$$

$$N = \left(E + F + \frac{1-\omega}{\omega}D \right)$$

De donde queda:

$$A = M - N = \frac{D}{\omega} - \left(E + F + \frac{1-\omega}{\omega}D \right) = D - E - F$$

Sin embargo este método no es muy utilizado en la práctica, ya que no se sabe a priori qué valor de ω es el óptimo para cada sistema lineal, por lo que se suele utilizar el método de relajación de Gauss-Seidel.

Teorema 3.4.2 [Método de relajación de Gauss-Seidel]

El método de relajación de Gauss-Seidel se define como el método iterativo, con un punto $\omega \in [0, 1]$, y multiplicando $\frac{D}{\omega}$ a ambos lados de la ecuación del método de Gauss-Seidel:

$$\begin{cases} x_0 \in \mathbb{K}^n \\ \frac{D}{\omega}x_k = Ex_k + Fx_{k-1} + b + \frac{1-\omega}{\omega}Dx_{k-1} \implies \\ \left(\frac{D}{\omega} - E\right)x_k = \left(F + \frac{1-\omega}{\omega}D\right)x_{k-1} + b \end{cases}$$

De lo que sacamos la matriz del método de relajación de Gauss-Seidel:

$$L_R = (D - \omega E)^{-1}((1 - \omega)D + \omega F)$$

Y su convergencia estará dada por el radio espectral de esta matriz, es decir:

$$\rho(L_R) < 1$$

Notese de nuevo que si $\omega = 1$, entonces el método de relajación de Gauss-Seidel coincide con el método de Gauss-Seidel, por lo que el método de relajación de Gauss-Seidel es una generalización del método de Gauss-Seidel.

Teorema 3.4.3 [Convergencia del método de relajación de Gauss-Seidel]

Si $\omega \notin (0, 2)$ entonces el método de relajación de Gauss-Seidel no converge.

Demostración. Veamos:

$$\det(L_R) = \det\left(\left(\frac{D}{\omega} - E\right)^{-1}\right) \cdot \det\left(F + \frac{1 - \omega}{\omega}D\right) = \frac{\overbrace{\det(F + \frac{1 - \omega}{\omega}D)}^{\Delta}}{\det(\frac{D}{\omega} - E)} =$$

$$\frac{\left(\frac{1 - \omega}{\omega}\right)^n \det(D)}{\left(\frac{1}{\omega}\right)^n \det(D)} = (1 - \omega)^n$$

Ahora, recordemos que $\det(L_R) = \prod_{\lambda \in \sigma(L_R)} \lambda$, por lo que igualando:

$$\prod_{\lambda \in \sigma(L_R)} \lambda = (1 - \omega)^n \implies$$

$$\|1 - \omega\|^n = \|(1 - \omega)^n\| = \left\| \prod_{\lambda \in \sigma(L_R)} \lambda \right\| = \prod_{\lambda \in \sigma(L_R)} \|\lambda\| \leq \rho(L_R)^n \implies \|1 - \omega\| \leq \rho(L_R)$$

Por lo que finalmente:

$$\begin{cases} \rho \geq \omega - 1 \implies \boxed{\omega \geq 2 \implies \rho \geq 1 \implies \text{Divergencia}} \\ \rho \geq 1 - \omega \implies \boxed{\omega \leq 0 \implies \rho \geq 1 \implies \text{Divergencia}} \end{cases}$$

□

Ahora veamos un caso en el que este método converge.

Teorema 3.4.4 [Convergencia del método de relajación de Gauss-Seidel para matrices d.e.d.]

Si A es una matriz d.e.d., entonces el método de relajación de Gauss-Seidel converge para todo $\omega \in (0, 1]$.

Demostración. Supongamos que $\exists \lambda \in \sigma(L_R)$ tal que $|\lambda| \geq 1$, por lo que $\rho(L_R) \geq 1$ y el método no converge. Entonces:

$$\det(L_R - \lambda I) = 0 \implies$$

$$0 = \det\left(\left(\frac{D}{\omega} - E\right)^{-1} \left(F + \left(\frac{1-\omega}{\omega}\right) D\right) - \lambda \underbrace{\left(\frac{D}{\omega} - E\right)^{-1} \left(\frac{D}{\omega} - E\right)}_I\right) =$$

$$\det\left(F + \left(\frac{1-\omega}{\omega}\right) D - \lambda \left(\frac{D}{\omega} - E\right)\right) = \det(B)$$

Por lo que esta nueva matriz B no es d.e.d., por lo que $\exists k \in \{1, \dots, n\}$ tal que:

$$b_{kk} \leq \sum_{j \neq k} |b_{kj}| \implies$$

$$\left| \frac{1-\omega-\lambda}{\omega} a_{kk} \right| \leq \underbrace{\sum_{i=k+1}^n |-a_{ki}|}_F + \underbrace{\sum_{i=1}^{k-1} |-\lambda a_{ki}|}_E = \sum_{i=k+1}^n |a_{ki}| + |\lambda| \sum_{i=1}^{k-1} |a_{ki}| \leq |\lambda| \sum_{i \neq k} |a_{ki}| \implies$$

$$|a_{kk}| \leq \left| \frac{\lambda\omega}{1-\omega-\lambda} \right| \sum_{i \neq k} |a_{ki}| \leq \sum_{i \neq k} |a_{ki}| \implies A \text{ no es d.e.d. !!}$$

□

Veamos un nuevo teorema que no demostraremos, pero que es interesante conocer.

Teorema 3.4.5 [Criterio de convergencia para métodos iterativos]

Sea $A = M - N$ una matriz h.d.p.

Ahora podemos definir:

$$B = M^* + N^* \quad \text{ó} \quad B = M + N^*$$

Si B es h.d.p., entonces $\rho(M^{-1}N) < 1$, por lo que el método iterativo generado por M converge.

Teorema 3.4.6 [Convergencia del método de relajación de Gauss-Seidel para matrices h.d.p.]

Sea A una matriz h.d.p. y $\omega \in (0, 2)$ entonces el método de relajación de Gauss-Seidel converge.

Observación 3.4.1

Notese que si $\omega = 1$, entonces el método de relajación de Gauss-Seidel coincide con el método de Gauss-Seidel, por lo que el método de Gauss-Seidel también converge para matrices h.d.p.

Demostración. Veamos que se cumple el teorema anterior, para ello definamos:

$$B = M^* + N = \left(\frac{D}{\omega} - E\right)^* + \left(F + \frac{1-\omega}{\omega} D\right) = \frac{D^*}{\omega} - E^* + F + \frac{1-\omega}{\omega} D$$

Ahora podemos usar que como A es h.d.p., entonces $D^* = D$, al ser matrices diagonales. Además, como A es h.d.p., podemos deducir que las matrices triangulares $E^* = F$ y $F^* = E$, al trasponer al hacer la traspuesta de A . Todo esto se aprecia en la siguiente igualdad:

$$A = \textcolor{green}{D} - \textcolor{red}{E} - \textcolor{blue}{F} =$$

$$= A^* = D^* - E^* - F^*$$

Por lo que llegamos a que:

$$B = \frac{2-\omega}{\omega}D - E^* + F = \frac{2-\omega}{\omega}D$$

Para que B sea h.d.p., es necesario que $\frac{2-\omega}{\omega} > 0$, lo cual se cumple para todo $\omega \in (0, 2)$, por lo que B es h.d.p., y por el teorema anterior, el método de relajación de Gauss-Seidel converge al tener $\rho(L_R) < 1$. $\square$

4 Interpolación polinómica

4.1 Motivación

Hay un problema clásico en análisis numérico que es el siguiente:

Dado un conjunto de puntos $x_0, x_1, \dots, x_n$ y un conjunto de valores $y_0, y_1, \dots, y_n$, encontrar una función f tal que $f(x_i) = y_i$ para todo $i = 0, 1, \dots, n$. Para ello, una de las formas más comunes de resolver este problema es mediante la interpolación polinómica, que consiste en encontrar un polinomio P de grado a lo sumo n tal que $P(x_i) = y_i$ para todo $i = 0, 1, \dots, n$.

Definición 4.1.1 [Espacio de polinomios]

El espacio de polinomios al conjunto:

$$\mathbb{R}[x] = \{p = a_0 + a_1x + a_2x^2 + \dots + a_nx^n : a_i \in \mathbb{R}, n \in \mathbb{N}\}$$

En particular, el espacio de polinomios de grado a lo sumo n se denota por:

$$\mathcal{P}_n = \{p = a_0 + a_1x + a_2x^2 + \dots + a_nx^n : a_i \in \mathbb{R}\}$$

Un caso particular de este problema es el siguiente:

$$\mathcal{P}_0 = \{a_0 : a_0 \in \mathbb{R}\}$$

Que es isomorfo a $\mathbb{R}$, es decir:

$$\mathcal{P}_0 \cong \mathbb{R}$$

De hecho, el espacio de polinomios de grado a lo sumo n es isomorfo a $\mathbb{R}^{n+1}$, es decir:

$$\mathcal{P}_n \cong \mathbb{R}^{n+1}$$

4.2 Problema de la interpolación polinómica

Formalizemos ahora el problema de la interpolación polinómica.

Definición 4.2.1 [Problema de la interpolación polinómica]

Sean:

$$\begin{cases} \{x_i\}_{i=0}^n \subset [a, b] : & x_i \neq x_j \iff i \neq j \\ \{y_i\}_{i=0}^n \subset \mathbb{R} \end{cases}$$

Encontrar $p \in \mathcal{P}_n$ que cumpla que:

$$p(x_i) = y_i \quad \forall i = 0, 1, \dots, n$$

En general, el problema se puede representar como un sistema de ecuaciones, que parten de:

$$\begin{cases} y_0 = p_n(x_0) = a_0 + a_1x_0 + a_2x_0^2 + \dots + a_nx_0^n \\ y_1 = p_n(x_1) = a_0 + a_1x_1 + a_2x_1^2 + \dots + a_nx_1^n \\ \vdots \\ y_n = p_n(x_n) = a_0 + a_1x_n + a_2x_n^2 + \dots + a_nx_n^n \end{cases} \implies$$

$$\underbrace{\mathcal{M}_{(n+1) \times (n+1)}}_X \cdot \underbrace{a}_{\mathbb{R}^{n+1}} = \underbrace{y}_{\mathbb{R}^{n+1}} \iff \begin{bmatrix} 1 & x_0 & x_0^2 & \dots & x_0^n \\ 1 & x_1 & x_1^2 & \dots & x_1^n \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \dots & x_n^n \end{bmatrix} \cdot \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{bmatrix} = \begin{bmatrix} y_0 \\ y_1 \\ \vdots \\ y_n \end{bmatrix}$$

Y el problema ahora consistirá en ver si la matriz X es invertible, lo que nos deja una única solución:

$$\exists! a = X^{-1}y \implies \exists! p \in \mathcal{P}_n : p = a_0 + a_1x + a_2x^2 + \dots + a_nx^n$$

Ejemplo

Veamos un ejemplo particular:

i	0	1	2
x	0	1	3
y	-3	4	5

En este caso, el sistema de ecuaciones es el siguiente:

$$\begin{cases} -3 = a_0 + a_1 \cdot 0 + a_2 \cdot 0^2 \\ 4 = a_0 + a_1 \cdot 1 + a_2 \cdot 1^2 \\ 5 = a_0 + a_1 \cdot 3 + a_2 \cdot 3^2 \end{cases} \implies \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 1 \\ 1 & 3 & 9 \end{bmatrix} \cdot \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} -3 \\ 4 \\ 5 \end{bmatrix}$$

Ahora veamos que ocurre con la matriz X . Para que sea invertible, es necesario que su determinante sea distinto de cero. El determinante de la matriz X es el siguiente (usando la regla de Vandermonde):

$$\det(X) = \prod_{i \neq j} (x_i - x_j) \neq 0 \implies \boxed{x_i \neq x_j \iff i \neq j}$$

4.3 Polinomios de Lagrange

En esta sección, vamos a ver un tipo de polinomios que nos van a resultar muy útiles para resultados teóricos.

Definición 4.3.1 [Polinomios de Lagrange]

Dado un conjunto de puntos $\{x_i, y_i\}_{i=0}^n$, que nos definan un problema de interpolación polinómica, buscaremos un polinomio $p \in \mathcal{P}_n$ de la siguiente forma:

$$p(x) = \sum_{i=0}^n y_i L_i(x)$$

Lo que nos lleva al siguiente sistema de ecuaciones:

$$\begin{cases} y_0 = p(x_0) = y_0 L_0(x_0) + y_1 L_1(x_0) + \dots + y_n L_n(x_0) \\ y_1 = p(x_1) = y_0 L_0(x_1) + y_1 L_1(x_1) + \dots + y_n L_n(x_1) \\ \vdots \\ y_n = p(x_n) = y_0 L_0(x_n) + y_1 L_1(x_n) + \dots + y_n L_n(x_n) \end{cases} \implies \begin{cases} y_0 = y_0 L_0(x_0) \\ y_1 = y_1 L_1(x_1) \\ \vdots \\ y_n = y_n L_n(x_n) \end{cases}$$

Lo que nos lleva a que:

$$L_k(x_j) = \delta_{kj} = \begin{cases} 1 & \text{si } k = j \\ 0 & \text{si } k \neq j \end{cases} \implies L_k(x) = \prod_{j \neq k} \frac{x - x_j}{x_k - x_j}$$

Donde los numeradores de la fracción se encargan de que el polinomio se anule en los puntos x_j con $j \neq k$, y el denominador se encarga de que el polinomio tome el valor 1 en el punto x_k (normalizando su valor).

El utilizar los polinomios de Lagrange se conoce como **Interpolación de Lagrange**.

Todo esto sera útil para interpolar funciones, creando los puntos de la forma $\{x_i, f(x_i)\}_{i=0}^n$, y buscando un polinomio p que interpole a la función f en esos puntos, es decir, que cumpla que $p(x_i) = f(x_i)$ para todo $i = 0, 1, \dots, n$.

Teorema 4.3.1 [Existencia y unicidad del polinomio de Lagrange]

Dado un conjunto de puntos $\{x_i, y_i\}_{i=0}^n$, que nos definan un problema de interpolación polinómica, entonces existe un único polinomio $p \in \mathcal{P}_n$ tal que $p(x_i) = y_i$ para todo $i = 0, 1, \dots, n$, y dicho polinomio viene dado por la fórmula de Lagrange:

$$p(x) = \sum_{i=0}^n y_i L_i(x)$$

Con:

$$L_i(x) = \prod_{j \neq i} \frac{x - x_j}{x_i - x_j}$$

Demostración. Veamos primero la existencia del polinomio de Lagrange. Para ello, basta con comprobar que el polinomio p definido por la fórmula de Lagrange cumple que $p(x_i) = y_i$ para todo $i = 0, 1, \dots, n$. Esto se cumple debido a la definición de los polinomios de Lagrange, que garantizan que $L_k(x_j) = \delta_{kj}$, y está bien definido ya que:

$$x_i \neq x_j \iff i \neq j \iff x_i - x_j \neq 0$$

Para ver la unicidad, supongamos que $\exists p, q \in \mathcal{P}_n$ tal que:

$$\forall i \in \{0, 1, \dots, n\} : p(x_i) = q(x_i) = y_i$$

Entonces definamos el polinomio $d(x)$ como:

$$d(x) = p(x) - q(x) \in \mathcal{P}_n \implies d(x_i) = p(x_i) - q(x_i) = y_i - y_i = 0 \quad \forall i = 0, 1, \dots, n$$

Como d es un polinomio de grado a lo sumo n que tiene $n + 1$ raíces distintas, entonces según el teorema fundamental del álgebra, d es el polinomio nulo, es decir, $d(x) = 0$ para todo $x \in \mathbb{R}$. Por lo tanto, $p(x) = q(x)$ para todo $x \in \mathbb{R}$, lo que implica que p y q son el mismo polinomio. Por lo tanto, el polinomio de Lagrange es único. $\square$

4.4 Error de interpolación

Podemos preguntarnos ahora, dado un conjunto de puntos $\{x_i, y_i\}_{i=0}^n$ y una función f tal que $f(x_i) = y_i$ para todo $i = 0, 1, \dots, n$, cuál es el error cometido al interpolar a la función f mediante el polinomio de Lagrange p . Para ello, definamos:

Definición 4.4.1

El error de interpolación de la función f mediante el polinomio de Lagrange p_n se define como la función:

$$E_n(x) = f(x) - p_n(x)$$

Ejemplo

Tomemos la función

$$f(x) = \frac{\sin(x)}{1+x^2}$$

y los nodos de interpolación


$$x_i \in \{-3, -2, -1, 0, 1, 2, 3\}, \quad y_i = f(x_i).$$

El polinomio interpolador de Lagrange de grado 6 es

$$p_6(x) = \sum_{i=0}^6 y_i L_i(x), \quad L_i(x) = \prod_{\substack{j=0 \\ j \neq i}}^6 \frac{x - x_j}{x_i - x_j}.$$

Al simplificar, obtenemos:

$$p_6(x) = 0.577015793023248 x - 0.167866563297343 x^3 + 0.0115862626780432 x^5.$$

**Teorema 4.4.1** [Error de interpolación]

Sea $f \in C^{n+1}([a, b])$ y $\{x_i\}_{i=0}^n \subset [a, b]$ con $x_i \neq x_j$ para todo $i \neq j$, $y_i = f(x_i)$ para todo $i = 0, 1, \dots, n$. Entonces $\forall x \in [a, b]$ introducimos:

$$I_x = (\min\{x \cup x_i\}, \max\{x \cup x_i\}) \subset [a, b]$$

Entonces $\exists \xi_x \in I_x$ tal que:

$$E_n(x) = f(x) - p_n(x) = \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \prod_{i=0}^n (x - x_i)$$

Donde podemos tomar normas para obtener una cota del error:

$$|E_n(x)| = \frac{\|f^{(n+1)}\|}{(n+1)!} \prod_{i=0}^n |x - x_i|$$

Demostración. Para demostrar el teorema, definamos la función auxiliar, teniendo en cuenta que hemos fijado el $x \notin \{x_i\}_{i=0}^n$:

$$F(y) = (f(y) - p_n(y)) \prod_n (x) - (f(x) - p_n(x)) \prod_n (y)$$

Ahora veamos lo siguiente:

1. $F \in C^{n+1}([a, b])$ ya que $f \in C^{n+1}([a, b])$ y p_n es un polinomio de grado a lo sumo n , por lo que $p_n \in C^\infty([a, b])$.
2. $F(x_i) = 0$ para todo $i = 0, 1, \dots, n$, ya que:

$$F(x_i) = \left(\underbrace{f(x_i)}_{y_i} - \underbrace{p_n(x_i)}_{y_i} \right) \prod_n (x - x_i) = 0$$

Por lo que F tiene al menos $n + 1$ raíces distintas.

3. $F(x) = 0$ ya que:

$$F(x) = (f(x) - p_n(x)) \prod_n (x - x_i) = 0$$

Ahora como F tiene $n + 2$ raíces distintas y $F \in C^{n+1}([a, b])$, entonces por el teorema de Rolle, $\exists c \in (a, b)$ tal que $F^{(n+1)}(c) = 0$, ya que podemos ir aplicando el teorema de Rolle a F , sacando $n + 1$ raíces distintas de F' , entre cada par de raíces, por lo que podemos sacar n raíces de F'' , y así sucesivamente, hasta llegar a $F^{(n+1)}$, que tendrá al menos una raíz distinta, que es el c que hemos mencionado. Ahora simplemente denotamos a esa raíz como ξ_x , y obtenemos que:

$$F^{(n+1)}(\xi_x) = 0$$

Ahora si evaluamos (recordando que $E_n(x) = f(x) - p_n(x)$):

$$F^{(n+1)}(y) = \left(f^{(n+1)}(y) - p_n^{(n+1)}(y) \right) \prod_n (x - x_i) - E_n(x) \cdot \left(\prod_n (y - x_i) \right)^{(n+1)}$$

Ahora si nos damos cuenta de que $(\prod_n (y - x_i))^{(n+1)} = (n + 1)!$ ya que el producto $\prod_n (y - x_i)$ es un polinomio de grado $n + 1$ con $n + 1$ raíces distintas, entonces su derivada $(n + 1)$ -ésima es igual a $(n + 1)!$. Además, como p_n es un polinomio de grado a lo sumo n , entonces $p_n^{(n+1)}(y) = 0$ para todo $y \in [a, b]$. Por lo tanto, obtenemos que:

$$F^{(n+1)}(y) = f^{(n+1)}(y) \prod_n (x - x_i) - E_n(x) \cdot (n + 1)!$$

Y como $F^{(n+1)}(\xi_x) = 0$, entonces:

$$0 = F^{(n+1)}(\xi_x) = f^{(n+1)}(\xi_x) \prod_n (x - x_i) - E_n(x) \cdot (n + 1)! \implies$$

$$E_n(x) = \frac{f^{(n+1)}(\xi_x)}{(n + 1)!} \prod_{i=0}^n (x - x_i)$$

□

4.5 Método de Newton

4.5.1 Diferencias divididas

Definición 4.5.1 [Diferencias divididas]

Dado un conjunto de puntos $\{x_i, y_i\}_{i=0}^n$, que nos definan un problema de interpolación polinómica, definimos las diferencias divididas de f en los puntos $x_0, x_1, \dots, x_n$ de la siguiente forma:

$$f[x_i] = f(x_i) = y_i$$

$$f[x_i, x_j] = \frac{f[x_i] - f[x_j]}{x_i - x_j} \quad \text{para } i \neq j$$

Y así sucesivamente, definiendo las diferencias divididas de orden n como:

$$f[x_i, x_{i+1}, \dots, x_{i+m}] = \frac{f[x_i, x_{i+1}, \dots, x_{i+m-1}] - f[x_{i+1}, x_{i+2}, \dots, x_{i+m}]}{x_i - x_{i+m}}$$

Ejemplo

Si queremos calcular las diferencias divididas con x_0, x_1, x_2 , entonces tenemos que:

$$\begin{aligned} f[x_0] &= f(x_0) = y_0 \\ f[x_0, x_1] &= \frac{f[x_0] - f[x_1]}{x_0 - x_1} = \frac{y_0 - y_1}{x_0 - x_1} \\ f[x_0, x_1, x_2] &= \frac{f[x_0, x_1] - f[x_1, x_2]}{x_0 - x_2} = \frac{\frac{y_0 - y_1}{x_0 - x_1} - \frac{y_1 - y_2}{x_1 - x_2}}{x_0 - x_2} \end{aligned}$$

Veamos ahora algunas propiedades interesantes de las diferencias divididas:

Proposición 4.5.1 [Simetría de las diferencias divididas]

Las diferencias divididas son simétricas respecto a sus argumentos, es decir, si permutamos los puntos x_i en la definición de las diferencias divididas, el valor de las diferencias divididas no cambia. Por ejemplo:

$$f[x_0, x_1] = \frac{f[x_0] - f[x_1]}{x_0 - x_1} = \frac{f[x_1] - f[x_0]}{x_1 - x_0} = f[x_1, x_0]$$

E incluso para diferencias divididas de orden superior, como:

$$f[x_0, x_1, x_2] = \frac{f[x_0, x_1] - f[x_1, x_2]}{x_0 - x_2} = \frac{f[x_1, x_2] - f[x_0, x_1]}{x_1 - x_0} = f[x_1, x_2, x_0]$$

En general, si σ es una permutación de $\{0, 1, \dots, n\}$, entonces:

$$f[x_0, x_1, \dots, x_n] = f[x_{\sigma(0)}, x_{\sigma(1)}, \dots, x_{\sigma(n)}]$$

4.5.2 Definición del método de Newton

La idea del método de Newton es construir el polinomio de interpolación de Lagrange de forma progresiva, es decir, primero construimos el polinomio de interpolación de Lagrange de grado 0, luego el de grado 1, y así sucesivamente, hasta llegar al polinomio de interpolación de Lagrange de grado n , es decir, la construcción se hará:

$$p_0(x) = f(x_0) \implies p_1(x) = N(p_0(x)) \implies p_2(x) = N(p_1(x)) \implies \dots \implies p_n(x) = N(p_{n-1}(x))$$

Definición 4.5.2 [Construcción del método de Newton]

Dado un conjunto de puntos $\{x_i, y_i\}_{i=0}^n$, que nos definan un problema de interpolación polinómica, podemos empezar a construir el polinomio de interpolación de la siguiente forma:

- $n = 0$: En este caso, el polinomio de interpolación es simplemente el polinomio constante que toma el valor y_0 en todo el intervalo, es decir:

$$p_0(x) = f(x_0) = f[x_0]$$

Esto nos deja el error:

$$E_0(x) = f(x) - p_0(x) = \frac{f[x] - f[x_0]}{x - x_0} \cdot (x - x_0) = f[x, x_0] \cdot (x - x_0) \underbrace{=}_{\text{simetría}} f[x_0, x] \cdot (x - x_0)$$

- $n = 1$: En este caso, el polinomio de interpolación es el polinomio de grado 1 que interpola a los puntos x_0 y x_1 , es decir:

$$\begin{aligned} p_1(x) &= \underbrace{p_0(x)}_{\in \mathcal{P}_0} + \underbrace{q_1(x)}_{\in \mathcal{P}_1} \in \mathcal{P}_1 \implies \\ p_1(x_0) &= f(x_0) = \underbrace{p_0(x_0)}_{f[x_0]} + \underbrace{q_1(x_0)}_0 \implies q_1(x_0) = \alpha \cdot (x - x_0) \implies \\ p_1(x_1) &= f(x_1) = \underbrace{p_0(x_1)}_{f[x_0]} + \underbrace{q_1(x_1)}_{\alpha \cdot (x_1 - x_0)} \implies \alpha = \frac{f[x_1] - f[x_0]}{x_1 - x_0} = f[x_0, x_1] \implies \\ &\boxed{p_1(x) = f[x_0] + f[x_0, x_1] \cdot (x - x_0)} \end{aligned}$$

Y el error en este caso es:

$$E_1(x) = f(x) - p_1(x) = \frac{f[x] - f[x_0, x_1]}{(x - x_0)(x - x_1)} \cdot (x - x_0)(x - x_1) = f[x, x_0, x_1] \cdot (x - x_0)(x - x_1)$$

Podemos reescribir el error y el polinomio de la siguiente forma, para hacer más evidente la construcción progressiva del método de Newton:

$$p_1(x) = p_0(x) + f[x_0, x_1] \cdot \prod_{j=0}^0 (x - x_j) \quad E_1(x) = f[x, x_0, x_1] \cdot \prod_{j=0}^1 (x - x_j)$$

- **Inducción:** Queremos probar que los polinomios de interpolación de grado n se pueden construir a partir del polinomio de interpolación de grado $n - 1$ de la siguiente forma:

$$p_n(x) = p_{n-1}(x) + f[x_0, x_1, \dots, x_n] \cdot \prod_{j=0}^{n-1} (x - x_j) \quad E_n(x) = f[x_0, x_1, \dots, x_n, x] \cdot \prod_{j=0}^n (x - x_j)$$

Teorema 4.5.1 [Correctitud del método de Newton]

Dado un conjunto de puntos $\{x_i, y_i\}_{i=0}^n$, que nos definan un problema de interpolación polinómica, entonces el polinomio de Newton construido de forma progressiva a partir de las diferencias divididas, es decir, el polinomio p_n definido por:

$$p_n(x) = p_{n-1}(x) + f[x_0, x_1, \dots, x_n] \cdot \prod_{j=0}^{n-1} (x - x_j)$$

Con $p_0(x) = f[x_0]$, es el polinomio de interpolación de Lagrange, es decir, el único polinomio $p \in \mathcal{P}_n$ tal que $p(x_i) = y_i$ para todo $i = 0, 1, \dots, n$. Además, el error cometido al interpolar a la función f

mediante el polinomio de Newton p_n es:

$$E_n(x) = f(x) - p_n(x) = f[x_0, x_1, \dots, x_n, x] \cdot \prod_{j=0}^n (x - x_j)$$

Demostración. En la definición hemos probado los casos base $n = 0$ y $n = 1$, por lo que ahora simplemente tenemos que probar el paso inductivo, es decir, suponer que el polinomio de interpolación de grado n se puede construir a partir del polinomio de interpolación de grado $n - 1$ de la forma:

$$p_n(x) = p_{n-1}(x) + f[x_0, x_1, \dots, x_n] \cdot \prod_{j=0}^{n-1} (x - x_j)$$

Y ahora queremos probar que el polinomio de interpolación de grado $n + 1$ se puede construir a partir del polinomio de interpolación de grado n de la forma:

$$p_{n+1}(x) = p_n(x) + f[x_0, x_1, \dots, x_{n+1}] \cdot \prod_{j=0}^n (x - x_j)$$

Para ello, basta con comprobar que el polinomio p_{n+1} debe ser de la forma:

$$p_{n+1}(x) = p_n(x) + q_{n+1}(x) \implies \begin{cases} \begin{cases} p_{n+1}(x_i) = \underbrace{p_n(x_i)}_{f[x_i]} + q_{n+1}(x_i) = f[x_i] \\ q_{n+1}(x_i) = 0 \implies q_{n+1}(x) = \alpha \cdot \prod_{j=0}^n (x - x_j) \end{cases} \\ p_{n+1}(x_{n+1}) = f[x_{n+1}] = p_n(x_{n+1}) + \alpha \cdot \prod_{j=0}^n (x_{n+1} - x_j) \end{cases} \quad \forall i = 0, 1, \dots, n \quad (1)$$

Ahora usando el error de interpolación, tenemos que:

$$E_n(x) = f(x) - p_n(x) \implies p_n(x) = f(x) - E_n(x) = f(x) - f[x_0, x_1, \dots, x_n, x] \cdot \prod_{j=0}^n (x - x_j)$$

Sustituyendo en la ecuación de $p_{n+1}(x_{n+1})$, obtenemos que:

$$p_{n+1}(x_{n+1}) = f[x_{n+1}] = f(x_{n+1}) - f[x_0, x_1, \dots, x_n, x_{n+1}] \cdot \prod_{j=0}^n (x_{n+1} - x_j) + \alpha \cdot \prod_{j=0}^n (x_{n+1} - x_j) \implies$$

$$\boxed{\alpha = f[x_0, x_1, \dots, x_n, x_{n+1}]} \implies$$

$$\boxed{p_{n+1}(x) = p_n(x) + f[x_0, x_1, \dots, x_n, x_{n+1}] \cdot \prod_{j=0}^n (x - x_j)}$$

Y el error en este caso es:

$$E_{n+1}(x) = f(x) - p_{n+1}(x) = f(x) - p_n(x) - f[x_0, x_1, \dots, x_n, x_{n+1}] \cdot \prod_{j=0}^n (x - x_j) = f[x_0, x_1, \dots, x_n, x_{n+1}, x] \cdot \prod_{j=0}^{n+1} (x - x_j)$$

□

4.6 Splines

Definición 4.6.1 [Partición de un intervalo]

Dado un intervalo $[a, b]$, una partición de dicho intervalo es un conjunto de puntos $\Delta = \{x_i\}_{i=0}^n$ tal que:

$$a = x_0 < x_1 < x_2 < \dots < x_n = b$$

Definición 4.6.2 [Función spline]

Dada una partición Δ y un conjunto de datos $\{(x_i, y_i)\}_{i=0}^n$, una función spline de orden $k \in \mathbb{N}$ es una función $S : [a, b] \rightarrow \mathbb{R}$ que cumple las siguientes condiciones:

1. $S \in C^{k-1}$ globalmente en $[a, b]$, es decir, S es continua y tiene derivadas continuas hasta el orden $k - 1$ en todo el intervalo $[a, b]$.
2. $S \in \mathcal{P}^k$ localmente en cada subintervalo $[x_i, x_{i+1}]$, es decir, S es un polinomio de grado a lo sumo k en cada subintervalo $[x_i, x_{i+1}]$.
3. $S(x_i) = y_i$ para todo $i = 0, 1, \dots, n$, es decir, S interpola a los datos dados en los puntos de la partición.

Esta función spline se denota comúnmente como S_k para indicar el orden del spline, y define un problema de interpolación spline, que consiste en encontrar una función spline S_k que interpole a los datos dados en los puntos de la partición.

Veamos algunos casos elementales:


Caso elemental $k = 1$: $S : [a, b] \rightarrow \mathbb{R}$ es un spline de orden 1 si S :

1. $S \in C^0([a, b])$, es decir, S es continua en $[a, b]$.
2. $S \in \mathcal{P}^1([x_i, x_{i+1}])$ para todo $i = 0, 1, \dots, n - 1$, es decir, S es un polinomio de grado a lo sumo 1 en cada subintervalo $[x_i, x_{i+1}]$, lo que significa que S es una función lineal por tramos.
3. $S(x_i) = y_i$ para todo $i = 0, 1, \dots, n$, es decir, S interpola a los datos dados en los puntos de la partición.

Gráficamente, si tomamos la siguiente tabla de datos:

x_i	y_i
1	3
2	-2
4	0
5	-1
6	4

Podemos construir el spline de orden 1 de la siguiente forma:



Caso elemental $k = 2$: $S : [a, b] \rightarrow \mathbb{R}$ es un spline de orden 2 si S :

1. $S \in C^1([a, b])$, es decir, S es continua y tiene derivada continua en $[a, b]$.
2. $S \in \mathcal{P}^2([x_i, x_{i+1}])$ para todo $i = 0, 1, \dots, n-1$, es decir, S es un polinomio de grado a lo sumo 2 en cada subintervalo $[x_i, x_{i+1}]$, lo que significa que S es una función cuadrática por tramos.
3. $S(x_i) = y_i$ para todo $i = 0, 1, \dots, n$, es decir, S interpola a los datos dados en los puntos de la partición.

Caso elemental $k = 3$: $S : [a, b] \rightarrow \mathbb{R}$ es un spline de orden 3 si S :

1. $S \in C^2([a, b])$, es decir, S es continua y tiene derivadas continuas hasta el orden 2 en $[a, b]$.
2. $S \in \mathcal{P}^3([x_i, x_{i+1}])$ para todo $i = 0, 1, \dots, n-1$, es decir, S es un polinomio de grado a lo sumo 3 en cada subintervalo $[x_i, x_{i+1}]$, lo que significa que S es una función cúbica por tramos.
3. $S(x_i) = y_i$ para todo $i = 0, 1, \dots, n$, es decir, S interpola a los datos dados en los puntos de la partición.

Podemos entonces escribir sus ecuaciones de la siguiente forma:

$$S(x) = a_0^i + a_1^i x + a_2^i x^2 + a_3^i x^3$$

$$S'(x) = a_1^i + 2a_2^i x + 3a_3^i x^2$$

$$S''(x) = 2a_2^i + 6a_3^i x$$

Ahora, nos podemos preguntar cuantas ecuaciones tenemos para determinar los coeficientes $a_0^i, a_1^i, a_2^i, \dots, a_n^i$ de cada polinomio. Para ello, tenemos que:

- Por la condición de interpolación, tenemos $n + 1$ ecuaciones, ya que $S(x_i) = y_i$ para todo $i = 0, 1, \dots, n$.
- Se suele añadir la condición de que el spline sea natural, es decir, que $S''(x_0) = S''(x_n) = 0$, lo que nos da 2 ecuaciones más.
- También se suelen dar condiciones de contorno de las derivadas al inicio y al final del intervalo, es decir, $S'(a) = \alpha$ y $S'(b) = \beta$, lo que nos da 2 ecuaciones más.

- A veces también se dan condiciones periódicas que nos dicen que $S^{(k)}(a) = S^{(k)}(b)$ para todo $k = 0, 1, \dots$, lo que nos da $n + 1$ ecuaciones más.

En el caso $k = 3$, si establecemos que el Spline sea natural, es decir, que $S''(x_0) = S''(x_n) = 0$, entonces podemos tener suficientes datos para determinar un único spline cúbico que interpole a los datos dados en los puntos de la partición. Esto se puede hacer en 2 pasos:

1. **Definir:** Para cada $i = 0, 1, \dots, n - 1$, definimos:

$$m_i = S''(x_i)$$

Que se denominan "momentos", y además se establece que $m_0 = m_n = 0$ por ser un spline natural. Después se escribe un lema que habla de la unicidad del Spline según los momentos.

2. **Momentos:** Sabiendo que S' es continua, entonces:

$$\begin{aligned} S'(x_i - 0) &= S'(x_i + 0) \implies \\ \begin{cases} S'(x_i + 0) = \frac{1}{2h_{i+1}}(-m_i h_{i+1}) + \frac{h_{i+1}}{6}(m_i - m_{i+1}) + f[x_i, x_{i+1}] \\ S'(x_i - 0) = \frac{m_i h_i}{2} + \frac{h_i}{6}(m_{i-1} - m_i) + f[x_{i-1}, x_i] \end{cases} &\implies \\ \frac{h_i}{6} + \left(\frac{h_{i+1}}{2} - \frac{h_i}{6} + \frac{h_i}{2} - \frac{h_i}{6} \right) m_i + \frac{h_{i+1}}{6} m_{i+1} &= f[x_{i-1}, x_i] - f[x_i, x_{i+1}] \implies \\ \underbrace{\frac{h_i}{h_i + h_{i+1}} m_{i-1} + 2m_i}_{\mu_i} + \underbrace{\frac{h_{i+1}}{h_i + h_{i+1}} m_{i+1}}_{\lambda_i} &= 6 \frac{f[x_{i-1}, x_i] - f[x_i, x_{i+1}]}{x_{i+1} - x_{i-1}} = -6f[x_{i-1}, x_i, x_{i+1}] \end{aligned}$$

Dejándonos el sistema, con $m = \begin{pmatrix} m_0 \\ m_1 \\ \vdots \\ m_n \end{pmatrix}$, $d = \begin{pmatrix} d_1 \\ d_2 \\ \vdots \\ d_{n-1} \end{pmatrix}$:

$$\Lambda m = d \implies \begin{pmatrix} 2 & \lambda_1 & 0 & \cdots & 0 \\ \mu_2 & 2 & \lambda_2 & \cdots & 0 \\ 0 & \mu_3 & 2 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & \lambda_{n-2} \\ 0 & 0 & \cdots & \mu_{n-2} & 2 \end{pmatrix} \begin{pmatrix} m_0 \\ m_1 \\ m_2 \\ \vdots \\ m_{n-2} \\ m_{n-1} \\ m_n \end{pmatrix} = \begin{pmatrix} d_1 \\ d_2 \\ d_3 \\ \vdots \\ d_{n-2} \\ d_{n-1} \end{pmatrix}$$

Como Λ es de diagonal estrictamente dominante, entonces el sistema tiene una única solución, lo que nos da los momentos m_i para todo $i = 0, 1, \dots, n$, y por lo tanto nos da un único spline cúbico que interpola a los datos dados en los puntos de la partición.

Lema 4.6.1 [Unicidad del Spline según los momentos]

Dado un conjunto de puntos $\{x_i, y_i\}_{i=0}^n$ y un conjunto de momentos $\{m_i\}_{i=0}^n$ con $m_0 = m_n = 0$, entonces existe un único spline cúbico S que interpola a los datos dados en los puntos de la partición y que tiene como momentos a los m_i dados.

Demostración. Hagamos una demostración constructiva.

1. Como $S \in \mathcal{P}^3$ es un polinomio de grado a lo sumo 3 en cada subintervalo $[x_i, x_{i+1}]$, entonces $S'' \in \mathcal{P}^1$ son rectas en cada subintervalo $[x_i, x_{i+1}]$, y deben de ser continuas al ser $S \in C^2$ globalmente en $[a, b]$.
2. Ahora si $x \in [x_i, x_{i+1}]$, donde denotamos $h_{i+1} = x_{i+1} - x_i$, entonces $S''(x) = \alpha m_i(x - x_i) + \beta m_{i+1}(x_{i+1} - x)$, ya que S'' es una recta que pasa por los puntos (x_i, m_i) y (x_{i+1}, m_{i+1}) . Despejando:

$$\begin{cases} S''(x_i) = m_i = \alpha m_i \underbrace{x_i - x_{i+1}}_{-h_{i+1}} \Rightarrow \alpha = -\frac{1}{h_{i+1}} \\ S''(x_{i+1}) = m_{i+1} = \beta m_{i+1} \underbrace{x_{i+1} - x_i}_{h_{i+1}} \Rightarrow \beta = \frac{1}{h_{i+1}} \end{cases} \Rightarrow \boxed{S''(x) = \frac{m_{i+1}(x - x_i) - m_i(x_{i+1} - x)}{h_{i+1}}}$$

3. Integrando:

$$S'(x) = \int S''(x)dx = \frac{1}{2h_{i+1}} (-m_i(x_{i+1} - x)^2 + m_{i+1}(x - x_i)^2) + a_i$$

$$S(x) = \int S'(x)dx = \frac{1}{6h_{i+1}} (m_i(x_{i+1} - x)^3 + m_{i+1}(x - x_i)^3) + a_i(x - x_i) + b_i$$

4. Ahora usando la condición de interpolación, tenemos que:

$$S(x_i) = f(x_i) = \frac{1}{6h_{i+1}} m_i h_{i+1}^3 + b_i \Rightarrow$$

$$\boxed{b_i = f(x_i) - \frac{1}{6} m_i h_{i+1}^2}$$

$$S(x_{i+1}) = f(x_{i+1}) = \frac{1}{6h_{i+1}} m_{i+1} h_{i+1}^3 + a_i h_{i+1} + \underbrace{f(x_i) - \frac{1}{6} m_i h_{i+1}^2}_{b_i} \Rightarrow$$

$$\boxed{a_i = \underbrace{\frac{f(x_{i+1}) - f(x_i)}{h_{i+1}}}_{f[x_i, x_{i+1}]} + \frac{h_{i+1}}{6} (m_i - m_{i+1})}$$

Dejando así que:

$$S(x) = \frac{1}{6h_{i+1}} (m_i(x_{i+1} - x)^3 + m_{i+1}(x - x_i)^3) +$$

$$+ \left(f[x_i, x_{i+1}] + \frac{h_{i+1}}{6} (m_i - m_{i+1}) \right) (x - x_i) + f(x_i) - \frac{1}{6} m_i h_{i+1}^2$$

□

Definición 4.6.3 [Spline cúbico natural o de Tipo I]

Un spline cúbico natural o de Tipo I es un spline cúbico que satisface las condiciones de contorno $S''(x_0) = S''(x_n) = 0$.

Veamos ahora un ejemplo de cómo construir un spline cúbico natural a partir de un conjunto de datos dado.

Ejemplo

Suponemos que tenemos la siguiente tabla de datos:

x_i	y_i
0	0
1	1
3	1

Y queremos construir el spline cúbico natural que interpole a estos datos. Para ello, seguimos los siguientes pasos:


1. **Definir los momentos:** Para cada $i = 0, 1, 2$, definimos:

$$m_i = S''(x_i)$$

Y así, nos queda, con $m_0 = m_2 = 0$ por ser un spline natural:

$$S'' = \begin{cases} m_1 x & \text{si } x \in [0, 1] \\ -\frac{m_1}{2}(x-3) & \text{si } x \in [1, 3] \end{cases}$$

Esto se puede apreciar si representamos gráficamente el spline cúbico natural que interpola a los datos dados:



2. **Momentos:** Ahora podemos integrar para obtener S' y S :

$$S' = \begin{cases} \frac{m_1}{2}x^2 + a_1 & \text{si } x \in [0, 1] \\ -\frac{m_1}{4}(x-3)^2 + a_2 & \text{si } x \in [1, 3] \end{cases} \Rightarrow$$

$$S = \begin{cases} \frac{m_1}{6}x^3 + a_1x + b_1 & \text{si } x \in [0, 1] \\ -\frac{m_1}{12}(x-3)^3 + a_2(x-1) + b_2 & \text{si } x \in [1, 3] \end{cases}$$

Nótese que en S aparece el término $a_2(x-1)$ en lugar de a_2x , esto es porque al integrar S' en el intervalo $[1, 3]$, el término a_2 se multiplica por $(x-1)$, ya que la integración se hace a partir del punto 1.

3. **Condición de interpolación:** Ahora usando la condición de interpolación, tenemos que:

$$S(0) = 0 \Rightarrow \boxed{b_1 = 0}$$

$$S(1) = 1 \Rightarrow \frac{m_1}{6} + a_1 + b_1 = 1 \Rightarrow \boxed{a_1 = 1 - \frac{m_1}{6}}$$

$$S(1) = 1 \Rightarrow -\frac{m_1}{12}(1-3)^3 + a_2(1-1) + b_2 = 1 \Rightarrow \frac{2m_1}{3} + b_2 = 1 \Rightarrow \boxed{b_2 = 1 - \frac{2m_1}{3}}$$

$$S(3) = 1 \Rightarrow -\frac{m_1}{12}(3-3)^3 + a_2(3-1) + b_2 = 1 \Rightarrow 2a_2 + b_2 = 1 \Rightarrow a_2 = \frac{1-b_2}{2} \Rightarrow \boxed{a_2 = \frac{m_1}{3}}$$

4. **Encontrar el momento m_1 :** Ahora, para encontrar el valor de m_1 , basta con usar la condición de que S'' es continua en $x = 1$, es decir:

$$S''(1-0) = S''(1+0) \implies \frac{m_1}{2} + a_1 = -m_1 + a_2 \implies \boxed{m_1 = -1}$$

Dejando así los parámetros del spline cúbico natural que interpola a los datos dados:

$$\begin{cases} a_1 = 1 - \frac{m_1}{6} = 1 + \frac{1}{6} = \frac{7}{6} \\ b_1 = 0 \\ a_2 = \frac{m_1}{3} = -\frac{1}{3} \\ b_2 = 1 - \frac{2m_1}{3} = 1 + \frac{2}{3} = \frac{5}{3} \end{cases}$$

5. **Resultado final:** Por lo tanto, el spline cúbico natural que interpola a los datos dados es:

$$S(x) = \begin{cases} -\frac{1}{6}x^3 + \frac{7}{6}x & \text{si } x \in [0, 1] \\ \frac{1}{12}(x-3)^3 - \frac{1}{3}(x-1) + \frac{5}{3} & \text{si } x \in [1, 3] \end{cases}$$

5 Diferenciación Numérica

5.1 Motivación

El objetivo de esta sección es aproximar la derivada de una función f en un punto x a partir de los valores de la función en ciertos puntos, y llegar incluso a estimar derivadas de orden superior, es decir:

$$\begin{array}{c|c} x_i & f(x_i) \\ \hline x_0 & f(x_0) \\ x_1 & f(x_1) \\ \vdots & \vdots \\ x_n & f(x_n) \end{array} \longrightarrow f'(x), f''(x), \dots, f^{(m)}(x)?$$

Además, en este problema, se puede suponer que la partición de los puntos x_i es equidistante, es decir, $x_i = x_0 + ih$ para $i = 0, 1, \dots, n$, donde h es el paso de la partición.

Tenemos a primera vista dos formas de abordar este problema:

- A Usar polinomios de interpolación para aproximar la función f y luego derivar el polinomio resultante. Este método es más **breve**.
- B Usar la forma de Taylor de la función f para obtener fórmulas de aproximación de la derivada. Este método es más **fácil**.

Veamos ambas ideas con más detalle.

5.2 Aproximación por interpolación

Idea A: Sabemos que:

$$f(x) = p_n(x) + E_n(x)$$

Donde:


$$p_n(x) = \sum_{i=0}^n f(x_i) L_i(x) \quad E_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \prod_{i=0}^n (x - x_i)$$

De lo que se deduce que:

$$f'(x) = \underbrace{p'_n(x)}_{\text{hay fórmulas aproximadas}} + E'_n(x)$$

Ejemplo

Veamos un ejemplo para $n = 1$.



Ahora podemos escribir:

$$p_1(x) = -\frac{f(x_i)(x - x_{i+1})}{h} + \frac{f(x_{i+1})(x - x_i)}{h}$$

Donde $h = x_{i+1} - x_i$. Derivando, obtenemos:

$$f'(x) \approx p'_1(x) = -\frac{f(x_i)}{h} + \frac{f(x_{i+1})}{h} = \frac{f(x_{i+1}) - f(x_i)}{h}$$

5.3 Aproximación mediante Taylor

Veamos ahora un ejemplo con el polinomio de Taylor.

Ejemplo

Consideremos tres nodos equiespaciados x_{i-1} , x_i y x_{i+1} .

Si queremos calcular el punto $f(x_i)$ a partir de los otros, tenemos que de manera aproximada:

$$f(x_{i+1}) = f(x_i) + hf'(x_i) + \frac{f''(\eta)}{2}h^2$$

De donde se deduce que:

$$f'(x_i) = \underbrace{\frac{f(x_{i+1}) - f(x_i)}{h}}_{\text{aproximación}} - \underbrace{\frac{f''(\eta)}{2}h}_{\text{error}}$$

Y el punto anterior, de forma análoga, se puede escribir como:

$$f(x_{i-1}) = f(x_i) - hf'(x_i) + \frac{f''(\xi)}{2}h^2$$

De donde se deduce que:

$$f'(x_i) = \underbrace{\frac{f(x_i) - f(x_{i-1})}{h}}_{\text{aproximación}} + \underbrace{\frac{f''(\xi)}{2}h}_{\text{error}}$$

5.4 Diferencias centradas

Ahora lo que podemos hacer es restar ambas fórmulas para obtener una nueva aproximación de la derivada:

$$\begin{aligned} \frac{f(x_{i+1})}{f(x_{i-1})} &= \frac{f(x_i) + hf'(x_i) + \frac{1}{2}f''(x_i)h^2 + \frac{1}{6}f'''(\eta)h^3}{f(x_i) - hf'(x_i) + \frac{1}{2}f''(x_i)h^2 - \frac{1}{6}f'''(\xi)h^3} \\ \frac{f(x_{i+1}) - f(x_{i-1})}{f(x_{i+1}) + f(x_{i-1})} &= \frac{2hf'(x_i) + \frac{1}{3}f'''(\zeta)h^3}{2f(x_i) + f''(x_i)h^2 + \frac{1}{12}f^{(4)}(\zeta)h^4} \end{aligned}$$

De donde se deduce que:

$$f'(x_i) = \underbrace{\frac{f(x_{i+1}) - f(x_{i-1})}{2h}}_{\text{aproximación}} - \underbrace{\frac{f'''(\zeta)}{6}h^2}_{\text{error}}$$

Por lo que hemos logrado aumentar el orden de la aproximación, es decir, el error ahora es de orden h^2 en lugar de h .

Podemos aumentar en 1 el grado del polinomio de Taylor obteniendo la siguiente fórmula:

$$\begin{aligned} \frac{f(x_{i+1})}{f(x_{i-1})} &= \frac{f(x_i) + hf'(x_i) + \frac{1}{2}f''(x_i)h^2 + \frac{1}{6}f'''(x_i)h^3 + \frac{1}{24}f^{(4)}(\eta)h^4}{f(x_i) - hf'(x_i) + \frac{1}{2}f''(x_i)h^2 - \frac{1}{6}f'''(x_i)h^3 + \frac{1}{24}f^{(4)}(\xi)h^4} \\ \frac{f(x_{i+1}) + f(x_{i-1})}{f(x_{i+1}) - f(x_{i-1})} &= \frac{2f(x_i) + f''(x_i)h^2 + \frac{1}{12}f^{(4)}(\zeta)h^4}{2hf'(x_i) + \frac{1}{3}f'''(\zeta)h^3} \end{aligned}$$

De donde se deduce que:

$$f''(x_i) = \underbrace{\frac{f(x_{i+1}) - 2f(x_i) + f(x_{i-1}))}{h^2}}_{\text{aproximación}} - \underbrace{\frac{f^{(4)}(\zeta)}{12}h^2}_{\text{error}}$$

5.5 Aplicaciones

La diferenciación numérica es un tema muy amplio, y se puede aplicar a múltiples campos, como por ejemplo:

- Análisis de datos.
- Simulación Numérica de Ecuaciones Diferenciales.

6 Integración Numérica

6.1 Motivación

El objetivo de la integración numérica es aproximar el valor de la integral definida de una función f en un intervalo $[a, b]$ a partir de los valores de la función en ciertos puntos, es decir:

$$\begin{array}{c|c} x_i & f(x_i) \\ \hline x_0 & f(x_0) \\ x_1 & f(x_1) \\ \vdots & \vdots \\ x_n & f(x_n) \end{array} \longrightarrow S = \int_a^b f(x)dx = \underbrace{\quad}_{\text{fórmula aproximada}} + \underbrace{E}_{\text{error}}$$

6.2 Aproximación por interpolación de Lagrange

La idea de este procedimiento se va a basar en utilizar los **Polinomios de Lagrange**:

$$\underbrace{f(x)}_{\in C^{n+1}[a,b]} = \underbrace{p_n(x)}_{\text{polinomio de interpolación de Lagrange}} + \underbrace{E_n(x)}_{\text{error de interpolación}}$$

Dónde:

$$p_n(x) = \sum_{i=0}^n f(x_i) L_i(x) \quad L_i(x) = \prod_{\substack{j=0 \\ j \neq i}}^n \frac{x - x_j}{x_i - x_j}$$

$$E_n(x) = \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \prod_{i=0}^n (x - x_i)$$


De donde se deduce que:


$$S = \int_a^b f(x)dx = \underbrace{\int_a^b p_n(x)dx}_{\tilde{S}_n} + \underbrace{\int_a^b E_n(x)dx}_{E_n}$$

Ahora podemos escribir la fórmula de aproximación de la integral:

$$\tilde{S}_n = \int_a^b p_n(x)dx = \int_a^b \sum_{i=0}^n f(x_i) L_i(x)dx = \sum_{i=0}^n f(x_i) \underbrace{\int_a^b L_i(x)dx}_{c_i} = \boxed{\sum_{i=0}^n c_i f(x_i)}$$

Es interesante destacar que para calcular integrales existen formulas abiertas, y formulas cerradas. Las fórmulas abiertas no incluyen los extremos del intervalo, mientras que las fórmulas cerradas sí los incluyen.





Podemos fijar, al igual que en la diferenciación numérica, una distancia fina entre los puntos de interpolación, es decir, $h = \frac{b-a}{n+2}$.

Veamos ahora distintos casos según n .

Caso $n = 0$: En este caso, el polinomio de interpolación de Lagrange es simplemente una constante, es decir, $p_0(x) = f(x_0)$. Por lo tanto, la fórmula de aproximación de la integral se reduce a:

$$\tilde{S}_0 = \int_a^b p_0(x) dx = \int_a^b f(x_0) dx = f(x_0)(b-a)$$

Utilizando ahora que en este caso $h = \frac{b-a}{2}$, podemos escribir la fórmula de aproximación de la integral como:

$$\boxed{\tilde{S}_0 = 2hf(x_0)}$$

Que es la fórmula del área del rectángulo. Podemos ahora intentar calcular el error cometido usando la siguiente función:

$$\varphi: \begin{array}{ccc} [0, h] & \longrightarrow & \mathbb{R} \\ x & \longmapsto & \varphi(x) \end{array} \longrightarrow \varphi(r) = \underbrace{\int_{x_0-r}^{x_0+r} f(x) dx}_{\text{exacto}} - \underbrace{2rf(x_0)}_{\text{aproximación}}$$

Donde $r \in [0, h]$, y nos deja:

$$\varphi(0) = 0, \quad \varphi(h) = \epsilon_0$$

Siendo ϵ_0 el error cometido. Ahora podemos derivar φ :

$$\varphi'(r) = f(x_0 + r) + f(x_0 - r) - 2f(x_0) \quad \varphi'(0) = 0$$

Si derivamos por segunda vez, obtenemos:

$$\varphi''(r) = f'(x_0 + r) - f'(x_0 - r) = f''(\xi_r) + f''(\eta_r) = 2f''(\zeta_r)$$

Usando que:

$$f'(x_0 + r) - f'(x_0 - r) = f''(\xi_r)(x_0 + r - (x_0 - r)) = 2rf''(\xi_r)$$

Part II

Ejercicios

Índice de Ejercicios

Hoja 1: Interpolación e integración numérica	68
--	----

Hoja de Ejercicios 1: Interpolación e integración numérica

Ejercicio 1

Prof

Enunciado: Hallar el polinomio P que interpola la función $f(x) = \cos(\pi x)$ en los puntos $x_0 = 0$, $x_1 = \frac{1}{2}$, $x_2 = 1$, $x_3 = \frac{3}{2}$.

Desarrollo: Si tenemos la función $f(x) = \cos(\pi x)$ y los puntos $x_0 = 0$, $x_1 = \frac{1}{2}$, $x_2 = 1$, $x_3 = \frac{3}{2}$, entonces construimos la tabla de valores:

x	0	$\frac{1}{2}$	1	$\frac{3}{2}$
y	1	0	-1	0

Ahora para construir el polinomio de interpolación, podemos usar la fórmula de Lagrange:

$$P(x) = \sum_{i=0}^3 y_i L_i(x)$$

Donde:

$$L_i(x) = \prod_{j=0, j \neq i}^3 \frac{x - x_j}{x_i - x_j}$$

Procedamos a calcular cada $L_i(x)$:

- Para $i = 0$:

$$L_0(x) = \frac{(x - \frac{1}{2})(x - 1)(x - \frac{3}{2})}{(0 - \frac{1}{2})(0 - 1)(0 - \frac{3}{2})} = \frac{(x - \frac{1}{2})(x - 1)(x - \frac{3}{2})}{\frac{3}{4}} = \frac{4}{3}(x - \frac{1}{2})(x - 1)(x - \frac{3}{2})$$

- Para $i = 1$ no es necesario ya que:

$$y_1 = 0 \implies y_1 L_1(x) = 0$$

- Para $i = 2$:

$$L_2(x) = \frac{(x - 0)(x - \frac{1}{2})(x - \frac{3}{2})}{(1 - 0)(1 - \frac{1}{2})(1 - \frac{3}{2})} = \frac{x(x - \frac{1}{2})(x - \frac{3}{2})}{-\frac{1}{4}} = -4x(x - \frac{1}{2})(x - \frac{3}{2})$$

- Para $i = 3$ no es necesario ya que:

$$y_3 = 0 \implies y_3 L_3(x) = 0$$

Dejando el polinomio:

$$P(x) = 1 \cdot L_0(x) + (-1) \cdot L_2(x) = \frac{4}{3}(x - \frac{1}{2})(x - 1)(x - \frac{3}{2}) + 4x(x - \frac{1}{2})(x - \frac{3}{2})$$

Ejercicio 2

Enunciado:

Desarrollo:

Ejercicio 3

Prof

Enunciado: Sean $\{x_0, x_1, \dots, x_n\} \subset \mathbb{R}$ puntos distintos. Demostrar:

(a)

$$\sum_{i=0}^n L_i(x) = 1, \quad x \in \mathbb{R}.$$

(b)

$$E_n(x) = f(x) - P_n(x) = \sum_{i=0}^n (f(x) - f(x_i)) L_i(x).$$

Desarrollo: Recordemos que los polinomios básicos de Lagrange están dados por

$$L_i(x) = \prod_{\substack{j=0 \\ j \neq i}}^n \frac{x - x_j}{x_i - x_j}, \quad i = 0, \dots, n,$$

y satisfacen la propiedad

$$L_i(x_k) = \delta_{ik} = \begin{cases} 1, & i = k, \\ 0, & i \neq k. \end{cases}$$

(a) Consideremos

$$S(x) = \sum_{i=0}^n L_i(x).$$

Como cada L_i tiene grado a lo sumo n , también S tiene grado a lo sumo n .

Evaluamos en los nodos x_k ($k = 0, \dots, n$):

$$S(x_k) = \sum_{i=0}^n L_i(x_k) = \sum_{i=0}^n \delta_{ik} = 1.$$

Es decir, S y el polinomio constante 1 (de grado $\leq n$) coinciden en los $n+1$ puntos distintos $x_0, \dots, x_n$.

Por unicidad del polinomio interpolador de grado $\leq n$, se concluye que

$$\sum_{i=0}^n L_i(x) = S(x) = 1, \quad \forall x \in \mathbb{R}.$$

(b) Partimos de la expresión de Lagrange del interpolador:

$$P_n(x) = \sum_{i=0}^n f(x_i) L_i(x).$$

Entonces

$$E_n(x) = f(x) - P_n(x) = f(x) - \sum_{i=0}^n f(x_i)L_i(x).$$

Usando el apartado anterior, $\sum_{i=0}^n L_i(x) = 1$, podemos escribir

$$f(x) = f(x) \sum_{i=0}^n L_i(x) = \sum_{i=0}^n f(x)L_i(x).$$

Sustituyendo en la expresión del error:

$$E_n(x) = \sum_{i=0}^n f(x)L_i(x) - \sum_{i=0}^n f(x_i)L_i(x) = \sum_{i=0}^n (f(x) - f(x_i))L_i(x).$$

Por tanto,

$$E_n(x) = f(x) - P_n(x) = \sum_{i=0}^n (f(x) - f(x_i))L_i(x).$$

Ejercicio 4

Prof

Enunciado: Sean $P \in \mathbb{P}_n$ y $n + 1$ puntos distintos $\{x_0, x_1, \dots, x_n\}$. Hallar el valor de

$$P[x_0, x_1, \dots, x_n].$$

Desarrollo: Tengamos por ejemplo:

$$p_1 = 5 + 2x \quad \{x_0 = 3, x_1 = 9\}$$

Podemos calcular la diferencia dividida de p_1 en los puntos x_0 y x_1 :

$$p_1[x_0, x_1] = \frac{p_1(x_1) - p_1(x_0)}{x_1 - x_0} = \frac{(5 + 2 \cdot 9) - (5 + 2 \cdot 3)}{9 - 3} = \frac{23 - 11}{6} = 2.$$

En general, si tenemos:

$$p_1 = a_0 + a_1x \quad \{x_0, x_1\}$$

Podemos calcular la diferencia dividida de p_1 en los puntos x_0 y x_1 :

$$p_1[x_0, x_1] = \frac{p_1(x_1) - p_1(x_0)}{x_1 - x_0} = \frac{(a_0 + a_1x_1) - (a_0 + a_1x_0)}{x_1 - x_0} = \frac{a_1(x_1 - x_0)}{x_1 - x_0} = a_1.$$

Ahora si tomamos $f = p_n$, tenemos que:

$$p_n(x) = p_{n-1}(x) + \underbrace{p_n[x_0, x_1, \dots, x_n]}_{q_n(x)} \prod_{j=0}^{n-1} (x - x_j).$$

Ejercicio 5

Prof

Enunciado: Sean $\{x_0, x_1, \dots, x_n\}$ con $x_i \neq x_j$ si $i \neq j$ y $f(x) = x^{n+1}$. Calcular el polinomio de interpolación de Lagrange de f en los puntos $\{x_0, x_1, \dots, x_n\}$ y determinar su término independiente.

Desarrollo: Sabemos que el polinomio de interpolación de Lagrange de $f(x) = x^{n+1}$ en los puntos $\{x_0, x_1, \dots, x_n\}$ es:

$$P_n(x) = \sum_{i=0}^n f(x_i) L_i(x) = \sum_{i=0}^n x_i^{n+1} \cdot \prod_{\substack{j=0 \\ j \neq i}}^n \frac{x - x_j}{x_i - x_j}.$$

Ahora podemos calcular el error de interpolación, que es:

$$E_n(x) = f(x) - P_n(x) = \frac{(x^{n+1})^{(n+1)}}{(n+1)!} \prod_{i=0}^n (x - x_i) = \frac{(n+1)!}{(n+1)!} \prod_{i=0}^n (x - x_i) = \prod_{i=0}^n (x - x_i).$$

Despejando nos queda:

$$P_n(x) = f(x) - E_n(x) = x^{n+1} - \prod_{i=0}^n (x - x_i).$$

Para determinar el término independiente de P_n , evaluamos en $x = 0$:

$$P_n(0) = 0^{n+1} - \prod_{i=0}^n (0 - x_i) = -(-1)^{n+1} \prod_{i=0}^n x_i = (-1)^n \prod_{i=0}^n x_i.$$

Y por tanto, el término independiente de P_n es $(-1)^n \prod_{i=0}^n x_i$.

Ejercicio 6

Enunciado: Demostrar que si $f \in C([a, b])$ y existe $f'(x_i)$ para algún $x_i \in [a, b]$, entonces la función

$$g(x) = \begin{cases} f[x, x_i], & x \neq x_i, \\ f'(x_i), & x = x_i, \end{cases}$$

es continua en el intervalo $[a, b]$ (esto permite definir la diferencia dividida $f[x, x_i]$ en todo punto del intervalo). ¿Tiene $f[x, x_i]$ alguna propiedad similar a $(\varphi\psi)' = \varphi'\psi + \varphi\psi'$?

Desarrollo:

Ejercicio 7

Enunciado: Sea $a > 0$, $\{-x_n, -x_{n-1}, \dots, -x_1, 0, x_1, \dots, x_n\} \subset [-a, a]$ y P_{2n} el polinomio de interpolación de Lagrange de $f : [-a, a] \rightarrow \mathbb{R}$ en estos puntos. Demostrar:

- (a) Si f es una función par (resp. impar), entonces P_{2n} es par (resp. impar).
- (b) Si f es par, existe $Q_n \in \mathbb{P}_n$ tal que $P_{2n}(x) = Q_n(x^2)$. ¿Quién es Q_n ? ¿Qué utilidad tiene esto?

Desarrollo:

Enunciado: Determinar los valores de λ y μ para que

$$S(x) = \begin{cases} \lambda x(x^2 + 1), & 0 \leq x \leq 1, \\ -\lambda x^3 + \mu x^2 - 5\lambda x + 1, & 1 \leq x \leq 2, \end{cases}$$

sea una función spline cúbica.

Desarrollo: Para que S sea una función spline cúbica, debe ser de clase C^2 en el intervalo $[0, 2]$. Esto implica que S debe ser continua, y sus primeras y segundas derivadas también deben ser continuas en el punto de unión $x = 1$ (en el resto del intervalo, cada parte es un polinomio cúbico, por lo que no hay problemas de continuidad allí).

- **Continuidad de S en $x = 1$:**

$$\begin{cases} S(x = 1 - 0) = \lambda \cdot 1 \cdot (1^2 + 1) = 2\lambda, \\ S(x = 1 + 0) = -\lambda \cdot 1^3 + \mu \cdot 1^2 - 5\lambda \cdot 1 + 1 = -6\lambda + \mu + 1. \end{cases} \implies 2\lambda = -6\lambda + \mu + 1 \implies \mu = 8\lambda - 1.$$

- **Continuidad de S' en $x = 1$:** Calculamos S' para cada parte:

$$\begin{aligned} S'(x) &= \begin{cases} \lambda(3x^2 + 1), & 0 \leq x \leq 1, \\ -3\lambda x^2 + 2\mu x - 5\lambda, & 1 \leq x \leq 2. \end{cases} \implies \\ \begin{cases} S'(x = 1 - 0) = \lambda \cdot (3 \cdot 1^2 + 1) = 4\lambda, \\ S'(x = 1 + 0) = -3\lambda \cdot 1^2 + 2\mu \cdot 1 - 5\lambda = -8\lambda + 2\mu. \end{cases} &\implies \\ 4\lambda = -8\lambda + 2\mu &\implies 12\lambda = 2\mu \implies \mu = 6\lambda. \end{aligned}$$

- **Resolvemos el sistema de ecuaciones:**

$$\begin{cases} \mu = 8\lambda - 1, \\ \mu = 6\lambda. \end{cases} \implies \begin{cases} 6\lambda = 8\lambda - 1 \implies -2\lambda = -1 \implies \lambda = \frac{1}{2}, \\ \mu = 6\lambda = 6 \cdot \frac{1}{2} = 3 \implies \mu = 3. \end{cases}$$

Por lo tanto, los valores de λ y μ para que S sea una función spline cúbica son $\lambda = \frac{1}{2}$ y $\mu = 3$, pero falta comprobar la continuidad de S'' en $x = 1$.

- **Continuidad de S'' en $x = 1$:** Calculamos S'' para cada parte:

$$\begin{aligned} S''(x) &= \begin{cases} \lambda(6x), & 0 \leq x \leq 1, \\ -6\lambda x + 2\mu, & 1 \leq x \leq 2. \end{cases} \implies \\ \begin{cases} S''(x = 1 - 0) = \lambda \cdot 6 \cdot 1 = 6\lambda, \\ S''(x = 1 + 0) = -6\lambda \cdot 1 + 2\mu = -6\lambda + 2\mu. \end{cases} &\implies \\ 6\lambda = -6\lambda + 2\mu &\implies 12\lambda = 2\mu \implies \mu = 6\lambda \iff \begin{cases} \lambda = \frac{1}{2}, \\ \mu = 3. \end{cases} \end{aligned}$$

Este resultado coincide con el obtenido anteriormente, por lo que no hay contradicciones y los valores de λ y μ son correctos.

- **Condiciones de contorno:** No se han especificado condiciones de contorno adicionales, por lo que no es necesario verificar nada más. Sin embargo, si se hubieran dado condiciones de contorno, habría que asegurarse de que S las cumpla. En particular, si S es de **Tipo I** entonces se deberían cumplir $S(0) = S(2) = 0$, lo cual no es el caso aquí, por lo que S no es de **Tipo I**.

Ejercicio 9

Enunciado: Sea $\Delta = \{a = x_0 < x_1 < \dots < x_n = b\}$ una partición del intervalo $[a, b]$. Demostrar:

(a) Si $n < 4$, toda función spline cúbica que verifique

$$S_{\Delta}^{(k)}(a) = S_{\Delta}^{(k)}(b) = 0, \quad k = 0, 1, 2,$$

es idénticamente nula.

(b) Si $n = 4$, la anterior función spline cúbica está unívocamente determinada por el valor que tome en x_2 .

Desarrollo:

Ejercicio 10

Enunciado: Demostrar, a partir del teorema de Rolle, la unicidad de la función spline cúbica de interpolación en los casos I y II.

Desarrollo:

Ejercicio 11

Enunciado: Sea $\Delta = \{x_0 = a < x_1 < \dots < x_n = b\}$ una partición del intervalo $[a, b]$ y $S_{\Delta}(y; \cdot)$ la función spline cúbica que interpola los valores $y = (y_0, y_1, \dots, y_n)^T$ con condiciones de tipo I. ¿Qué deben verificar los valores $\{y_0, y_1, \dots, y_n\}$ para que $S_{\Delta}(y; \cdot)$ coincida en todo el intervalo $[a, b]$ con un polinomio $P \in \mathbb{P}_3$?

Desarrollo:

Ejercicio 12

Enunciado: Aplicar la regla de Simpson compuesta a la integral

$$\int_1^2 \frac{dt}{t}$$

para obtener una aproximación de $\ln(2)$, determinando el número m de subintervalos necesario para que el error cometido en esa aproximación sea inferior a 10^{-3} .

Desarrollo:

Ejercicio 13

Enunciado: Hallar la expresión de la regla de Simpson abierta compuesta.

Desarrollo:

Ejercicio 14

Enunciado: Se considera la fórmula de integración

$$\int_0^1 f(x) dx \simeq A(f(x_0) + f(x_1)).$$

Hallar el valor de A , x_0 y x_1 para que la fórmula sea exacta para polinomios del mayor grado posible. ¿Cuál es este grado?

Desarrollo:

Ejercicio 15

Enunciado: Encontrar una fórmula que aproxime

$$\int_1^3 f(x) dx$$

utilizando los valores de f en los puntos 0, 2 y 4, y que sea exacta para polinomios del mayor grado posible. ¿Cuál es este grado?

Desarrollo:

Ejercicio 16

Enunciado: Dado $n \in \mathbb{N}$, se considera $h = \frac{1}{n}$, $x_i = ih$ para $i = 0, 1, \dots, n$ y la función

$$f_n(x) = x^n \cos(2\pi nx).$$

Hallar el valor de la aproximación de

$$\int_0^1 f_n(x) dx$$

que se obtiene utilizando la fórmula de Newton-Côtes cerrada de $n + 1$ puntos.

Desarrollo:

Part III

Exámenes

Índice de Exámenes

Examen 1: Primer examen	76
-----------------------------------	----

Examen 1: Primer examen

Part IV

Apéndice

Índice de Apéndice

Apéndice A: Normas comunes	78
Apéndice B: Agradecimientos	80
B.1 Varios compañeros	80

Apéndice A: Normas comunes

Definición A.0.1 [Norma euclídea de un vector]

Dado un vector $x \in \mathbb{R}^n$, su norma euclídea se define como

$$\|x\|_2 = \sqrt{x_1^2 + x_2^2 + \cdots + x_n^2}.$$

Definición A.0.2 [Norma 1 de un vector]

Dado un vector $x \in \mathbb{R}^n$, su norma 1 se define como

$$\|x\|_1 = \sum_{i=1}^n |x_i|.$$

Definición A.0.3 [Norma infinito de un vector]

Dado un vector $x \in \mathbb{R}^n$, su norma infinito se define como

$$\|x\|_\infty = \max_{1 \leq i \leq n} |x_i|.$$

Definición A.0.4 [Norma p de un vector]

Dado un vector $x \in \mathbb{R}^n$ y $p \geq 1$, su norma p se define como

$$\|x\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}.$$

Definición A.0.5 [Norma 1 de una matriz]

Dada una matriz $A \in \mathbb{R}^{m \times n}$, su norma 1 se define como

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|.$$

Es decir, el máximo de las sumas absolutas de las columnas.

Definición A.0.6 [Norma infinito de una matriz]

Dada una matriz $A \in \mathbb{R}^{m \times n}$, su norma infinito se define como

$$\|A\|_{\infty} = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|.$$

Es decir, el máximo de las sumas absolutas de las filas.

Definición A.0.7 [Norma de Frobenius]

Dada una matriz $A \in \mathbb{R}^{m \times n}$, su norma de Frobenius se define como

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2}.$$

Definición A.0.8 [Norma 2 o espectral de una matriz]

Dada una matriz $A \in \mathbb{R}^{m \times n}$, su norma 2 (o espectral) se define como

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)},$$

donde $\lambda_{\max}(A^T A)$ es el mayor valor propio de $A^T A$. Equivalentemente, es el mayor valor singular de A .

Definición A.0.9 [Norma p subordinada de una matriz]

Dada una matriz $A \in \mathbb{R}^{m \times n}$ y una norma vectorial $\|\cdot\|_p$, la norma p subordinada de A se define como

$$\|A\|_p = \sup_{\|x\|_p=1} \|Ax\|_p.$$

Apéndice B: Agradecimientos

Queremos expresar nuestro más sincero agradecimiento a todas las personas que han hecho posible la realización de este trabajo.

B.1 Varios compañeros

Por su inestimable ayuda en la revisión del contenido teórico y por sus valiosas sugerencias que han enriquecido significativamente este trabajo, queremos agradecer a los siguientes compañeros:

- Daniel Pozo Ranchal
- Alba Cervantes Menéndez
- Teresa Marín Marín (especial gratitud por su ayuda en la revisión de la redacción)
- Marta Simó Álvarez
- Jesus Sancho Hagen
- Jorge San Pedro Solanas

This work is licensed under a Creative Commons “Attribution-NonCommercial-NoDerivs 3.0 Unported” license.

